

## Pravděpodobnostní (randomizované) algoritmy

**pravděpodobnostní** algoritmus dělá (na rozdíl od **deterministického** algoritmu) **náhodné** kroky, např. k některým krokům používá hodnoty získané z generátoru náhodných čísel tím pádem dvě různá spuštění téhož pravděpodobnostního algoritmu na stejných datech mají (s velkou pravděpodobností) různý průběh

pravděpodobnostních algoritmů je mnoho typů, zde zmíníme jen dva a to algoritmy typu Las Vegas a typu Monte Carlo

### **Algoritmy typu Las Vegas**

výsledek je vždy správný, náhodnost ovlivňuje pouze dobu běhu algoritmu, tj. po jaké cestě se algoritmus ke správnému výsledku dobere

Příklad: randomizovaný QuickSort – od deterministické verze se liší náhodnými výběry pivotu při každém dělení posloupnosti, což poskytuje následující výhody

- dává dobrý průměrný čas (tj.  $O(n \log n)$ ) i v případě, že data na vstupu nejsou náhodné permutace – žádný vstup není apriori špatný (pro každý deterministický výběr pivotu existují apriori špatné vstupy)
- může být spuštěn paralelně v několika kopiích, výsledek je získán z kopie, kde výpočet skončí nejdříve (pro deterministickou verzi nemá takový postup žádný smysl)

# Algoritmy typu Monte Carlo

náhodnost ovlivňuje jak dobu běhu, tak správnost výsledku: algoritmus může udělat chybu, ale pouze jednostranně (u odpovědí ANO/NE) a s omezenou pravděpodobností

Příklad: Rabin-Millerův algoritmus na testování prvočíselnosti

Úloha: pro zadané přirozené číslo  $n$  (rychle) rozhodnout zda je  $n$  prvočíslo

Trocha teorie (Malá) Fermatova věta (bez důkazu):

Nechť  $p$  je prvočíslo. Potom  $\forall k \in \{1, 2, \dots, p-1\}$  platí  $k^{p-1} \equiv 1 \pmod{p}$

Myšlenka: pokud  $n$  není prvočíslo, tak zkusíme (náhodně) najít „svědka“  $k$ , porušujícího  $k^{n-1} \equiv 1 \pmod{n}$ , který „dovádí“, že  $n$  je opravdu číslo složené (není to prvočíslo)

Problém: pro některá složená čísla je svědků příliš málo, takže je „příliš malá pravděpodobnost, že nějakého svědka (náhodně) vybereme.“

Definice: Nechť  $T$  je množina dvojic přirozených čísel, kde  $(k, n) \in T$  pokud  $0 < k < n$  a je splněna alespoň jedna z následujících dvou podmínek:

1. neplatí  $k^{n-1} \equiv 1 \pmod{n}$ ,
2. existuje  $i$  takové, že  $m = (n-1) / 2^i$  je přirozené číslo a platí  $1 < \text{NSD}(k^{m-1}-1, n) < n$

Věta 1: Číslo  $n$  je složené tehdy a jen tehdy, když existuje  $k$  takové, že  $(k, n) \in T$ .

Věta 2: Nechť  $n$  je složené číslo. Pak existuje alespoň  $(n-1)/2$  takových čísel  $k$ , pro které platí  $(k, n) \in T$ .

```

Rabin-Miller(n);
for i:=1 to počet do
   $k_i := \text{náhodné přirozené číslo z intervalu } [1, n-1];$ 
  if  $(k_i, n) \in T$  then Report (n je složené);
  Abort;
Report (n je prvočíslo)

```

Pokud Rabin-Miller(n) rozhodne, že  $n$  je složené, tak je to zaručeně správný výsledek (byl nalezen „svědek“), pokud Rabin-Miller(n) rozhodne, že  $n$  je prvočíslo, tak se může jednat o chybu, ale pouze v případě, že všechna vybraná  $k_i$  byli „ne-svědci“ pro složené číslo  $n$ , což ale může (díky Větě 2) nastat nejvýše s pravděpodobností

$$P(\text{chyba}) \leq (1/2)^{\text{počet}}$$

pokud jsou výběry jednotlivých  $k_i$  vzájemně nezávislé

Vlastnosti algoritmu:

- zvyšováním počtu iterací (počtu testovaných  $k_i$ ) lze dostat libovolně malou (předem zvolenou) pravděpodobnost chyby
- jednotlivé iterace (testy pro různá  $k_i$ ) lze provádět paralelně

Časová složitost:

každá iterace trvá jen polynomiálně vzhledem k délce zápisu čísla  $n$  (tj. k délce vstupu), k tomu je ovšem potřeba ukázat, že test zda  $(k_i, n) \in T$  je možno provést v čase polynomiálním v  $\log n$ , což není triviální (je nutné mít další znalosti z teorie čísel)

## Kryptografie s veřejným klíčem (asymetrickou šifrou)

- každý účastník  $X$  má svůj veřejný klíč  $PX$  a soukromý klíč  $SX$
- $SX$  je znám pouze  $X$ , veřejný klíč  $PX$  může  $X$  sdělit všem s kterými komunikuje, nebo může být dokonce zveřejněn ve veřejně dostupném seznamu klíčů (třeba na webu)
- oba klíče specifikují funkce, které lze aplikovat na jakoukoli zprávu: tedy pokud  $D$  je množina všech konečných posloupností bitů (množina všech možných zpráv), tak obě funkce musí být prosté funkce zobrazující  $D$  na  $D$  (tj. jsou to permutace množiny  $D$ )
- funkci specifikovanou soukromým klíčem  $SX$  značíme  $SX()$  a funkci specifikovanou veřejným klíčem  $PX$  značíme  $PX()$ , přičemž předpokládáme, že každá z těchto funkcí je efektivně vyčíslitelná pokud známe příslušný klíč
- funkce  $SX()$  a  $PX()$  musí tvořit vzájemně inverzní pár funkcí – pro každou zprávu (konečnou posloupnost bitů)  $M$  tedy musí platit  $SX(PX(M)) = M$  a  $PX(SX(M)) = M$ .
- bezpečnost šifry stojí a padá s tím, že nikdo kromě účastníka  $X$  není schopen v „rozumném“ čase spočítat  $SX(M)$  pro jakoukoli zprávu  $M$ , což znamená, že
  1. účastník  $X$  musí držet klíč  $SX$  v absolutním bezpečí před vyzrazením
  2. funkce  $SX()$  nesmí být efektivně vyčíslitelná na základě znalosti  $PX$  (a schopnosti efektivně vyčíslit funkci  $PX()$ ), což je hlavní obtíž při návrhu systému šifrování s veřejným klíčem

Předpokládejme, že máme 2 účastnice: **A** (Alici) a **B** (Barboru) s klíči **SA**, **PA**, **SB** a **PB**

## Posílání zašifrované zprávy a její rozšifrování

Barbora chce poslat Alici zašifrovanou zprávu **M**:

- Barbora si opatří Alicin veřejný klíč **PA** (přímo od Alice či z veřejného seznamu klíčů)
- Barbora spočítá **zašifrovaný text**  $C = PA(M)$  a pošle ho Alici
- Alice na **C** aplikuje svůj soukromý klíč **SA**, tedy spočítá  $SA(C) = SA(PA(M)) = M$
- Pokud **C** zachytí někdo jiný než Alice, nemá šanci získat **M**, protože neumí efektivně spočítat **SA(C)**.

## Posílání autentizované a podepsané (nešifrované) zprávy

Alice chce odpovědět Barboře tak, aby Barbora měla jistotu, že odpověď **Q** přichází od Alice a že text odpovědi nebyl pozměněn:

- Alice spočítá svůj **digitální podpis** **q** pro zprávu **Q** pomocí svého soukromého klíče, tj. spočítá  $q = SA(Q)$  a pošle Barboře dvojici **(Q,q)** – tj. zpráva **Q** odchází nešifrovaně
- Barbora spočítá  $PA(q) = PA(SA(Q)) = Q$  a porovná to s došlou zprávou **Q**
- Pokud se obě zprávy zcela shodují, má Barbora jistotu, že zpráva přichází od Alice a nebyla cestou pozměněna
- Pokud se zprávy liší, tak buď je podpis **q** falešný (nebyl vytvořen funkcí **SA()**) nebo je podpis pravý ale nezašifrovaná zpráva **Q** byla cestou pozměněna

## Posílání autentizované a podepsané zašifrované zprávy

Alice chce poslat Barboře zprávu  $M$  tak, aby Barbora měla jistotu, že  $M$  přichází od Alice a že text  $M$  nebyl pozměněn. Navíc Alice chce, aby si  $M$  mohla přečíst pouze Barbora a nikdo jiný.

- Alice spočítá svůj digitální podpis pro  $M$ , tedy spočítá  $m = SA(M)$
- Alice zašifruje dvojici  $(M, m)$  pomocí Barbořina veřejného klíče, tedy spočítá zašifrovaný text  $C = PB(M, m)$  a pošle  $C$  Barboře
- Barbora rozšifruje  $C$  pomocí svého soukromého klíče, tedy spočítá  $SB(C) = (M, m)$
- Barbora ověří platnost Alicina podpisu a autenticitu  $M$  pomocí Alicina veřejného klíče, tj. spočítá  $PA(m)$  a porovná to s  $M$  – při neshodě Barbora ví, že buď bylo  $C$  cestou změněno (úmyslně či přenosovou chybou) nebo  $C$  nepřichází od Alice.

## Hybridní šifrování

Pokud je zpráva  $M$ , kterou chce Barbora poslat Alici, velmi dlouhá a výpočet  $C = PA(M)$  a následně  $M = SA(C)$  by trval příliš dlouho, je možné použít šifrování s veřejným klíčem v kombinaci s nějakou symetrickou šifrou  $K$ , která šifruje zprávy rychle:

- Barbora spočítá  $C = K(M)$ , což je opět dlouhá posloupnost bitů, k tomu spočítá  $PA(K)$ , což je krátká posloupnost bitů (ve srovnání s  $M$  a  $PA(M)$ ) a pošle  $(C, PA(K))$  Alici
- Alice rozšifruje  $PA(K)$  pomocí svého  $SA$ , takže dostane  $K$ , pomocí kterého rozšifruje  $C$  a tak získá  $M$

## Hybridní autentizace a podepisování

Pro dlouhou zprávu  $M$  je také časově náročné počítat digitální podpis  $m = SA(M)$ . Zde si vypomůžeme (veřejně známou) **hashovací funkcí**  $h$ , která má následující dvě vlastnosti:

1. I pro dlouhé  $M$  lze  $h(M)$  spočítat velmi rychle, typicky je  $h(M)$  krátký (např. 128 bitový) **otisk** (fingerprint) zprávy  $M$ .
2. Je výpočetně velmi obtížné (v rozumném čase nemožné) najít k  $M$  jinou zprávu  $Q$  takovou, aby platilo  $h(M) = h(Q)$

Pokud chce Alice podepsat dlouhou zprávu posílanou Barboře, může postupovat takto:

- Alice spočítá otisk  $h(M)$  zprávy  $M$ , udělá z něj digitální podpis  $m = SA(h(M))$  a pošle Barboře dvojici  $(M, m)$
- Barbora obdrží  $M$  a také spočítá otisk  $h(M)$  který poté porovná s rozšifrovaným Aliciným digitálním podpisem  $PA(m) = PA(SA(h(M)))$ . Pokud byla  $M$  cestou změněna, tak dojde k neshodě, protože díky vlastnosti 2 je těžké pozměnit  $M$  tak, aby se její otisk nezměnil.

## Certifikační authority

Pokud si Alice pořizuje Barbořin veřejný klíč z veřejně dostupného seznamu (nebo jí ho Barbora posílá po síti), jak může mít jistotu, že nejde o podvrh? Pokud by byl klíč podvržen a následné zprávy modifikovány nebo podvrhovány stejným člověkem, který podvrhl svůj klíč jako Barbořin, tak jejich nepravost nelze zjistit (protože daný člověk bude mít k podvrženému veřejnému klíči i odpovídající soukromý klíč). Řešení:

- Existuje **certifikační autorita Z**, jejíž veřejný klíč **PZ** má každý účastník (tedy i Alice) nainstalován u sebe (například přišel na CD s šifrovacím softwarem).
- Barbora pak má od autority **Z** vydán certifikát ve tvaru **C** = „Barbořin klíč je **PB**“ podepsaný autoritou **Z**, tedy dvojici **(C, SZ(C))** – toto může mít Barbora také již od koupě šifrovacího softwaru, nebo certifikát získá jinou bezpečnou cestou
- Tuto dvojici **(C, SZ(C))** připojí Barbora ke každé podepisované zprávě, takže Alice (i kdokoli jiný) zjistí pomocí veřejného klíče **PZ**, že **C** bylo opravdu vydáno autoritou **Z**, a že tedy **PB** opravdu je Barbořin veřejný klíč

### **RSA (Rivest, Shamir, Adelman) šifra**

pro vysvětlení RSA potřebujeme řadu pojmů a tvrzení z teorie čísel

Věta: Necht' **a, b** jsou přirozená čísla. Pak **NSD(a, b)** je nejmenší kladný prvek množiny

$$L = \{ax + by \mid x, y \in \mathbb{Z}\}$$

Důsledek: Necht' **a, b** jsou přirozená čísla. Pokud **d** je přirozené číslo, které dělí **a** i **b**, tak **d** dělí také **NSD(a, b)**.

Věta: Necht' **a, b** jsou přirozená čísla, kde **b > 0**. Pak **NSD(a, b) = NSD(b, a mod b)**.

**EUCLID(a, b)**

if **b=0** then **Return(a)**

else **Return(EUCLID(b, a mod b))**



Lemma: Necht'  $a > b \geq 0$  a  $\text{EUCLID}(a,b)$  udělá  $k \geq 1$  rekurzivních kroků. Pak  $a \geq F(k+2)$  a  $b \geq F(k+1)$ , kde  $F(i)$  je  $i$ -té Fibonacciho číslo.

Důsledek (Lamého věta): Necht'  $a > b \geq 0$  a  $F(k) \leq b < F(k+1)$ . Pak  $\text{EUCLID}(a,b)$  udělá nejvýše  $k - 1$  rekurzivních kroků.

Věta (bez Dk):  $F(k) = \Theta(\varphi^k)$ , kde  $\varphi = (1+\sqrt{5})/2$  (což je tzv. „zlatý řez“).

Důsledek: Necht'  $a > b \geq 0$  a  $F(k) \leq b < F(k+1)$ . Pak  $\text{EUCLID}(a,b)$  udělá nejvýše  $O(\log b)$  rekurzivních kroků.

Pozorování: Pokud  $a,b$  jsou dvě nejvýše  $t$ -bitová binární čísla, tak  $\text{EUCLID}(a,b)$  provede  $O(t)$  rekurzivních kroků a v každém z nich  $O(1)$  aritmetických operací na (nejvýše)  $t$ -bitových číslech, tj.  $O(t^3)$  bitových operací, pokud předpokládáme, že každá aritmetická operace na  $t$ -bitových číslech potřebuje  $O(t^2)$  bitových operací (což je snadné ukázat).  $\text{EUCLID}$  je tedy polynomiální algoritmus vzhledem k velikosti vstupu.

Euklidův algoritmus lze snadno rozšířit tak, aby počítal také koeficienty  $x,y$ , pro které  $\text{NSD}(a,b) = ax + by$ .

$\text{EXTENDED-EUCLID}(a,b)$

if  $b=0$  then Return( $a,1,0$ )

else  $(d',x',y') := \text{EXTENDED-EUCLID}(b, a \bmod b);$

$(d,x,y) := (d',y',x' - \lfloor a/b \rfloor y');$

Return( $d,x,y$ )

Věta (bez Dk): Necht'  $n > 1$  a  $a < n$  jsou dvě nesoudělná přirozená čísla. Pak má rovnice  $ax \equiv 1 \pmod{n}$ , právě jedno řešení  $0 < x < n$  (a pokud jsou  $a, n$  soudělná, tak nemá žádné řešení).

Definice: Řešení rovnice  $ax \equiv 1 \pmod{n}$  značíme  $(a^{-1} \pmod{n})$  a nazýváme **multiplikativní inverz** čísla  $a$  modulo  $n$  (aby existoval, tak musí být  $a, n$  nesoudělná).

Pozorování:  $(a^{-1} \pmod{n})$  snadno získáme pomocí rozšířeného Euklidova algoritmu.

Věta (speciální důsledek tzv. „čínské věty o zbytcích“ – bez Dk): Necht'  $a, b$  jsou nesoudělná přirozená čísla. Pak pro každá přirozená čísla  $x, y$  platí:  $x \equiv y \pmod{ab}$  tehdy a jen tehdy, když  $x \equiv y \pmod{a}$  a zároveň  $x \equiv y \pmod{b}$ .

Věta (malá Fermatova): Necht'  $p$  je prvočíslo. Pak  $\forall k \in \{1, 2, \dots, p-1\}$  platí  $k^{p-1} \equiv 1 \pmod{p}$ .

Nyní máme vše co potřebujeme k definici a vysvětlení **RSA**:

1. Náhodně vyber dvě velká prvočísla  $p$  a  $q$  (např. každé s 200 binárními ciframi).
2. Spočítej  $n = pq$  (v uvedeném případě má  $n$  cca 400 binárních cifer).
3. Vyber malé liché číslo  $e$ , které je nesoudělné s číslem  $(p-1)(q-1)$ .
4. Spočítej multiplikativní inverz  $d$  čísla  $e$  modulo  $(p-1)(q-1)$ .
5. Zveřejni  $(e, n)$  jako **veřejný RSA klíč** a uschovej  $(d, n)$  jako **soukromý RSA klíč**.

Věta (korektnost RSA): Funkce  $P(M) = M^e \pmod{n}$  a  $S(M) = M^d \pmod{n}$  definují dvojici inverzních funkcí na množině všech zpráv, tj. na množině všech čísel v  $Z_n = \{0, 1, \dots, n-1\}$ .

## Proč je RSA bezpečná?

Na základě  $(e, n)$  není (zatím) nikdo schopen spočítat  $d$  aniž by znal rozklad  $n = pq$  a tím pádem také číslo  $(p-1)(q-1)$ . A faktorizace velkých čísel je výpočetně těžký problém.

## Jak je RSA rychlá?

To, jak rychle lze spočítat  $P(M)$  a  $S(M)$  závisí na tom, jak rychle umíme počítat zbytek modulo  $n$  při umocňování, tj. jak rychle lze spočítat  $a^b \bmod n$ .

**UMOCNI**  $(a, b, n)$  {kde binární zápis čísla  $b$  je  $\langle b_k, \dots, b_0 \rangle$ }

$c := 1; d := a \bmod n;$

for  $i := k-1$  downto  $0$  do

$c := 2 \cdot c;$

$d := (d \cdot d) \bmod n;$

if  $b_i = 1$  then  $c := c + 1;$

$d := (d \cdot a) \bmod n;$

Return( $d$ )

Časová složitost: Pokud  $a, b$  jsou nejvýše  $t$ -bitová binární čísla, tak **UMOCNI** provede  $O(t)$  aritmetických operací na (nejvýše)  $t$ -bitových číslech, tj.  $O(t^3)$  bitových operací, pokud předpokládáme, že každá aritmetická operace na  $t$ -bitových číslech potřebuje  $O(t^2)$  bitových operací (což je snadné ukázat).