Učební texty k státní bakalářské zkoušce Obecná informatika

25. srpna 2011



Vážený študent/čitateľ,

toto je zbierka vypracovaných otázok pre bakalárske skúšky Informatikov. Otázky boli vypracované študentmi MFF počas prípravy na tieto skúšky, a teda zatiaľ neboli overené kvalifikovanými osobami (profesormi/dokotorandmi mff atď.) - preto nie je žiadna záruka ich správnosti alebo úplnosti.

Väčšina textov je vypracovaná v čestine resp. slovenčine, prosíme dodržujte túto konvenciu (a obmedzujte teda používanie napr. anglických textov). Ak nájdete nejakú chybu, nepresnosť alebo neúplnú informáciu - neváhajte kontaktovať administrátora alebo niektorého z prispievateľov, ktorý má write-prístup k svn stromu, s opravou :-) Podobne - ak nájdete v "texte" veci ako ??? a TODO, znamená to že danú informáciu je potrebné skontrolovať, resp. doplniť...

Texty je možné ďalej používať a šíriť pod licenciou **GNU GFDL** (čo pre všetkých prispievajúcich znamená, že musia súhlasiť so zverejnením svojich úprav podľa tejto licencie).

Veríme, že Vám tieto texty pomôžu k úspešnému zloženiu skúšok.

Hlavní writeři:-):

- ajs
- andree http://andree.matfyz.cz/
- Hydrant
- joshis / Petr Dvořák
- kostej
- nohis
- $\bullet \ \ tuetschek \ http://tuetschek.wz.cz/$

Úvodné verzie niektorých textov vznikli prepisom otázok vypracovaných "písomne na papier", alebo inak ne-TEX-ovsky. Autormi týchto pôvodných verzií sú najmä nasledujúce osoby: gASK, Grafi, Kate (mat-15), Nytram, Oscar, Stando, xStyler. Časť je prebratá aj z pôvodných súborkových textov... Všetkým patrí naša/vaša vďaka.

V roce 2011 některé otázky updatovali a rozšířili: Karel Bílek (http://karelbilek.com), peter.black, Michal Krkavec.

Obsah

1.1 Jazyk, formule, Scinantila, tautologie 4 1.2 Rozbochmichost, pravidnost a dokazatelnost 6 1.3 Véty o kompaktuosti a tiphosti výrokové a prediktávek logiky 10 1.4 Normalit vary výrokových formili, prasent tvary formuli prediktavé logiky 12 2 Automaty a jazyky 1 2.1 Uzwárové vlastnosti tříd jazyků 18 3 Algoritmy a datové struktury 18 3.1 Zivávěnové vlastnosti tříd jazyků 18 3. Zivávěnové vlastnosti najovávání 18 3. Zivávěnová vlastnosti tříd jazyků 20 3. Zivávěnová provincenci algoritmy vlastnostnosti provincenci algoritmy přihrádová třídení, třídeí site 32 3. Zivávěnová vlastnosti tříd jazyků 20 3. Zivávěnová vlastnosti třídení, pr	1	Logika	4
1.4 Normální tvary výrokových formulí, prenexní tvary formulí predikátové logiky 12 2 Antomaty a jazyky 13 2.1 Automaty – Chowského bierarchie, třídy antomatů a gramatik, determinismus a nedeterminismus. 13 2.1.1 Uzávérové vlastnosti tříd jazyků 18 3 Algoritmy a datové struktury 18 3.1 Casová složitost algoritmi, složitost v nejhorším a přůměrném případé 18 3.2 Třídy složitost 19 a NP, převoditehost, NP-úphost 20 3.2.1 Převoditehost 20 3.3.1 Metoda rozděl a pamíj – aplikace a unalýza složitosti 22 3.3.2 Násobení matic n xn a Strassemiv algoritmus 23 3.3.3 Metoda rozděl a pamíj – aplikace a unalýza složitosti 22 3.3.3 Metoda rozděl a pamíj – aplikace a unalýza složitosti 22 3.3.1 Medaří vshedávací stronu, vyvakování, hady 23 3.3 Metoda rozděl a pamíj – aplikace a unalýza složitosti 23 3.3 Mergečot 24 3.3 Mergečot 24 3.4 Binární vyhledávací stronu, vyvakování, hady 26 3.5 Evenchu třídění, porovnávací algoritmy hujířínkové třídění, třídící sítě 33 3.7 Gradová dlgoritmy 34 3.8 Paracitávní vařove		1.2 Rozhodnutelnost, splnitelnost, pravdivost a dokazatelnost	6
2.1. Automaty - Chomského hierarchie, třídy utomatů a gramatik, determinismus a nedeterminismus. 2.1.1 Uzávěrové vlastnosti tříd jazyků 3. Algoritmy a datové struktury 3.1. Časová složitost algoritmů, složitost v nejhorším a průměrném případě 3.2. Třídy složitosti P a Pp. převoditelnost, NP-úphnost 3.2. Třídy složitosti P a Np. převoditelnost, NP-úphnost 3.3. Metoda rozděl a panuj – aplikace a analýza složitosti 3.3.1 Násobení dlouhých čácel v lepším mež kondratichém asse. 3.3.3.1 Násobení dlouhých čácel v lepším mež kondratichém asse. 3.3.2 Složitosti P a Násobení mate n xn a Strassenův algoritmus 3.3.3.1 Hlediní k-tého nejmenšího prvku (mediám) v lin. čase (Blum et al.) 3.4 Binámí výhledávací stromy, vynazování, haldy 3.5 Hasování 3.6 Sokvaciní fřídění, porovnávací algoritmy, přihrádkové třídění, třídící síté 3.7 Grafové algoritmy 3.8 Tanazitvní nězávěn 3.9 Algoritmy vyhledávání v textu 4.4 Janazování 3.10 Algebraické algoritmy 4.4 Janazování 3.11 Základy kryptografie, RSA, DES 3.12 Pravděpodobostní algoritmy - testování prvočíselnosti 3.13 Aproximační algoritmy 4.2 Databáze 4.1 Podstata a architektury DB systemů 4.2 Rolační datový model, rebaří algoritm 4.3 Rebaří datový model, rebaří algoritm 4.4 Algoritmy návňu schémat relací 4.5 Základy SQI 4. Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.6 Procesy, vládkan, plánování 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 5.1 Architektury počítačů a sítí 5.1 Architektury požitačů a sítí 5.2 Processy, umlitiprocesory 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 5.4 Procesy, vládkan, plánování 5.5 Systémy souborni, adresárová struktury 5.7 Zablokování a zotavení z něj 5.10 Systémy souborni, adresárová struktury 5.11 Bezpečenska, atentizace, přistupová práva 5.11 Spojovace, a uterožece, autorizace, přistupová práva 5.11 Spojovace, a capacyovace			
2.1.1 Uzávérové vlastnosti tříd jazyků 3.1 Casová složitost algoritmů, složitost v nejhorším a průměrném případě 1.1.2 Třídy složitosti P a NP, převoditelnost 3.2.1 Přivoditelnost 3.2.1 Přivoditelnost 3.3.3 Metoda rozděl a panuj – aplilace a analýra složitosti 3.3.1 Násobení dlouhých čisel v lepším než kvadratickém čase. 3.3.2 Násobení mátic n.× n a Strasseniú algoritmus 3.3.3 Hisofaní k-tcho nejmenšího prvku (medifaní) v lin. čase (Blum et al.) 3.3.4 Mergešort 3.3.5 Hisofaní k-tcho nejmenšího prvku (medifaní) v lin. čase (Blum et al.) 3.4 Mergešort 3.3.6 Mařování 3.5 Hašování 3.6 Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídě slůž 3.7 Grafové algoritmy 3.8 Tranzitivní uzávěr 3.9 Algoritmy vyhledisvání v textu 3.10 Algoritmy vyhledisvání v textu 3.11 Základy kryptografie, RSA, DES 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 3.13 Aproximační algoritmy – testování prvočíselnosti 3.14 Pravděpodobostní algoritmy – testování prvočíselnosti 3.15 Aproximační algoritmy 4.1 Základy kryptografie, RSA, DES 4.1 Podstata a architektury DB systemů 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Relační datový model, relační algebra 4.4 Algoritmy návrhu schémat relaci 5.6 Transakciní zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 5.6 Procesov, multiprocesory 5.7 Architektury počítačů a sítí 5.1 Architektury počítačů a sítí 5.2 Procesov, multiprocesory 5.3 V stupní a výstupní sařízení, ukládání a přenos dat 5.4 Prácitektury počítačů 5.5 Procesov, uklkan plňnování 5.6 Synchronizační primitíva, vzdjemné vyloučení 5.10 Systémy somborní, adrasárová struktury 5.11 Bezpešova, vlakna plňnování 5.12 Prácitektury OS 5.13 Rodna protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flove control, congestion control, NAT 104 6. Programovací jazyky 6.1 Principy implementace procedurálních a objektové orientovaných programo	2	Automaty a jazyky 1	3
3.1 Časová složitosti P. NP, převoditelnost, NP-dphost 3.2 Třídy skožitosti P. NP, převoditelnost, NP-dphost 3.2.1 Převoditelnost 3.3.1 Násobení dlouhých císel v lepším než kvadrstickém čase. 3.3.2 Násobení matic n.v.n. a Strasseniv algoritmus 3.3.3 Násobení matic n.v.n. a Strasseniv algoritmus 3.3.3 Rledání k-těho nejmenšího prvku (mediňnu) v lin. čase (Blum et al.) 3.3.4 MergeSort 3.3.4 MergeSort 3.3.5 Rledání k-těho nejmenšího prvku (mediňnu) v lin. čase (Blum et al.) 3.4 Binární vyhledávace stromy, vyvažování, haldy 3.5 Blašování 3.6 Sekveníní třídení, porovnávací algoritmy, přihrádkové třídění, třídící síte 3.7 Grafové algoritmy 3.7 Grafové algoritmy 3.8 Tanatitvní uzávěc 3.9 Algoritmy vyhledávání v textu 3.10 Algebraické algoritmy 4.1 Základy kryptografie, RSA, DES 3.12 Pravděpodobostní algoritmy 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Rokační datový model, relační algebra 4.1 Podstata a architektury DB systemů 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Rokační datový model, relační algebra 4.4 Algoritmy návrhu schémat relací 4.5 Základy SQI 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 5.1 Architektury počítače 5.2 Procesory, multiprocesory 5.3 Vstumy na výstupi zaživení, ukládání a přenos dat 5.4 Architektury počítače 5.5 Procesory, multiprocesory 5.7 Zablokování a zodavení z něj 5.8 Organizace pamětí, alokační algoritmy 5.9 Principy virtuální pamětí, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 5.1 Architektury OS 5.1 Systémy souborů, adresářové struktury 5.2 Procesory, multiprocesory 5.3 Vstupní u výstupně pravít, alivněný práva 5.4 Procesory, multiprocesory 5.5 Procesory, udána, plánování 5.6 Procesory, multiprocesory 5.7 Jostování a postování přepřednování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 5.1 Systémy souborů, adresářové struktury 5.2 Principy virtuální procesorá z ně			
3.1 Časová složitosti P. NP, převoditelnost, NP-dphost 3.2 Třídy skožitosti P. NP, převoditelnost, NP-dphost 3.2.1 Převoditelnost 3.3.1 Násobení dlouhých císel v lepším než kvadrstickém čase. 3.3.2 Násobení matic n.v.n. a Strasseniv algoritmus 3.3.3 Násobení matic n.v.n. a Strasseniv algoritmus 3.3.3 Rledání k-těho nejmenšího prvku (mediňnu) v lin. čase (Blum et al.) 3.3.4 MergeSort 3.3.4 MergeSort 3.3.5 Rledání k-těho nejmenšího prvku (mediňnu) v lin. čase (Blum et al.) 3.4 Binární vyhledávace stromy, vyvažování, haldy 3.5 Blašování 3.6 Sekveníní třídení, porovnávací algoritmy, přihrádkové třídění, třídící síte 3.7 Grafové algoritmy 3.7 Grafové algoritmy 3.8 Tanatitvní uzávěc 3.9 Algoritmy vyhledávání v textu 3.10 Algebraické algoritmy 4.1 Základy kryptografie, RSA, DES 3.12 Pravděpodobostní algoritmy 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Rokační datový model, relační algebra 4.1 Podstata a architektury DB systemů 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Rokační datový model, relační algebra 4.4 Algoritmy návrhu schémat relací 4.5 Základy SQI 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 5.1 Architektury počítače 5.2 Procesory, multiprocesory 5.3 Vstumy na výstupi zaživení, ukládání a přenos dat 5.4 Architektury počítače 5.5 Procesory, multiprocesory 5.7 Zablokování a zodavení z něj 5.8 Organizace pamětí, alokační algoritmy 5.9 Principy virtuální pamětí, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 5.1 Architektury OS 5.1 Systémy souborů, adresářové struktury 5.2 Procesory, multiprocesory 5.3 Vstupní u výstupně pravít, alivněný práva 5.4 Procesory, multiprocesory 5.5 Procesory, udána, plánování 5.6 Procesory, multiprocesory 5.7 Jostování a postování přepřednování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 5.1 Systémy souborů, adresářové struktury 5.2 Principy virtuální procesorá z ně	3	Algoritmy a datové struktury	8
3.3 Metoda rozděl a panuj – aplikace a snalýza složitostí 3.3.1 Násobení dlohných čísel v lepším než kvadratickém čase. 23 3.3.2 Násobení matic n×n a Strassenův algoritmus 3.3.3 Hledání k-tého nejmenšího prvku (mediánn) v lin. čase (Blum et al.) 23.4 Binární vyhledávací stromy, vyvažování, haldy 24 3.4 Binární vyhledávací stromy, vyvažování, haldy 25 3.6 Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídkcí šíté 33 3.7 Grafové algoritmy 37 38. Tranzitivní uzávér 38 39. Algoritmy vyhledávání v textu 41 3.10 Algebraické algoritmy 44 3.11 Základy kryptografie, RSA, DES 48 3.12 Pravdepodobostní algoritmy – testování prvočíselnosti 3.12 Pravdepodobostní algoritmy – testování prvočíselnosti 3.12 Pravdepodobostní algoritmy – testování prvočíselnosti 4.1 Podstata a architektury DB systemů 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 4.3 Relační datový model, relační algoritm 4.4 Algoritmy akvrhu schémat relací 4.5 Základy SQL 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.7 Tedmologie XML, XML Schema 4.8 Organizace data na vnější pamětí, B-stromy a jejich varianty 5.4 Architektury počítačů a šítí 5.1 Architektury počítačů a šítí 5.2 Procesy, vnikina, plánování 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 5.4 Architektury počítačů a sítí 5.1 Zablokování a zodavní z něj 5.9 Procesy, vikkna, plánování 5.0 Synchronizacní přimitika, vzájemné vyloučení 5.1 Synchronizacní přimitika, vzájemné vyloučení 5.1 Zablokování a zodavní z něj 5.1 Synchronizacní přimitika, vzájemné vyloučení 5.2 Procesy, vikkna, plánování 5.2 Procesy, vikkna, plánování 5.3 Rodine protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flove control, congestion control, NAT 5.1 Spojované a nesepojované služby, spolehlivost, zabezpečení protokolu 5.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, ses		3.1 Časová složitost algoritmů, složitost v nejhorším a průměrném případě	8
3.3.2 Násobení matic nxn a Strassenův algoritmus 3.3.3.1 Hledání k-tého nejmenšího prvku (mediánu) v lin. čase (Blum et al.) 3.4 Mergešort. 24 3.3.4 Mergešort. 24 3.3.4 Mergešort. 24 3.5 Hlašování 26 3.5 Hlašování 26 3.6 Sekvenční třídení, porovnávací algoritmy, přihrádkové třídení, třídící sítě 33 3.7 Gradové algoritmy 37 3.8 Tramatitvní uzávěr 43 3.9 Algoritmy vyhledávání v textu 44 3.10 Algebraické algoritmy 44 3.11 Základy kryptografie, RSA, DES 48 3.12 Pravděpodobostní algoritmy - testování prvočíselnosti 50 3.13 Aproximační algoritmy - testování prvočíselnosti 50 3.13 Aproximační algoritmy 52 4 Databáze 53 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návřnu sekémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.6 Trechnologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítače 74 5.1 Architektury počítače 74 5.2 Procesovy, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adressírové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury počínače a cutorizace, přístupová práva 101 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 116 6 116 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 116 6 12 6 Vejektové orientované programování 116		3.3 Metoda rozděl a panuj – aplikace a analýza složitosti	2
3.3.3 Hledání k-tého nejmenšího prvku (mediánu) v lin. čase (Blum et al.)			
3.4 Binární vyhledávací stromy, vyvažování, haldy 26 3.5 Hašování 29 3.6 Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídící sítě 33 3.7 Grafové algoritmy 37 3.8 Tranzitvní uzávěr 43 3.9 Algoritmy vyhledávání v textu 44 3.10 Algebraické algoritmy 46 3.11 Základy kryptografie, RSA, DES 48 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy 50 3.13 Aproximační algoritmy 52 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relacní datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Pechnologie XML, XML Schema 69 4.8 Organizace data na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítače 74 5.2 Procesory, multiprocesory 73 5.3 Vstupní a výstupní za		3.3.3 Hledání k-tého nejmenšího prvku (mediánu) v lin. čase (Blum et al.)	4
3.6 Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídící sítě 33 3.7 Grafové algoritmy 37 3.8 Tranzitvní uzávěr 43 3.9 Algoritmy vyhledávání v textn 44 3.10 Algebraické algoritmy 44 3.11 Základy kryptografie, RSA, DES 48 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy – testování prvočíselnosti 55 3.13 Aproximační algoritmy – testování prvočíselnosti 55 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schéma relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítačů a sítí 73 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 5.5 Procesory, vlákna, plánování 85 5.6 Synchronizační primitíva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 99 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabuky, segmentace 90 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 100 6 Programovací jazyky 61 61 61 61 62 Objektové orientované programování 116			
3.7 Grafové algoritmy 3.8 Tranzitivní uzávér 3.9 Algoritmy vyhledávání v textu 4.1.10 Algorbaické algoritmy 4.2.11 Základy kryptografie, RSA, DES 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 3.13 Aproximační algoritmy 5.2.2 Pravděpodobostní algoritmy – testování prvočíselnosti 3.14 Pravděpodobostní algoritmy – testování prvočíselnosti 3.15 Aproximační algoritmy 5.2.2 Databáze 5.3 4.1 Podstata a architektury DB systemů 5.3 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 6.4.3 Relační datový model, relační algebra 6.5 Základy SQL 6.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 6.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 6.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 6.7 Technologie XML, XML Schema 6.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 7.0 5.1 Architektury počítačů a sítí 5.1 Architektury počítačů a sítí 5.2 Procesory, multiprocesory 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 5.4 Architektury OS 5.5 Procesy, vlákna, plánování 5.6 Synchronizační primitiva, vzájemné vyloučení 5.7 Zablokování a zotavení z něj 5.8 Organizace paměti, alokační algoritmy 9.2 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabuky, segmentace 9.5 10 Systémy souborů, adresářové struktury 9.7 5.11 Bezpeřnost, autentizace, autorizace, přístupová práva 1.0 5.12 Architektury OS 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 1.10 6 Programovací jazyky 6.1 Principy niplementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.2 Objektové orientované programování			
3.8 Tranzitivní uzávěr 43 3.9 Algoritmy vyhledávání v textu 44 3.10 Algebraické algoritmy 46 3.11 Základy kryptografie, RSA, DES 48 3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy – testování prvočíselnosti 50 4.1 Podstata a architektury DB systemů 52 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologic XML, XML Schema 69 4.8 Organizace dat na vnejší paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítačů a sítí 73 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury počítačů 85 5.5 Procesy, vlákna, plánování 85 <			
3.10 Algebraické algoritmy		3.8 Tranzitivní uzávěr	
3.11 Základy kryptografie, RSA, DES 48 3.12 Pravdépodobostní algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy 52 4 Databáze 53 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesny, uklána, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy			
3.12 Pravděpodobostní algoritmy – testování prvočíselnosti 50 3.13 Aproximační algoritmy 52 4 Databáze 53 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologic XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítačů a sítí 73 5.2 Procesory, multiprocesory 74 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační přimitiva, vzájemné vyloučení 87 5.7 Zalolokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 <			
3.13 Aproximační algoritmy 52 4 Databáze 53 4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítače 74 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.12 Principy virtuální paměti, stránko			
4.1 Podstata a architektury DB systemů 53 4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva			2
4.2 Konceptualní, logická a fyzická úroveň pohledu na data 56 4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97	4	Databáze 5	3
4.3 Relační datový model, relační algebra 58 4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101			3
4.4 Algoritmy návrhu schémat relací 61 4.5 Základy SQL 63 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury OS 103 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 104 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.2 Objektově orientované programování 116			
4.5 Základy SQL 4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 4.7 Technologie XML, XML Schema 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 5 Architektury počítačů a sítí 5.1 Architektury počítače 5.2 Procesory, multiprocesory 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 5.5 Procesy, vlákna, plánování 5.6 Synchronizační primitiva, vzájemné vyloučení 5.7 Zablokování a zotavení z něj 5.8 Organizace paměti, alokační algoritmy 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 5.10 Systémy souborů, adresářové struktury 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 5.12 Architektury OS 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 5.12 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.1 Objektově orientované programování			
4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování 66 4.7 Technologie XML, XML Schema 69 4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 74 5.2 Procesory, multiprocesory 75 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury OS 103 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 104 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení112 6.2 Objektově orientované programování 116			
4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty 70 5 Architektury počítačů a sítí 73 5.1 Architektury počítačů a sítí 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury OS 103 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 104 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení112 6.2 Objektově orientované programování 116			
5 Architektury počítačů a sítí 5.1 Architektury počítače 74 5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 91 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 93 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury OS 103 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 104 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.2 Objektově orientované programování 116			
5.1 Architektury počítače		4.6 Organizace dat na vnejsi pameti, D-stroniy a jejich varianty	U
5.2 Procesory, multiprocesory 79 5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS 84 5.5 Procesy, vlákna, plánování 85 5.6 Synchronizační primitiva, vzájemné vyloučení 87 5.7 Zablokování a zotavení z něj 91 5.8 Organizace paměti, alokační algoritmy 92 5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace 98 5.10 Systémy souborů, adresářové struktury 97 5.11 Bezpečnost, autentizace, autorizace, přístupová práva 101 5.12 Architektury OS 103 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT 104 5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu 110 6 Programovací jazyky 112 6.2 Objektově orientované programování 116	5		
5.3 Vstupní a výstupní zařízení, ukládání a přenos dat 82 5.4 Architektury OS			
5.5 Procesy, vlákna, plánování		V / I V	
5.6 Synchronizační primitiva, vzájemné vyloučení		· ·	
5.7 Zablokování a zotavení z něj			
5.8 Organizace paměti, alokační algoritmy			
segmentace		v	
5.10 Systémy souborů, adresářové struktury			
5.11 Bezpečnost, autentizace, autorizace, přístupová práva			
 5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT			
flow control, congestion control, NAT			3
5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu			1
6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.2 Objektově orientované programování			
6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 112 6.2 Objektově orientované programování	6	Programovací jazyky 11	2
		3.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení 11	2
о.э мергосесциани programovani, юдіске programovani			
6.4 Generické programování – šablony a generika			

1 Logika

Požadavky

- Jazyk, formule, sémantika, tautologie.
- Rozhodnutelnost, splnitelnost, pravdivost, dokazatelnost.
- Věty o kompaktnosti a úplnosti výrokové a predikátové logiky.
- Normální tvary výrokových formulí, prenexní tvary formulí predikátové logiky.

1.1 Jazyk, formule, sémantika, tautologie

logika prvního řádu

V logice pracujeme s formulemi a termy, což jsou slova (řetězce znaků dané abecedy) formálního jazyka. Jazyk prvního řádu může zahrnovat:

- neomezeně mnoho symbolů pro proměnné x_1, x_2, \dots
- symboly pro logické spojky $(\neg, \lor, \&, \rightarrow, \leftrightarrow)$
- symboly pro kvantifikátory (∀ obecný, ∃ existenční)
- funkční symboly $f_1, f_2 \dots$ s aritou $n \geq 0$ (např. +, -, 1, *)
- predikátové symboly $p_1, p_2 \dots$ s aritou $n \ge 1$ (např. $\ge, =, \approx, \in, \subset$)
- může (ale nemusí) obsahovat binární predikát "=", který pak se pak ale musí chovat jako rovnost, tj. splňovat určité axiomy.

Proměnné, logické spojky, kvantifikátory a "=" jsou logické symboly, ostatní symboly se nazývají speciální, jelikož určují specifika jazyka a tím vymezují oblast, kterou jazyk popisuje. Výroková a predikátová logika se řadí mezi logiky prvního řádu. Ty pracují jen s jazyky prvního řádu, které mají pouze jeden typ proměnných (pro prvky zvané individua). Jazyky vyšších řádů mají kromě proměnných pro individua také další typy proměnných (pro přirozená čísla, funkce, relace, množiny a další typy objektů).

Každý formální systém logiky prvního řádu obsahuje:

- jazyk
- axiomy
- odvozovací pravidla (pomocí nichž tvoříme důkazy a odvozujeme věty).

Ze symbolů jazyka tvoříme dva druhy slov:

- termy popisují individua (objekty) vzniklé z uvedených operací
- formule vyjadřují tvrzení o objektech.

Definice (jazyk výrokové logiky)

Jazyk L_P výrokové logiky nad množinou P obsahuje prvky množiny P zvané prvotní formule nebo výrokové proměnné (typicky jde o slova nějakého formálního jazyka např. x, y, ABC, nula), symboly pro logické spojky $(\neg, \lor, \&, \rightarrow, \leftrightarrow)$ a pomocné symboly (závorky).

Definice (jazyk predikátové logiky)

Jazyk predikátové logiky obsahuje symboly pro proměnné, *predikátové* a *funkční* symboly, symboly pro *logické spojky*, symboly pro *kvantifikátory* a *pomocné* symboly (závorky).

Definice (redukce jazyka)

Pro zmenšení množiny axiomů je vhodné redukovat počet logických spojek, se kterými pracujeme, na několik základních a ostatní vnímat jako odvozené. Je možno zvolit negaci a implikaci jako spojky základní a v predikátové logice obecný kvantifikátor. Zkratky pak vypadají jako (A&B) za formuli $\neg(A \to \neg B)$, $(A \lor B)$ odpovídá $(\neg A \to B)$ a nakonec $(A \leftrightarrow B)$ redukujeme na $((A \to B)\&(B \to A))$.

Definice (formule výrokové logiky)

Pro jazyk výrokové logiky jsou následující výrazy formule:

- 1. každá výroková proměnná $p \in P$
- 2. pro formule A, B i výrazy $\neg A$, $(A \lor B)$, (A & B), $(A \to B)$, $A \leftrightarrow B$
- 3. každý výraz vzniknuvší konečným užitím pravidel 1. a 2.

Tedy všechny formule jsou konečná slova.

Definice (term – v predikátové logice)

V predikátové logice je term:

- 1. každá proměnná
- 2. výraz $f(t_1, \ldots, t_n)$ pro n-ární funkční symbol f a termy t_1, \ldots, t_n
- 3. každý výraz vzniknuvší konečným užitím pravidel 1. a 2.

Podslovo termu, které je samo o sobě term, se nazývá podterm.

Definice (formule predikátové logiky)

V predikátové logice je formule každý výraz tvaru $p(t_1,\ldots,t_n)$ pro p predikátový symbol a t_1,\ldots,t_n termy. Stejně jako ve výrokové logice je formule i (konečné) spojení jednodušších formulí log. spojkami. Formule jsou navíc i výrazy $(\exists x)A$ a $(\forall x)A$ pro formuli A a samozřejmě cokoliv, co vznikne konečným užitím těchto pravidel. Podslovo formule, které je samo o sobě formule, se nazývá podformule.

Definice (volné a vázané proměnné, otevřené, uzavřené formule, sentence)

Výskyt proměnné x ve formuli je $v\'{a}zan\'{y}$, je-li tato součástí nějaké podformule tvaru $(\exists x)A$ nebo $(\forall x)A$. V opačném případě je volný. Formule je otevřená, pokud neobsahuje vázanou proměnnou, je uzavřená (nebo také sentence), když neobsahuje volnou proměnnou. Proměnná může být v téže formuli volná i vázaná (např. $(x=z) \to (\exists x)(x=z)$).

Definice (pravdivostní ohodnocení – ve výrokové logice)

Sémantika zkoumá pravdivost formulí. Výrokové proměnné samotné neanalyzujeme – jejich hodnoty máme dány už z vnějšku, máme pro ně $množinu \ pravdivostních \ hodnot \ (\{0,1\}).$

 $Pravdivostní ohodnocení e: P \rightarrow \{0,1\}$ je zobrazení, které každé výrokové proměnné přiřadí právě jednu hodnotu z množiny pravdivostních hodnot. Je-li známo ohodnocení proměnných, lze určit $pravdivostní hodnotu \bar{v}$ pro každou formuli (při daném ohodnocení) – indukcí podle její složitosti, podle tabulek pro logické spojky.

Definice (realizace jazyka, termů a ohodnocení proměnných – v predikátové logice)

Realizace jazyka nebo též interpretace jazyka je definována množinovou strukturou M, která ke každému symbolu jazyka a množině proměnných přiřadí nějakou množinu individuí. Popisuje "hodnoty" všech funkčních a predikátových symbolů. M obsahuje:

- $\bullet\,$ neprázdnou množinu individu
íM.
- \bullet zobrazení $f_M:M^n\to M$ pro každý n-ární funkční symbol f
- $\bullet\,$ relaci $p_M\subset M^n$ pro každý $n\text{-ární predikát}\ p$

Realizace termů se uvažuje pro daný jazyk L a jeho realizaci \mathcal{M} . Ohodnocení proměnných je zobrazení $e: X \to M$ (kde Xje množina proměnných). Realizace termu t při ohodnocení e (značíme t[e]) se definuje následovně:

- t[e]=e(x) je-li t proměnná x• $t[e]=f_M(t_1[e],\ldots,t_n[e])$ pro term t tvaru $f(t_1,\ldots,t_n)$.

Ohodnocení závisí na zvoleném \mathcal{M} , realizace termů při daném ohodnocení pak jen na konečně mnoha hodnotách z něj. Pokud jsou x_1, \ldots, x_n všechny proměnné termu t a e, e' dvě ohodnocení tak, že $\forall i \in \{1, \ldots, n\}$ platí $e(x_i) = e'(x_i)$, pak t[e] = t[e'].

Definice (pozměněné ohodnocení – v predikátové logice)

Pozměněné ohodnocení e(x/m) je ohodnocení, ve kterém jsme změnili hodnotu jedné proměnné. Formálně pro ohodnocení e, proměnnou x a individuum $m \in M$ je definováno:

$$e(x/m)(y) = \begin{cases} m & \text{(je-li } y \text{ proměnná } x, \, y \equiv x) \\ e(y) & \text{(jinak,)} \end{cases}$$

Definice $(tautologie \models -ve \ v\acute{y}rokov\acute{e} \ logice)$

Formule je tautologie, jestliže je pravdivá při libovolném ohodnocení proměnných ($\models A$).

Definice (teorie)

Množině formulí říkáme teorie.

Definice (pravdivá formule – ve výrokové logice)

Formule výrokové logiky A je pravdivá při ohodnocení e, je-li $\bar{e}(A) = 1$ (kde \bar{e} je definováno z ohodnocení prvotních formulí e induktivně podle tabulek pro logické spojky). V opačném případě je formule nepravdivá.

Definice (model, tautologický důsledek $T \models -ve \ výrokové \ logice$)

Model nějaké teorie ve výrokové logice je takové ohodnocení proměnných, že každá formule z této teorie je pravdivá. Teorie Uje tautologický důsledek teorie T, jestliže každý model T je také modelem $U(T \models U)$.

1.2 Rozhodnutelnost, splnitelnost, pravdivost a dokazatelnost

Z těchto témat se rozhodnutelnosti budeme věnovat až jako poslední, protože k vyslovení některých vět budeme potřebovat pojmy definované v částech o splnitelnosti, pravdivosti a dokazatelnosti.

Definice (formální systém výrokové logiky)

Pracujeme s redukovaným jazykem (jen s log. spojkami \neg, \rightarrow). Formální systém výrokobé logiky obsahuje:

- 1. $jazyk L_P$ výrokové logiky nad množinou prvotních formulí P,
- 2. schémata axiomů výrokové logiky, ze kterých pro libovolné formule A, B, C jazyka L_P vznikají axiomy tvaru
 - (a) $A \to (B \to A)$ (A1 "implikace sebe sama"), (b) $(A \to (B \to C)) \to [(A \to B) \to (A \to C)]$ (A2 "roznásobení"),
 - (c) $(\neg B \rightarrow \neg A) \rightarrow (A \rightarrow B)$ (A3 "obrácená negace implikace"),
- 3. odvozovací pravidlo (modus ponens) z formulí A a $A \rightarrow B$ odvoď formuli B.

Definice (substituce, instance, substituovatelnost – v predikátové logice)

Substituce termů za proměnné $(t_{x_1,...,x_n}[t_1,...,t_n])$ je současné nahrazení všech výskytů proměnných x_i termy t_i (pro $x_1,...,x_n$ různé proměnné a $t,t_1,...,t_n$ termy). Jedná se opět o term.

Instance formule je současné nahrazení všech volných výskytů nějakých proměnných za termy. Je to taky formule, vyjadřuje speciálnější tvrzení – ne vždy ale lze provést substituci bez změny významu formule. Term t je substituovatelný za proměnnou x do formule A, pokud žádný volný výskyt proměnné x ve formuli A neleží v oboru platnosti některého z kvantifikátorů ($\forall y$ nebo $\exists y$), kde y je proměnná obsažená v termu t. (Neboli pokud pro každou proměnnou y obsaženou v t žádná podformule formule A tvaru ($\exists y$)B ani ($\forall y$)B neobsahuje volný výskyt x.)

Poznámka

Proměnné v termu t se substitucí nesmí stát vázanými. Je-li A otevřená formule, pak je každý term substituovatelný za každou proměnnou vyskytující se v A. Stejně pokud žádná proměnná obsažená v termu t není v A vázaná. To jsou ale jen jednoduché příklady susbtituovatelnosti (např. pro proměnnou z je term tvaru z substituovatelný za proměnnou x do formule $x = 0 \rightarrow \neg (\exists z) (z \neq 0)$, i když pro něj ani jedna z těchto podmínek neplatí).

Definice (formální systém predikátové logiky)

Pracujeme s redukovaným jazykem (jen s log. spojkami \neg , \rightarrow a jen s kvantifikátorem \forall). Schémata axiomů predikátové logiky vzniknou z těch ve výrokové logice prostým dosazením libovolných formulí predikátové logiky za výrokové proměnné. Modus ponens platí i v pred. logice. PL obsahuje navíc další dva axiomy a odvozovací pravidlo:

- schéma specifikace: $(\forall x)A \to A_x[t]$
- $schéma přeskoku: (\forall x)(A \to B) \to (A \to (\forall x)B)$, pokud proměnná x nemá volný výskyt v A.
- pravidlo generalizace: $\frac{A}{(\forall x)A}$

Toto je formální systém pred. logiky bez rovnosti. S rovností přibývá symbol = a další tři axiomy.

Věta (o kvantifikátorech)

- (pravidlo zavedení \forall) Je-li $\vdash A \to B$ a proměnná x nemá v A volný výskyt, pak $\vdash A \to (\forall x)B$.
- (pravidlo zavedení \exists) Je-li $\vdash A \to B$ a proměnná x nemá v B volný výskyt, pak $\vdash (\exists x)A \to B$.
- (distribuce kvantifikátorů) Pokud $\vdash A \to B$, pak $\vdash (QxA) \to (QxB)$ pro Q obecný nebo existenční kvantifikátor.

Definice (splnitelnost – ve výrokové logice)

Formule A ve výrokové logice je splnitelná, jestliže existuje ohodnocení e takové, že A je pravdivá při e. Množina formulí T je splnitelná, pokud existuje ohodnocení e takové, že každá formule $A \in T$ je pravdivá při e. Potom e nazýváme modelem teorie T (značíme $e \models T$).

Definice $(d\mathring{u}kaz \vdash -ve\ v\acute{y}rokov\acute{e}\ logice)$

Důkaz A je konečná posloupnost formulí $A_1, \ldots A_n$, jestliže $A_n = A$ a pro každé $i = 1, \ldots n$ je A_i buď axiom, nebo je odvozená z předchozích pravidlem modus ponens (v predikátové logice navíc možnost použití pravidla generalizace). Existuje-li důkaz formule A, pak je tato dokazatelná ve výrokové logice (je větou výrokové logiky, značíme $\vdash A$).

Definice $(d\mathring{u}kaz\ z\ p\check{r}edpoklad\mathring{u}\ T\vdash)$

Důkaz formule A z předpokladů je posloupnost formulí $A_1, \ldots A_n$ taková, že $A_n = A$ a $\forall i \in \{1, \ldots n\}$ je A_i axiom, nebo prvek množiny předpokladů T, nebo je odvozena z přechozích pravidlem modus ponens. Existuje-li důkaz A z T, pak A je dokazatelná z T, značíme $T \vdash A$.

Věta (o dedukci – ve výrokové logice)

Pro T množinu formulí a formule A, B platí $T \vdash A \rightarrow B$ právě když $T, A \vdash B$.

Idea důkazu

- \rightarrow Máme důkaz formule $A\rightarrow B,$ k němu můžeme z předpokladu připojit Aa pomocí MP odvodit B.
- $\leftarrow A_1, \ldots, A_n = B$ je důkaz formule B z předpokladů T, A. Indukcí dokážeme, že $T \vdash A \rightarrow A_i$, tedy pro i = n jsme hotovi.

Věta (o dedukci – v predikátové logice)

Nechť T je množina formulí pred. logiky, A je uzavřená formule a B lib. formule, potom $T \vdash A \to B$ právě když $T, A \vdash B$.

Idea důkazu

Podobně jako ve VL, pouze v indukčním kroku mohlo být použito pravidlo generalizace, proto požadujeme, aby A byla uzavřená.

Důsledek

Pro libovolnou množinu formulí T a formule A, B, C platí:

$$T \vdash A \to (B \to C)$$
 právě když $T, A, B \vdash C$ právě když $T \vdash B \to (A \to C)$,
$$T \vdash (A \to (B \to C)) \to (B \to (A \to C))$$
,
$$\vdash (A \to B) \to [(B \to C) \to (A \to C)].$$

Poslednímu vztahu říkáme věta o skládání implikací, výše je ukázáno, že v implikaci nezáleží na pořadí předpokladů.

Věta (o neutrální formuli – ve výrokové logice)

Nechť T je množina výrokových formulí, nechť A, B jsou formule. Jestliže $T, A \vdash B$ a $T, \neg A \vdash B$, pak $T \vdash B$.

Definice (uzávěr formule – v predikátové logice)

Jsou-li x_1, \ldots, x_n všechny proměnné s volným výskytem ve formuli A, potom $(\forall x_1) \ldots (\forall x_n) A$ je uzávěr formule A.

Věta (věta o instancích – v predikátové logice)

Je-li A' instance formule A, pak jestliže platí $\vdash A$, platí i $\vdash A'$.

Věta (věta o uzávěru – v predikátové logice)

Je-li A' uzávěr formule A, pak $\vdash A$ platí právě když $\vdash A'$.

Definice (Tarského definice pravdy – v predikátové logice)

Pro daný (redukovaný, tj. jen se "základními" log. spojkami) jazyk predikátové logiky L, \mathcal{M} jeho interpretaci, ohodnocení e a formuli A tohoto jazyka platí:

- 1. A je pravdivá v M při ohodnocení e nebo platná v M při ohodnocení e (značíme $M \models A[e]$), když:
 - A je atomická tvaru $p(t_1, \ldots, t_n)$, kde p není rovnost a $(t_1[e], \ldots, t_n[e]) \in p_M$.
 - A je atomická tvaru $t_1 = t_2$ a $t_1[e] = t_2[e]$
 - A je tvaru $\neg B$ a $\mathfrak{M} \not\models B[e]$
 - A je tvaru $B \to C$ a $\mathcal{M} \not\models B[e]$ nebo $\mathcal{M} \models C[e]$
 - A je tvaru $(\forall x)B$ a $\mathcal{M} \models B[e(x/m)]$ pro každé $m \in M$
 - A je tvaru $(\exists x)B$ a $\mathcal{M} \models B[e(x/m)]$ pro nějaké $m \in M$
- 2. A je $pravdivá v interpretaci <math>\mathcal{M}$ nebo $platná v interpretaci <math>\mathcal{M}$ ($\mathcal{M} \models A$), jestliže je A pravdivá v M při každém ohodnocení proměnných (pro uzavřené formule stačí jedno ohodnocení, splnění je vždy stejné)

Definice (logicky pravdivá/platná formule – v predikátové logice)

Formule A je validní (logicky pravdivá/platná) (značíme $\models A$), když je platná při každé interpretaci daného jazyka.

Definice (spornost, bezespornost)

Množina formulí T je $sporn\acute{a}$, pokud je z předpokladů T dokazatelná libovolná formule, jinak je T $bezesporn\acute{a}$. T je $maxim\acute{a}ln\acute{a}$ $bezesporn\acute{a}$ množina, pokud je T bezesporná a navíc jediná její bezesporná nadmnožina je T samo. Množina všech formulí dokazatelných z T se značí Con(T).

Věta (o bezespornosti a splnitelnosti – ve výrokové logice)

Množina formulí výrokové logiky je bezesporná, právě když je splnitelná.

Definice (teorie, model – obecně)

Pro nějaký jazyk L prvního řádu je množina T formulí tohoto jazyka teorie prvního řádu. Formule z T jsou speciální axiomy teorie T. Pro interpretaci $\mathcal M$ jazyka L je $\mathcal M$ model teorie T (značíme $\mathcal M \models T$), pokud jsou všechny speciální axiomy T pravdivé v $\mathcal M$. Formule A je $s\acute{e}mantickým$ $d\mathring{u}sledkem$ T (značíme $T \models A$), jestliže je pravdivá v každém modelu teorie T.

Rozhodnutelnost

Definice (rekurzivní funkce a množina)

Rekurzivní funkce jsou všechny funkce popsatelné jako $f: \mathbb{N}^k \to \mathbb{N}$, kde $k \geq 1$, tedy všechny "algoritmicky vyčíslitelné" funkce. Množina přirozených čísel je rekurzivní množina (rozhodnutelná množina), pokud je rekurzivní její charakteristická funkce (funkce určující, které prvky do množiny patří).

Definice (spočetný jazyk, kód formule)

Spočetný jazyk je jazyk, který má nejvýš spočetně mnoho speciálních symbolů. Pro spočetný jazyk, kde lze efektivně (rekurzivní funkcí) očíslovat jeho speciální symboly, lze každé jeho formuli A přiřadit její $k\acute{o}d$ formule - přir. číslo #A.

Definice (množina kódů vět teorie)

Pro T teorii s jazykem aritmetiky definujeme $množinu\ k\acute{o}d\mathring{u}\ v\check{e}t\ teorie\ T$ jako $Thm(T)=\{\#A|A\ \text{je}\ uzavřená\ formule\ a\ T\vdash A\}.$

Definice (rozhodnutelná teorie)

Teorie T s jazykem aritmetiky je $rozhodnuteln\acute{a}$, pokud je množina Thm(T) rekurzivní. V opačném případě je T $nerozhodnuteln\acute{a}$.

Věta (Churchova o nerozhodnutelnosti predikátové logiky)

Pokud spočetný jazyk L prvního řádu obsahuje alespoň jednu konstantu, alespoň jeden funkční symbol arity k>0 a pro každé přirozené číslo spočetně mnoho predikátových symbolů, potom množina $\{\#A|A$ je uzavřená formule a $L\models A\}$ není rozhodnutelná.

Věta (o nerozhodnosti predikátové logiky)

Nechť L je jazyk prvního řádu bez rovnosti a obsahuje alespoň 2 binární predikáty. Potom je predikátová logika (jako teorie) s jazykem L nerozhodnutelná.

Definice (Tři popisy aritmetiky)

Je dán jazyk $L = \{0, S, +, \cdot \leq\}.$

- Robinsonova aritmetika "Q"s jazykem L má 8 násl. axiomů:
 - 1. $S(x) \neq 0$
 - $2. \ S(x) = S(y) \to x = y$
 - 3. $x \neq 0 \rightarrow (\exists y)(x = S(y))$
 - 4. x + 0 = x
 - 5. x + S(y) = S(x+y)
 - 6. $x \cdot 0 = 0$
 - 7. $x \cdot S(y) = (x \cdot y) + x$
 - 8. $x \le y \leftrightarrow (\exists z)(z + x = y)$

Poznámka: Někdy, pokud není potřeba definovat uspořádání, se poslední axiom spolu se symbolem "≤" vypouští.

- Peanova aritmetika "P" má všechny axiomy Robinsonovy kromě třetího, navíc má Schéma(axiomů) indukce pro formuli A a proměnnou x platí: $A_x[0] \to \{(\forall x)(A \to A_x[S(x)]) \to (\forall x)A\}$.
- *Úplná aritmetika* má za axiomy všechny uzavřené formule pravdivé v \mathbb{N} , je-li \mathbb{N} standardní model aritmetiky "pravdivá aritmetika". *Teorie modelu* \mathbb{N} je množina $Th(\mathbb{N}) = \{A | A \text{ je uzavřená formule a } \mathbb{N} \models A\}$.

Platí: $Q \subseteq P \subseteq Th(\mathbb{N})$. Q má konečně mnoho axiomů, je tedy rekurzivně axiomatizovatelná. P má spočetně mnoho axiomů, kódy axiomů schématu indukce tvoří rekurzivní množinu. $Th(\mathbb{N})$ není rekurzivně axiomatizovatelná.

Věta (Churchova o nerozhodnutelnosti aritmetiky)

Každé bezesporné rozšíření Robinsonovy aritmetiky Q je nerozhodnutelná teorie.

Věta (Gödel-Rosserova o neúplnosti aritmetiky)

Žádné bezesporné a rekurzivně axiomatizovatelné rozšíření Robinsonovy aritmetiky Q není úplná teorie.

Report (Nečaský)

Predikátová logika - popis jazyka, realizace, ohodnocení, splnitelnost, Tarského definice pravdivosti.

Report (Bednárek)

Tady se dá popsat hooodně papíru definicemi - například definice pravdivosti je v PL o něco komplikovanější. To jsem taky učinil a po projití 5 listů A4 (píšu velkým písmem) mi bylo satisfakci Bednárkovo: "no myslím, že to bylo celkem vyčerpávající"

Report (Kofroň)

Rozhodnutelnost, splnitelnost, pravdivost, dokazatelnost - to mě nepotěšilo, ale zplodil jsem co je výroková logika, ohodnocení, vysvětlil ty pojmy v otázce, ukázal CNF, DNF jak na ně upravit... zkoušející byl nedočkavý, tak jsem nakonec nenapsal nic o PL, s tím, že to kdyžtak dopíšu pak (což nechtěl). Ptal se docela dost, hlavně otázky které jsem nečekal, tak pro další generace tu máme výběr: Složitost zjišťování splnitelnosti pro CNF (3-SAT je NP, ale chtěl vědět co třeba 2-SAT - to je polynomiální, chtěl vědět jak by se to naprogramovalo), stejně ho zajímala složitost u zjištění tautologie... nakonec z toho byl docela příjemný pokec.

Report (Skopal)

Pro Skopala na tuhle otázku si připravte nějaký pěkný příklad nedokazatelné formule nebo nerozhodnutelného problému. Definiciu rozhodnutelnosti som vedel, ale nevedel som mu nic blizsie povedat a rekurzivne spocetnych mnozinach, vyzeral byt trosku nahnevany (lebo prave o tom chcel pocut a bol velmi prekvapeny ako je mozne, ze sme to nebrali) ale podarilo sa mi spravne argumentovat a vysvetlit, ze to je az Slozitost I a nie bc predmety, takze nakoniec v poho. (Ale mal som strach ako male decko.)

1.3 Věty o kompaktnosti a úplnosti výrokové a predikátové logiky

Definice (úplná teorie)

Teorie T s jazykem L prvního řádu je *úplná*, je-li bezesporná a pro libovolnou uzavřenou formuli A je jedna z formulí A, $\neg A$ dokazatelná v T.

♥ Věta (o korektnosti – ve výrokové logice) №

Pro teorii T a formuli A platí $T \vdash A \Rightarrow T \models A$. (Každá v T dokazatelná formule je v T pravdivá.)

Důkaz

Indukcí na větách T. Každý axiom je pravdivý (ověříme přímo) a pravidlo modus ponens také zachovává pravdivost.

Věta (o bezespornosti a modelech – ve výrokové logice)

Má-li teorie model, je bezesporná.

Důkaz

Formule A a $\neg A$ nemohou být zároveň platné v žádném modelu.

Věta (o spoustě věcí – ve výrokové logice)

Nechť A, B jsou formule teorie T. Platí následující tvrzení.

- 1. (a) Teorie T je sporná, právě když je v ní dokazatelný spor.
 - (b) (Důkaz sporem.) $T, \neg A$ je sporná právě když $T \vdash A$.
- 2. Buď ${\cal T}$ maximální bezesporná teorie. Pak platí:
 - (a) $T \vdash A \Leftrightarrow A \in T \Leftrightarrow T, A$ je bezesporná
 - (b) $A \in T \Leftrightarrow \neg A \notin T$ a dále $(A \to B) \in T \Leftrightarrow (\neg A \in T \text{ nebo } B \in T)$.
 - (c) Ohodnocení e takové, že $e(p) = 1 \Leftrightarrow p \in T$ pro každou výrokovou proměnnou p, je jediný model T.
- 3. Bezesporná teorie má maximální bezesporné rozšíření (v témže jazyce).
- 4. (O existenci modelu.) Teorie má model, právě když je bezesporná.
- 5. (O kompaktnosti.) Teorie má model (tedy je splnitelná), právě když každá její konečná podteorie má model (je splnitelná).
- 6. (O úplnosti.) $T \vdash A \Leftrightarrow T \models A$ platí pro každou teorii T a její formuli A. Důsledkem je bezespornost výrokové logiky a dokazatelné v ní jsou právě tautologie.

Důkaz

- 1. (a) Je-li A spor $(\vdash \neg A)$ a přitom $T \vdash A$, pak díky větě $\vdash \neg A \to (A \to B)$ platí jakýkoliv výrok B.
 - (b) \Rightarrow Je-li $T, \neg A$ sporná, pak $T \vdash \neg A \to A$ užitím věty o dedukci. Díky větě $\vdash (\neg A \to A) \to A$ pak platí $T \vdash A$. \Leftarrow Opět díky větám o dedukci a $\vdash \neg A \to (A \to B)$ lze dokázat libovolnou formuli.
- 2. (a) z definic a maximálnosti
 - (b) $\neg A \notin T \Leftrightarrow T, \neg A$ je sporná $\Leftrightarrow T \vdash A \Leftrightarrow A \in T$ dle 2a) a důkazu sporem. Tvrzení o implikaci: Když $A \to B \in T$, tak z $\neg A \notin T$ plyne $A \in T$. Pak $T \vdash B$ a díky 2a) je $B \in T$. Když $\neg A \in T$, tak $T \vdash A \to B$ díky větě $\vdash \neg C \to (C \to D)$, tedy $A \to B \in T$ díky a). Podobně když $B \in T$, tak $T, A \vdash B$, tudíž $T \vdash A \to B$.
 - (c) Platí $A \in T \Leftrightarrow e(A) = 1$, což plyne indukcí dle složitosti A ihned užitím b). Tedy $e \models T$. Konečně pro $e' \models T$ máme $e'(p) = 1 \Leftrightarrow p \in T$ pro každou výrokovou proměnnou p, tedy e' = e.
- 3. Plyne z principu maximality (ekvivalentního s axiomem výběru), aplikujeme-li jej na množinu všech bezesporných teorií S s $S \supseteq T$, na níž uvažujeme uspořádání inkluzí. Každý řetězec R v popsaném uspořádání má majorantu, kterou je jeho sjednocení $\bigcup R$, neboť to je teorie rozšiřující T, která je bezesporná, protože spor v ní je sporem v nějaké teorii z R.
- 4. \Leftarrow Má-li T model e a $T \vdash A$, tak e(A) = 1, tedy $e(\neg A) = 0$, tedy $T \nvdash \neg A$ a T je bezesporná.
 - \Rightarrow Nechť je T bezesporná. Dle 3) existuje maximální bezesporná teorie $T'\supseteq T$ a dle 2c) existuje model teorie T', což je i model T.
- 5. Plyne z 4) z toho, že teorie je bezesporná, právě když je bezesporná každá její konečná podteorie.
- 6. \Rightarrow je věta o korektnosti, v opačném směru předpokládáme $T \models A$. Pak je $T, \neg A$ sporná dle tvrzení o existenci modelu 4), tedy $T \vdash A$ dle důkazu sporem 1b).

Věta (o ekvivalenci – ve výrokové logice)

Vznikne-li formule A' z A nahrazením některého výskytu podformule B formulí B', tak platí:

- 1. $\vdash B \leftrightarrow B' \rightarrow A \leftrightarrow A'$,
- 2. $T \vdash B \leftrightarrow B' \Rightarrow T \vdash A \leftrightarrow A'$.

- Věta (o existenci modelu, úplnosti a kompaktnosti − v predikátové logice)
 - 1. (O existenci modelu.) Každá bezesporná teorie má model kardinality nejvýše ||L(T)||.
 - 2. (O úplnosti.) Formule teorie T je dokazatelná, právě když je pravdivá $(T \vdash A \Leftrightarrow T \models A)$.
 - 3. (O kompaktnosti.) Teorie má model (je splnitelná), právě když každá její konečná část má model. ($T \models A$ právě když $T' \models A$ pro nějakou konečnou podteorii $T' \subseteq T$.)

Důkaz

- 2. Pro formuli A(x) užitím pravidla generalizace, důkazu sporem a věty o existenci modelu máme: $T \not\vdash A \Leftrightarrow T \not\vdash (\forall x)A \Leftrightarrow T, (\exists x) \neg A$ je bezesporná $\Leftrightarrow T, (\exists x) \neg A$ má model $\Leftrightarrow T \not\models A$.
- 3. Plyne z toho, že teorie je sporná, právě když je nějaká její konečná část sporná.

Report (IOI 21. 6. 2011)

Zformulujte větu o existenci modelu a dokažte pomocí ní tvrzení: je-li T nějaká L-teorie a ϕ je L-sentence, tak $T \models \phi \Rightarrow T \vdash \phi$.

1.4 Normální tvary výrokových formulí, prenexní tvary formulí predikátové logiky

Poznámka (vlastnosti log. spojek)

Platí:

- 1. $A \wedge B \vdash A$; $A, B \vdash A \wedge B$
- 2. $A \leftrightarrow B \vdash A \rightarrow B$; $A \rightarrow B$, $B \rightarrow A \vdash A \leftrightarrow B$
- $3. \land je idempotentní, komutativní a asociativní.$
- 4. $\vdash (A_1 \to \dots (A_n \to B) \dots) \leftrightarrow ((A_1 \land \dots \land A_n) \to B)$
- 5. DeMorganovy zákony: $\vdash \neg (A \land B) \leftrightarrow (\neg A \lor \neg B); \vdash \neg (A \lor B) \leftrightarrow (\neg A \land \neg B)$
- 6. \vee je monotonní ($\vdash A \rightarrow A \vee B$), idempotentní, komutativní a asociativní.
- 7. \vee a \wedge jsou navzájem distributivní.

Věta (o ekvivalenci ve výrokové logice)

Jestliže jsou podformule $A_1 \dots A_n$ formule A ekvivalentní s $A'_1 \dots A'_n$ ($\vdash A'_i \leftrightarrow A_i$) a A' vytvořím nahrazením A'_i místo A_i , je i A ekvivalentní s A'. (Důkaz indukcí podle složitosti formule, rozborem případů A_i tvaru $\neg B, B \rightarrow C$)

Lemma (o důkazu rozborem případů)

Je-li T množina formulí a A, B, C formule, pak $T, (A \vee B) \vdash C$ platí právě když $T, A \vdash C$ a $T, B \vdash C$.

Definice (normální tvary DNF, CNF)

Výrokovou proměnnou nebo její negaci nazveme literál. Klauzule budiž disjunkce několika literálů. Formule v normálním konjunktivním tvaru (CNF) je konjunkce klauzulí. Formule v disjunktivním tvaru (DNF) je disjunkce konjunkcí literálů.

Poznámka (hornovské klauzule)

Prolog pracuje s hornovskými klauzulemi, což jsou klauzule, ve kterých se vyskytuje nejvýše jeden pozitivní (nenegovaný) literál.

Věta (o normálních tvarech)

Pro každou formuli A lze sestrojit formule A_k, A_d v konjunktivním, resp. disjunktivním tvaru tak, že $\vdash A \leftrightarrow A_d, \vdash A \leftrightarrow A_k$. (Důkaz z DeMorganových formulí a distributivity, indukcí podle složitosti formule)

Prenexní tvary formulí predikátové logiky

Věta (o ekvivalenci v predikátové logice)

Nechť formule A' vznikne z A nahrazením některých výskytů podformulí B_1, \ldots, B_n po řadě formulemi B'_1, \ldots, B'_n . Je-li $\vdash B_1 \leftrightarrow B'_1, \ldots, \vdash B_n \leftrightarrow B'_n$, potom platí i $\vdash A \leftrightarrow A'$.

Definice (prenexní tvar)

Formule predikátové logiky A je v prenexním tvaru, je-li

$$A \equiv (Q_1 x_1)(Q_2 x_2) \dots (Q_n x_n) B,$$

kde $n \ge 0$ a $\forall i \in \{1, ..., n\}$ je $Q_i \equiv \forall$ nebo \exists , B je otevřená formule a kvantifikované proměnné jsou navzájem různé. B je otevřené jádro A, část s kvantifikátory je prefix A.

Definice (varianta formule predikátové logiky)

Formule A' je $varianta\ A$, jestliže vznikla z A postupným nahrazením podformulí (Qx)B (kde Q je \forall nebo \exists) formulemi $(Qy)B_x[y]$ a y není volná v B.

Věta (věta o variantách – v predikátové logice)

Je-li A' varianta formule A, pak jestliže platí $\vdash A$, platí i $\vdash A'$.

Lemma (o prenexních operacích)

Pro převod formulí do prenexního tvaru se používají tyto operace (výsledná formule je s původní ekvivalentní). Pro podformule B, C, kvantifikátor Q a proměnnou x:

- 1. podformuli lze nahradit nějakou její variantou
- 2. $\vdash \neg (Qx)B \leftrightarrow (\overline{Q}x)\neg B$
- 3. $\vdash (B \to (Qx)C) \leftrightarrow (Qx)(B \to C)$, pokud x není volná v B
- 4. $\vdash ((Qx)B \to C) \leftrightarrow (\overline{Q}x)(B \to C)$, pokud x není volná v C
- 5. $\vdash ((Qx)B \land C) \leftrightarrow (Qx)(B \land C)$, pokud x není volná v C
- 6. $\vdash ((Qx)B \lor C) \leftrightarrow (Qx)(B \lor C)$, pokud x není volná v C

Věta (o prenexních tvarech)

Ke každé formuli A predikátové logiky lze sestrojit ekvivalentní formuli A', která je v prenexním tvaru. (Důkaz: indukcí podle složitosti formule a z prenexních operací, někdy je nutné přejmenovat volné proměnné)

2 Automaty a jazyky

Požadavky

- Chomského hierarchie, třídy automatů a gramatik, determinismus a nedeterminismus.
- Uzávěrové vlastnosti tříd jazyků.

2.1 Automaty – Chomského hierarchie, třídy automatů a gramatik, determinismus a nedeterminismus.

- Popište jednotlivé třídy jazyků a jejich vztahy; definujte třídy pomocí odpovídajících gramatik. Napište priklady gramatik pro jednotlivé třídy.
- Popište automaty, ktere tyto tridv jazyku rozpoznávají i s ohledem na jejich (ne)deterministicnost.

Třídy automatů a gramatik

Definice (Konečný automat)

Konečný automat je pětice $A = (Q, X, \delta, q_0, F)$, kde Q je stavový prostor (množina všech možných stavů), X je abeceda (množina symbolů), δ je přechodová funkce $\delta: Q \times X \to Q$, $q_0 \in Q$ je poč. stav a $F \subseteq Q$ množina koncových stavů.

Definice

Slovo w je posloupnost symbolů v abecedě X. Jazyk L je množina slov, tedy $L \subseteq X^*$, kde X^* je množina všech posloupností symbolů abecedy X. λ je prázdná posloupnost symbolů. Rozšířená přechodová funkce je $\delta^*: Q \times X^* \to Q$ - tranzitivní uzávěr δ . Jazyk rozpoznávaný konečným automatem – regularní jazyk je $L(A) = \{w | w \in X^*, \delta^*(q_0, w) \in F\}$. Pravá kongruence je taková relace ekvivalence na X^* , že $\forall u, v, w \in X^*: u \sim v \Rightarrow uw \sim vw$. Je konečného indexu, jestliže X^*/\sim (rozklad na třídy ekvivalence) má konečný počet tříd.

Věta (Nerodova)

Jazyk L nad konečnou abecedou X je rozpoznatelný kon. automatem \Leftrightarrow existuje pravá kongruence konečného indexu \sim na X^* tak, že L je sjednocením jistých tříd rozkladu X^*/\sim .

Věta (Pumping (iterační) lemma)

Pro jazyk rozpoznatelný kon. automatem (tzn. regulární) L existuje $n \in \mathbb{N}$ tak, že libovolné slovo $z \in L, |z| \ge n$ lze psát jako uvw, kde $|uv| \le n$, $|v| \ge 1$ a $\forall i \ge 0 : uv^i w \in L$.

Definice

Dva automaty jsou ekvivalentní, jestliže přijímají stejný jazyk. Homomorfismus (isomorfismus) automatů je zobrazení, zachovávající poč. stav, přech. funkci i konc. stavy (+ prosté a na). Pokud existuje homomorfismus automatů $A \to B$, pak jsou tyto dva ekvivalentní (jen 1 implikace!). Dosažitelný stav $q - \exists w \in X^* : \delta^*(q_0, w) = q$. Relace ekvivalence je automatovou kongruencí, pokud zachovává konc. stavy a přech. funkci. Ke každému automatu existuje redukt - ekvivaletní automat bez nedosažitelných a navzájem ekvivalentních stavů. Ten je určen jednoznačně pro daný jazyk (až na isomorfismus), proto lze zavést normovaný tvar.

Poznámka (Operace s jazyky)

S jazyky lze provádět množinové operace (\cup, \cap) , rozdíl $(\{w|w \in L_1\&w \notin L_2\})$, doplněk $(\{w|w \notin L\})$, dále zřetězení $(L_1 \cdot L_2 = \{uv|u \in L_1, v \in L_2\})$, mocniny $(L^0 = \lambda, L^{i+1} = L^i \cdot L)$, iterace $(L^* = L^0 \cup L^1 \cup L^2 \cup ...)$, otočení $(L^R = \{u^R|u \in L\})$, levý $(L_2 \setminus L_1 = \{v|uv \in L_1, u \in L_2\})$ i pravý $(L_1/L_2 = \{u|uv \in L_1, v \in L_2\})$ kvocient L_1 podle L_2 a derivace (kvocienty podle jednoslovného jazyka). Třída jazyků rozpoznatelných konečnými automaty je na tyto operace uzavřená.

Definice (Regulární jazyky)

Třída reguláních jazyků nad abecedou X je nejmenší třída, která obsahuje \emptyset , $\forall x \in X$ obsahuje x a je uzavřená na sjednocení, iteraci a zřetězení.

Věta (Kleenova)

Jazyk je regulární ⇔ je rozpoznatelný konečným automatem.⁴

¹Pokud dvě různá slova u,v převedou automat do stejného stavu (=jsou navzájem ekvivalentní $(u \sim v)$), pak musí patřit do stejné třídy rozkladu. Pokud k těmto dvěma slovům přidáme stejné slovo zprava, pak tato zřetězená slova budou opět patřit do stejné třídy rozkladu (=musí být navzájem ekvivalentní $(uw \sim vw)$). A toto je právě ta vlastnost definující pravou kongruenci.

 $^{^{2}}$ Důležitě tedy je, že pokud je jazyk regulární, pak pro něj musí existovat pravá kongruence, která (což je nejdůležitější) rozkládá všechna slova

jazyka do konečně mnoha tříd.

³Platí i pro konečné jazyky: když je jazyk konečný, tak si za n stačí vzít délku nejdelšího slova a pak to pro všechny slova delší než n (tj. žádná) platí taky.

⁴Důkaz se dá indukcí podle počtu hran v nedeterministickém automatu.

Definice (Regulární výrazy)

Regulární výrazy nad abecedou $X = x_1, ..., x_n$ jsou nejmenší množina slov v abecedě $x_1, ..., x_n, \emptyset, \lambda, ^+, \cdot, ^*, (,)$, která obsahuje výrazy \emptyset a λ a $\forall i$ obsahuje x_i a je uzavřená na sjednocení (+), zřetězení (\cdot) a iterace (*). Hodnota reg. výrazu a je reg. jazyk [a], lze takto reprezentovat každý reg. jazyk.

Definice (Dvoucestné konečné automaty)

Dvoucestný konečný automat je pětice (Q, X, δ, q_0, F) , kde oproti kon. automatu je $\delta : Q \times X \to Q \times \{-1, 0, 1\}$ (tj. pohyb čtecí hlavy). Přijímá slovo, pokud výpočet začal vlevo v poč. stavu a čtecí hlava opustila slovo w vpravo v konc. stavu (mimo slovo končí výpočet okamžitě).

Poznámka

Jazyky přijímané dvoucestnými automaty jsou regulární - každý dvoucestný automat lze převést na (nedeterministický) konečný automat.

Definice (Zásobníkové automaty)

Zásobníkový automat je sedmice $M=(Q,X,Y,\delta,q_0,Z_0,F)$, kde proti konečným automatům je Y abeceda pro symboly na zásobníku, Z_0 počáteční symbol na zásobníku a funkce instrukcí $\delta:Q\times(X\cup\{\lambda\})\times Y\to \mathcal{P}(Q\times Y^*)$. Je z principu nedeterministický; vždy se nahrazuje vrchol zásobníku, nečte ale pokaždé vstupní symboly. Instrukci $(p,a,Z)\to(q,w)$ lze vykonat, pokud je automat ve stavu p, na zásobníku je Z a na vstupu a. Vykonání instrukce znamená změnu stavu, pokud $a\neq\lambda$, tak i posun čtecí hlavy a odebrání Z ze zásobníku, kam se vloží w (prvním písmenem nahoru). Výpočet končí buď přečtením slova, nebo v případě, že pro danou situaci není definována instrukce (Situace zás. automatu je trojice (p,u,v), kde $p\in Q,u$ je nepřečtený zbytek slova a v celý zásobník).

Přijímat slovo je možné buď koncovým stavem (slovo je přečteno a automat v konc. stavu), nebo zásobníkem (slovo je přečteno a zásobník prázdný – konc. stavy jsou v takovém případě nezajímavé - $F = \emptyset$).

Poznámka

Pro zás. automat přijímající konc. stavem vždy existuje ekvivalentní automat $(L(A_1) = L(A_2))$ přijímající zásobníkem a naopak.

Definice (Přepisovací systém)

Přepisovací (produkční) systém je dvojice R=(V,P), kde V je konečná abeceda a P množina přepisovacích pravidel (uspořádaných dvojic prvků z V^*). Slovo w se *přímo přepíše* na z ($w \Rightarrow z$), pokud $\exists u, v, x, y \in V^* : w = xuy, z = xvy, (u, v) \in P$. Derivace (odvození) je zřetězení několika přímých přepsání.

Definice (Formální (generativní) gramatika)

Formální gramatika je čtveřice $G = (V_N, V_T, S, P)$, kde V_N je množina neterminálních symbolů (ostatní znaky např. S), V_T množina terminálních symbolů ("znaky z abecedy"), S startovací symbol ($S \in V_N$) a P množina pravidel. Jazyk generovaný gramatikou je $L(G) = \{w | w \in V_T^*, S \Rightarrow^* w\}$.

Věta

Každý bezkontextový jazyk je rozpoznáván zásobníkovým automatem, přijímajícím prázdným zásobníkem. Stejně pro každý zásobníkový automat existuje bezkontextová gramatika, která generuje jazyk jím přijímaný.

Poznámka (Vlastnosti bezkontextových gramatik)

Bezkontextová gramatika je redukovaná, pokud $\forall X \in V_N$ existuje terminální slovo $w \in V_T^*$ tak, že $X \Rightarrow^* w$ a navíc $\forall X \in V_N, X \neq S$ existují slova u, v tak, že $S \Rightarrow^* uXv$. Ke každé bezkontextové gramatice lze sestrojit ekvivalentní redukovanou.

Pro každé terminální slovo v bezkontextové gramatice existují derivace, které se liší jen pořadím použití pravidel (a prohozením některých pravidel dostanu stejné terminální slovo), proto lze zavést levé (pravé) derivace - tj. kanonické derivace. Pokud $X \Rightarrow^* w$, pak existuje i levá (pravá) derivace. Znázornění průběhu derivací je možné určit derivačním stromem – určuje jednoznačně pravou/levou derivaci.

Bezkontextová gramatika je *víceznačná* (nejednoznačná), pokud v ní existuje slovo, které má dvě různé levé derivace; jinak je *jednoznačná*. Jazyk je jednoznačný, pokud k němu existuje generující jednoznačná gramatika. Pokud je každá gramatika nějakého jazyka nejednoznačná, je tento *podstatně nejednoznačný*.

Definice (Greibachové normální forma)

Gramatika je v Greibachové normální formě, jsou-li všechna její pravidla ve tvaru $A \to au$, kde $a \in V_T$ a $u \in V_N^*$. Ke každému bezkontextovému jazyku existuje gramatika v G. normální formě tak, že $L(G) = L \setminus \{\lambda\}$. Každou bezkontextovou gramatiku lze převést do G. normální formy.

Poznámka (Úpravy bezkontextových gramatik)

Spojením více pravidel $(A \to uBv, B \to w_1, ...B \to w_k$ se převede na $A \to uw_1v|...|uw_kv)$ dostanu ekvivalentní gramatiku. Stejně tak odstraněním levé rekurze (převod přes nový neterminál).

Definice (Chomského normální forma)

Pro gramatiku v Chomského normální formě jsou všechna pravidla tvaru $X \to YZ$ nebo $X \to a$, kde $X, Y, Z \in V_N$, $a \in V_T$. Ke každému bezkontextovému jazyku L existuje gramatika G v Chomského normální formě tak, že $L(G) = L \setminus \{\lambda\}$

Poznámka (Vlastnosti třídy bezkontextových jazyků)

Třída bezkontextových jazyků je uzavřená na sjednocení, zrcadlení, řetězení, iteraci a pozitivní iteraci, substituci a homomorfismus, inverzní homomorfismus a kvocient s regulárním jazykem. Není uzavřená na průnik a doplněk.

Definice (Dyckův jazyk)

Dyckův jazyk je definován nad abecedou $a_1, a'_1, ...a_n, a'_n$ gramatikou

$$S \to \lambda |SS| a_1 S a'_1 | \dots |a_n S a'_n$$

Je bezkontextový, popisuje správná uzávorkování a lze jím popisovat výpočty zásobníkových automatů, tedy i bezkontextové jazyky.

Definice (Turingův stroj)

Turingův stroj je pětice $T=(Q,X,\delta,q_0,F)$, kde X je abeceda, obsahující symbol ε pro prázdné políčko, přechodová funkce $\delta:(Q\setminus F)\times X\to Q\times X\times \{-1,0,1\}$ popisuje změnu stavu, zápis na pásku a posun hlavy. Výpočet končí, není-li definována žádná instrukce (spec. platí pro $q\in F$). Konfigurace Turingova stroje jsou údaje, popisující stav výpočtu – nejmenší souvislá část pásky, obsahující všechny neprázdné buňky a čtenou buňku, vnitřní stav a poloha hlavy. Krok výpočtu je $uqv\vdash wpz$ pro u část slova vlevo od akt. pozice na pásce, v od čteného písmena dál a q stav stroje. Výpočet je posloupnost kroků, slovo w je přijímáno, pokud $q_0w\vdash^* upv, p\in F$. Jazyky (množiny slov bez ε) přijímané Turingovými stroji jsou rekurzivně spočetné.

Věta

Každý jazyk typu 0 (s gramatikou s obecnými pravidly) je rekurzivně spočetný.

Chomského hierarchie

Definice (Chomského hierarchie)

Chomského hierarchie je rozdělení gramatik do 4 tříd podle omezení na pravidla:

Poznámka

S $\mathcal{L}1 \supset \mathcal{L}2$ nastává problém, protože bezkontextové gramatiky umožňují pravidla tvaru $X \to \lambda$. Řešením je převod na nevypouštějící bezkontextové gramatiky - takové bezkontextové gramatiky, které nemají pravidla typu $X \to \lambda$.

Věta (o nevypouštějících bezkontextových gramatikách)

Ke každé bezkontextové G existuje nevypouštějící bezkontextová G_0 tak, že

$$L(G_0) = L(G) \setminus \{\lambda\}$$

Je-li $\lambda \in L(G)$, pak $\exists G_1$, t.ž. $L(G_1) = L(G)$ a jediné pravidlo v G_1 s λ na pravé straně je $S \to \lambda$ a S není v G_1 na pravé straně žádného pravidla.

Poznámka (Lineární gramatiky)

Pro každou gramatiku typu G3 lze sestrojit konečný automat, který přijímá právě jazyk jí generovaný, stejně tak pro každý konečný automat lze sestrojit gramatiku G3. Levé lineární gramatiky také generují regulární jazyky, díky uzavřenosti na reverzi. Lineární gramatiky, s pravidly typu $X \to uYv, X \to w$, kde $X, Y \in V_N, u, v, w \in V_T^*$, generují lineární jazyky - silnější než regulární jazyky.

Definice (Separovaná a nevypouštějící gramatika)

Separovaná gramatika je gramatika (obecně libovolné třídy), obsahující pouze pravidla tvaru $\alpha \to \beta$, kde buď $\alpha, \beta \in V_N^+$, nebo $\alpha \in V_N$ a $\beta \in V_T \cup \{\lambda\}$. Nevypouštějící (monotónní) gramatika (také se neomezuje na konkrétní třídu) je taková, že pro každé pravidlo $u \to v$ platí $|u| \le |v|$.

Poznámka (Kontextové gramatiky)

Ke každé kontextové gramatice lze sestrojit ekvivalentní separovanou. Ke každé monotónní gramatice lze nalézt ekvivalentní kontextovou.

Determinismus a nedeterminismus

Definice (Nedeterministický konečný automat)

Nedeterministický konečný automat je pětice (Q, X, δ, S, F) , kde Q je mn. stavů, X abeceda, F mn. konc. stavů, S množina počátečních stavů a $\delta: Q \times X \to \mathcal{P}(Q)$ je přechodová funkce. Slovo w je takovým automatem přijímáno, pokud existuje posloupnost stavů $\{q_i\}_{i=1}^n$ tak, že $q_1 \in S$, $q_{i+1} \in \delta(q_i, x_i)$, $q_{n+1} \in F$.

Poznámka

Pro každý nedeterministický konečný automat A lze sestrojit deterministický kon. automat B tak, že jimi přijímané jazyky jsou ekvivalentní (může to znamenat exponenciální nárůst počtu stavů).

Definice (Deterministický zásobníkový automat)

Deterministický zásobníkový automat je $M=(Q,X,Y,\delta,q_0,Z_0,F)$ takové, že $\forall p\in Q, \forall a\in (X\cup\{\lambda\}), \forall Z\in Y$ platí $|\delta(p,a,Z)|\leq 1^5$ a navíc pokud pro nějaké p,Z je $\delta(p,\lambda,Z)\neq\emptyset$, pak $\forall a\in X$ je $\delta(p,a,Z)=\emptyset^6$.

Poznámka

Deterministický zásobníkový automat je "slabší" než nedeterministický, rozpoznává deterministické bezkontextové jazyky koncovým stavem a bezprefixové bezkontextové jazyky prázdným zásobníkem (takové jazyky, kde $u \in L(M) \Rightarrow \forall w \in X^* : uw \notin L(M)$) - když se poprvé zásobník automatu vyprázdní, výpočet určitě končí.

Bezprefixové bezkontextové jazyky jsou vždy deterministické, opačně to neplatí. Deterministický bezkontextový jazyk lze na bezprefixový převést zřetězením s dalším symbolem, který není v původní abecedě.

Regulární jazyky a bezprefixové bezkontextové jazyky jsou neporovnatelné množiny.

Definice (Nedeterministický Turingův stroj)

Nedet. Turingův stroj je pětice $T = (Q, X, \delta, q_0, F)$, kde oproti deterministickým je $\delta : (Q \setminus F) \times X \to \mathcal{P}(Q \times X \times \{-1, 0, 1\})$. Přijímá slovo w, pokud existuje nějaký výpočet $q_0w \vdash^* upv$ tak, že $p \in F$.

Poznámka

Nedeterministické Turingovy stroje přijímají právě rekurzivně spočetné jazyky, tj. nejsou silnější než deterministické. Výpočty nedet. stroje lze totiž díky nekonečnosti pásky simulovat deterministickým (např. prohledáváním do šířky).

Definice (Lineárně omezený automat)

Lineárně omezený automat je nedeterministický Turingův stroj s omezenou páskou (např. symboly l a r, které nelze přepsat ani se dostat mimo jejich rozmezí). Slovo je přijímáno, pokud $q_0lwr \vdash^* upv$, kde $p \in F$. Prostor výpočtu je omezen délkou vstupního slova. Lineárně omezené automaty přijímají právě kontextové jazyky.

Poznámka (Rozhodnutelnost)

Turingův stroj může nepřijmout slovo buď skončením výpočtu v nekoncovém stavu, nebo pokud výpočet nikdy neskončí. Turingův stroj rozhoduje jazyk L, když přijímá právě slova tohoto jazyka a pro libovolné slovo je jeho výpočet konečný. Takové jazyky se nazývají rekurzivní.

Problém zastavení výpočtu Turingova stroje je algoritmicky nerozhodnutelný (kvůli možnosti jeho simulace jiným Turingovým strojem). Pro bezkontextové jazyky je algoritmicky rozhodnutelné, zda dané slovo patří do jazyka. Pro bezkontextovou gramatiku nelze algoritmicky rozhodnout, zda $L(G) = X^*$. Pro dvě kontextové gramatiky je nerozhodnutelné, zda jejich jazyky mají neprázdný průnik.

Report (Hnetynka)

napisal som hierachiu, pravidla gramatik, ake automaty rozpoznavaju jednotlive gramatiky, pre reg gram veticky o KA a reg jazykoch. Pytal sa ma ako jednotlive automaty pracuju, zadal par jednoduchych prikladov a chcel zdovodnenie do akych tried patri -nakreslit/opisat slovami KA, gramatiky, ZA + dokaz pomocou pumping lemma. Pytal sa, do akej triedy by som zaradil rozpoznavanie prg jazykov, napr Java. Povedal som kontextove, ale zdovodnit som to velmi nevedel. Potvrdil ze su to kontextove + ze prave kvoli dobrym znalostam sa pouzivaju bezkontextove v kombinacii s analyzou kontextu (kedze na poradi jednotlivych riadkov zalezi) (znamka 1-2, ze zalezi na druhej inf otazke)

Report (Bulej)

napisal som gramatiky, odpovedajuce automaty, vysvetlil inkluzie a to bohato stacilo

Report (Bednarek)

Měl jsem definice hierarchie a srovnání s příslušnými automaty, nástin (opravdu lehce) inkluzí mezi třídami jazyků, Greibachové a Chomského n.f. plus nějaké příklady jazyků, které dokazují ostrou inkluzi, ale bez přesnějších důkazů (kouzelná věta: "to se ukáže přes pumping lemma";-)) Ptal se mě na srovnání deterministických a nedeterministických verzí jednotlivých druhů automatů, což jsem věděl. Informatika za jedna.

Report (Kucera)

Toto se obeslo bez problemu, stacilo to definovat, a rict ktere automaty prijimaij ktere jazyky, umet je definovat. Vety kolem moc zajem nevzbudily (Nerudovka, pump. lemma):-)

Report (Fiala)

Napsal sem třídy automatů, gramatik, determinismus/nedeterminismus a pak ještě rozhodnutelnost. Při procházení sem dostával doplňující otázky typu: "Jak nějak líp omezit odhad o nárustu počtu stavu při převodu NKA do KA" (záleží na počtu počátečních stavů a na počtu "stejnejch" přechodů z jednotlivých stavů.), U rozhodnutelnosti náznak důkazu halting problem a další.

Report (Bednárek)

Tak jsem napsal automat a gramatiku ke každé třídě jazyků, determ./nedeterm. verze a jak je to kde s jejich silou. Drobné chyby v definicích nevadily, když byly po upozornění opraveny. U RJ se zeptal ještě na reg. výrazy a pak taky proč že se rekurzivně spočetné jazyky jmenují jak se jmenují (kde je ta rekurze), což jsem nevěděl a byl poučen.

⁵definuje ze v kazdem kroku si nemuzeme vybirat

⁶definuje ukončení vypoctu

Report (IOI 10.2.2011)

- a) Popište jednotlivé třídy jazyků a jejich vztahy definujte třídy pomocí odpovidajícich gramatik. Napište přiklady gramatik pro jednotlivé třídy.
- b) Popište automaty, ktere tyto třídy jazyků rozpoznávají i s ohledem na jejich (ne)determinstičnost.

Report (IOI 21. 6. 2011)

- 4.1 Popište Chomského hierarchii tříd jazyků, jak se nazývají jazyky v každé třídě, jaký typ gramatiky je generuje a jaký typ automatu je přijímá.
- 4.2 Uveď te příklad neregulárního jazyka a ukažte, že není regulární.
- 4.3 Existuje uzávěrová vlastnost, na kterou nejsou uzavřené jazyky typu 0? TODO

Report (IP 21. 6. 2011)

Ukažte, že následující gramatika G je víceznačná $S \to if$ then S else S | if then S | λ Vytvořte gramatiku G', která nebude víceznačná, a bude platit L(G) = L(G').

Existuje obecně k libovolné bezkontextové gramatice G jednoznačná gramatika G' taková, že L(G) = L(G')?

Uzávěrové vlastnosti tříd jazyků 2.1.1

(tohle asi nikdy nebude samostatna otazka) TODO: nejaka zduvodneni

Poznámka (DBKJ nejsou uzavřené na homomorfismus (BKJ ano)!)

 $L_1 = \{a^i b^j c^k | i = j\}$ je DBKJ $L_2 = \{a^i b^j c^k | j = k\}$ je DBKJ $0L_1 \cup 1L_2$ je DBKJ, $1L_1 \cup 1L_2$ není DBKJ položme h(0) = 1 a h(x) = x pro ostatní symboly $h(0L_1 \cup 1L_2) = 1L_1 \cup 1L_2$

Poznámka (BKJ nejsou uzavřené na průnik (DBKJ ano))

- $L_1 = \{a^i b^i c^j | i, j > 0\}$
- $L_2 = \{a^i b^j c^j | i, j \ge 0\}$

TODO

Poznámka (Doplněk deterministického BKJ je opět deterministický BKJ!)

prohodíme koncové a nekoncové stavy potíže:

- nemusí přečíst celé vstupní slovo
- krok není definován (např. vyprázdnění zásobníku)

snadno ošetříme "podložkou" na zásobníku

- cyklus (zásobník roste, zásobník pulsuje)
- odhalíme pomocí čítače
- po přečtení slova prochází koncové a nekoncové stavy stačí si pamatovat, zda prošel koncovým stavem

3 Algoritmy a datové struktury

Požadavky

- Časová složitost algoritmů, složitost v nejhorším a průměrném případě.
- Třídy složitosti P a NP, převoditelnost, NP-úplnost.
- Metoda "rozděl a panuj" aplikace a analýza složitosti.
- Binární vyhledávací stromy, vyvažování, haldy.
- Hašování.
- Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídící sítě.
- Grafové algoritmy prohledávání do hloubky a do šířky, souvislost, topologické třídění, nejkratší cesta, kostra grafu, toky v sítích.
- Tranzitivní uzávěr.
- Algoritmy vyhledávání v textu.
- Algebraické algoritmy DFT, Euklidův algoritmus.
- Základy kryptografie, RSA, DES.
- Pravděpodobnostní algoritmy testování prvočíselnosti.
- Aproximační algoritmy.

3.1 Casová složitost algoritmů, složitost v nejhorším a průměrném případě

Definice (časová složitost)

Časovou složitostí algoritmu rozumíme závislost jeho časových nároků na velikosti konkrétních vstupních dat. Analogicky se definuje i **paměťová složitost**. Dobu zpracování úlohy o velikosti n značíme T(n)

Časovou složitost často zkoumáme z několik hledisek:

- v nejhorším případě maximální počet operací pro nějaká data,
- v nejlepším případě minimální počet operací pro nějaká data,
- v průměrném (očekávaném) případě průměr pro všechna možná vstupní data (někdy též střední hodnota náhodné veličiny T(n)).

Poznámka

Jako jednu "operaci", nebo-li krok algoritmu rozumíme jednu elementární operaci nějakého abstraktního stroje (např. Turingova stroje), proveditelnou v konstantním čase. Intuitivně je možné chápat to jako několik operací počítače, které dohromady netrvají více, než nějakou pevně danou dobu.

Poznámka

Casová složitost problému je rovna složitosti nejlepšího algoritmu řešícího daný problém.

Asymptotická složitost

Definice

Řekneme, že funkce f(n) je asymptoticky menší nebo rovna než g(n), značíme f(n) je O(g(n)), právě tehdy, když

$$\exists c > 0 \ \exists n_0 \ \forall n > n_0 : 0 \le f(n) \le c \cdot g(n)$$

Funkce f(n) je asymptoticky větší nebo rovna než g(n), značíme f(n) je $\Omega(g(n))$, právě tehdy, když

$$\exists c > 0 \ \exists n_0 \ \forall n > n_0 : 0 \le c \cdot g(n) \le f(n)$$

Funkce f(n) je **asymptoticky stejná** jako g(n), značíme f(n) je $\Theta(g(n))$, právě tehdy, když

$$\exists c_1, c_2 > 0 \ \exists n_0 \ \forall n > n_0 : 0 \le c_1 \cdot g(n) \le f(n) \le c_2 \cdot g(n)$$

Poznámka

Asymptotická složitost zkoumá chování algoritmů na "velkých" datech a dle jejich složitosti je zařazuje do skupin (polynomiální, exponenciální...). Při zkoumání se zanedbávají aditivní a multiplikativní konstanty.

Amortizovaná složitost

Definice (Amortizovaná složitost)

Amortizovaná časová složitost počítá průměrný čas na jednu operaci při provedení posloupnosti operací. Používá se typicky pro počítání časové složitosti operací nad datovými strukturami. Dává realističtější horní odhad složitosti posloupnosti operací, než počítání s nejhorším případem u každé operace.

Agregační metoda

Spočítáme (nejhorší možný) čas T(n) pro posloupnost operací. Amortizovaná cena jedné operace je potom $\frac{T(n)}{n}$.

Účetní metoda

Od každé operace "vybereme" určitý "obnos", ze kterého "zaplatíme" za danou operaci a pokud něco zbude, dáme to na účet. Pokud je operace dražší než kolik je její obnos, tak potřebný rozdíl vybereme z účtu. Zůstatek na účtu musí být stále nezáporný. Pokud uspějeme, tak "obnos" = amortizovaná cena jedné operace.

Poznámka

Jde o to, že některá operace může trvat krátce, ale "rozháže" datovou strukturu, takže následující operace potřebují víc času. Nebo naopak trvá dlouho a datovou strukturu "uspořádá", takže ostatní operace jsou kratší.

3.2 Třídy složitosti P a NP, převoditelnost, NP-úplnost

TODO: doplnit, tohle asi nestaci na pohodovou zkousku (aspon podle toho co jsem vnimal, jsa svedek zkouseni u Dr. Yaghoba) – chce to napr. nejaky priklad prevedeni jako delal Kucera, mozna jeste neco

3.2.1 Převoditelnost

Definice

- Úloha Pro dané zadání (vstup, instanci úlohy) najít výstup s danými vlastnostmi.
- Optimalizační úloha Pro dané zadání najít optimální (většinou nejmenší nebo největší) výstup s danými vlastnostmi.
- Rozhodovací problém Pro dané zadání odpovědět ANO/NE.

Definice (převody mezi rozhodovacími problémy)

Nechť A, B jsou dva rozhodovací problémy. Říkáme, že A je **polynomiálně redukovatelný** (**převoditelný**) na B, pokud existuje zobrazení f z množiny zadání problému A do množiny zadání problému B s následujícími vlastnostmi:

- Nechť X je zadání problému A a Y zadání problému B, takové, že f(X) = Y. Potom je X kladné zadání problému A právě tehdy, když Y je kladné zadání problému B.
- Nechť X je zadání problému A. Potom je zadání f(X) problému B (deterministicky sekvenčně) zkonstruovatelné v polynomiálním čase vzhledem k velikosti X.

Jiná definice: Mějme rozhodovací algoritmus A, výsledek algoritmu chápejme jako funkce A(x) na vstupu x, pak algoritmus A je redukovatelný na B ($A \to B$) když $\forall A : B(f(x)) = A(x)$ pro polynomiální f.

Obě definice říkají, že B je "aspoň tak těžký", jako A (může ale být těžší!). Název je trochu zavádějící – neredukujeme na $leh\check{c}i$, ale na $t\check{e}\check{z}\check{s}i$ algoritmus. Platí ale, že pokud B je polynomiálně složitý, je i A.

Převoditelnost je kvaziuspořádání – je reflexivní a tranzitivní. Není ale symetrický – na to je potřeba vytvořit třídy složitosti, ty potom symetrické jsou a nad nimi je převoditelnost uspořádání.

Definice (3-SAT)

3-SAT (z anglického "satisfiability") je rozhodovací problém, který jako vstup dostane logickou formuli určitého typu a rozhodne, zda je, nebo není plnitelná, tj. jestli existuje nějaké její ohodnocení, které je pravdivé. Logická formule musí být následujícího typu:

$$(a_1 \lor b_1 \lor c_1) \land (a_2 \lor b_2 \lor c_2) \dots \land (a_n \lor b_n \lor c_n),$$

kde a_n, b_n, c_n jsou buď x_i nebo $\not x_i$ pro nějaká $i \subset \mathbb{N}$.

Definice (3-COL)

3-COL, nebo také trojbarevnost grafu, je následující problém: dostanu graf a musím určit, jestli jej lze obarvit třemi barvami.

Definice (Problém nezávislé množiny v grafu)

Problém nezávislé množiny v grafu: Existuje v daném grafu velikosti N nezávislá množina velikosti K?

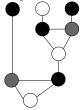
Věta

 $3\text{-SAT} \to 3\text{-COL}$

Důkaz

Pro 3-SAT si uděláme grafík, který bude obarvitelný \Leftrightarrow 3-SAT má řešení.

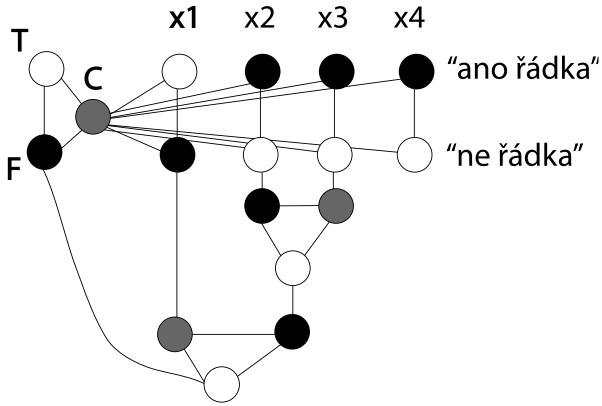
Pravdu si budu v grafu reprezentovat jako bílou, nepravdu jako černou, třetí barva je pomocná. Nejdříve si udělám "konstrukt", co mi pro každou kombinaci tří barev "vrátí" logický or.



Když do výše uvedeného konstruktu jakoby "vložím" do horní řádky barvy, odpovídající tří pravdivostním hodnotám, nemůžu spodní vrchol obarvit jinak, než jako logický or tří barev. Tyto konstrukty mi budou sloužit pro reprezentaci $(a \lor b \lor c)$.

Udělám si teď jeden střední bod (C jako centrum), k němu přidám nejdřív dva body T a F a potom pro každou proměnnou přidám dva body, reprezentující x a x a spojím je dohromady a s C. Než začnu přidávat "konstrukty" na vyhodnocování trojic, podívám se na vlastnosti. Musí platit:

- \bullet $C,\,T$ a Fmusí mít každá jinou barvu
- \bullet pro všechny body musí být buď x nebo \cancel{x} T barva a ta druhá F barva



BÚNO můžu říct, že C je šedivá, T bílá a F černá, černá mi vyjadřuje nepravdu, bílá pravdu. Potom za ně "navěsím" ty konstrukty – buď na x, nebo na x, podle toho, která z nich ve trojici zrovna je – a jejich spodní vrchol připojím F vrchol (to "vynucuje", aby vrchol byl T). Na obrázku je formule ($x_1 \lor x_2 \lor x_3$).

Tento graf je obarvitelný právě tehdy, když je formule splnitelná, a je sestavitelný v polynomiálním čase.

Definice (třída P)

Třídu složitosti P (někdy též PTIME) tvoří problémy řešitelné sekvenčními deterministickými algoritmy v polynomiálním čase, tj. jejich časová složitost je $O(n^k)$. O algoritmech ve třídě P také říkáme, že jsou **efektivně řešitelné.**

Definice (*třída NP*)

Třída NP (NPTIME) je třída problémů řešitelných v polynomiálním čase sekvenčními nedeterministickými algoritmy.

Poznámka

Ví se, že $P \subseteq NP$. Neví se však, zda $P \neq NP$. Předpokládá se to, ale ještě to nikdo nedokázal.

Příklady problémů ze třídy NP

- KLIKA(úplný podgraf) Je dán neorientovaný graf G a číslo k. Existuje v G úplný podgraf velikosti aspoň k?
- **HK**(Hamiltonovská kružnice) Je dán neorientovaný graf G. Existuje v G Hamiltonovská kružnice?
- **SP**(Součet podmnožiny) Jsou dána přirozená čísla a_1, \ldots, a_n, b . Existuje podmnožina čísel a_1, \ldots, a_n , jejíž součet je přesně b?

Definice (NP-těžký problém)

Problém B je **NP-těžký**, pokud pro libovolný problém A ze třídy NP platí, že A je polynomiálně redukovatelný na B.

Definice (NP-úplný problém)

Problém je NP-úplný, pokud patří do třídy NP a je NP-těžký.

Důsledky

- Pokud je A NP-těžký a navíc je A polynomiálně redukovatelný na B, tak je B taky NP-těžký.
- Pokud existuje polynomiální algoritmus pro nějaký NP-těžký problém, pak existují polynomiální algoritmy pro všechny problémy ve třídě NP.

Věta (Cook-Levin 1971)

Existuje NP-úplný problém. (Dokázáno pro SAT)

3.3 Metoda rozděl a panuj – aplikace a analýza složitosti

Je to celé napsané dost rozvláčně, ale podle mě není nutné umět celé (například vzorce ze Strassena může chtít jenom sadista), spíš tomu všemu nějak rozumět. Zdroje: Cepkovy a MJovy přednášky na ADS1.

Definice (Metoda rozděl a panuj)

Rozděl a panuj je metoda návrhu algoritmů (ne strukturované programování), která má 3 kroky:

- 1. rozděl rozdělí úlohu na několik podúloh stejného typu, ale menší velikosti
- 2. vyřeš vyřeší podúlohy buď přímo pro dostatečně malé (často triviální), nebo rekurzivně dělíme dál pokud jsou ještě moc velké
- 3. sjednoť sjednotí řešení podúloh do řešení původní úlohy

Poznámka (Vytvoření rekurentní rovnice)

Pro časovou složitost algoritmů typu rozděl a panuj zpravidla dostávám nějakou rekurentní rovnici.

- T(n) budiž doba zpracování úlohy velikosti n, za předpokladu, že $T(n) = \Theta(1)$ pro $n \leq n_0$.
- D(n) budiž doba na rozdělení úlohy velikosti n na a podúloh stejné velikosti $\frac{n}{c}$.
- S(n) budiž doba na sjednocení řešení podúloh velikosti $\frac{n}{c}$ na jednu úlohu velikosti n.

Dostávám rovnici

$$T(n) = \begin{cases} D(n) + aT(\frac{n}{c}) + S(n) & n > n_0 \\ \Theta(1) & n \le n_0 \end{cases}$$

Metody řešení rekurentních rovnic

Poznámka (k řešení rekurentních rovnic)

- Předpoklad $T(n) = \Theta(1)$ pro dostatečně malá n nepíšeme explicitně do rovnice
- Zanedbáváme celočíselnost (tj. píšeme $\frac{n}{2}$ místo $\lceil \frac{n}{2} \rceil$ a $\lfloor \frac{n}{2} \rfloor$)
- Nehledíme na konkrétní hodnoty aditivních a multiplikativních konstant, asymptotické notace používám i v zadání rekurentních rovnic, i v jejich řešení.

♀ Věta (Substituční metoda) **♀**

- 1. Uhodnu asymptoticky správné řešení
- 2. Přímo nebo indukcí ověřím správnost (zvláště horní a dolní odhad)

♀ Věta (Metoda "kuchařka" (Master Theorem)) **♀**

Nechť $a \ge 1, c > 1, d \ge 0 \in \mathbb{R}$ a nechť $T : \mathbb{N} \to \mathbb{N}$ je neklesající funkce taková, že $\forall n$ tvaru c^k platí

$$T(n) = aT(\frac{n}{c}) + \Theta(n^d)$$

Potom

- 1. Je-li $a \neq c^d$, pak T(n) je $\Theta(n^{\max\{\log_c a, d\}})$
- 2. Je-li $a = c^d$, pak T(n) je $\Theta(n^d \log_c n)$

Věta (Master Theorem, varianta 2)

Nechť $0 < a_i < 1$, kde $i \in \{1, \dots, k\}$ a $d \ge 0$ jsou reálná čísla a nechť $T : \mathbb{N} \to \mathbb{N}$ splňuje rekurenci

$$T(n) = \sum_{i=1}^{k} T(a_i \cdot n) + \Theta(n^d)$$

Nechť je číslo x řešením rovnice $\sum_{i=1}^{k} a_i^x = 1$. Potom

- 1. Je-li $x \neq d$ (tedy $\sum_{i=1}^k a_i^d \neq 1$), pak T(n) je $\Theta(n^{\max\{x,d\}})$ 2. Je-li x=d (tedy $\sum_{i=1}^k a_i^d = 1$), pak T(n) je $\Theta(n^d \log n)$

3.3.1 Násobení dlouhých čísel v lepším než kvadratickém čase.

Klasickým "školním" algoritmem pro násobení na papíře $\Rightarrow O(n^2)$

Libovolné 2N-ciferné číslo mužeme zapsat jako $10^N A + B$, kde A a B jsou N-ciferná. Součin dvou takových čísel pak bude $(10^N A + B) * (10^N C + D) = (10^{2N} AC + 10^N (AD + BC) + BD)$. Sčítat dokážeme v lineárním čase, násobit mocninou deseti také (dopíšeme příslušný počet nul na konec čísla), N-ciferná čísla budeme násobit rekurzivním zavoláním téhož algoritmu. Pro časovou složitost tedy bude platit T(N) = O(N) + 4T(N/2). Nyní tuto rovnici můžeme snadno vyřešit, ale ani to dělat nebudeme, neboť nám vyjde, že $T(N) \approx N^2$, čili jsme si oproti původnímu algoritmu vůbec nepomohli.

Přijde trik. Místo čtyř násobení čísel poloviční délky nám budou stačit jen tři: spočteme AC, BD a (A + B) * (C + D) = AC + AD + BC + BD, přičemž pokud od posledního součinu odečteme AC a BD, dostaneme přesně AD + BC, které jsme předtím počítali dvěma násobeními. Časová složitost nyní bude T(N) = O(N) + 3T(N/2).

Master theorem:
$$T(n) = 3T(n/2) + O(n) \Rightarrow a = 3b = 2d = 1; 3 > 21 \Rightarrow \Theta(n^{\log_2 3}) \approx \Theta(n^{1.58})$$

3.3.2 Násobení matic $n \times n$ a Strassenův algoritmus

Nejdříve si připomeneme definici násobení dvou čtvercových matic typu $n \times n$. Platí, že prvek v i-tém řádku a j-tém sloupci výsledné matice Z se rovná standardnímu skalárnímu součinu i-tého řádku první matice X a j-tého sloupce druhé matice Y. Formálně zapsáno:

$$Z_{ij} = \sum_{k=1}^{n} X_{ik} \cdot Y_{kj}.$$
 i
 X
 Y
 Z

Algoritmus, který by násobil matice podle této definice, by měl časovou složitost $\Theta(n^3)$, protože počet prvků ve výsledné matici je n^2 a jeden skalární součin vektorů dimenze n vyžaduje lineární počet operací.

My se s touto časovou složitostí ovšem nespokojíme a budeme postupovat podobně jako při vylepšování algoritmu na násobení velkých čísel. Bez újmy na obecnosti předpokládejme, že budeme násobit dvě matice typu $n \times n$, kde $n = 2^k, k \in \mathbb{N}$. Obě tyto matice rozdělíme na čtvrtiny a tyto části postupně označíme u matice X písmeny A, B, C a D, u matice Y písmeny P, Q, R a S. Z definice násobení matic zjistíme, že čtvrtiny výsledné matice Z můžeme zapsat pomocí součinů částí násobených matic. Levá horní čtvrtina bude odpovídat výsledku operací AP + BR, pravá horní čtvrtina bude AQ + BS, levá dolní CP + DR a zbylá CQ + DS (viz obrázek).

Násobení rozčtvrcených matic

Převedli jsme tedy problém násobení čtvercových matic řádu n na násobení čtvercových matic řádu n/2. Tímto rozdělováním bychom mohli pokračovat, dokud bychom se nedostali na matice řádu 1, jejichž vynásobení je triviální. Dostali jsme tedy klasický algoritmus typu rozděl a panuj. Pomohli jsme si ale nějak? V každém kroku provádíme 8 násobení matic polovičního řádu a navíc konstantní počet operací na n^2 prvcích. Dostáváme tedy rekurentní zápis časové složitosti:

$$T(n) = 8T\left(\frac{n}{2}\right) + \Theta(n^2).$$

Použitím Master Theoremu lehce dojdeme k závěru, že složitost je stále $\Theta(n^3)$, tedy stejná jako při násobení matic z definice. Zdánlivě jsme si tedy nepomohli, ale stejně jako tomu bylo u násobení velkých čísel, i teď můžeme zredukovat počet násobení matic polovičního řádu, které nejvíce ovlivňuje časovou složitost algoritmu. Není to bohužel nic triviálního, a proto si raději rovnou řekneme správné řešení. Jedná se o Strassenův algoritmus, který redukuje potřebný počet násobení na 7, a ještě před tím, než si ukážeme, jak funguje, dokážeme si, jak nám to s časovou složitostí vlastně pomůže:

$$T(n) = 7T\left(\frac{n}{2}\right) + \Theta(n^2) \Longrightarrow \Theta(n^{\log_2 7}) = \Theta(n^{2.808}).$$

Výsledná složitost Strassenova algoritmu je tedy $\Theta(n^{2.808})$, což je sice malé, ale pro velké matice znatelné zlepšení oproti algoritmu vycházejícímu přímo z definice ^{7 8}.

Lemma (vzorce pro násobení blokových matic ve Strassenově algoritmu)

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix} \cdot \begin{pmatrix} P & Q \\ R & S \end{pmatrix} = \begin{pmatrix} T_1 + T_4 - T_5 + T_7 & T_3 + T_5 \\ T_2 + T_4 & T_1 - T_2 + T_3 + T_6 \end{pmatrix}$$

kde:

$$T_1 = (A+D) \cdot (P+S)$$
 $T_5 = (A+B) \cdot S$
 $T_2 = (C+D) \cdot P$ $T_6 = (C-A) \cdot (P+Q)$
 $T_3 = A \cdot (Q-S)$ $T_7 = (B-D) \cdot (R+S)$
 $T_4 = D \cdot (R-P)$

3.3.3 Hledání k-tého nejmenšího prvku (mediánu) v lin. čase (Blum et al.)

Algoritmus (Blum et al.)

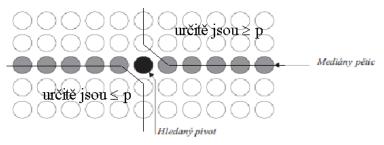
Select(X,k)

- 1. Pokud $n \leq 5 \Rightarrow$ vyřešíme přímo
- 2. Vstup rozdělíme na pětice $P_1...P_{\lceil n/5 \rceil}$ (poslední může být neúplná), to zvládneme v O(n)
- 3. $\forall i \in \{1...\lceil n/5\rceil\}$: $m_i := median(Pi)$, to zvládneme v O(n)
- 4. $pivot := Select(m_1, ..., m_{\lceil n/5 \rceil}, \lceil n/10 \rceil)$ (medián mediánů)
- 5. Rozdělime X na L(=menší než pivot), S(=stejné jako pivot), P(=větší než pivot)
- 6. Rekurzivně se zavoláme na jednu z L, S, P (tu, ve ktere se ma vyskytovat hledany prvek tj. podle jejich velikosti a k⁹)

Časová složitost:

V každém kroku vypadne alespoň $\frac{3n}{10}$ prvků.

Důkaz. Představme si vybrané pětice seřazené podle velikosti od největšího prvku a zakresleme je do sloupců. Jejich mediány tedy vyplňují prostřední řadu. Tyto pětice pak seřaď me podle velikosti jejich mediánů (nejmenší vlevo)¹⁰. Hledaný pivot se tedy nachází (pokud předpokládáme pro jednoduchost lichý počet pětic) přesně uprostřed. O prvcích nad pivotem a napravo od něj můžeme určitě říct, že jsou větší nebo rovny pivotu, prvky pod ním a nalevo od něj jsou zase určitě menší nebo rovny pivotu. Podle algoritmu vždy vypadne jedna nebo druhá skupina prvků o velikosti alespoň $\frac{3n}{10}$ prvků (z obrázku).



Pětice

V každém kroku funkce volá sama sebe na vstup velikosti nejvýše n/5 a pak na 7n/10 ostatní operace jsou lineární, nejhorší případ: $T(n) = O(n) + T(\frac{n}{5}) + T(\frac{7n}{10})$, odhadneme že odpovídá lin.složitosti O(n).

 $D\mathring{u}kaz$. Přímo že $T(n) = \Theta(n) \Leftrightarrow \exists k > 0 : \exists n_0 \in \mathbb{N} \ \forall n \geq n_0 : T(n) = kn$ pro nějakou dostatečně velkou konstantu k.

$$T(n) = \Theta(n) + T(\frac{n}{5}) + T(\frac{7n}{10}) \Leftrightarrow kn = n + k\frac{n}{5} + k\frac{7n}{10} = n + k\frac{9n}{10} \Leftrightarrow 10 = k \text{ (dosadili jsme T(n) = kn)}$$

⁷Zatím nejlepší dokázaný algoritmus má časovou složitost $\Theta(n^{2.376})$, ovšem s velkou multiplikativní konstantou.

 $^{^8\}mathrm{Strassen}$ se da pouzit i pro vypocet determinantu.

 $^{^9 \}mathrm{bud}$ je $k \leq |L|,$ nebo $|L| < k \leq |L| + |S|,$ nebo|L| + |S| < k

¹⁰ bacha algoritmus nic takoveho nedělá, jen nám to pomůže v úvaze o správnosti

3.3.4 MergeSort

Tento třídící algoritmus pracuje na principu, že vstup rozdělíme na dvě (skoro) stejně velké části, které rekurzivním voláním setřídíme, a nakonec výsledné dvě posloupnosti slijeme do jedné.

Algoritmus (MergeSort)

- 1. Vstup: posloupnost x_1, \ldots, x_n .
- 2. Pokud $n \le 1 \Rightarrow$ vrátíme vstup.
- 3. $y_1, \ldots, y_{\lfloor n/2 \rfloor} \leftarrow MergeSort(x_1, \ldots, x_{\lfloor n/2 \rfloor}).$
- 4. $z_1, \ldots, z_{\lceil n/2 \rceil} \leftarrow MergeSort (x_{\lfloor n/2 \rfloor+1}, \ldots, x_n).$
- 5. Vrátíme $MergeSort\ (y_1,\ldots,y_{\lfloor n/2\rfloor};z_1,\ldots,z_{\lceil n/2\rceil}).$

Na slití dvou setříděných posloupností do jedné používáme funkci Merge:

Merge $(y_1,\ldots,y_a;z_1,\ldots,z_b)$

- 1. $i \leftarrow 1, j \leftarrow 1, k \leftarrow 1$.
- 2. Dokud $k \leq a + b$:
- 3. Je-li (j > b) nebo $(i \le a) \& (y_i < z_j) \Rightarrow x_k \leftarrow y_i, k + +, i + +$.
- 4. Jinak $\Rightarrow x_k \leftarrow z_i, k++, j++$.
- 5. Vrátíme x_1, \ldots, x_n .

Pozorování:

Merge trvá $\Theta(n)$, neboť každou ze slévaných posloupností projdeme právě jednou.

Časová složitost:

Rozdělování a slévání nám trvá lineárně dlouho, takže pro časovou složitost MergeSortu platí tato rekurentní rovnice, kterou vyresime pomocí MT:

$$T(n) = 2 \cdot T(n/2) + \Theta(n) \Longrightarrow \Theta(n^1 \log n) = \Theta(n \log n).$$

Paměťová složitost¹¹:

$$M(n) = d \cdot n + M(n/2) = d \cdot n + d \cdot n/2 + d \cdot n/4 + \dots < 2dn = \Theta(n).$$

Tento vztah platí pro nějakou vhodnou konstantu d. Můžeme ho opět nahlédnout například ze stromu rekurzivních volání. Podívejme se na libovolnou cestu od kořene do listu. V jednotlivých vrcholech potřebujeme paměti přesně $d \cdot n/2^k$, kde k je číslo hladiny. Když tyto hodnoty sečteme přes všechny vrcholy na této cestě, výsledek bude konvergovat k 2dn, což dává paměťovou složitost $\Theta(n)$.

Závěr:

Mergesort běží V čase $\Theta(n \log n)$ a paměti $\Theta(n)$. Lineární paměťová složitost není výhodná, ale na druhou stranu se tento algoritmus velmi hodí například na třídění lineárních spojových seznamů.

 $^{^{11}\}mathrm{pro}$ zajímavost, neni to asi nutne umet odvodit

3.4 Binární vyhledávací stromy, vyvažování, haldy

Binární strom

Definice

Dynamická množina je množina prvků (datová struktura), měnící se v čase. Každý její prvek je přístupný přes ukazatel a obsahuje:

- klíč (jednu položku, typicky hodnotu z lin. uspořádané množiny),
- ukazatel(e) na další prvky,
- případně další data.

Na takové množině jsou definovány tyto operace:

- find nalezení prvku podle klíče
- insert přidání dalšího prvku
- delete odstranění prvku
- min, max nalezení největšího / nejmenšího prvku
- succ, pred nalezení následujícího / předcházejícího prvku k nějakému předem danému

Definice

Binární strom je dynamická množina, kde každý prvek (uzel, node) má kromě klíče a příp. dalších dat tři ukazatele na levého a pravého syna a rodiče. Speciální uzel je kořen, který má NULLový ukazatel na rodiče. Ten je v binárním stromě jeden. Uzly, které mají NULLové ukazatele na pravého i levého syna, se nazývají listy.

Podstrom je část stromu (vybrané prvky), která je sama stromem - např. pokud se jako kořen určí jeden z prvků. Levý(pravý) podstrom nějakého prvku je strom, ve kterém je kořenem levý(pravý) syn tohoto prvku. Výška stromu je délka nejdelší cesty od kořenu k listu.

Binární strom je *vyvážený*, pokud max. 1 uzel má jednoho syna (tj. všechny vnitřní uzly kromě až na jeden mají oba syny, listy z definice nemají žádného). Výška vyváženého stromu roste logaritmicky vzhledem k počtu uzlů. Výška nevyváženého stromu může růst až lineárně vzhledem k počtu prvků (i "spojový seznam" je platný bin. strom).

Binární vyhledávací strom

Definice

Binární vyhledávací strom je takový binární strom, ve kterém je jeho struktura určená podle klíču jeho uzlů: pro každý uzel s klíčem hodnoty k platí, že jeho levý podstrom obsahuje jen uzly s menší hodnotou klíče než k a jeho pravý podstrom jen uzly s hodnotou klíče větší nebo rovnou k.

Algoritmus (Vyhledávání v bin. stromě)

```
Find( x - kořen, k - hledaná hodnota klíče ){
    while( x != NULL && k != x->klíč ){
        if ( k < x->klíč )
            x = x->levý_syn;
        else
            x = x->pravý_syn;
    }
    return x;
}
```

Složitost je O(h) v nejhorším případě, kde h je výška stromu (tj. pro nevyvážené stromy až O(n) kde n je počet prvků). Asymptotická časová složitost ostatních operací je stejná.

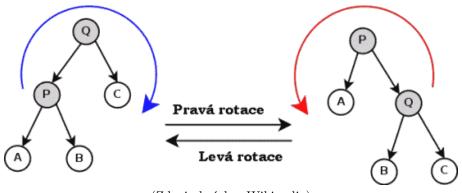
Vložení a vymazání prvku se provádí prostým nalezením místa, kam by se prvek měl vložit (nebo kde už je), a přepojením pointerů.

Vyvažované vyhledávací stromy

Kvůli zajištění větší rychlosti (menší asymptotické časové složitosti) operací byly vytvořeny speciální druhy binárních vyhledávacích stromů, které jsou průběžně vyvažovány, aby měly max. výšku menší než $c \cdot \log n$, kde n je počet uzlů a c nějaká konstanta.

Definice (Pomocné operace na stromech)

Pro vyvažování stromů při vkládání a odebírání uzlů se definují pomocné operace: pravá a levá rotace. Zachovávají vlastnosti bin. vyhledávacích stromů a jsou proveditelné v konstatním čase - jde jen o přepojení uzlů násl. způsobem (pro pravou rotaci na uzlu Q a levou na P):



(Zdroj obrázku: Wikipedia)

Definice (Červeno-černé stromy)

Červeno-černé stromy jsou binární vyhledávací stromy s garantovanou max. výškou $O(\log n)$, kde n je počet uzlů, tj. operace na nich mohou mít asymptotickou časovou složitost $O(\log n)$. Pro jejich popis je nutné definovat interni uzly - všechny uzly stromu a externi uzly - na (interních) listech (a uzlech s jedním potomkem) uměle přidané NULLové ukazatele (de facto "listy" červeno-černého stromu). Externí uzly slouží jenom jako abstrakce pro popis stromů, při implementaci se s nimi neoperuje. Červeno-černý strom má tyto čtyři povinné vlastnosti:

- 1. Každý uzel (externí i interní) má definovanou barvu, a to černou nebo červenou.
- 2. Každý externí uzel je černý.
- 3. Každý červený vrchol musí mít oba syny černé.
- 4. Každá cesta od libovolného vrcholu k listům v jeho podstromě musí obsahovat stejný počet černých uzlů.

Pro červeno-černé stromy se definuje výška uzlu x ($\mathbf{h}(x)$) jako počet uzlů na nedelší možné cestě k listu v jeho podstromě. Černá výška uzlu ($\mathbf{bh}(x)$) je počet černých uzlů na takové cestě.

Věta (Vlastnosti červeno-černých stromů)

Podstrom libovolného uzlu x obsahuje alespoň $2^{\mathbf{bh}(x)} - 1$ interních uzlů. Díky tomu má červeno-černý strom výšku vždy nejvýše $2\log(n+1)$ (kde n je počet uzlů). (Důkaz prvního tvrzení indukcí podle $\mathbf{h}(x)$, druhého z prvního a třetí vlastnosti červeno-černých stromů)

Důsledek

Operace hledání (minima, maxima, následníka, ...), které jsou stejné jako u obecných binárních vyhledávacích stromů, mají garantovanou časovou složitost $O(\log n)$.

Algoritmus (Vkládání a odebírání uzlů v červeno černých stromech)

Obě operace mají podle garantované max. výšky garantovanou čas. složitost $O(\log n)$ pro n počet uzlů. Protože bez porušení vlastností červeno-černých stromů lze kořen vždy přebarvit načerno, můžeme pro ně předpokládat, že kořen stromu je vždy černý.

Vkládání vypadá následovně:

- Nalezení místa pro vložení a přidání nového prvku jako v obecných bin. vyhl. stromech, nový prvek se přebarví načerveno.
- Pokud je jeho otec černý, můžeme skončit vlastnosti stromů jsou splněné. Pokud je červený, musíme strom upravovat (tady předpokládám, že otec přidávaného uzlu je levým synem, opačný připad je symetrický):
- Je-li i strýc červený, přebarvit otce a strýce načerno a přenést chybu o patro výš (je-li děd černý, končím, jinak můžu pokračovat až do kořene, který už lze přebarvovat beztrestně).
- Je-li strýc černý a přidaný uzel je levým synem, udělat pravou rotaci na dědovi a přebarvit uzly tak, aby odpovídaly vlastnostem stromů.
- Je-li strýc černý a přidaný uzel je pravým synem, udělat levou rotaci na otci a převést tak na předchozí případ.

Odebírání se provádí takto:

- Odstraním uzel stejně jako v předchozím případě. Opravdu odstraněný uzel (z přepojování) má max. jednoho syna.
 Pokud odstraňovaný uzel byl červený, neporuším vlastnosti stromů, stejně tak pokud jeho syn byl červený to řeším jeho přebarvením načerno.
- V opačném případě (tj. syn odebíraného -x je černý) musím udělat násl. úpravy (přep. že x je levým synem svého nového otce, v op. případě postupuji symetricky):
- x prohlásím za "dvojitě černý" a této vlastnosti se pokouším zbavit.
- Pokud je bratr x (buď w) červený, pak má 2 černé syny provedu levou rotaci na rodiči x, prohodím barvy rodiče x a uzlu w a převedu tak situaci na jeden z násl. případů:
- Je-li w černý a má-li 2 černé syny, prohlásím x za černý a přebarvím w načerveno, rodiče přebarvím buď na černo (a končím) nebo na "dvojitě černou" a propaguji chybu (mohu dojít až do kořene, který lze přebarovat beztrestně).
- ullet Je-li w černý, jeho levý syn červený a pravý černý, vyměním barvy w s jeho levým synem a na w použiji pravou rotaci, čímž dostanu poslední případ:

• Je-li w černý a jeho pravý syn červený, přebarvím pravého syna načerno, odstraním dvojitě černou z x, provedu levou rotaci na w a pokud měl původně w (a x) červeného otce, přebarvím w načerveno a tohoto (teď už levého syna w) přebarvím načerno.

Definice (AVL stromy (Adelson-Velsky & Landis))

AVL stromy jsou, podobně jako červeno-černé stromy, bin. vyhledávací stromy, které zaručují max. logaritmický nárůst výšky vzhledem k počtu prvků. Pro každý uzel x se v AVL stromu definuje $faktor\ vyvážení$ jako rozdíl výšky jeho levého a pravého podstromu: $\mathbf{bf}(x) = h(\mathbf{x} - \mathbf{evý}) - h(\mathbf{x} - \mathbf{pravý})$. Pro všechny uzly v AVL stromu platí, že $|\mathbf{bf}(x)| \le 1$.

Věta (Zaručení výšky AVL stromů)

Výška AVL stromu s n vrcholy je $O(\log n)$. (Důkaz: buď T_n AVL strom výšky n s minimálním počtem uzlů. Ten má podstromy T_{n-1} a T_{n-2} atd., tj. velikost minimálního AVL stromu roste jako Fibonacciho posloupnost, tedy $|T_n| \ge (\frac{1+\sqrt{5}}{2})^{n-1}$. Důkaz tohoto indukcí.)

Algoritmus (Operace na AVL stromech)

Vyhledávací operace se provádí stejně jako na obecných bin. vyhledávacích stromech, vkládání a odebírání prvků taky, ale pokud tyto operace poruší zákl. vlastnost AVL stromů ($|\mathbf{bf}(x) = 2|$), je nutné provést vyvažování – pomocí rotací (které mohou být propagovány až ke kořeni). Při vkládání a odebírání je navíc nutné průběžně (nejhůře až ke kořeni) upravovat indikaci faktoru vyvážení jednotlivých uzlů.

Halda

Definice

Halda(heap) je dynamická množina se stromovou strukturou (binární halda je binární strom), pro kterou platí tzv. "vlastnost haldy":

Je-li x potomek y, pak x->klíč $\geq y$ ->klíč

Haldy s touto nerovností jsou tzv. min-heapy, pokud je nerovnost opačná, jde o max-heap.

(Binární) haldy

Binární haldy jsou nejčastějším typem haldy. Zajišťují nalezení minimálního prvku v konstantním čase a odebrání a přidání minima v čase $O(\log n)$. V každé hladině od první až do předposlední je max. možný počet uzlů, v poslední jsou uzly co nejvíce "vlevo" – tedy max. výška haldy s n prvky je $(\log n) + 1$. Proto je pro binární haldy jednoduše proveditelná jejich datová reprezentace polem (bez pointerů), kde při indexování od 0 má uzel na indexu k:

- Levého a pravého syna na indexu 2k + 1, resp. 2k + 2 (pokud to není víc než celk. počet prvků, potom syny nemá).
- Rodiče na indexu $\lceil \frac{k}{2} \rceil 1$.

Přidání uzlu do haldy znamená přidání prvku na konec haldy a dokud má jeho rodič větší klíč, jeho prohazování s rodičem (tedy posouvání o vrstvu výš). Při *odebírání uzlu* z haldy tento nahradím posledním prvkem v haldě a potom dokud neplatí vlastnost haldy (nejméně jeden z potomků má menší klíč), prohazuji ho s potomkem s menším klíčem (a posouvám o vrstvu níž).

Vytvoření haldy je možné v čase O(n), kde n je počet prvků v haldě – přidání 1 prvku do haldy trvá O(h), kde h je aktuální výška (a h roste od 0 až k $\lceil \log n \rceil$, počet prvků ve výšce k je $\frac{n}{2^{k+1}}$, bereme-li výšku listů rovnou nule) - v součtu za všechny prvky jde o $O(n \cdot \sum_{h=0}^{\lceil \log n \rceil} \frac{h}{2^h})$.

Binární halda se používá např. \bar{k} *třídění haldou* (heapsortu), kdy se z dat, která je potřeba utřídit, nejdříve postaví halda, a potom se opakuje operace odebrání kořene (tj. minimálního prvku).

Fibonacciho haldy

Fibonacciho haldy mají nízkou časovou složitost běžných operací – amortizovaně O(1) pro vložení, hledání minima apod.; odebrání prvku a odebrání minima má složitost $O(\log n)$ pro n prvků v haldě. Tvoří ji skupina stromů, vyhovujících "vlastnosti haldy". Každý uzel haldy s n prvky má max. $\log n$ potomků a ve svém podstromě minimálně F_{k+2} uzlů, kde F_k je k-té Fibonacciho číslo. To je zajištěno pravidlem, že při odebírání prvků lze z nekořenového uzlu oddělit max. 1 syna, jinak je nutné oddělit i tento uzel a ten se pak stane kořenem dalšího stromu. Počet stromů se snižuje při odebírání minima, kdy jsou spojovány dohromady.

Fibonacciho haldy se používají pro efektivní implementaci složitějších operací, jako např. Jarníkova nebo Dijkstrova algoritmu.

3.5 Hašování

Definice (slovníkový problém)

Dáno univerzum U, máme reprezentovat $S \subseteq U$ a navrhnout algoritmy pro operace

- MEMBER(x) zjistí zda $x \in S$ a pokud ano nalezne kde,
- INSERT(x) pokud $x \notin S$, vloží x do struktury reprezentující S,
- DELETE(x) když $x \in S$, smaže x ze struktury reprezentující S.

Například pomocí pole můžeme tyto operace implementovat rychle, ale nevýhodou je prostorová náročnost. Pro velké množiny je to někdy dokonce nemožné. *Hašování* se snaží zachovat rychlost operací a odstranit prostorovou náročnost.

Podívejme se nyní na základní ideu hašování. Mějme univerzum U a množinu $S \subseteq U$ takovou, že |S| << |U|. Dále mějme funkci $h: U \to \{0, 1, \dots, m-1\}$. Množinu S potom reprezentujeme tabulkou (polem) o velikosti m tak, že prvek $x \in S$ je uložen na řádku h(x).

Definice (Hašovací funkce, kolize)

Funkci $h: U \to \{0, 1, \dots, m-1\}$ potom nazýváme **hašovací funkcí**. Situaci h(s) = h(t), pro $s \neq t$; $s, t \in S$ nazveme **kolize**.

Jelikož mohutnost univerza U je větší než velikost hašovací tabulky, nelze se kolizím úplně vyhnout. Existuje spousta různých metod, jak kolize řešit. Podívejme se tedy na některé podrobněji.

Definice

Ještě si zavedeme některé značení. Velikost S (hašované množiny) označme \mathbf{n} , velikost tabulky (pole) označme \mathbf{m} , a faktor naplnění $\alpha = \frac{n}{m}$.

Hašování se separovanými řetězci

Použijeme pole velikosti m, jehož i-tá položka bude spojový seznam S_i takový, že $s \in S_i \Leftrightarrow h(s) = i$, pro $s \in S$. Čili každý řádek pole obsahuje spojový seznam všech (kolidujících) prvků, které jsou hašovány na tento řádek. Seznamy nemusí být uspořádané, vznikají tak, jak jsou vkládány jednotlivé prvky do struktury.

Algoritmus (Hašování se separovanými řetězci)

- MEMBER Spočteme hodnotu hašovací funkce h(x), prohledáme řetězec začínající na pozici h(x) a zjistíme zda se prvek nachází, či nenachází ve struktuře. Pokud se prvek v databázi nachází, tak musí nutně ležet v tomto řetězci.
- INSERT Zjistíme zda x je v řetězci h(x), pokud ne, přidáme ho nakonec, v opačném případě neděláme nic.
- **DELETE** Vyhledá x v řetězci h(x) a smaže ho. Pokud se tam x nenachází, neudělá nic.

Očekávaný počet testů v neúspěšném případě je přibližně $e^{-\alpha} + \alpha$ a při úspěšném vyhledávání přibližně $1 + \frac{\alpha}{2}$.

Hašování s uspořádanými řetězci

Jak již je zřejmé z názvu je tato metoda téměř stejná jako předchozí. Jediný rozdíl je, že jednotlivé seznamy jsou uspořádány vzestupně dle velikosti prvků.

Algoritmus (Hašování s uspořádanými řetězci)

Rozdíly jsou pouze pro operaci **MEMBER**, kde skončíme prohledávání, když dojdeme na konec, nebo když nalezneme prvek, který je větší než hledaný a operaci **INSERT**, které vkládá prvek na místo kde jsme ukončili vyhledávání (před prvek, který ho ukončil).

Očekávaný počet testů v neúspěšném případě je přibližně roven $e^{-\alpha} + 1 + \frac{\alpha}{2} - \frac{1}{\alpha}(1 - e^{-\alpha})$ a v úspěšném případě je přibližně $1 + \frac{\alpha}{2}$.

Nevýhodou předchozích dvou metod je nerovnoměrné využití paměti. Zatímco některé seznamy mohou být dlouhé, v některých není prvek žádný. Řešením je najít způsob, jak kolidující prvky ukládat na jiné (prázdné) řádky tabulky. Potom je ale nutné každý prvek tabulky rozšířit a položky pro práci s tabulkou.

Čím použijeme sofistikovanější metodu ukládání dat do tabulky, tím více budeme potřebovat položek pro práci s tabulkou a tedy vzroste paměťová náročnost. Naším cílem je tedy najít rozumný kompromis mezi sofistikovaností (rychlostí) strategie a její paměťovou náročností. Podívejme se na další algoritmy, které se o to pokoušejí.

Hašování s přemísťováním

Seznamy jsou tentokrát ukládány do tabulky a implementovány jako dvousměrné. Potřebujeme tedy dvě položky pro práci s tabulkou: next – číslo řádku obsahující další prvek seznamu a previous – číslo řádku obsahující předchozí prvek seznamu. Když dojde ke kolizi, tj. chceme vložit prvek a jeho místo je obsazené prvkem z jiného řetězce, pak tento prvek z jiného řetězce přemístíme na jiný prázdný řádek v tabulce (proto hašování s přemísťováním).

Algoritmus (Hašování s přemísťováním)

Algoritmus **MEMBER** funguje stejně jako u hašování se separovanými řetězci, jen místo ukazatele na další prvek použije hodnotu next z tabulky. Při operaci **INSERT** vložíme prvek kam patří pokud je tam místo, pokud již je místo obsazeno prvkem který tam patří, čili zde začíná seznam kolidujících prvků (previous = prázdné), pak postupujeme po položkách next až na konec seznamu, vložíme prvek na některý volný řádek tabulky a vyplníme správně hodnoty next a previous. Pokud je místo obsazeno prvkem z jiného seznamu ($previous \neq prázdné$), tak tento prvek přemístíme na některý volný řádek, správně přepíšeme položky next a previous v měněném seznamu a vkládaný prvek uložíme na jeho místo. Operace **DELETE** je vcelku přímočará, jenom je třeba, pokud mažeme první prvek seznamu na jeho místo přesunout ten druhý v pořadí (pokud existuje).

Očekávaný počet testů je v neúspěšném případě roven přibližně $(1 - \frac{1}{m})^n + \frac{n}{m} \approx e^{-\alpha} + \alpha$ a v úspěšném je stejný jako pro hašování se separovanými řetězci a tedy $\frac{n-1}{2m} + 1 \approx 1 + \frac{1}{\alpha}$.

Hašování se dvěma ukazateli

Hašování s přemísťováním má tu nevýhodu, že díky přemisťování prvků jsou operace INSERT a DELETE časově náročné. Tato metoda tedy implementuje řetězce jako jednosměrné seznamy, ale takové které nemusejí začínat na svém místě, tj. řetězec S_j obsahující prvky $s \in S$ takové, že h(s) = j, nemusí začínat na j-tém řádku. Místo ukazatele na předchozí prvek tak do položek pro práci s tabulkou přidáme ukazatel na místo, kde začíná řetězec příslušný danému řádku. Položky pro práci s tabulkou tedy budou: next – číslo řádku tabulky kde je další prvek seznamu, begin – číslo řádku tabulky obsahující první prvek seznamu příslušného tomuto místu.

Algoritmus (Hašování se dvěma ukazateli)

Položka begin v j-tém řádku je vyplněna právě tehdy, když reprezentovaná množina S obsahuje prvek $s \in S$ takový, že h(s) = j. Algoritmy jsou potom podobné těm u hašování s přemísťováním, ale přemísťování prvků je nahrazeno odpovídajícími změnami v položce begin daných řádků.

Díky práci s položkami jsou operace INSERT a DELETE rychlejší než při hašování s přemísťováním, ale začátek řetězce v jiném řádku tabulky přidá navíc jeden test, což změní složitost operace MEMBER.

Očekávaný počet testů v neúspěšném případě je přibližně $1 + \frac{\alpha^2}{2} + \alpha + e^{-\alpha}(2 + \alpha) - 2$ a při úspěšném vyhledávání je roven $1 + \frac{(n-1)(n-2)}{6m^2} + \frac{n-1}{2m} \approx 1 + \frac{\alpha^2}{6} + \frac{\alpha}{2}$

Srůstající hašování

Nyní se podíváme na několik verzí metody, která se nazývá srůstající hašování. Budeme potřebovat jedinou položku pro práci s tabulkou a to ukazatel jednosměrného spojového seznamu. Na rozdíl od předchozích metod zde nejsou řetězce separované, v jednom řetězci mohou být prvky s různou hodnotou hašovací funkce. Když máme přidat prvek s, tak ho zařadíme do řetězce, který se nachází na h(s)-tém řádku tabulky. Řetězce tedy v této metodě srůstají. Různé verze této metody se liší tím, kam přidáváme nový prvek a podle práce s pamětí. Dělí se na standardní srůstající hašování bez pomocné paměti a na hašování používající pomocnou paměť, kterému se říká jen srůstající hašování.

Nejdříve se budeme věnovat metodám standardního srůstajícího hašování (bez pomocné paměti):

- LISCH late-insertion standard coalesced hashing vkládá se za poslední prvek řetězce,
- EISCH early-insertion standard coalesced hashing vkládá se za první prvek řetězce.

Přirozená efektivní operace DELETE pro standardní srůstající hašování není známa. Na druhou stranu i primitivní algoritmy mají rozumnou očekávanou časovou složitost.

Další otázka zní, proč používat metodu EISCH, když programy pro metodu LISCH jsou jednodušší. Odpověď je na první pohled dost překvapující. Při úspěšném vyhledávání je metoda EISCH rychlejší než metoda LISCH. Je to proto, že je o něco pravděpodobnější, že se bude pracovat s novým prvkem. V neúspěšném případě jsou samozřejmě obě metody stejné, neboť řetězce jsou u obou stejně dlouhé.

Metody srůstajícího hašování (s pomocnou pamětí) mají použitou paměť rozdělenou na dvě části. Na tu přímo adresovatelnou hašovací funkcí a na pomocnou část. Adresovací část má m řádků, pokud hašovací funkce má hodnoty z oboru $\{0,1,\ldots,m-1\}$, v pomocné části jsou řádky ke kterým nemáme přístup přes hašovací funkci. Když při přidávání nového prvku vznikne kolize, tak se nejprve vybere volný řádek z pomocné části a teprve když je pomocné část zaplněna použijí se k ukládání kolidujících prvků řádky z adresovatelné části tabulky. Tato strategie oddaluje srůstání řetězců. Srůstající hašování se tedy, aspoň dokud není zaplněna pomocná část tabulky, podobá hašování se separovanými řetězci. Existují základní tři varianty:

- LICH late-insertion coalesced hashing vkládá prvek na konec řetězce,
- VICH early-insertion coalesced hashing vkládá prvek na řádek h(x) pokud je prázdný a nebo hned za prvek na řádku h(x).
- EICH varied-insertion coalesced hashing vkládá se za poslední prvek řetězce, který je ještě v pomocné části. Pokud v pomocné části žádný není, vkládá se hned za prvek na pozici h(x).

Tyto metody nepodporují přirozené efektivní algoritmy pro operaci DELETE.

Hašování s lineárním přidáváním

Následující metoda nepoužívá žádné položky pro práci s tabulkou to znamená, že způsob nalezení dalšího řádku řetězce je zabudován přímo do metody. Metoda funguje tak, že pokud chceme vložit prvek do tabulky a nastane kolize, najdeme první následující volný řádek a tam prvek vložíme. Předpokládáme, že řádky jsou číslovány modulo m, čili vytvářejí cyklus délky m.

Tato metoda sice využívá minimální velikost paměti, ale v tabulce vznikají shluky obsazených řádků a proto je při velkém zaplnění pomalá. Navíc metoda nepodporuje efektivní operaci DELETE.

Shrnutí

Zde uvedeme pořadí metod hašování podle očekávaného počtu testů.

Neúspěšné vyhledávání:

- 1. Hašování s uspořádanými separovanými řetězci,
- 2. Hašování se separovanými řetězci = Hašování s přemísťováním,
- 3. Hašování se dvěma ukazateli.
- 4. VICH = LICH
- 5. EICH.
- 6. LISCH = EISCH,
- 7. Hašování s lineárním přidáváním.

Úspěšné vyhledávání

- 1. H. s uspořádanými řetězci = H. se separovanými řetězci = H. s přemísťováním,
- 2. Hašování se dvěma ukazateli,
- 3. VICH,
- 4. LICH,
- 5. EICH,
- 6. EISCH,
- 7. LISCH,
- 8. Hašování s lineárním přidáváním.

Poznámka

Metody se separovanými řetězci a srůstající hašování používají více paměti. Metoda s přemísťováním vyžaduje více času – na přemístění prvku. Otázka která z metod je nejlepší není proto jednoznačně rozhodnutelná a je nutné pečlivě zvážit všechny okolnosti nasazení metody a všechny naše požadavky na ní, než se rozhodneme, kterou použijeme.

Univerzální hašování

Pro dobré fungování hašování potřebujeme mimo jiné, aby vstupní data byla rovnoměrně rozdělena a toho někdy není možné dosáhnout. Odstranit tento nedostatek se pokouší metoda $univerzální \ hašování$. Základní idea této metody je taková, že máme množinu H hašovacích funkcí z univerza do tabulky velikosti m takových, že pro $S \subseteq U, \ |S| \le m$ se většina funkcí chová dobře v tom smyslu, že má malý počet kolizí. Hašovací funkci potom zvolíme z množiny H (takovou s rovnoměrným rozdělením). Jelikož funkci volíme my, můžeme požadavek rovnoměrného rozdělení zajistit.

Perfektní hašování

Jiná možnost jak vyřešit kolize, je najít takzvanou perfektní hašovací funkci, tj. takovou které nepřipouští kolize. Nevýhoda této metody je, že nelze dost dobře implementovat operaci INSERT, proto se dá prakticky použít pouze tam, kde předpokládáme hodně operací MEMBER a jen velmi málo operací INSERT. Kolize se potom dají řešit třeba malou pomocnou tabulkou, kam se ukládají kolidující data.

Pro rozumné fungování metody je nutné, aby hašovací funkce byla rychle spočitatelná a aby její zadání nevyžadovat mnoho paměti, nejvýhodnější je analytické zadání.

Naopak jedna z výhod je, že nalezení perfektní hašovací funkce, může trvat dlouho, neboť ho provádíme pouze jednou na začátku algoritmu.

Externí hašování

Externí hašování řeší trochu jiný problém, než výše popsané metody. Chceme uložit data na externí médium a protože přístup k externím médiím je o několik řádů pomalejší, než práce v interní paměti, bude naším cílem minimalizovat počet přístupů do ní. Externí paměti bývá rozdělena na stránky a ty většinou načítáme do interní paměti celé. Tato operace je však velice pomalá. Problémem externího hašování je tedy nalézt datovou strukturu pro uložení dat na vnější paměti a algoritmy pro operace INSERT, DELETE a MEMBER, tak abychom použili co nejmenší počet komunikací mezi vnější a vnitřní pamětí.

Metod externího hašování je opět mnoho. Některé používají pomocnou datovou strukturu v interní paměti, kterou často nazýváme adresář. Pokud metody nemají žádnou takovou pomocnou strukturu neobejdou se obvykle bez oblasti přetečení.

3.6 Sekvenční třídění, porovnávací algoritmy, přihrádkové třídění, třídící sítě

TODO: trochu víc formalismu by tu neškodilo, taky je potřeba sjednotit óčkovou notaci (zřejmě prosté nahrazení symbolu O symbolem Θ by stačilo, ale chce to ověřit).

Sekvenční třídění a porovnávací algoritmy

Pojmy "sekvenční třídění" a "porovnávací algoritmy" mohou znamenat vlastně cokoliv, takže uvedu pár nejběžnějších třídících algoritmů a budu doufat, že to bude ke zkoušce stačit :-(. Zdrojem mi budiž Wikipedie a kniha Algoritmy a programovací techniky Doc. P. Töpfera.

Algoritmus (Selection sort, třídění výběrem)

Selection sort je jeden z nejjednodušších třídích algoritmů. Jde o vnitřní třídění – tedy celá posloupnost prvků by měla být v paměti. Má časovou složitost $\Theta(n^2)$ a obecně bývá pomalejší než insertion sort. Pracuje následovně:

Udržuje si množinu setříděných prvků na začátku posloupnosti (pole), která je na začátku prázdná a na konci představuje celé pole. Zbytek pole za setříděnou množinou je neuspořádaný. V jednom kroku vždy vybere jeden prvek a vloží ho do utříděné části (kterou tím zvětší o 1 a zároveň zmenší nesetříděnou). Jeden krok algoritmu (kterých je n pro n prvků v každém případě) vypadá takto:

- 1. Najdi nejmenší prvek z nesetříděného úseku.
- 2. Vlož ho přesně za konec setříděného úseku (a prvek co tam byl původně si s ním vymění místo)

Heapsort, který popíšu později, může být považovaný za variantu selection sortu, protože také vybírá minimum a začleňuje do setříděné části.

Algoritmus (Insertion sort, třídění vkládáním)

Insertion sort je také relativně jednoduchý a na velké datové soubory neefektivní, ale jednoduchý na implementaci a rychlejší než nejprimitivnější algoritmy bubble sort a selection sort. Navíc je efektivní pro data, která jsou už částečně předtříděná – v nejhorším případě sice běží v čase $O(n^2)$, ale v nejlepším případě (úplné setřídění dat) je lineární – obecně běží v čase O(n+d), kde d je počet inverzí ve tříděné posloupnosti. Navíc je stabilní (zachovává pořadí prvků se stejným klíčem) a "in-place", tedy nepotřebuje žádné pomocné datové struktury. Proti selection sortu ale většinou potřebuje více přepisování (a to může u velkých datových struktur vadit).

V jednom kroku vždy vezme nějaký prvek (berou se po řadě od začátku pole), zapamatuje si jeho hodnotu, a dokud před ním jsou prvky s větším klíčem, posouvá je na pozici o 1 větší (čímž vždy přepíše následující, takže původní prvek se ztratí) a pokud narazí na prvek s menším klíčem, do za něj napíše onen zapamatovaný prvek (a místo tam je, protože celou cestu k němu posouval prvky). Algoritmus vypadá takto:

```
insert sort( array a ){
  for( i = 1; i < a.length - 1; ++i ){
    value = a[i];
    j = i-1;
    while( j >= 0 && a[j] > value ){
       a[j + 1] = a[j];
       j = j-1;
    }
    a[j+1] = value;
}
```

Jednou z variant insertion sortu je Shell sort, který porovnává prvky ne vedle sebe, ale vzdálené o nějaký počet polí, který se postupně zmenšuje. Může dosahovat složitost $O(n^{3/2})$ až $O(n^{4/3})$. S jistými úpravami se u něj dá dosáhnout až $O(n \log^2 n)$. Jiné vylepšení je library sort, který si při vkládání nechává mezery pro další prvky (podobně jako v knihovně nejsou poličky úplně plné) – ten může s velkou pravděpodobností běžet v čase $O(n \log n)$, ale zase potřebuje větší paměťový prostor.

Algoritmus (Bubble sort, bublinkové třídění)

Bubble sort je velmi jednoduchý třídící algoritmus (asi nejjednodušší na implementaci), s časovou složitostí $O(n^2)$. V nejlepším případě (pro úplně setříděná data) mu ale stačí jen jeden průchod, takže O(n). Většinou ale bývá pomalejší i než insertion sort, takže se na velké množiny dat nehodí.

Algoritmus prochází v jednom kroku celé pole a hledá pozice, kde se prvek s menším klíčem nachází bezprostředně za prvkem s větším klíčem. Takovéto dva prvky pak vymění. Kroky opakuje, dokud neprojde celé pole bez jediného prohození prvků (nebo v "tupější" variantě n-krát pro n prvků, protože pak je zaručeno, že posloupnost bude pro libovolné pořadí prvků setříděná – ta má ale pak složitost $O(n^2)$ v každém případě!).

Vylepšení algoritmu lze dosáhnout jednoduchou úvahou: největší prvek je už při prvním průchodu polem odsunutý až na konec. To se samozřejmě opakuje pro každý průchod (ve druhém je předposlední na druhém místě od konce atp.), takže lze průchody postupně zkracovat a konec pole už netestovat – dosáhneme tím v průměru dvojnásobné rychlosti.

Variantou bubble sortu je shake sort neboli cocktail sort, který střídavě prochází posloupnost prvků nejdřív od začátku a pak od konce (a přitom provádí to samé jako bubble sort). Tím může v některých případech o trochu třídění zrychlit –

příkladem budiž posloupnost prvků (2,3,4,5,1), která potřebuje jen 1 průchod cocktail-sortem tam a jeden zpět, ale pro bubble-sort by potřebovala 4.

Dalším vylepšením bubble sortu je $Comb\ sort$, který o něco zvyšuje rychlost. Je založen na stejné myšlence jako shell sort – tedy nejsou porovnávány prvky bezprostředně za sebou, ale prvky posunuté o nějaký ofset – ten je na začátku roven délce posloupnosti, a postupně se dělí "zkracovacím faktorem" (běžná hodnota 1.3) až dosáhne jedné. Složitost se pohybuje mezi $O(n^2)$ v nejhorším případě a $O(n\log n)$ v nejlepším. V průměrném případě jde stále o $O(n^2)$, ale s menší konstantou než u bubble-sortu (TODO: tohle je potřeba set-sakra ověřit ... opsané z německé wiki a "talk:Comb sort" na anglické, takže fakt "důvěryhodné").

Algoritmus (Heap sort, třídění haldou)

Heapsort je také třídící algoritmus založený na porovnávání a myšlenkově vychází ze selection sortu, ke kterému přidává práci s haldou. Většinou bývá pro typická vstupní data pomalejší než quicksort, ale zaručuje časovou složitost $O(n \log n)$ i v nejhorším případě. Jde o "in-place" algoritmus (halda se může nacházet přímo v nesetříděné části pole), ale není "stabilní".

Algoritmus sám, máme-li vyřešené operace na haldě, je velice jednoduchý – nejdříve pro každý prvek opakuje jeho vložení do haldy (takže postupně vytvoří *n*-prvkovou haldu, která se s každým krokem zvětšuje o 1), pro implementaci haldy na začátku pole je vhodný "max-heap", a potom opakuje odebrání maxima a jeho přesun na volné místo hned za konci zmenšivší se haldy – takže od konce pole postupně roste směrem k začátku setříděná posloupnost.

Upravený heapsort s použitím ternární haldy dosahuje o multiplikativní konstantu lepší výsledky, existuje i (prý :-)) složitá varianta smoothsort, která se blíží časové složitosti O(n), pokud jsou data částečně předtříděná – heapsort totiž pracuje pro libovolnou posloupnost v čase $O(n \log n)$.

Algoritmus (Merge sort, třídění sléváním)

Dalším třídícím algoritmem založeným na porovnávání prvků je mergesort. Je stabilní, takže zachovává pořadí dat se stejným klíčem. Jde o příklad algoritmu typu "rozděl a panuj", stejně jako u níže popsaného quicksortu. Byl vynalezen Johnem Von Neumannem. Je založen na rozdělení posloupnosti na dvě zhruba stejné poloviny, rekurzivním setřídění a potom "slévání" dvou již setříděných posloupností. Jeho časová složitost je $O(n\log n)$ i v nejhorším případě, provádí většinou méně porovnání než quicksort, má větší nároky na paměť v případě rekurzivního volání (existuje ale i nerekurzivní verze), ale většinou nepracuje na místě a potřebuje alokovat paměť pro výstup setříděných posloupností (i toto se dá odstranit, ale je to zbytečně složité a přílišné zrychlení oproti použití jiného algoritmu nepřinese). Jeho přístup ho ale činí ideálním k použití na médiích se sekvenčním přístupem k datům (např. pásky). Jde tedy použít i ke třídění na vnější paměti – detaily viz sekce o databázích.

Postup práce je následující:

- 1. Rozděl nesetříděnou posloupnost na dvě (zhruba) poloviční části
- 2. Pokud mají více než jeden prvek, setřiď je rekurzivním zavoláním mergesortu (tj. pro každou z nich pokračuj od kroku 1 do konce algoritmu), jinak pokračuj následujícím krokem.
- 3. Slij dvě setříděné posloupnosti do jedné vyber z obou posloupností první prvek, a pak opakovaně prvky porovnávej, zapisuj do setříděné posloupnosti menší z nich a doplňuj dvojici z té poloviční posloupnosti, odkud pocházel zapsaný prvek.

Algoritmus (Quicksort)

Quicksort je jedním z nejrychlejších algoritmů pro třídění na vnitřní paměti, přestože v nejhorším případě může jeho časová složitost dosáhnout až $\Theta(n^2)$. Pro ideální i průměrná data dosahuje $\Theta(n \log n)$. Je také založen na principu "rozděl a panuj", i když poněkud jiným způsobem než předchozí zmiňovaný, od něhož se liší i tím, že není stabilní.

Algoritmus nejdřív vybere nějaký prvek, tzv. *pivot*, a prvky s klíčem větší než pivot přesune do jiné části pole než ty s klíčem menším. Pak rekurzivně třídí obě části pole – když se dostane k polím délky 1, problém je vyřešen. Postup vypadá takto:

- 1. Vyber pivot (jeden prvek ze seznamu). Tady jde o největší magii, protože k dosažení nejlepší rychlosti by se měl pokaždé vybírat medián. Nejjednodušší je vybrat první, ale tento výběr ovlivňuje výslednou rychlost práce, takže se vyplatí např vzít tři prvky, porovnat je a vzít si z nich ten prostřední.
- 2. Postupuj od začátku pole a hledej první prvek větší nebo rovný než pivot. Až ho najdeš, postupuj od konce a najdi první prvek menší než pivot.
- 3. Prvky prohoď a opakuj krok 2 a 3, dokud se hledání od začátku a od konce nepotká na nějaké pozici tu pojmenujeme třeba k.
- 4. Rekurzivním voláním setřiď prvky (0, ..., k) a (k+1, ..., n-1) (má-li tříděné pole délku n) to znamená pro obě části pole pokračuj od kroku 1. Pokud je k=0 nebo k=n-2, není třeba už rekurzivního volání, protože posloupnosti délky 1 jsou setříděné.

Pro algoritmus existuje i nerekurzivní verze (stačí rekurzi nahradit zásobníkem úseků čekajících na zpracování). Je vidět, že na volbě pivotu závisí všechno – pokud pokaždé jako pivot volím 1. nebo n-1. hodnotu v poli v pořadí podle velikosti, dělím pak vždy na části o délce 1 a n-1, takže tento rekurzivní krok provedu až n-krát a dostanu se k času $\Theta(n^2)$. Samozřejmě, díky existenci algoritmu pro nalezení mediánu v čase $\Theta(n)$ je možné i tady dosáhnout zaručené složitosti $\Theta(n \log n)$, ale v praxi je to kvůli vysoké multiplikativní konstantě nepoužitelné – k výběru pivotu se většinou s úspěchem užívá nějaká jednoduchá heuristika, jak je nastíněno v popisu algoritmu samotného.

Heapsort bývá pomalejší než quicksort, ale zaručuje nízkou časovou složitost i pro nejhorší případ a navíc potřebuje méně paměti – nároky quicksortu navíc (kromě tříděné posloupnosti) jsou $O(\log n)$ minimálně, kvůli nutnosti použití rekurzivního

volání nebo zásobníku. Oproti mergesortu ho nelze použít na data se sekvenčním přístupem, tyto nevýhody ale vyvažuje relativní jednoduchostí implementace a rychlostí v průměrném případě.

Variantou quicksortu je introsort, který ho kombinuje s heapsortem, pokud hloubka rekurze dosáhne nějakých nepřijatelných hodnot – tak je zaručena časová složitost $\Theta(n \log n)$ i v nejhorším případě (samozřejmě je to ale v nejhorším případě pořád pomalejší než použití jen heapsortu). Jedna z variant tohoto algoritmu se dá použít k hledání k-tého nejmenšího prvku (tedy i mediánu), kdy dosahuje složitosti O(n) průměrně až $O(n^2)$ nejhůře.

Přihrádkové třídění

Algoritmus (Bucket sort, Radix sort, přihrádkové třídění)

Radix sort je zvláštní třídící algoritmus – jeho složitost je totiž lineární. Dosahuje to tím, že neporovnává všechny tříděné prvky (složitost problému třídění pomocí porovnávání je $\Theta(n \log n)$, takže by to jinak nebylo možné), je ho ale možné použít jen pro třídění dat podle klíče z nějaké ne příliš velké množiny – max. rozsah tříděných hodnot závisí na tom, jak velké pole si můžeme dovolit vymezit v paměti pro tento účel.

Nejjednodušší varianta (tzv. pigeonhole sort, nebo-li counting sort) opravdu počítá s klíči ze zadaného rozmezí [l,h]. Pro něj si připraví cílové pole velikosti h-l+1, tj. "přihrádky". Do nich pak přímo podle klíče přehazuje čtené prvky (jestliže přihrádky realizujeme jako seznamy, bude třídění dokonce stabilní). Nakonec projde přihrádky od začátku do konce a co v nich najde, to vypíše (a výstup bude setříděný). Variantou counting sortu je bucket sort, kdy se do jedné přihrádky nedávají jen prvky se stejným klíčem, ale prvky s klíčem v nějakém malém rozmezí – ty pak lze setřídit rychle, protože jich zřejmě nebude mnoho, a navíc se ušetří paměť.

Protože ale klíče velikosti max. tisíců hodnot jsou většinou trochu málo, v praxi se běžně používají složitější varianty – ty zahrnují několik průchodů nahoře popsaného algoritmu, při nichž se třídí jenom podle části klíče. Ty se dělí na ty, které začínají od nejméně významné části klíče (least significant digit radix sort) a ty, které jdou od nejvýznamnější části (most significant digit). První z nich mají tu výhodu, že lze zachovat stabilitu třídění, druhá zase může třídit i podle klíčů různé délky a zastavovat se po nalezení unikátních prefixů, takže se hodí např. pro lexikografické třídění podle řetězcových klíčů.

Třídění typu least significant digit vypadá následovně:

- 1. Vezmi nejméně významnou část klíče (určitý počet bitů).
- 2. Rozděl podle této části klíče data do přihrádek, ale v nich zachovej jejich pořadí (to je nutné kvůli následnému průchodu, zároveň to dělá z tohoto algoritmu stabilní třídění).
- 3. Opakuj toto pro další (významnější) část klíče.

Most significant digit varianta (rekurzivní verze, je založená na bucket sortu) běhá takto:

- 1. Vezmi nejvýznamnější část klíče (první písmeno, například).
- 2. Rozděl prvky podle této části do přihrádek (takže v jedné se jich octne docela hodně)
- 3. Rekurzivně setřiď každou z přihrádek (začni podle další části klíče), pokud je v ní více než jeden prvek (tohle zaručí zastavení za rozlišujícím prefixem).
- 4. Slep přihrádky do jedné (setříděné) posloupnosti.

Popisované algoritmy většinou potřebují O(n + (h - l)) času k třídění, je-li h - l (zhruba) počet přihrádek – to znamená, že sice jde o složitost lineární, ale lineární i v počtu přihrádek, což se nemusí vždy oproti konvenčnímu třídění vyplatit. Navíc jsou problémem vysoké nároky na paměť (nelze třídění provést "na místě" v jediném poli). Pro malou množinu hodnot klíčů (nebo u most significant digit varianty krátké odlišující prefixy) jsou ale časově efektivnější.

Třídící sítě

Zdrojem této sekce jsou zápisky z přednášek Prof. L. Kučery Algoritmy a datové struktury II.

Definice (Bitonická posloupnost)

Řekneme, že posloupnost prvků je *bitonická*, pokud po spojení do cyklu (tedy nultý prvek za *n*-tý) obsahuje dva monotónní úseky. Nebo-li obsahuje až na fázový posuv dva monotónní úseky.

Definice (Komparátor)

Komparátor je speciální typ hradla (představme si pod tím nedělitelnou elektronickou součástku, případně jen virtuální), která má dva výstupy a dva vstupy. Pokud na vstupy přivedeme dva prvky (klíče, čísla), z levého výstupu vydá menší z nich a z pravého výstupu větší (takže vlastně porovná dva prvky a na výstup je vyplivne ve správném pořadí). Pracuje v konstantním čase.

Definice (*Třídící síť*)

Třídící síť je správně sestavená množina komparátorů dohromady spojená vstupy a výstupy tak, že při přivedení posloupnosti délky n na vstup ji vydá setříděnou na výstupu. Komparátory v ní jsou rozčleněné do hladin, jejichž počet pak udává celkovou dobu výpočtu – předpokládá se tam, že komparátory v jednotlivých vrstvách pracují paralelně, takže třídící sítě mohou dosahovat časové složitosti pouhých $O(\log n)$. Algoritmus s takovou časovou složitostí sice existuje, ale má velmi vysokou multiplikativní konstantu, takže se v praxi nepoužívá. Příkladem třídící sítě je i bitonické třídění.

Algoritmus (Bitonické třídění)

Bitonická třídící síť je založena na použití bitonických posloupností a rekurze. Obvod (pro třídění dat délky n) se dělí na dvě části:

- První část setřídí (rekurzivně) 1/2 vstupu vzestupně, druhou polovinu sestupně a tím vytvoří bitonickou posloupnost. Obsahuje tedy dvě třídící sítě pro třídění posloupností délky $\frac{n}{2}$.
- Druhá část třídí jen bitonické posloupnosti první její vrstva rozdělí bitonickou posloupnost na vstupu na dvě bitonické posloupnosti (z větších a menších čísel). Další vrstvy už jsou opět implementovány rekurzivně tedy druhá vrstva dostane dvě posloupnosti a vyrobí z nich čtyři atd., až nakonec dojde k "bitonickým posloupnostem" délky 1.

K rozdělení jedné bitonické posloupnosti délky k na dvě stačí jen $\frac{k}{2}$ komparátorů, které porovnávají vždy i-tý a k+i-tý prvek. Dojde sice k nějakému fázovému posuvu, ale to ničemu nevadí. Dobře je to vidět při znázornění na kružnici, doporučuji prohlédnout si postup v programu Algovision Prof. Kučery (http://kam.mff.cuni.cz/~ludek/AlgovisionPage.html).

Je vidět, že počet vrstev potřebných k dělení bitonických posloupností délky N je log_2N (B(N) = log N). Pro celkový počet vrstev, a tedy dobu zpracování – T(n) nám vychází následující vzorec

$$T(N) = T(\frac{n}{2}) + B(N) = \log N + \log(N/2) + \dots + 1$$

z čehož díky vzorci pro součet aritmetické posloupnosti $1+2+\cdots+k=\frac{k(k+1)}{2}$ vyjde

$$T(N) = O(\frac{1}{2}\log^2 N)$$

3.7 Grafové algoritmy

TODO: nejake vyuziti tech algoritmu (staci priklad plusminus ke kazdemu druhu ulohy)

Graf

Definice

 $Graf\ G$ je dvojice (V,E), kde V je množina bodů (vrcholů) a E množina jejich dvojic (hran). Je-li E množinou neuspořadaných dvojic, jde o neorientovaný graf. Jsou-li dvojice uspořádané, jedná se o orientovaný graf. Velikost množiny V se značí n, velikost E je m - |V| = n, |E| = m.

Graf je možné strojově reprezentovat např. pomocí $matice\ sousednosti$ – matice, kde je na souřadnicích (u,v) hodnota 1, pokud z u do v je hrana a 0 jinak. Pro neorientované grafy je souměrná podle hlavní osy. Matice zabírá $\Theta(n^2)$ místa v paměti. Další možností jsou $seznamy\ sousedů$ – dvě pole, jedno příslušné vrcholům, druhé hranám. V prvním jsou uložené indexy do druhého pole, určující kde začínají seznamy hran vedoucích z vrcholu (příslušejícímu k indexu v prvním poli). Paměťová náročnost je $\Theta(m+n)$.

Prohledávání do hloubky a do šířky

Algoritmy, které postupně projdou všechny vrcholy daného souvislého neorientovaného grafu.

Algoritmus (Prohledávání do šířky/Breadth-First Search)

Prochází všechny vrcholy grafu postupně po vrstvách vzdáleností od iniciálního vrcholu. K implementaci se používá fronta (FIFO).

```
BFS( V - vrcholy, E - hrany, s - startovací vrchol ){
  obarvi vrcholy bíle, nastav jim nekonečnou vzdálenost od s a předchůdce NULL;
  dej do fronty vrchol s;

  while( neprázdná fronta ){
    vyber z fronty vrchol v;
    foreach( všechny bíle obarvené sousedy v = u ){
        obarvi u šedě a nastav mu vzdálenost d(v) + 1 a předchůdce v;
        dej vrchol u do fronty;
    }
    v přebarvi na černo a vyhod' z fronty.
  }
}
```

Běží v čase $\Theta(m+n)$, protože každý vrchol testuje 2x pro každou hranu, do fronty ho dává 1x a obarvení mu mění 2x. Tento algoritmus je základem několika dalších, např. pro testování souvislosti grafu, hledání minimální kostry nebo nejkratší cesty.

Algoritmus (Prohledávání do hloubky/Depth-First Search)

Prochází postupně všechny vrcholy - do hloubky (pro každý vrchol nejdřív navštíví první jeho nenavštívený sousední vrchol, pak první sousední tohoto vrcholu atp. až dojde k vrcholu bez nenavštívených sousedů, pak se vrací a prochází další ještě nenavštívené sousedy). Pro implementaci se používá buď zásobník, nebo rekurze. Zásobníková verze vypadá stejně jako prohledávání do šířky (místo fronty je zásobník).

Rekurzivní verze - při zavolání na startovní vrchol projde celý graf:

```
DFS(v - vrchol){
  označ v jako navštívený;
  foreach( všechny nenavštívené sousedy v = u )
     DFS( u );
}
```

Časová složitost je $\Theta(m+n)$, stejně jako u prohledávání do šířky.

Souvislost

Definice

Cesta v grafu G = (V, E) z vrcholu a do vrcholu b je posloupnost v_0, v_1, \ldots, v_n taková, že $v_0 = a, v_n = b$ a pro všechna $v_i, i \in \{1, \ldots, n\}$ je $(v_{i-1}, v_i) \in E$. Graf G = (V, E) je souvislý, pokud pro každé dva vrcholy $u, v \in V$ existuje v G cesta z u do v. Toto platí pro orientované i neorientované grafy.

Algoritmus (Testování souvislosti grafu/počítání komponent souvislosti)

Algoritmus využívá prohledávání do šířky (nebo do hloubky) - v 1 kroku vždy najde dosud nenavštívený vrchol, začne z něj procházet graf a takto projde(oddělí) jednu komponentu souvislosti. Pokud skončí po prvním kroku, graf je souvislý. Počet kroků, potřebných k navštívení všech vrcholů grafu, je zároveň počtem komponent souvislosti.

Časová složitost je $\Theta(m+n)$, protože o algoritmu platí to samé co o prohledávání do šířky – žádný vrchol nebude přidán do fronty více než jednou a testován více než 2x pro každou hranu.

Topologické třídění

Definice

Topologické uspořádání vrcholů orientovaného grafu $G = (V, \overrightarrow{E})$ je funkce $t : V \to \{1, \dots, n\}$ taková, že pro každou hranu $(i, j) \in E$ je t(i) < t(j). Lze provést pouze pro acyklické orientované grafy.

Algoritmus (Primitivní algoritmus)

V každém kroku najde vrchol, z něhož nevedou žádné hrany. Přiřadí mu nejvyšší volné číslo (začíná od n) a odstraní ho ze seznamu vrcholů. Uspořádání takto vytvořené je topologické, složitost algoritmu je $\Theta(n(m+n))$.

Algoritmus (Rychlý algoritmus)

K topologickému uspořádání se dá použít modifikace prohledávání do hloubky. Není třeba ani graf předem testovat na přítomnost cyklů, algoritmus toto objeví. Pro každý navštívený vrchol si poznamená čas jeho opuštění, uspořádání podle klesajících časů opuštění je topologické.

```
topologické_třídění( v - vrchol ) {
  global t; // čas opuštění, iniciální hodnota 0
  označ v jako navštívený;
  foreach ( u in sousední vrcholy v ) {
    if ( u je navštívený, ale ne opuštěný ) {
      chyba - cyklus;
      return;
    }
    else if ( u není navštívený )
      topologické_třídění( u );
  }
  označ v jako opuštěný v čase t;
  t = t + 1;
}
```

Časová složitost zůstává stejná jako u prohledávání do šířky, tedy $\Theta(m+n)$, protože všechny kroky prováděné v rámci navštívení 1 vrcholu vyžadují jen konstatní počet operací.

Poznámka

Topologické třídění se používá např. k zjištění nejvhodnějšího pořadí provedení navzájem závislých činností.

Hledání nejkratší cesty v grafu

Definice

Ohodnocení hran - váhová funkce je funkce, která každé (orientované) hraně přiřazuje její "délku" nebo "cenu" jejího projití. Definuje se jako $w: E \to \mathbb{R}$. Délka (orientované) cesty $p = v_0, v_1, \dots, v_n$ v ohodnoceném grafu (grafu s váhovou funkcí) je potom $w(p) = \sum_{i=1}^n w(v_{i-1}, v_i)$.

Vzdálenost dvou vrcholů u,v (váha nejkr. cesty z u do v) je $\delta(u,v)=\min\{w(p)|p$ je cesta z u do v}, pokud nějaká cesta z u do v existuje, jinak $\delta(u,v)=\infty$. Nejkratší cesta p z u do v je taková, pro kterou $w(p)=\delta(u,v)$.

Poznámka

Pro hledání nejkratší cesty v obecném grafu bez ohodnocení hran (tj. délka cesty je počet hran na ní) stačí prohledávání do šířky.

Algoritmus (Algoritmus kritické cesty (pro DAG))

Pro hledání nejkratší cesty do všech bodů z jednoho zdroje v orientovaném acyklickém grafu (DAG) používá topologické třídění, které je pro takovýto graf proveditelné; spolu se zpřesňováním horních odhadů vzdáleností vrcholů.

Mám daný startovací vrchol s. Definuji d(s, v) jako horní odhad vzdálenosti s a v, tj. vždy $d(s, v) \ge \delta(s, v)$ pro lib. vrchol v. Hodnoty d(s, v) před započetím výpočtu inicializuji na $+\infty$.

V algoritmu se provádí operace "Relax", znamenající zpřesnění odhadu d(s,v) za použití cesty vedoucí z s do v, končící hranou (u,v) – pokud má taková cesta nižší váhu než byl předchozí odhad d(s,v), položím d(s,v)=d(s,u)+w(u,v). Tato operace zachovává invariant $d(s,v) \geq \delta(s,v)$.

```
Relax (u, v) { //u = source, v = destination
  if (v.distance > u.distance + uv.weight) {
    v.distance := u.distance + uv.weight
    v.predecessor := u
  }
kritická cesta( V - vrcholy, E - hrany, s - startovací vrchol ){
  topologicky setřid' V;
  inicializace - nastav d(s,v) = nekonečno pro všechny vrcholy;
  foreach( vrchol v, v pořadí podle top. třídění ){
    proved' operaci Relax za použití cest
        vedoucích do v přes všechna možná u;
  }
}
```

Výsledek dává nejkratší cesty díky topologickému setřídění grafu – pro nejkr. cestu $p \ge s$ do v platí $t(v_i) < t(v_{i+1})$ a pokud mám $d(s,u) = \delta(s,u)$ a provedu Relax na v podle (u,v), pak dostanu $d(s,v) = \delta(s,v)$, z čehož se korektnost dá dokázat indukcí podle počtu hran na cestě.

Složitost algoritmu je $\Theta(n+m)$, protože taková je složitost topologického třídění a zbytek algoritmu každou hranu i každý vrchol testuje právě 1x.

Algoritmus (Dijkstrův algoritmus)

Pracuje na libovolném orientovaném grafu s nezáporným ohodnocením hran.

```
Dijkstra( V - vrcholy, E - hrany, s - startovací vrchol ){
   inicializace - nastav d(s,v) = nekonečno pro všechny vrcholy;
   S = prázdný; // množina "vyřízených" vrcholů
   Q = V; // množina "nevyřízených" vrcholů
   while( Q není prázdná ){
     vyber u, vrchol s nejmenším d z množiny Q;
     vlož vrchol u do S;
     foreach( v, z u do v vede hrana )
        proved' operaci Relax pro v přes u;
   }
```

Casová složitost při implementaci množin S a Q pomocí haldy je: $\Theta(n \cdot \log n)$ pro inicializaci (n vložení do haldy), $\Theta(n \cdot \log n)$ celkem pro vybírání prvků s nejmenším d, jedno provedení Relax při změně d trvá $\Theta(\log n)$ (úprava haldy) a provede se max. m-krát; tedy celkem $\Theta((m+n) \cdot \log n)$.

Algoritmus (Bellman-Ford)

}

Bellman-Fordův algoritmus lze použít nejobecněji, ale je nejpomalejší. Funguje na libovolném grafu (pokud najde cyklus, jehož celková váha je záporná, a tedy nejkratší cesty nemají smysl, vrací chybu).

```
Bellman-Ford( V - vrcholy, E - hrany, s - startovací vrchol ){
  inicializace - nastav d(s,v) = nekonečno pro všechny vrcholy;
  d(s,s) = 0;
  // n-1 iterací, každá projde všechny hrany
  for( i = 1; i < |V|; ++i ) {
   foreach( hrana (u,v) z E )
      proved' operaci Relax pro v přes u;
  }
  // hledání záporného cyklu
  foreach( hrana (u,v) z E ){
   if (d(v) > d(u) + w(u,v)){
      chyba - záporný cyklus;
      return;
   }
 }
}
```

Složitost algoritmu je $\Theta(m \cdot n)$. Vždy najde nejkratší cestu, protože v grafu bez záporných cyklů může mít cesta max. $n - 17K\check{c}(1)$ vrcholů. Důkaz nalezení záporného cyklu sporem, se sumou vah všech hran na něm (položím $< 0K\check{c}(0)$).

Poznámka (Nejkratší cesty pro všechny dvojice vrcholů)

Pro hledání nejkratších cest pro všechny dvojice vrcholů lze buď použít n-krát běh některého z předchozích algoritmů, nebo Algoritmus "násobení matic" či Floyd-Warshallův algoritmus. Ty oba používají matice sousednosti W_G a počítají matici vzdáleností D_G .

První z nich postupuje indukcí podle počtu hran na nejkr. cestě, vyrábí matice $D_G(x)$ pro x hran na nejkratší cestě. $D_G(1)$ je W_G , pro výpočet kroku i vždy $D_G(i-1)$ "vynásobí" $D_G(1)$ použitím zvláštního "násobení", kde násobení hodnot je nahrazeno sčítáním a sčítání výběrem minima. Složitost je s využitím asociativity takto definovaného "násobení" $\Theta(n^3 \log n)$.

Floyd-Warshallův algoritmus jde indukcí podle velikosti množiny vrcholů, povolených jako vnitřní vrcholy na cestách. Používá $d_{u,v}(k)$ jako min. váhu cesty z u do v s vnitř. vrcholy z množiny $\{1,\ldots,k\}$. V iniciálním kroku je taky $D_G(1)=W(G)$. Pro i-tý krok je $d_{u,v}(i)=\min\{d_{u,v}(i-1),d_{u,i}(i-1)+d_{i,v}(i-1)\}$. Složitost je $\Theta(n^3)$, navíc jeden krok je velice rychlý – celkově je algoritmus většinou rychlejší než Bellman-Fordův a pro záporné cykly se časem na diagonále objeví záp. číslo, proto je není třeba testovat předem.

Minimální kostra grafu

Úkolem v této úloze je najít kostru T (acyklický souvislý podgraf) grafu (V, E) s celkovou minimální vahou hran. Vždy platí $|T| = |V| - 17K\check{c}(1)$. Bez újmy na obecnosti lze předpokládat, že ohodnocení hran jsou nezáporná (lze ke všem přičíst konstantu a výsledek se nezmění).

Algoritmus (Borůvkův / Kruskalův algoritmus)

Celková složitost je $\Theta(m \log m)$ při použití spojových seznamů: Setřídění hran podle váhy $\Theta(m \log m)$, nalezení čísla komponenty konstantní čas, max. počet přečíslování komponent při slévání (přečíslovávám-li vždy menší ze slévaných komponent) pro 1 vrchol je $\Theta(\log n)$, tj. celkem $\Theta(n \log n)$.

Algoritmus je korektní - vždy nalezne kostru, protože přidá právě $|V|-17K\check{c}(1)$ hran a nevytvoří nikdy cyklus. Minimalita kostry se dokáže sporem – mám-li F vrácenou algoritmem a H nějakou min. kostru, tak pokud je w(F)>w(H), najdu hranu $e\in F\setminus H$, vezmu kostru $H_1=H\cup e\setminus f$ (a $w(e)\leq w(f)$). Pokud mám $\forall e$ nalezené f takové, že w(e)=w(f), jsou F i H minimální, jinak H taky nebylo minimální, protože $H_17K\check{c}(1)$ je menší.

```
Algoritmus (Jarníkův / Primův algoritmus )
```

```
if ( v je v Q a klíč(v) > w(u,v) ){
        klíč(v) = w(u,v);
        soused(v) = u;
    }
}
return ( (V,F) jako min. kostru (V,E) );
}
```

Složitost algoritmu je $\Theta(m \log n)$, pokud je Q reprezentováno jako bin. halda - nejvýše m-krát upravuji klíč nějakého vrcholu, což má v haldě složitost $\Theta(\log n)$, výběr minima max. n-krát $\Theta(\log n)$ a inicializace jen $\Theta(n)$.

Vytvořený graf je kostra, protože nikdy nevzniká cyklus (připojuji právě vrcholy z Q, která je na konci prázdná). Důkaz minimality podle konstrukce – najdu první hranu e v min. kostře H, která není ve výsledku alg. F, pak najdu $f \in H$, t.ž. $F \setminus e \cup f$ je kostra, z algoritmu je $w(f) \geq w(e)$. Vezmu $H_1 = H \setminus f \cup e$, vím, že $w(H_1) \leq w(H)$ a tedy $H_1 7K\check{c}(1)$ je min. kostra, iterací tohoto postupně dostanu, že $H_k = F$ je min. kostra.

Toky v sítích

není požadaváno v IP a ISPS

Definice (Síť, tok)

Sit' je čtveřice (G, z, s, c), kde G je (orientovaný) graf, z zdrojový a s cílový vrchol (stok, spotřebič) a $c: E \to \mathbb{R}^+$ funkce kapacity hran. Tok sítí je taková funkce $t: E \to \mathbb{R}^+$, že pro každou hranu (u, v) je 0Kč $(0) \le t((u, v)) \le c((u, v))$ a navíc pro každý vrchol v kromě z a s (uzel sitě) platí $\sum_{e=(u,v)} t(e) = \sum_{e=(v,w)} t(e)$ (tj. přebytek toku - rozdíl toho co do vrcholu vteče a co z něj odteče $\delta(t, v)$ je pro uzly sítě nulový). Velikost toku se definuje jako $|t| = \delta(t, s)$.

Algoritmus (Ford-Fulkersonův algoritmus)

Algoritmus používá myšlenku zlepšitelné cesty - tj. pokud existuje v grafu neorientovaná cesta ze z do s taková, že pro hrany ve směru od zdroje je t < c a pro hrany ve směru ke zdroji $t > 0K\check{c}(0)$, pak mohu tok zlepšit (o minimum rezerv). Algoritmus opakuje takovýto krok, dokud je možné ho provést. Neřeší výběr cesty, proto je dost pomalý a pokud nejsou hodnoty t racionální čísla, může se i zacyklit.

Ve chvíli zastavení algoritmu získám max. tok, neboť množina $A = \{v \mid ze \ z \ do \ v \ vede zlepšitelná cesta \}$ je v tom okamžiku řez (množina $A \subset V$ taková, že $z \in V$, $s \notin V$) a jeho velikost ($\sum_{e \in E} c(e), e = (u, v), u \in A, v \notin A$) je stejná jako velikost získaného toku.

Algoritmus (Dinitzův algoritmus)

Řeší výběr zlepšitelné cesty – vybírá vždy nejkratší cestu (což obecně popisuje Edmunds-Karpův algoritmus). Dinitzova varianta používá sit rezerv, což je graf (V,R), kde hrana $e=(v,w)\in R$, pokud má tok hranou kladnou rezervu, tj. r=c(v,w)-t(v,w)+t(w,v)>0 $K\check{c}(0)$. Zlepšující cesta odpovídá normální orientované cestě v síti rezerv. Převod na pův. graf ze sítě rezerv je jednoduchý, mohu předpokládat, že jedním ze směrů mezi dvěma vrcholy neteče nic.

Průběh algoritmu: na začátku nastaví všem hranám rezervu r(v, w) = c(v, w). Potom postupuje po fázích - v 1 fázi:

- Vyhodí ze sítě rezerv všechny hrany, které nejsou na nejkratší cestě $z \to s$ (2x prohledávání do šířky).
- Vezme jednu z nejkr. cest v síti rezerv a zlepší podle ní tok.
- Vyhodí vzniklé slepé cesty v síti rezerv (testuji jen hrany, co vyhazuji, a jejich konc. vrcholy)
- \bullet Toto opakuje, dokud jsou v síti rezerv cesty $z \to s$ dané nejkratší délky.

Další fází algoritmus pokračuje, dokud existuje vůbec nějaká cesta $z \to s$ v síti rezerv. Fází je tím pádem max. n (max. délka cesty ze z do s), v 1 fázi se prochází max. m cest (klesá počet použitelných hran), nalezení 1 cesty je O(n) (jdu přímo) a vyhazování slepých cest max O(m) celkem za fázi (každou hranu vyhodím jen jednou). Celková složitost je tedy $O(n^2m)$.

Algoritmus (Goldbergův algoritmus (preflow-push, algoritmus vlny))

Nehledá v grafu zlepšující cesty, v průběhu výpočtu v grafu není tok, ale vlna (ze zdroje teče vždy více nebo rovno než max. tok). Preflow – "vlna" – je funkce $t: E \to \mathbb{R}^+$ taková, že $\forall e \in E: 0 \le t(e) \le c(e)$, tedy přebytky toku ve vrcholech (δ) jsou povolené. Ve chvíli, kdy žádný vrchol nemá přebytek toku (δ) , dostávám (maximální) tok. Pro každý vrchol v si algoritmus pamatuje "výšku" h(v). Také pracuje se sítí rezerv.

- Inicializace: h(z) = n, $h(v, v \neq z) = 0K\check{c}(0)$, $t(e) = 0 \ \forall e, \ \delta(v) = 0 \ \forall v$.
- Úvodní preflow: převede ze zdroje maximum možného (t(e) = c(e)) po směru) do sousedních vrcholů.
- Hlavní cyklus: opakuje se, dokud existuje vnitřní vrchol v s kladným δ . pro vrchol v:
 - pokud existuje hrana (v, w) nebo (w, v), t.ž. $r(e) > 0K\check{c}(0)$ (v daném směru) a $h(v) \ge h(w)$, potom se převede $\min(\delta(v), r(e))$ z v do w.
 - jinak se zvýší h(v) o 1.

Po celou dobu běhu algoritmu platí invariant $e=(v,w), r(e)>0 \Rightarrow h(v)\leq 1+h(w)$. To zaručuje, že nalezený tok po zastavení je maximální (zdroj je ve výšce n, stok 0, tedy každá cesta překonává někde rozdíl $-33K\check{c}(2)$). Vrcholy nejde zvedat donekonečna, takže se algoritmus zastaví: pro každý vnitřní vrchol v platí, že je-li $\delta(v)>0K\check{c}(0)$, pak existuje v síti rezerv cesta $v\to z$. To zaručuje, že $h(v)\leq 2n-17K\check{c}(1)$ - pokud mám vrchol v tak, že $h(v)=2n-17K\check{c}(1)$ a $\delta(v)>0K\check{c}(0)$, potom existuje cesta $v\to z$ s kladnými rezervami a podle invariantu jde každá hrana na ní max. o 1 nahoru (tedy max. o $n-17K\check{c}(1)$ celkem).

Složitost Goldbergova algoritmu je $O(n^2 \cdot m)$.

3.8 Tranzitivní uzávěr

Definice

Tranzitivní uzávěr orientovaného grafu je orientovaný graf s původními vrcholy a platí, že existuje hrana z uzlu u do uzlu v právě tehdy, když v původním orientovaném grafu existuje libovolná orientovaná cesta z uzlu u do uzlu v.

Poznámka

Platí, že matice dosažitelnosti v grafu G = matice sousednosti tranzitivního uzávěru grafu G.

Z každého vrcholu vypustit DFS (Depth-first search – prohledávání do hloubky), do společné matice zaznamenávat dosažené vrcholy (řádek odpovídá vrcholu, sloupce vrcholům, které jsou z něho dosažitelné) – složitost O(n(n+m)).

Warshallův algoritmus

Iterativní konstrukce matice dosažitelnosti, postupně počítá matice W_k , kde $w_{i,j}^{[k]} = 1$, pokud mezi vrcholy i a j existuje cesta,

jejíž všechny vnitřní vrcholy jsou mezi vrcholy $1 \dots k$. Z matice W_k lze spočítat matici $W^{[k+1]}:W^{[k+1]}_{i,j}=W^{[k]}_{i,j}||(W^{[k]}_{i,k+1}\&\&W^{[k]}_{k+1,j})$ – buď vede mezi vrcholy i,j cesta, která nepoužije vrcholk+1, nebo taková, která ho použije – v tom případě ale musí vést cesty mezi vrcholy i,k+1 a k+1,j, které používají pouze vrcholy $1 \dots k$, jejich spojením je cesta mezi vrcholy i, j

Matice W^1 je matice incidence původního grafu.

Pseudokód (vstup: I – matice incidence, $[0,1]^{n\times n}$):

```
Procedure Warshall(I)
W := I;
for k:=1 to n
begin
  for i:=1 to n
  begin
    for j:=1 to n
  w_{i,j} = w_{i,j} || (w_{i,k} \& \& w_{k,j})
  end
end
return W;
```

Složitost algoritmu je jasně $O(n^3)$ (potřebuje $2n^3$ bitových operací), což může být lepší pro grafy s hodně hranami (počet hran se blíží n^2), než složitost n*DFS ($n*(n+m) \approx n*(n+n^2) = n^2 + n^3$)

TODO: ještě něco?

3.9 Algoritmy vyhledávání v textu

Toto sú len veľmi stručné výťahy z wikipedie. Aktuálne sú tu len preto, aby si človek rýchlo vybavil, o čom tie algoritmy sú:-)

Rabin-Karp

Umožňuje vyhľadávanie viacerých reťazcov v texte naraz - užitočné napr. na hľadanie plagiátov. Základnou myšlienkou je vyhľadávanie v texte pomocou hashov (rolling hashes - idea je s[i+1..i+m] = s[i..i+m-1] - s[i] + s[i+m])...

Algoritmus pre vyhľadávanie jedného reťazca:

```
1 function RabinKarp(string s[1..n], string sub[1..m])
      hsub := hash(sub[1..m])
2
3
      hs := hash(s[1..m])
4
      for i from 1 to n-m+1
5
          if hs = hsub
6
              if s[i..i+m-1] = sub
7
                  return i
8
          hs := hash(s[i+1..i+m])
9
      return not found
```

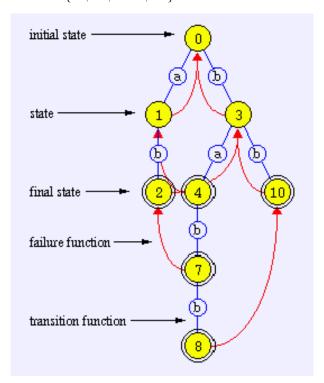
Najhoršia zložitosť je $\Omega(mn)$. Pri vyhľadávaní viacerých reťazcov len spočítame hashe všekých hľadaných stringov a pri nájdení niektorého z hashov príslušný reťazec porovnáme s textom... Ostatné algoritmy spotrebujú čas O(n) na nájdenie 1 reťazca a teda O(nk) na vyhľadanie k reťazcov. Naproti tomu tento algoritmus má očakávanú zložitosť O(n+k) - pretože vyhľadávanie v hashovacej tabuľke, či je hash podreťazca textu rovný hashu niektorého z hľadaného reťazcov, trvá O(1).

Aho-Corasick

Dokáže vyhľadávať viacero reťazcov naraz - používa na to trie-like štruktúru (konečný automat), ktorý obsahuje nasledujúce "prvky":

- 1. konečná množina Q stavy
- 2. konečná abeceda A
- 3. transition funkcia $g: Q \times A \rightarrow Q + \{fail\}$
- 4. failure funkcia $h: Q \to Q + \{fail\}$. h(q) = q' práve vtedy keď spomedzi všetkých stavov Q dáva q' najdlhší suffix z path(q).
- 5. konečná množina F koncové stavy

Príklad "hotového" automatu pre slová P={ab, ba, babb, bb}:



Zložitosť vyhľadávania je lineárna vzhľadom k dĺžke textu a počtu nájdených "slov" (pozn.: ten môže byť až kvadradický slovník a, aa, aaa, aaaa; reťazec aaaa). Trie štruktúru je možné vyrobiť raz a potom používať počas vyhľadávania - uchovávame si najdlší match a používame suffix odkazy (aby sme udržali linearitu výpočtu).

Výstavba stromu se provede prostým zařazováním slov do trie-stromu podle prefixů. Na této struktuře je potom možné v lineárním čase (vzhledem k počtu znaků hledaných slov) předpočítat hodnoty failure funkce: automat vždy pustíme na sufix aktuálně zkoušeného slova, bez prvního znaku. Díky tomu, že průběžně ukládáme hodnoty nalezených slov, pro každé písmeno provede max. 2 kroky (postup vpřed a uložení hodnoty, kam bych spadnul).

Knuth-Morris-Pratt

Obdoba Aho-Corasick, ale hľadá len jedno slovo. Samozrejme nie je potrebná dopredná funkcia (vždy iba nasledujúci znak), používa sa "partial match" tabuľka (failure funkcia).

```
algorithm kmp_search:
    input:
        S (the text to be searched)
        W (the word sought)
    m = 0 (the beginning of the current match in S)
    i = 0 (the position of the current character in W)
    an array of integers, T (the table, computed elsewhere)
    while m + i is less than the length of S, do:
        if W[i] = S[m + i],
            i = i + 1
            if i equals the length of W,
                return m
        otherwise,
            m = m + i - T[i],
            if i is greater than 0,
                i = T[i]
    (if we reach here, we have searched all of S unsuccessfully)
    return the length of S
  Zložitosť algoritmu je je O(k) (k je dĺžka S) - cyklus je vykonaný najviac 2k krát.
  Algoritmus na výrobu tabuľky:
algorithm kmp_table:
    input:
        W (the word to be analyzed)
        T (the table to be filled)
    i = 2 (the current position we are computing in T)
    j = 0 (the zero-based index in W of the next
           character of the current candidate substring)
    (the first few values are fixed but different
          from what the algorithm might suggest)
    let T[0] = -1
    T[1] = 0
    while i is less than the length of W, do:
        (first case: the substring continues)
        if W[i-1] = W[j],
            T[i] = j + 1
            i = i + 1
            j = j + 1
        (second case: it doesn't, but we can fall back)
        otherwise, if j > 0,
            j = T[j]
        (third case: we have run out of candidates. Note j = 0)
        otherwise,
            T[i] = 0
            i = i + 1
```

Zložitosť tohoto algoritmu je O(n) (n je dĺžka W) - cyklus skončí najviac po 2n iteráciách.

3.10 Algebraické algoritmy

Diskrétní Fourierova Transformace (DFT)

Diskrétní Fourierova transformace se používá, chceme-li zachytit hodnotu (přepokládejme, že 2π -periodické) funkce na intervalu $[-\pi,\pi]$ v nějakých n bodech. To je dobré např. pro vzorkování elektrického nebo zvukového signálu a jiné operace. Pro nějakou funkci nám tak stačí znát vektor dimenze n (a n je počet vzorků na 2π).

Je to založeno na Fourierových řadách – dá se ukázat, že funkce 1, $\cos kx$ a $\sin kx$ pro $k \ge 1$ tvoří ortogonální bázi prostoru spojitých funkcí na intervalu $[-\pi,\pi]$. Protože potřebujeme znát jenom konečný počet vzorků, stačí nám jen konečný podprostor s konečnou bází. Máme-li rozklad nějaké 2π -periodické funkce do Fourierovy řady $f(x) = c + \sum_{k=1}^{\infty} a_k \sin kx + \sum_{k=1}^{\infty} b_k \cos kx$, dá se jednoduše ukázat, že pro hodnoty v bodech $-\pi, -\pi + \frac{\pi}{n}, -\pi + 2\frac{\pi}{n}, \dots, -\pi + (n-1)\frac{\pi}{n}$ stačí sumy do $\frac{n}{2} - 1$ pro sinusové řady a $\frac{n}{2}$ pro kosinové – vyšší koeficienty v takových bodech jsou nulové. Takže n hodnot funkce f na intervalu $[-\pi,\pi]$ lze reprezentovat vektorem n čísel v bázi $1, \cos x, \dots, \cos \frac{n}{2}x, \sin x, \dots, \sin(\frac{n}{2}-1)x$.

Jednodušeji to lze ukázat v komplexních číslech – je známo, že

$$e^{ix} = \cos x + i \cdot \sin x$$

takže vektor hodnot funkce lze ekvivalentně reprezentovat v bázi $e^{i \cdot 2\pi \frac{k}{n}}$, $k \in \{0, \dots, n\}$, neboť všechny vektory původní báze lze zapsat jako lineární kombinace vektorů nové báze. Definujeme hodnotu

$$\omega := e^{i \cdot 2\pi \frac{1}{n}}$$
 (a to je vlastně "něco jako" $\sqrt[n]{1}$)

vidíme, že ω^k je n-periodická funkce, takže nezáleží na hranicích sumace $\left(-\frac{n}{2}+1,\ldots,\frac{n}{2}\right)$ je ekvivalentní $0,\ldots,n-1$). Potom se posloupnost n komplexních čísel $\alpha_0,\ldots,\alpha_{n-1}$ (např. hodnot naší funkce v bodech $-\pi+\frac{2\pi k}{n},\ k\in\{0,\ldots,n-1\}$) transformuje na posloupnost n komplexních čísel A_0,\ldots,A_{n-1} (do báze $\omega^i,\ i\in\{0,\ldots,n-1\}$) použitím vzorečku:

$$A_j = \sum_{k=0}^{n-1} \alpha_k \omega^{kj} \quad j = 0, \dots, n-1$$

Tento převod označujeme jako diskrétní Fourierovu transformaci.

Inverzní diskrétní Fourierova transformace je opačný problém – z n Fourierových koeficientů A_k chceme zpětně vypočítat hodnoty funkce α_k v bodech $-\pi + \frac{2\pi k}{n}$, $k \in \{0, \dots, n-1. \text{ Platí:} \}$

$$\alpha_j = \frac{1}{n} \sum_{k=0}^{n-1} A_k \omega^{-kj}$$
 $j = 0, \dots, n-1$

Důkaz

Definujeme matici $W:W_{p,q}=\omega^{pq}$, potom $A=W\alpha$ (vektorově), takže $a=W^{-1}A$. Definujeme $W':W'_{p,q}=\omega^{-pq}$ a dokážeme, že $W\cdot W'=n\cdot I_n$. Máme

$$(W \cdot W')_{p,q} = \sum_{s=0}^{n-1} W_{p,s} \cdot W'_{s,q} = \sum_{s=0}^{n-1} \omega^{(p-q) \cdot s}$$

a potom pro

- p = q platí $\sum_{s=0}^{n-1} \omega^{(p-q)\cdot s} = \sum_{s=0}^{n-1} \omega^0 = \sum_{s=0}^{n-1} 1 = n$
- $p \neq q$ definujeme

$$Q := \omega^{p-q}$$

a dostaneme geometrickou posloupnost $Q^0 + Q^1 + \cdots + Q^{n-1}$, pro jejíž součet prvních n členů platí vzorec

$$\sum_{s=0}^{n-1} Q^s = Q^0 \frac{Q^{n-1+1} - 1}{Q - 1} = 1 \frac{1 - 1}{Q - 1} = 0$$

${\bf Algoritmus} \ (\textit{Fast Fourier transform} \ (\textit{FFT}))$

Fast Fourier transform je algoritmus pro počítání diskrétní Fourierovy transformace vektorů rozměru $n=2^k$ v čase $\Theta(n \log n)$. Mám-li matici Fourierových koeficientů $W, W_{p,q} = \alpha_q \omega^{pq}$, mohu ji rozdělit na liché a sudé sloupce, u sudých vyjádřit ω^q a pro spodní polovinu řádek (se sumami jdoucími po dvou) mohu snížit exponent u ω o n/2 (díky periodicitě) a vyjdou stejná čísla:

$$A_j = \sum_{k=0}^{n-1} \alpha_k \omega^{kj}$$
 $j \in \{0, \dots, n-1\}$

$$A_{j} = \sum_{k=0}^{\frac{n}{2}-1} \alpha_{2k} \omega^{2kj} + \omega^{j} \sum_{k=0}^{\frac{n}{2}-1} \alpha_{2k+1} \omega^{2kj}$$
 $j \in \{0, \dots, \frac{n}{2}-1\}$

$$A_{j+\frac{n}{2}} = \sum_{k=0}^{\frac{n}{2}-1} \alpha_{2k} \omega^{2k(j+\frac{n}{2})} + \omega^{(j+\frac{n}{2})} \sum_{k=0}^{\frac{n}{2}-1} \alpha_{2k+1} \omega^{2k(j+\frac{n}{2})}$$
 $j \in \{0, \dots, \frac{n}{2}-1\}$

Poznámka: pro rychlé a jednoduché pochopení těch blektů co jsem tu napsal doporučuji Kučerův program Algovision http://kam.mff.cuni.cz/~ludek/AlgovisionPage.html DFT je tam názorně a přehledně ukázaná.

TODO: Související obecné "věci" o Fourierově transofrmaci, použití při spektrální analýze (Nyquist-Shannon sampling theorem), datové kompresi (Diskrétní kosinová transformace), násobení polynomů (+násobení velkých integerů).

Euklidův algoritmus

Euklidův algoritmus je postup (algoritmus), kterým lze určit největšího společného dělitele dvou přirozených čísel, tzn. nejvyšší číslo takové, že beze zbytku dělí obě čísla.

Algoritmus (pomocí rekurze):

```
function gcd(a, b)
   if b = 0 return a
   else return gcd(b, a mod b)
   Algoritmus (pomocí iterace):
function gcd(a, b)
   while b
   (soubor zde končí :-( )
```

3.11 Základy kryptografie, RSA, DES

Základy kryptografie¹²

♀ Definice (Kryptografický systém) **♀**

Prostor otevřených zpráv M, šifrovaných zpráv C, šifrovacích a dešifrovacích klíčů K a K'. Efektivní generování klíčů $G: N \to K \times K'$, šifrování $E: M \times K \to C$, dešifrování $D: C \times K' \to M$.

- Symetrické (sdílený klíč $k_e = k_d$) rychlé, krátké klíče, potreba menit klice a bezpecne si je vymenit
- Asymetrické (veřejný klíč $k_e \neq k_d$) delsi klice a pomalejsi nez symetrické, neni potřeba tajná výměna, neni potřeba tak často měnit klíče

Definice (Nahodné generátory)

Používají se pro generování klíčů pro šifry (např RSA) a v proudových šifrách.

- HW zařízení často založená na jevech generujících statisticky náhodné "šumové" signály, například z tepelného šumu polovodiče.
- SW jsou založeny na pozorování jevů v počítači z hlediska programu náhodných, často z uživatelského vstupu (např. PuTTYgen používá pro generování RSA klíče přejízdění myší).
- Pseudonáhodné jsou deterministické programy generující posloupnost čísel pokud možno nerozlišitelnou od náhodné.
 - př. kongruenční generátor: $X_{n+1} = (aX_n + c) modm$
 - používají se v proudových šifrách

Definice (Hashovaci funkce)

Funkci $h: U \to \{0, 1, \dots, m-1\}$ nazýváme **hašovací funkcí**. ¹³

Požadavky:

- Rovnoměrné a náhodné rozložení hodnot
- Odolnost na kolize (výpočetně složité najít pro $x \neq x \ h(x) = h(y)$)
- Jednosměrná funkce (výpočetně složité najít y k x pro h(x) = y)
- Efektivní algoritmus

Využití: CRC (kontrolní součet), ukládání hesel (MD5,SHA) ...

Definice (Model utocnika podle Doleva a Yao)

- Může získat libovolnou zprávu putující po síti
- Je právoplatným uživatelem sítě a tudíž může zahájit komunikaci s jiným uživatelem
- Může se stát příjemcem zpráv kohokoliv
- Může zasílat zprávy komukoliv zosobněním se za jiného uživatele
- Neumi rozume resit NP-uplne problemy (ani slozitejsi)¹⁴
- Bez správného klíče nemůže nalézt zprávu k šifrované zprávě a nemůže vytvořit platnou šifrovanou zprávu z dané zprávy,
 vše vzhledem k nějakému šifrovacímu algoritmu

Definice (Cile utoku)

důvěrnost dat uživatel může určit kdo má data vidět, a systém skutečně dovolí pracovat s daty pouze povoleným uživatelům celistvost dat možnost podstrčení falešných dat

dostupnost systému DoS (Denial of Service)

Příklad

Ukazku pouziti nejakeho sifrovaciho protokolu (zvolil jsem kombinace symetricka sifra sifrovani, asymetricka predani klicu k symetricke).

TODO

Definice (protokol Diffie-Hellman)

- Diffie-Hellman výmena klícu je kryptografický protokol, který umožnuje navázat bezpecné spojení. Pro bezpecné spojení je potreba si vymenit klíc k symetrické šifre pres ješte nezabezpecený kanál. Práve tento protokol to umožnuje aniž by byl klíc jednoduše poslán v otevrené forme.
- Alice si vymyslí velké prvocíslo p, generátor g konečné grupy $G = (Z_p^*, \cdot)$ a $a \in [1, p-1)$ vypocte A pošle Bobovi [g,p,A], Bob vypocte B a pošle ho Alici oba si vypocítají $K \Rightarrow$ muzou zacit symetricky sifrovanou komunikaci
- Puvodne nezabezpecoval autentifikaci ucastniku = nachylny k utoku man-in-the-middle. Man-in-the-middle muze vytvorit komunikaci s dvema ruznymi Diffie-Hellman klici, jeden s Alici a druhej s Bobem, a pak se tvarit jako Alice k Bobovi a obracene, treba pomoci dekodovani a rekodovani zprav mezi nimi. Nejaka metoda autentifikace mezi temito osobami je nutna.
- Problému nalezení císla a ze znalosti ga mod p se ríká problém diskrétního logaritmu. Tento problém je stále považován za velmi obtížný.

RSA (Rivest-Shamir-Adleman)

Asymetrická šifra (různé klíče pro šifrování a dešifrování), použitelná jako šifra s veřejným klíčem. Kryptoschéma je založeno na Eulerove formuli.

Alice a Bob se verejne dohodnou na hranici N a chtejí si vymenovat tajné zprávy $0 \le m < N$. Inicializace:

- 1. vybrat dvě dostatečně velká prvočísla p, q tak aby $n = p \cdot q < N$
- 2. Alice spočítá $\varphi(n)=(p-1)\cdot(q-1)$ (Eulerova funkce $\varphi(n)$ je počet čísel menších než n, která jsou s n nesoudělná)
- 3. vybrat etakové, že $1 < e < \varphi(n)$ a e je nesoudělné s $\varphi(n)$
 - dvojice (n, e) bude $ve\check{r}ejn\acute{y}$ klíč $(public\ key)$
- 4. vybrat d tak, aby

$$d \cdot e \equiv 1 \mod \varphi(n)$$

takové d lze najít rozšířeným euklidovým algoritmem

– dvojice (n,d) bude $de \check{s}ifrovac\acute{\iota}\ kl \acute{\iota}\check{c}\ (private\ key)$

Šifrování:

- 1. Alice posílá public key Bobovi (čísla n a e), nechává si private key
- 2. Bob chce Alici poslat zprávu m tak spočítá :

$$c = m^e \mod n$$

3. Bob odešle c Alici

Dešifrování:

- 1. Alice přijala c
- 2. Spočítá:

$$m = c^d \mod n$$

Šifra (to, že to vůbec funguje, tedy, že $m=(m^e)^d$) se opírá o několik netriviálních vět algebry...

- Pro reálné použití císla približne 100 až 200 bitu. Klíc e volíme jako prvocíslo vetší než (p-1) a (q-1). Hranice bezpecnosti pro modul n je N=1024 bitu, rozumné 1500 bitu, lépe 2048
- Není známa metoda vedoucí k rozbití tohoto algoritmu
- Slabostí je hypotetická možnost vytvorit elektronický podpis zprávy bez znalosti dešifrovacího klíce na základe zachycení vhodných predchozích zašifrovaných zpráv.
- například SSH protokol používá RSA klíče

 $^{^{12} {\}rm sestaveno}$ podle vrazedneho zkouseni Jaghobem

 $^{^{13} {\}rm viz}$ otázku Hašování

¹⁴tzn. i slabší: Nemůže odhadnout náhodné číslo z dostatečně velkého prostoru

3.12 Pravděpodobostní algoritmy – testování prvočíselnosti

(tato otázka nebyla asi nikdy zkoušena, a tak je to jenom takovy nástřel Zdroj: výborné Čepkovy slajdy na ADS2 - zda se ze je ocenuju az ted :))

Pravděpodobnostní (náhodnostní) algoritmy jsou nedeterministické algoritmy, které se snaží najít řešení rychleji nebo řešení těžko řešitelných problémů. Pravděpodobnostní algoritmus se může náhodně rozhodovat mezi různými možnostmi jak pokračovat. Pro stejný vstup může dávat takový algoritmus různé výsledky, které mohou být dokonce nesprávné. Mnohdy se tedy na daném vstupu spustí pravděpodobnostní algoritmus vícekrát, aby se s větší pravděpodobností dospělo ke správnému výsledku.

Pravděpodobnostních algoritmů je mnoho typů, zde zmíníme jen dva a to algoritmy typu Las Vegas a typu Monte Carlo.

Algoritmy typu Las Vegas

Výsledek je vždy správný, náhodnost ovlivňuje pouze dobu běhu algoritmu, tj. po jaké cestě se algoritmus ke správnému výsledku dobere.

Příklad (randomizovaný QuickSort)

Od deterministické verze se liší náhodnými výběry pivota při každém dělení posloupnosti, což poskytuje následující výhody

- dává dobrý průměrný čas (tj. $O(n \log n)$) i v případě, že data na vstupu nejsou náhodné permutace žádný vstup není apriori špatný (pro každý deterministický výběr pivota existují apriori špatné vstupy)
- může být spuštěn paralelně v několika kopiích, výsledek je získán z kopie, kde výpočet skončí nejdříve (pro deterministickou verzi nemá takový postup žádný smysl)

Algoritmy typu Monte Carlo

Náhodnost ovlivňuje jak dobu běhu, tak správnost výsledku: algoritmus může udělat chybu, ale pouze jednostranně (u odpovědí ANO/NE) a s omezenou pravděpodobností.

Příklad (Rabin-Millerův algoritmus na testování prvočíselnosti)

Pro zadané přirozené číslo n (rychle) rozhodnout zda je n prvočíslo

```
Věta (Malá Fermatova)
```

```
Nechť p je prvočíslo. Potom \forall k \in \{1, 2, \dots, p-1\} platí k^{p-1} \equiv 1 \pmod{p}
```

Pokud n není prvočíslo, tak zkusíme (náhodně) najít "svědka" k, porušujícího $k^{n-1} \equiv 1 \pmod{n}$, který "dosvědčuje", že n je opravdu číslo složené (není to prvočíslo). Problém - pro některá složená čísla je svědků příliš málo, takže je příliš malá pravděpodobnost, že nějakého svědka (náhodně) vybereme.

Definice

Nechť T je množina dvojic přirozených čísel, kde $(k, n) \in T$ pokud 0 < k < n a je splněna alespoň jedna z následujících dvou podmínek:

```
1. neplatí k^{n-1} \equiv 1 \pmod{n},
```

```
2. existuje i takové, že m = (n-1)/2^i je přirozené číslo a platí 1 < NSD(k^{m-1}-1,n) < n
```

Věta (1)

Číslo n je složené tehdy a jen tehdy, když existuje k takové, že $(k,n) \in T$.

Věta (2)

Nechť n je složené číslo. Pak existuje alespoň (n-1)/2 takových čísel k, pro které platí $(k,n) \in T$.

Algoritmus:

```
Rabin-Miller(n);
    for i:=1 to počet do
        ki := náhodné přirozené číslo z intervalu [1,n-1];
        if (ki,n) in T then Return(n je složené);
    Return(n je prvočíslo)
```

Pokud Rabin - Miller(n) rozhodne, že n je složené, tak je to zaručeně správný výsledek (byl nalezen "svědek"), pokud Rabin - Miller(n) rozhodne, že n je prvočíslo, tak se může jednat o chybu, ale pouze v případě, že všechna vybraná k_i byli "ne-svědci" pro složené číslo n, což ale může (díky Větě 2) nastat nejvýše s pravděpodobností

$$P(chyba) \le (1/2)^{pocet}$$

pokud jsou výběry jednotlivých k_i vzájemně nezávislé

Vlastnosti algoritmu:

- \bullet zvyšováním počtu iterací (počtu testovaných k_i) lze dostat libovolně malou (předem zvolenou) pravděpodobnost chyby
- \bullet jednotlivé iterace (testy pro různá k_i) lze provádět paralelně

Časová složitost:

každá iterace trvá jen polynomiálně vzhledem k délce zápisu čísla n (tj. k délce vstupu), k tomu je ovšem potřeba ukázat, že test zda $(k_i, n) \in T$ je možno provést v čase polynomiálním v log n, což není triviální (je nutné mít další znalosti z teorie čísel)

3.13 Aproximační algoritmy

(tato otázka asi nebyla nikdy zkoušena takže je to jenom takový nástřel, asi má cenu seto učit až když pochopíte NP-úplné problémy (hlavně kliku a rozvrh) Zdroj: Čepkovy slajdy na ADS2)

Aprox. algoritmy jsou vhodné tam, kde je nalezení optimálního řešení "beznadějné" (časově příliš náročné), typicky u NP-těžkých optimalizačních úloh (optimalizačních verzí NP-úplných rozhodovacích problémů). Mají následující tři vlastnosti:

- 1. konstruují suboptimální řešení
- 2. poskytují odhad kvality zkonstruovaného řešení vzhledem k optimu
- 3. běží v polynomiálním čase (jinak nejsou zajímavé)

Příklad (maximalizační úlohy (optimalizační verze KLIKY))

Pro daný neorientovaný graf najdi největší (počtem vrcholů) kliku (úplný podgraf). Po aproximačním algoritmu chceme garanci typu $f(APROX) \ge \frac{3}{4}f(OPT)$, kde f(X) je v tomto případě počet vrcholů (tj. velikost kliky) v řešení X, OPT je optimální řešení a APROX je řešení vydané aproximačním algoritmem.

Příklad (*Příklad minimalizační úlohy (optimalizační verze ROZ*))

Rozvrh na paralel. strojích. Pro dané úkoly a daný počet strojů najdi nejkratší rozvrh. Po aproximačním algoritmu chceme garanci typu $f(APROX) \leq 2f(OPT)$.

Definice

Chyba aproximačního algoritmu je definována jako poměr (podíl) f(APROX)/f(OPT) pro minimalizační úlohy a f(OPT)/f(APROX) pro maximalizační úlohy. Relativní chyba je pak definována jako |f(APROX)f(OPT)|/f(OPT).

Algoritmus (Naivní aproximační algoritmus FRONTA)

pro optimalizační verzi ROZ: bere úkoly postupně podle jejich čísel a každý úkol vždy umístí na stroj, který je volný nejdříve.

Značení:

OPT = optimální rozvrh, Q = rozvrh zkonstruovaný algoritmem FRONTA, délka(OPT) = o, délka(Q) = q

Věta

Pokud m je počet strojů, tak $q \leq ((2m-1)/m)o$ a tento odhad již nelze zlepšit.

Důkaz. důkazy všech vět z této kapitoly najdete třeba u hippiese:

http://hippies.matfyz.info/poznamky/predmet_ads2/gallery.php?ID=28

Důsledek

Aproximační algoritmus FRONTA má poměrovou chybu 2.

 $D\mathring{u}kaz$. 1. Těsnost odhadu: Pro každé m zkonstruujeme zadání, pro které platí v dokazované nerovnosti rovnost, a to následujícím způsobem

```
x_1 = x_2 = \ldots = x_{m-1} = m-1 \ (m-1 \text{ úkolů délky } m-1)

x_m = x_{m+1} = \ldots = x_{2m-2} = 1 \ (m-1 \text{ úkolů délky } 1)

x_{2m-1} = m \ (1 \text{ úkol délky } m)
```

2. Platnost nerovnosti: Nechť j je úkol končící jako poslední v rozvrhu Q (končící v čase q) a nechť t je okamžik zahájení úkolu j. Potom žádný procesor nemá prostoj před časem t a platí $mq \leq (2m-1)o$.

Algoritmus (Lepší aproximační algoritmus USPOŘÁDANÁ FRONTA)

pro optimalizační verzi ROZ: pracuje stejně jako FRONTA, ale na začátku úkoly setřídí do nerostoucí posloupnosti podle jejich délek.

Značení:

```
OPT = optimální rozvrh,

U = rozvrh zkonstruovaný algoritmem USPOŘÁDANÁ FRONTA,

délka(OPT) = o, délka(U) = u
```

Věta

Pokud m je počet strojů, tak $u \leq ((4m-1)/3m)o$ a tento odhad již nelze zlepšit.

Důsledek

Aproximační algoritmus USPOŘÁDANÁ FRONTA má poměrovou chybu 4/3.

 $D\mathring{u}kaz$. Těsnost odhadu: Pro každé liché m zkonstruujeme zadání, pro které platí v dokazované nerovnosti rovnost, a to následujícím způsobem

```
\begin{array}{l} x_1 = x_2 = 2m-1 \ (2 \ \text{úkoly délky} \ 2m-1) \\ x_3 = x_4 = 2m-2 \ (2 \ \text{úkoly délky} \ 2m-2) \\ x_{2m-3} = x_{2m-2} = m+1 \ (2 \ \text{úkoly délky} \ m+1) \\ x_{2m-1} = x_{2m} = x_{2m+1} = m \ (3 \ \text{úkoly délky} \ m) \end{array}
```

Lemma

Pokud pro všechny úkoly platí $x_i \leq 1/3o$ pak u = o.

Dokončení důkazu: Nechť j je úkol končící jako poslední v rozvrhu U (končící v čase u). Pokud $x_j > 1/3o$ tak použijeme Lemma, v opačném případě je důkaz velmi podobný jako pro algoritmus FRONTA.

4 Databáze

Požadavky

- Podstata a architektury DB systémů.
- Konceptuální, logická a fyzická úroveň pohledů na data.
- Relační datový model, relační algebra.
- Algoritmy návrhu schémat relací, normální formy, referenční integrita.
- Základy SQL.
- Transakční zpracování, vlastnosti transakcí.
- Organizace dat na vnější paměti, B-stromy a jejich varianty.

4.1 Podstata a architektury DB systemů

Zdroje: Wikipedie, slidy Dr. T. Skopala k Databázovým systémům

Definice (Databáze)

Databáze je logicky uspořádaná (integrovaná) kolekce navzájem souvisejících dat. Je sebevysvětlující, protože data jsou uchovávána společně s popisy, známými jako metadata (také schéma databáze). Data jsou ukládána tak, aby na nich bylo možné provádět strojové dotazy – získat pro nějaké parametry vyhovující podmnožinu záznamů.

Někdy se slovem "databáze" myslí obecně celý databázový systém.

Definice (Systém řízení báze dat)

Systém řízení báze dat (SŘBD, anglicky database management system, DBMS) je obecný softwarový systém, který řídí sdílený přístup k databázi, a poskytuje mechanismy, pomáhající zajistit bezpečnost a integritu uložených dat. Spravuje databázi a zajišťuje provádění dotazů.

Definice (Databázový systém)

Databázovým systémem rozumíme trojici, sestávající z:

- databáze
- systému řízení báze dat
- chudáka admina

Smysl databází

Hlavním smyslem databáze je schraňovat datové záznamy a informace za účelem:

- sdílení dat více uživateli,
- zajištění unifikovaného rozhraní a jazyků definice dat a manipulace s daty,
- znovuvyužitelnosti dat,
- bezespornosti dat a
- snížení objemu dat (odstranění redundance).

Databázové modely

Definice (schéma, model)

Typicky pro každou databázi existuje strukturální popis druhů dat v ní udržovaných, ten nazýváme *schéma*. Schéma popisuje objekty reprezentované v databázi a vztahy mezi nimi. Je několik možných způsobů organizace schémat (modelování databázové struktury), známých jako *modely*. V modelu jde nejen o způsob strukturování dat, definuje se také sada operací nad daty proveditelná. Relační model například definuje operace jako "select" nebo "join". I když tyto operace se nemusejí přímo vyskytovat v dotazovacím jazyce, tvoří základ, na kterém je jazyk postaven. Nejdůležitější modely v této sekci popíšeme.

Poznámka

Většina databázových systémů je založena na jednom konkrétním modelu, ale čím dál častější je podpora více přístupů. Pro každý logický model existuje více fyzických přístupů implementace a většina systémů dovolí uživateli nějakou úroveň jejich kontroly a úprav, protože toto má velký vliv na výkon systému. Příkladem nechť jsou indexy, provozované nad relačním modelem.

"Plochý" model

Toto sice nevyhovuje úplně definici modelu, přesto se jako triviální případ uvádí. Představuje jedinou dvoudimensionální tabulku, kde data v jednom sloupci jsou považována za popis stejné vlastnosti (takže mají podobné hodnoty) a data v jednom řádku se uvažují jako popis jediného objektu.

Relační model

Relační model je založen na predikátové logice a teorii množin. Většina fyzicky implementovaných databázových systémů ve skutečnosti používá jen aproximaci matematicky definovaného relačního modelu. Jeho základem jsou relace (dvoudimensionální tabulky), atributy (jejich pojmenované sloupce) a domény (množiny hodnot, které se ve sloupcích můžou objevit). Hlavní datovou strukturou je tabulka, kde se nachází informace o nějaké konkrétní třídě entit. Každá entita té třídy je potom reprezentována řádkem v tabulce – n-ticí atributů.

Všechny relace (tj. tabulky) musí splňovat základní pravidla – pořadí sloupců nesmí hrát roli, v tabulce se nesmí vyskytovat identické řádky a každý řádek musí obsahovat jen jednu hodnotu pro každý svůj atribut. Relační databáze obsahuje více tabulek, mezi kterými lze popisovat vztahy (všech různých kardinalit, tj. 1:1,1:n apod.). Vztahy vznikají i implicitně např. uložením stejné hodnoty jednoho atributu do dvou řádků v tabulce. K tabulkám lze přidat informaci o tom, která podmnožina atributů funguje jako klíč, tj. unikátně identifikuje každý řádek, některý z klíčů může být označen jako primární. Některé klíče můžou mít nějaký vztah k vnějšímu světu, jiné jsou jen pro vnitřní potřeby schématu databáze (generovaná ID).

Hierarchický model

V hierarchickém modelu jsou data organizována do stromové struktury – každý uzel má odkaz na nadřízený (k popisu hierarchie) a setříděné pole záznamů na stejné úrovni. Tyto struktury byly používány ve starých mainframeových databázích, nyní je můžeme vidět např ve struktuře XML dokumentů. Dovolují vztahy 1 : N mezi dvěma druhy dat, což je velice efektivní k popisu různých reálných vztahů (obsahy, řazení odstavců textu, tříděné informace). Nevýhodou je ale nutnost znát celou cestu k záznamu ve struktuře a neschopnost systému reprezentovat redundance v datech (strom nemá cykly).

Síťový model

Síťový model organizuje data pomocí dvou hlavních prvků, záznamů a množin. Záznamy obsahují pole dat, množiny definují vztahy 1:N mezi záznamy (jeden vlastník, mnoho prvků). Záznam může být vlastníkem i prvkem v několika různých množinách. Jde vlastně o variantu hierarchického modelu, protože síťový model je také založen na konceptu více struktur nižší úrovně závislých na strukturách úrovně vyšší. Už ale umožňuje reprezentovat i redundantní data. Operace nad tímto modelem probíhají "navigačním" stylem: program si uchovává svoji současnou pozici mezi záznamy a postupuje podle závislostí, ve kterých se daný záznam náchází. Záznamy mohou být i vyhledávány podle klíče.

Fyzicky jsou většinou množiny – vztahy – reprezentovány přímo ukazateli na umístění dat na disku, což zajišťuje vysoký výkon při vyhledávání, ale zvyšuje náklady na reorganizace. Smysl síťové navigace mezi objekty se používá i v objektových modelech.

Objektový model

Objektový model je aplikací přístupů známých z objektově-orientovaného programování. Je založen na sbližování programové aplikace a databáze, hlavně ve smyslu použití datových typů (objektů) definovaných na jednom místě; ty zpřístupňuje k použití v nějakém běžném programovacím jazyce. Odstraní se tak nutnost zbytečných konverzí dat. Přináší do databází také věci jako zapouzdření nebo polymorfismus. Problémem objektových modelů je neexistence standardů (nebo spíš produktů, které by je implementovaly).

Kombinací objektového a relačního přístupu vznikají *objektově-relační* databáze – relační databáze, dovolující uživateli definovat vlastní datové typy a operace na nich. Obsahují pak hybrid mezi procedurálním a dotazovacím programovacím jazykem.

Architektury databázových systémů

Zdroj: Wiki ČVUT (státnice na FELu ;-))

Architektury databázových systémů se obecně dělí na

- centralizované (kde se databáze předpokládá fyzicky na jednom počítači) a
- distribuované,

případně na

- jednouživatelské a
- víceuživatelské.

Distribuované databázové systémy

Distribuovaný systém řízení báze dat je vlastně speciálním případem obecného distribuovaného výpočetního systému. Jeho implementace zahrnuje fyzické rozložení dat (včetně možných replikací databáze) na více počítačů – uzlů, přičemž jejich popis je integrován v globálním databázovém schématu. Data v uzlech mohou být zpracovávána lokálními SŘBD, komunikace je organizována v síťovém provozu pomocí speciálního softwaru, který umí zacházet s distribuovanými daty. Fyzicky se řeší rozložení do uzlů, svázaných komunikačními kanály, a jeho transparence (neviditelnost – navenek se má tvářit jako jednolitý systém). Každý uzel v síti je sám o sobě databázový systém a z každého uzlu lze zpřístupnit data kdekoliv v síti.

Dále se dělí na dva typy:

- Federativní databáze neexistuje globální schéma ani centrální řídící autorita, řízení je také distribuované.
- Heterogenní databázové systémy jednotlivé autonomní SŘBD existují (vznikly nezávisle na sobě) a jsou integrovány, aby spolu mohly komunikovat.

Výhodou oproti centralizovaným systémům je vyšší efektivita (data mohou být uložena blízko místa nejčastějšího používání), zvýšená dostupnost, výkonnost a rozšiřitelnost; nevýhodou zůstává problém složitosti implementace, distribuce řízení a nižší bezpečnost takových řešení.

Víceuživatelské databázové systémy

Víceuživatelské jsou takové systémy, které umožňují vícenásobný uživatelský přístup k datům ve stejném okamžiku. V důsledku možného současného přístupu více uživatelů je nutné systém zabezpečit tak, aby i nadále zajišťoval integritu a konzistenci uložených dat. Existují obecně dva možné přístupy:

- Uzamykání Dříve často používaná metoda založená na uzamykání aktualizovaných záznamů, v případě masivního využití aktualizačních příkazů u ní ale může docházet k značným prodlevám.
- Multiversion Concurency Control Modernější vynález. Jeho princip spočívá v tom, že při požadavku o aktualizaci záznamu v tabulce je vytvořena kopie záznamu, která není pro ostatní uživatele až do provedeného commitu viditelná.

4.2 Konceptualní, logická a fyzická úroveň pohledu na data

TODO: sjednotit terminologii, snad to popisuje to co tu má být, ale zdroje jsou pochybné (Wikipedie tady neodvádí zrovna ideální práci a ČVUT Wiki se moc nerozepisuje).

Definice (Datové modelování)

Datové modelování je proces vytvoření konkrétního datového modelu (schématu) databáze pomocí aplikace nějakého abstraktního databázového modelu. Datové modelování zahrnuje kromě definice struktury a organizace dat ještě další implictiní nebo explicitní omezení na data do struktury ukládaná.

Vrstvy modelování

Druhy datových modelů mohou být tří typů, podle tří různých pohledů na databáze (tři "vrstvy", které se navzájem doplňují):

- konceptuální schéma (datový model) nejabstraktnější, popisuje význam organizace databáze třídy entit a jejich vztahy.
- logické schéma popisuje význam konceptuálního schématu z hlediska databázové implementace popisy tabulek, programových tříd nebo XML tagů (podle zvoleného databázového modelu)
- fyzické schéma nejkonkrétnější, popisuje fyzické uložení dat a stroje na kterých systém poběží.

Na tomto rozdělení je důležitá nezávislost jednotlivých vrstev – takže se implementace jedné z nich může změnit, aniž by bylo nutné výrazně upravovat ostatní (samozřejmě musí zůstat konzistetní vzhledem k ostatním vrstvám). Během implementace nějaké databázové aplikace se začíná vytvořením konceptuálního schématu, pokračuje jeho upřesnění logickým schématem a naknec jeho fyzickou implementací podle fyzického schématu (modelu).

Poznámka

V tomto pohledu (který je podle standardu ANSI z r. 1975) jsou databázové modely, popsané v předchozí sekci, příklady abstraktních logických datových modelů. Někde je však tato úroveň označována jako "fyzická" a "jiná logická" se vtěsní ještě mezi ni a konceptuální.

Konceptuální schéma

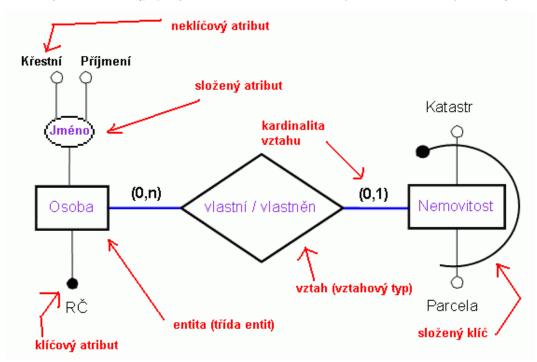
Konceptuální schéma (datový model) popisuje podstatné objekty (*třídy entit*, "koncepty"), jejich charakteristiky (*atributy*) a vztahy mezi nimi (asociace mezi dvojicemi tříd entit). Nepopisuje přímo implementaci v databázi, jen význam nějakého celku, který bude databází představován. Jde o modelování "datové reality", z pohledu uživatele (analytika, konstruktéra databáze).

Příklady

Pár příkladů vztahů mezi třídami entit (z Wikipedie):

- Each PERSON may be the vendor in one or more ORDERS.
- Each ORDER must be from one and only one PERSON.
- PERSON is a sub-type of PARTY. (Meaning that every instance of PERSON is also an instance of PARTY.)

De-facto standardem pro konceptuální datové modelování jsou *ER-diagramy* (entity-relationship diagramy). Hodí se hlavně pro "plochá" formátovaná data (takže třeba pro objektové nebo relační databáze, ale ne pro XML apod.). Používají dva typy "objektů" – *entity* (třídy entit) a *vztahy*. Jde o obdobu UML z objektového programování. Příklad ER-diagramu se vztahem dvou entit je na následujícím obrázku (popisuje i další vlastnosti – atributy entit a kardinality vztahů):



(Obrázek je upravený, rozšířený a popsaný příklad ze slidů Dr. T. Skopala k Databázovým systémům)

Logické schéma

Logické schéma je datový model organizace nějakého specifického celku pomocí jednoho z databázových modelů – podle databázových modelů popsaných v předchozí sekci, tj. např. pomocí relačních tabulek, objektových tříd nebo XML. Svojí úrovní abstrakce se nachází mezi konceptuálním a fyzickým schématem.

Fyzické schéma

Fyzické datové modely jsou modely, ktere používají databazové stroje směrem k nižším vrstvám (operačního) systému. V zásadě jde o různé způsoby fyzického uložení dat (tedy schémata organizace souborů) – sekvenční soubory, B-stromy apod.

4.3 Relační datový model, relační algebra

Definice (Relační datový model)

Relační schéma je n-tice $R(A_1:D_1,A_2:D_2,...,A_n:D_n)$, kde množiny D_i jsou tzv. (atributové) domény (odpovídá dat.typům v tabulkách) - uvádějí se nepovinně, množina A_i je atribut (odpovídá sloupci hodnot v tabulce) dále definujme $relaci^{15}$ $R \subseteq A_1 \times A_2...A_n$ jako množinu n-tic $(a_1,a_2,...,a_n)$ (odpovídá konktrétním datům v tabulce) kde $a_i \in A_i$ a prvek $relace\ r \in R$ (odpovídá řádku v tabulce).

```
Příklad (Relační datový model)
```

```
definujeme atributy:
```

Definice (Relační algebra)

Relační algebra je množina operací (unárních, či binárních) na relacích se schématy, jejichž výsledkem je opět relace (a její schéma). Deklarativní dotazovací jazyk – tj. neprocedurální, nicméně struktura výrazu navádí na pořadí a způsob vyhodnocení. Výsledkem je vždy konečná relace – "bezpečně" definované operace.

Definice (Operace)

Nezbytné operace pro zachování vyjadřovací síly jazyka:

zákazník-schéma (jméno:string, ulice:string, město:string)

- přejmenování unární operace, pouze se přejmenují atributy schématu, s daty se nic neděje (tj. výslekem je stejná relace a stejné schéma, pouze příslušné atributy mají jiná jména)
 - $\langle R, R(A_i \to B_i, A_j \to B_j, ...) \rangle$
- sjednocení schémata musí mít stejny počet atributů a kompatibilní domény $\langle R_1, R_1(A) \rangle \cup \langle R_2, R_2(A) \rangle = \langle R_1 \cup R_2, R_x(A) \rangle$
- rozdíl množin schémata musí mít stejny počet atributů a kompatibilní domény $< R_1, R_1(A) > < R_2, R_2(A) > = < R_1 R_2, R_2(A) >$
- kartézský součin vyžaduje disjuktní schemata, pokud existují stejná jména atributů musí se nejdříve přejmenovat $\langle R_1, R_1(A) \rangle \times \langle R_2, R_2(B) \rangle = \langle R_1 \times R_2, R_x(\{R_1\} \times A \cup \{R_2\} \times B) \rangle$
 - –zde je vhodné si všimnout pravé strany tím že Skopal ve schématu provedl kartézský součin množiny atributů s jeno-prvkovou množinou " R_1 " vlastně přejmenoval atributy na " R_1A_1, R_2A_2, \dots " aby nám ve výsledném schématu nevznikly atributy s totožným jménem

Α	В	С	D	Ε
α	1	α	10	+
β	2	β	10	+
-	r	β	20	-
		γ	10	-
			.5	

I	$r \times s$				
	Α	В	С	D	E
	α	1	α	10	+
	α	1	β	10	+
	α	1	β	20	-
	α	1	γ	10	-
	β	2	α	10	+
	β	2	β	10	+
	β	2	β	20	-
	β	2	γ	10	-

příklad kart.součinu

• selekce - výběr těch prvků u relace z R, které splňují logickou podmínku $\varphi(u)$ – podmínka je zadána Boolským výrazem (tj. pomocí spojek and, or, not) atomických formulí $t_1\Theta t_2$ nebo $t_1\Theta a$, kde $\Theta \in \{<,>,=,\geq,\leq,\neq\}$ a t_i jsou jména atributů $\langle R(\varphi), R(A) \rangle = \langle \{u|u \in R \& \varphi(u)\}, R(A) \rangle$

 $^{^{15}}$ ano R - relace je něco jiného než R(A) - relační schéma, Skopal bohužel používá toto trošku matoucí značení

• **projekce** - u[C] je prvek relace zbavený hodnot atributů $A \setminus C$, případné duplicitní prvky jsou odstraněny $\langle R[C], R(A) \rangle = \langle \{u[C] \in R\}, R(C) \rangle$ kde $C \subseteq A$

Α	В	С
α	10	1
α	20	1
β	30	1
β	40	2

Α	С		Α	С
α	1		α	1
α	1	=	β	1
β	1		β	2
β	2			

příklad projekce pro R[A, C]

Operace vzniklé skládáním základních operací:

• průnik - schémata musí mít stejny počet atributů a kompatibilní domény $< R_1, R_1(A) > \cap < R_2, R_2(A) > = < R_1 \cap R_2, R_x(A) >$

–dá se vyjádřit také jako: $R_1 \cap R_2 = (R_1 \cup R_2 \setminus (R_1 \setminus R_2)) \setminus (R_1 \setminus R_2)$

• přirozené spojení (natural join) - spojení prvků relace přes stejné hodnoty všech atributů sdílených mezi A a B, –pokud $A \cap B = \emptyset$, přirozené spojení je vlastně kartézský součin (spojuje se přes prázdnou množinu, tj. libovolně –"všechno se vším")

–pokud A=B, přirozené spojení je průnik (spojí se pouze stejné řádky)

 $< R, R(A) > * < S, S(B) > = < \{u | u[A] \in R \& u[B] \in S\}, R_x(A \cup B) >$

-lze vyjádřit pomocí kartézského součinu, selekce a projekce

Α	В	С	D
α	1	α	а
β	2	γ	а
γ	4	β	b
α	1	γ	а
δ	2	β	b

В	D	E
1	а	α
3	а	β
1	а	γ
2	b	δ
3	b	ε
	s	

1	'MS				
	Α	В	С	D	Е
	α	1	α	а	α
	α	1	α	а	γ
	α	1	γ	а	α
	α	1	γ	а	γ
	δ	2	β	b	δ

příklad přirozeného spojení

 \bullet dělení - definujeme si \oplus jako zřetězení řádků

$$< R, R(A) > \div < S, S(B \subset A) > = < \{t | \forall s \in S : (t \oplus s) \in R\}, R_x(A - B) > -$$
lze vyjádřit pomocí kartézského součinu a projekce:

 $R \div S = R[A \setminus B] \setminus ((R[A \setminus B] \times S) \setminus R)[A \setminus B]$

Α	В		
α	1		
α	2		
α	3		
β	1		
γ	1		
δ	1		
δ	3		
δ	4		
δ	6		
ε	1		
ε	2		

В	
1	
2	
S	

příklad dělení

Poznámka (Relační úplnost)

Jestliže dva výrazy označují stejný dotaz, jsou oba výrazy ekvivalentní. Dotazovací jazyk, kterým lze vyjádřit všechny konstrukce relační algebry (tj. všechny dotazy, které lze popsat relační algebrou) se nazývá relačně úplný.

Definice (Relační kalkulus)

 $Využití \ aparátu \ predikátové \ logiky \ 1. \ řádu \ pro \ dotazování. \ Rozšíření \ o \ "databázové" \ predikáty, jejichž \ dvojí \ forma \ definuje:$

-doménový kalkul (DRK) -pracuje s daty na úrovni atributů

-n-ticový kalkul (NRK) -pracuje s daty na úrovni n-tic (prvků relace/řádků)

Výsledkem dotazu v DRK / NRK je opět relace (a její schéma).

Příklad (srovnání RA, DRK, NRK)

definujeme rel.schémata:

FILM(JMENO_FILMU, JMENO_HERCE)
HEREC(JMENO_HERCE, ROK_NAROZENI)

a dotaz je: Ve kterých filmech hráli všichni herci?

RA:

 $FILM \div HEREC[JMENO_HERCE]$

DRK:

 $\{(f)|FILM(f) \land \forall h(HEREC(h) \Rightarrow FILM(f,h))\}$

NRK:

 $\{film[JMENO_FILMU] \mid \forall herec(HEREC(herec) \Rightarrow f(FILM(f) \land f.JMENO_HERCE = herec.JMENO_HERCE \land f.JMENO_FILMU = film.JMENO_FILMU))\}$

Report (IOI 10.2.2011)

- a) Popište relacní datový model. Co je relacní algebra a k cemu slouzi?
- b) Jaké znáte operace RA? Formulujte predpoklady pouzitelnosti kazdé operace. Definujte vysledek dané operace nad relacemi.
- c) Které operace jsou nezbytné pro zachovaní vyjadrovaci sily jazyka respektive, je mozné nekteré operace formulovat pomoci ostatních operaci? Které a jak?

Report (IOI 21.6.2011)

Co je to relační algebra a jaké operace používá?

- 5.2 U každé operace popište schéma relace, na které se dá tato operace použít a definujte výsledek operace.
- 5.3 Jsou všechny operace nezbytné pro zachování vyjadřovací síly jazyka? (Pokud ne, které jsou?)
- 5.4 Čemu odpovídá operace přirozené spojení na relacích, které mají totožné schéma?
- 5.5 Čemu odpovídá operace přirozené spojení na relacích, jejichž schémata jsou disjunktní?

4.4 Algoritmy návrhu schémat relací

Normální formy

Normalizace, anomálie

Normalizace databází je technika návrhu relačních databázových tabulek, pri které se minimalizují duplicity informací - a zamezuje se tak nekonzistentnosti dat. Stupně normalizace se "popisují" pomocí normálních forem - čím vyšší forma, tým vyšší striktnost...

Problémy řešené normalizací:

- update anomaly pokud se změní jedna kopie redundantních dat, je třeba změnit i ostatní kopie, jinak se databáze stane nekonzistentní, př.: tabulka (člověk, adresa, skill); kdyby se nevykonal update správně, může tabulka zůstat v nekonzistentním stavu (např. by se mohly změnit jen některé adresy jednoho člověka)
- insertion anomaly při vložení dat příslušejících jedné entitě je potřeba zároveň vložit data i o jiné entitě, např. v tabulce (fakulta, datum založení, kurz) můžeme zaznamenat jen data pro fakulty, které mají kurzy...
- deletion anomaly Při vymazání dat příslušejících jedné entitě je potřeba vymazat data patřící jiné entitě. V předchozí tabulce bude fakulta vymazána úplně, když se všemi kurzy.

Ideálně by relační databáze měla být navržena tak, aby vylučovala možnost takových anomalií. Normalizace obvykle zahrňuje dekomponování nenormalizované tabulky na dvě nebo více tabulek takových, že po jejich spojení (join) dostaneme všechny původní informace.

Abychom mohli definovat normální formy, potřebujeme znát funkční závislosti jednotlivých atributů entit relační databáze a vědět, které atributy jsou klíčové a které ne.

Definice (Funkční závislosti)

Řekneme, že atribut B je **funkčně závislý** na atributu A (značíme $A \to B$), jestliže pro každou hodnotu atributu A existuje právě jedna hodnota atributu B. Rozšířené funkční závislosti se definují pro množinu atributů (pro každou n-tici atributů z nějaké množiny existuje právě jedna hodnota závislého(závislých) atributu(atributů)).

Funkční závislosti splňují tzv. $Armstrongova\ pravidla$, což zahrnuje pro množiny atributů X,Y,Z:

- 1. triviální závislost: $X \supseteq Y \implies X \to Y$
- 2. transitivitu: $X \to Y \land Y \to Z \implies X \to Z$
- 3. kompozici: $X \to Y \land X \to Z \implies X \to YZ$
- 4. dekompozici: $X \to YZ \implies X \to Y \land X \to Z$

Definice (Klíč)

Nadklíčem, někdy též **superklíčem**, schématu *A* rozumíme každou podmnožinu množiny *A*, na níž *A* funkčně závisí. Jinak řečeno nadklíč je množina atributů, která jednoznačně určuje řádek tabulky.

 \mathbf{K} líč, nebo také **potenciální klíč** (candidate key), schématu A je takový nadklíč schématu A, jehož žádná vlastní podmnožina není nadklíčem A. Čili minimální nadklíč.

Každý atribut, který je obsažen alespoň v jednom potenciálním klíči se nazývá klíčový, ostatní atributy jsou neklíčové.

Definice (Normální formy)

- První normální forma
 - Tabulka je v první normální formě, jestliže lze do každého pole dosadit pouze jednoduchý datový typ (jsou dále nedělitelné). To zahrnuje i neexistenci více sloupců tabulky se stejným druhem obsahu:

$$\left.\begin{array}{l} (\text{manager, podřízený1, podřízený2, podřízený3}) \\ (\text{manager, podřízení-vice_hodnot_v_jednom_sloupci}) \end{array}\right\} \rightarrow \left(\text{manager, podřízený}\right)$$

- Druhá normální forma
 - Existuje klíč a všechna neklíčová pole jsou funkcí celého klíče (a tedy ne jen jeho částí).

$$(custID, \, name, \, address, \, city, \, state, \, zip) \rightarrow \\ (custID, \, name, \, address, \, zip) \\ + (zip, \, city, \, state)$$

- Třetí normální forma
 - Tabulka je ve třetí normální formě, jestliže každý neklíčový atribut není transitivně závislý na žádném klíči schématu (resp. každý neklíčový atribut je přímo závislý na klíči schématu) neboli je-li ve druhé normální formě a zároveň neexistuje jediná závislost neklíčových sloupců tabulky.

$$(deptID, deptName, managerID, hireDate) \rightarrow (deptID, deptName, managerID)$$

Atribut "hireDate" je sice funkčně závislý na klíči deptID, ale jen proto, že hireDate závisí na managerID, které závisí na deptID.

- Boyce-Coddova normální forma
 - Pro každou netriviální závislost $X \to Y$ platí, že X obsahuje klíč schématu R (X je nadklíč).

Algoritmy návrhu schémat relací

Schémata relací by měla být navrhována tak, aby odpovídala předem připravenému konceptuálnímu modelu (např. pomocí ER diagramů) a zároveň pokud možno splňovala co nejpřísnější požadavky na normální formy. Pro modelování relační databáze existují dva přístupy:

- 1. Získání množiny relačních schémat (ručně nebo převodem z např. ER diagramu) a provádění normalizace pro každou tabulku zvlášť
- 2. Návrh tzv. univerzálního schématu databáze jedna velká tabulka pro celou databázi (vč. platných funkčních závislostí) a normalizace prováděná globálně

První možnost je relativně intuitivní (s ER diagramy) a jednoduchá, ale hrozí riziko přílišného rozdrobení databáze na velký počet malých tabulek (a nadbytečný i vzhledem k požadované normální formě). V druhém způsobu jsou entity jednotlivých relací "vypozorovány" jako efekt funkčních závislostí, což není příliš průhledné a jednoduše proveditelné, ale minimalizuje to šanci na rozdrobení databáze. Oba přístupy lze také zkombinovat – převést ER model databáze do schémat a některá (nebo až všechna) potom před normalizací sloučit.

Normalizace

Jediným způsobem, jak u nějakého obecného relačního schématu dosáhnout normální formy (obecně se požaduje většinou 3NF nebo BCNF), je rozdělení na několik podschémat. Dá se to provést ručně nebo algoritmicky a existuje více přístupů podle požadavku na normální formu, bezztrátovost (dekompozice relace R(A,F) do $R_1(A_1,F_1)$ a $R_2(A_2,F_2)$ je bezeztrátová, když $A1 \cap A2 \to A1$ nebo $A1 \cap A2 \to A2$, tedy opětovným spojením do původní relace nevzniknou další řádky) nebo pokrytí závislostí (dekompozice R(A,F) do $R_1(A_1,F_1)$ zachovává pokrytí závislostí, když $F^+ = F_1^+ \cup F_2^+$ – nesmí se ztratit závislost ani v rámci dílčího schématu, ani jdoucí napříč schématy).

Algoritmus (Dekompozice)

Dekompozice je algoritmus, který relační schéma převede do Boyce-Coddovy normální formy. Zaručuje zachování bezeztrátovosti, ale už ne pokrytí závislostí (bez ohledu na algoritmus toto u BCNF někdy není možné). Jeho běh vypadá následovně:

- 1. Vyber nějaké schéma, které není v BCNF.
- 2. Vezmi pro něj neklíčovou závislost $X \to Y$ (tak že X není klíč) a dekomponuj podle ní vyhoď ze schématu Y a dej XY do zvláštní tabulky.
- 3. Opakuj od kroku 1, dokud existuje schéma, které není v BCNF.

Algoritmus (Syntéza)

Algoritmus syntézy obecně dosahuje třetí normální formy a zachovává pokrytí závislostí (ale ne bezeztrátovost). Pro relační schéma R s množinou funkčních závislostí F vypadá následovně:

- 1. Udělej minimální pokrytí F (vzhledem k tranzitivitě), nazvi ho G.
- 2. Sluč funkční závislosti zG se stejnou levou stranou a z každé vytvoř jedno schéma.
- 3. Zahoď schémata, která jsou podmnožiny jiných.

Nakonec je možné sloučit schémata s funkčně ekviv. klíči ($K1 \leftrightarrow K2$), ale může to porušit normální formu, které bylo dosaženo! Pro zachování bezeztrátovosti lze do přidat nějaké schéma, obsahující univerzální klíč celého původního (neděleného) schématu.

Poznámka

Pro nalezení minimálního pokrytí atributů se používá pomocný algoritmus, který se chová takto:

- 1. Dekomponuj všechny funkční závislosti na elementární (na pravé straně je jen jeden sloupec)
- 2. Odstraň z nich redundantní atributy (takové z levé strany, které funkčně závisí na jiných z levé strany)
- 3. Odstraň redundantní funkční závislosti (tj. takové, které jsou tranzitivním důsledkem jiných pravá strana funkčně závisí na levé, i když z množiny funkčních závislostí onu redundantní odstraním)

Pro druhý i třetí krok je potřeba získat *atributový uzávěr* (množina všech atributů i tranzitivně závislých na levé straně) – to se opakovaně zkouší, jestli díky funkčním závislostem nedostanu z atributů původní množiny nějaké další atributy (dokud nacházím další, přidávám je do množiny a opakuji).

Referenční integrita

- pomáhá udržovat vztahy v relačně propojených databázových tabulkách, zabraňuje vzniku nekonzistentních dat
- kontrola přípustných hodnot
- kontrola existence položky s daným klíčem v druhé tabulce (podle cizího klíče)

Chování při porušení integrity:

- ON UPDATE, ON DELETE podmínka spuštění akce
- ON ... RESTRICT defaultní řešení (hlášení chyby)
- CASCADE kaskádová aktualizace/smazání (smaže příslušné řádky v odkazované tabulke)
- SET NULL nastavení odkazovaných řádků závislé tabulky na NULL
- SET DEFAULT nastavení pevně určené hodnoty
- NO ACTION

4.5 Základy SQL

TODO: převzato od "programátorů" z otázky "SQL", vzhledem k tomu, že u nás se to jmenuje "základy SQL" tak to možná nemusí být tak podrobné

Zdroje: slidy z přednášek Databázové systémy a Databázové aplikace Dr. T. Skopala a Dr. M. Kopeckého.

Standardy SQL

SQL (Structured query language) je standardní jazyk pro přístup k relačním databázím (a dotazování nad nimi). Je zároveň jazykem pro definici dat (definition data language), vytváření a modifikace schémat (tabulek), manipulaci s daty (data manipulation language), vkláání, aktualizace, mazání dat, řízení transakcí, definici integritních omezení aj. Jeho syntaxe odráží snahu o co nejpřirozenější formulace požadavků – je podobná anglickým "větám".

SQL je standard podle norem ANSI/ISO a existuje v několika (zpětně kompatibilních) verzích (označovaných podle roku uvedení):

SQL 86 – první "nástřel", průnik implementací SQL firmy IBM

SQL 89 – malá revize motivovaná komerční sférou, mnoho detailů ponecháno implementaci

SQL 92 – mnohem silnější a obsáhlejší jazyk. Zahrnuje už

- modifikace schémat, tabulky s metadaty,
- vnější spojení, množinové operace
- kaskádové mazání/aktualizace podle cizích klíčů, transakce
- kurzory, výjimky

Standard existuje ve čtyřech verzích: Entry, Transitional, Intermediate a Full.

SQL 1999 – přináší mnoho nových vlastností, např.

- objektově-relační rozšíření
- nové datové typy reference, pole, full-text
- podpora pro externí datové soubory, multimédia
- triggery, role, programovací jazyk, regulární výrazy, rekurzivní dotazy ...

SQL 2003 – další rozšíření, např. XML management

Komerční systémy implementují SQL podle různých norem, někdy jenom SQL-92 Entry, dnes nejčastěji SQL-99, ale nikdy úplně striktně. Některé věci chybí a naopak mají všechny spoustu nepřenositelných rozšíření – např. specifická rozšíření pro procedurální, transakční a další funkcionalitu (T-SQL (Microsoft SQL Server), PL-SQL (Oracle)). S novými verzemi se kompatibilita zlepšuje, často je možné používat obojí syntax. Přenos aplikace za běhu na jinou platformu je ale stále velice náročný – a to tím náročnější, čím víc věcí mimo SQL-92 Entry obsahuje. Pro otestování, zda je špatně syntax SQL, nebo zda jen daná databázová platforma nepodporuje některý prvek, slouží SQL validátory (které testují SQL podle norem.

Dotazy v SQL

Hlavním nástrojem dotazů v SQL je příkaz SELECT. Sdílí prvky relačního kalkulu i relační algebry – obsahuje práci se sloupci, kvantifikátory a agregační funkce z relačního kalkulu a další operace – projekce, selekce, spojení, množinové operace – z relační algebry. Na rozdíl od striktní formulace relačního modelu databáze povoluje duplikátní řádky a NULLové hodnoty atributů.

Netříděný dotaz v SQL sestává z:

- příkazu(ů) SELECT (hlavní logika dotazování), to obsahuje vždy
- může obsahovat i množinové operace nad výsledky příkazů SELECT UNION, INTERSECTION ...

Výsledky nemají definované uspořádání (resp. jejich pořadí je určeno implementací vyhodnocení dotazu).

Příkaz SELECT vypadá následovně (tato verze už zahrnuje i třídění výsledků):

```
SELECT [DISTINCT]

výraz1 [[AS] c_alias1] [, ...]

FROM

zdroj1 [[AS] t_alias1] [, ...]

[WHERE podmínka_ř]

[GROUP BY výraz_g1 [, ...]

[HAVING podmínka_s]]

[ORDER BY výraz_o1 [, ...] ASC/DESC]
```

Kde

 $\bullet\,$ výrazy mohou být sloupce, sloupce s agregačními funkcemi, výsledky dalších funkcí ...

```
výraz = <název sloupce>, <konstanta>, (DISTINCT) COUNT( <název sloupce> ), [DISTINCT] [ SUM | AVG ]( <výraz> ), [ MIN | MAX ]( <výraz> ) a navíc lze použít operátory +, -, *, /.
```

- zdroje jsou tabulky nebo vnořené selecty
- výrazy i zdroje být přejmenovány pomocí AS, např. pro odkazování uvnitř dotazu nebo jména na výstupu (od SQL-92)
- podmínka je logická podmínka (spojovaná logickými spojkami AND, OR) na hodnoty dat ve zdrojích:

```
podminka = <výraz> BETWEEN <x> AND <y>, <výraz> LIKE "%_ ... ",
<výraz> IS [NOT] NULL,
<výraz> > = <> <= < > [<výraz>/ ALL / ANY <dotaz>],
<výraz> NOT IN [<seznam hodnot> / <dotaz>], EXIST ( <dotaz> )
```

- GROUP BY znamená agregaci podle unikátních hodnot jmenovaných sloupců (v ostatních sloupcích vznikají množiny hodnot, které se spolu s oněmi unikátnímí vyskytují na stejných řádkách
- HAVING označuje podmínku na agregaci
- ORDER BY definuje, podle hodnot ve kterých sloupcích nebo podle kterých jiných výrazů nad nimi provedených se má výsledek setřídit (ASC požaduje vzestupné setřídění, DESC sestupné).

SQL nemá příkaz na omezení rozsahu na některé řádky (jako např. "potřebuji jen 50.-100. řádek výpisu"), a to lze řešit buď složitě standardně (počítání kolik hodnot je menších než vybraná, navíc náročné na hardware) nebo pomocí některého nepřenositelného rozšíření.

Pořadí vyhodnocování jednoho příkazu SELECT (nebereme v úvahu optimalizace):

- 1. Nejprve se zkombinují data ze všech zdrojů (tabulek, pohledů, poddotazů). Pokud jsou odděleny čárkami, provede se kartézský součin (to samé co CROSS JOIN), v SQL-92 a vyšším i složitější spojení JOIN ON (vnitřní spojení podle podmínky), NATURAL JOIN ("přirozené" spojení podle stejných hodnot stejně pojmenovaných sloupců), OUTER JOIN ("vnější" spojení, do kterého jsou zahrnuty i záznamy, pro které v jednom ze zdrojů není nalezeno nic, co by odpovídalo podmínce, doplněnné NULLovými hodnotami) atd.
- 2. Vyřadí se vzniklé řádky, které nevyhovují podmínce (WHERE)
- 3. Zbylé řádky se seskupí do skupin se stejnými hodnotami uvedených výrazů (HAVING), každá skupina obsahuje atomické sloupce s hodnotami uvedených výrazů a množinové sloupce se skupinami ostatních hodnot sloupců.
- 4. Vyřadí se skupiny, nevyhovující podmínce (HAVING)
- 5. Výsledky se setřídí podle požadavků
- 6. Vygeneruje se výstup s požadovanými hodnotami
- 7. V případě DISTINCT se vyřadí duplicitní řádky

Poznámka

- Klauzule GROUP BY setřídí před vytvořením skupin všechny řádky dle výrazů v klauzuli. Proto by se měl seskupovat co
 nejmenší možný počet řádek. Pokud je možné řádky odfiltrovat pomocí WHERE, je výsledek efektivnější, než následné
 odstraňování celých skupin.
- Klauzule DISTINCT třídí výsledné záznamy (před operací ORDER BY), aby našla duplicitní záznamy. Pokud to jde, je vhodné se bez ní obejít.
- Klauzule ORDER BY by měla být použita jen v nutných případech. Není příliš vhodné ji používat v definicích pohledů, nad kterými se dále dělají další dotazy

Definice a manipulace s daty, ostatní příkazy

Standard SQL podporuje několik druhů datových typů:

- textové v národní a globální (UTF) znakové sadě (několika druhů proměnné a pevné délky): CHARACTER(n), NCHAR(n), CHAR VARYING(n)
- číselné typy NUMERIC(p[,s]), INTEGER, INT, SMALLINT, FLOAT(presnost), REAL, DOUBLE PRECISION
- datumové typy DATE, TIME, TIMESTAMP, TIMESTAMP(presnost_sekund) WITH TIMEZONE

Databázové servery ne vždy podporují všechny uvedené typy. Nemusí je podporovat nativně, někdy si pouze "přeloží" název typu na podobný nativně podporovaný typ.

Příkaz CREATE TABLE

Tento příkaz slouží k vytvoření nové tabulky. Je nutné definovat její název, atributy a jejich domény (datové typy); dále je mo6né definovat integritní omezení (klíče, cizí klíče, odkazy, podmínky). Příkaz vypadá následovně:

```
CREATE TABLE <název> <def. sloupce/i.o. tabulky, ...>
```

```
def. sloupce = <název> <dat.typ>
        [DEFAULT NULL|<hodnota>] [<i.o.sloupce>]
dat.typ = [VARCHAR(n) | BIT(n) | INTEGER | FLOAT | DECIMAL ...]
i.o.sloupce = [CONSTRAINT <jméno>] [NOT NULL / UNIQUE / PRIMARY KEY],
        REFERERENCES <tabulka>(<sloupec>) <akce>, CHECK <podmínka>
akce = [ON UPDATE / ON DELETE]
        [CASCADE / SET NULL / SET DEFAULT / NO ACTION(hlášení chyby) ]
i.o.tabulky = UNIQUE, PRIMARY KEY <sloupec, ... >,
        FOREIGN KEY <sloupec, ... >,
        REFERENCES <tabulka>(<sloupec, ... >),
        CHECK( <podmínka> )
```

Příkazy pro manipulaci se schématem

• Úprava tabulky:

```
ALTER TABLE <název> ADD {COLUMN} <def.sloupce>, ADD <i.o.tabulky>,
    ALTER COLUMN <sloupec> [ SET / DROP ], DROP COLUMN <sloupec>,
    DROP CONSTRAINT <jméno i.o.>
```

• Smazání tabulky (není to samé jako vymazání všech dat z tabulky!):

```
DROP TABLE <tabulka>
```

Vytvoření "pohledu" – navenek se chová jako tabulka, ale vnitřně se při každém dotazu provede vnořený dotaz (který definicí pohledu zapisuji):

```
CREATE VIEW <název "tabulky"> ( <sloupec, ... > )
AS <dotaz> {WITH [ LOCAL / CASCADED ] CHECK OPTION }
```

Některé databázové platformy umožňují do takto vytvořených pohledů i zapisovat.

Příkazy pro manipulaci s daty

• Vložení nových dat do tabulky

```
INSERT INTO <tabulka> ( <sloupec, ... > )
   [VALUES ( <výraz, ... > ) / (<dotaz>) ]
```

• Úprava dat (na řádcích které vyhovují podmínce se nastaví zadané hodnoty vybraným sloupcům):

```
UPDATE <tabulka> SET
   ( <sloupec> = [ NULL / <výraz> / <dotaz> ] , ... )
   WHERE (<podmínka>)
```

• Smazání řádků vyhovujících podmínce z tabulky:

```
DELETE FROM <tabulka> ( WHERE <podminka> )
```

4.6 Transakční zpracování, vlastnosti transakcí, uzamykací protokoly, zablokování

Definice (Transakce)

Transakce je jistá posloupnost nebo specifikace posloupnosti akcí práce s databází, jako jsou čtení, zápis nebo výpočet, se kterou se zachází jako s jedním celkem.

Hlavním smyslem používání transakcí, tj. transakčního zpracování, je udržení databáze v konzistentním stavu. Jestliže na sobě některé operace závisí, sdružíme je do jedné transakce a tím zabezpečíme, že budou vykonány buď všechny, nebo žádná. Databáze tak před i po vykonání transakce bude v konzistentním stavu. Aby se uživateli transakce jevila jako jedna atomická operace, je nutné zavést příkazy COMMIT a ROLLBACK. První z nich signalizuje databázi úspěšnost provedení transakce, tj. veškeré změny v databázi se stanou trvalými a jsou zviditelněny pro ostatní transakce, druhý příkaz signalizuje opak, tj. databáze musí být uvedena do původního stavu.

Tyto příkazy většinou není nutné volat explicitně, např. příkaz COMMIT je vyvolán po normálním ukončení programu realizujícího transakci. Příkaz ROLLBACK pro svou funkci vyžaduje použití tzv. *žurnálu* (logu) na nějakém stabilním paměťovém médiu. Žurnál obsahuje historii všech změn databáze v jisté časové periodě.

Jednoduchá transakce vypadá většinou takto:

- 1. Začátek transakce,
- 2. provedení několika dotazů čtení a zápisů (žádné změny v databázi nejsou zatím vidět pro okolní svět),
- 3. Potvrzení (příkaz COMMIT) transakce (pokud se transakce povedla, změny v databázi se stanou viditelné).

Pokud nějaký z provedených dotazů selže, systém by měl celou transakci zrušit a vrátit databázi do stavu v jakém byla před zahájením transakce (operace ROLLBACK).

Transakční zpracování je také ochrana databáze před hardwarovými nebo softwarovými chybami, které mohou zanechat databázi po částečném zpracování transakce v nekonzistentním stavu. Pokud počítač selže uprostřed provádění některé transakce, transakční zpracování zaručí, že všechny operace z nepotvrzených ("uncommitted") transakcí budou zrušeny.

Vlastnosti transakcí

Podívejme se nyní na vlastnosti požadované po transakcích. Obvykle se používá zkratka prvních písmen anglických názvů vlastností **ACID** – atomicity, consistency, isolation (independence), durability.

atomicita – transakce se tváří jako jeden celek, musí buď proběhnout celá, nebo vůbec ne.

konzistence – transakce transformuje databázi z jednoho konzistentního stavu do jiného konzistentního stavu.

nezávislost – transakce jsou nezávislé, tj. dílčí efekty transakce nejsou viditelné jiným transakcím.

trvanlivost – efekty úspěšně ukončené (potvrzené, "commited") transakce jsou nevratně uloženy do databáze a nemohou být zrušeny.

Transakce mohou být v uživatelských programech prováděny paralelně (spíše zdánlivě paralelně, stejně jako je paralelismus multitaskingu na jednoprocesorových strojích jen zdánlivý, zajistí to ale možnost paralelizace "nedatabázových" akcí a pomalé transakce nebrzdí rychlé). Je zřejmé, že posloupnost transakcí může být zpracována paralelně různým způsobem. Každá transakce se skládá z několika akcí. Stanovené pořadí provádění akcí více transakcí v čase nazveme **rozvrhem**.

Rozvrh, který splňuje následující podmínky, budeme nazývat legální:

- Objekt je nutné mít uzamknutý, pokud k němu chce transakce přistupovat.
- Transakce se nebude pokoušet uzamknout objekt již uzamknutý jinou transakcí (nebo musí počkat, než bude objekt odemknut).

Důležitými pojmy pro paralelní zpracování jsou sériovost či uspořádatelnost. **Sériové rozvrhy** zachovávají operace každé transakce pohromadě (a provádí se jen jedna transakce najednou). Pro n transakcí tedy existuje n! různých sériových rozvrhů. Pro získání korektního výsledku však můžeme použít i rozvrhu, kde jsou operace různých transakcí navzájem prokládány. Přirozeným požadavkem na korektnost je, aby efekt paralelního zpracování transakcí byl týž, jako kdyby transakce byly provedeny v nějakém sériovém rozvrhu. Předpokládáme-li totiž, že každá transakce je korektní program, měl by vést výsledek sériového zpracování ke konzistentnímu stavu. O systému zpracování transakcí, který zaručuje dosažení konzistentního stavu nebo stejného stavu jako sériové rozvrhy, se říká, že zaručuje **uspořádatelnost**.

Mohou se vyskytnout problémy, které uspořádatelnosti zamezují. Ty nazýváme konflikty. Plynou z pořadí dvojic akcí různých transakcí na stejném objektu. Existují tři typy konfliktních situací:

- 1. WRITE-WRITE přepsání nepotvrzených dat
- 2. READ-WRITE neopakovatelné čtení
- 3. WRITE-READ čtení nepotvrzených ("uncommitted") dat

Řekneme, že rozvrh je konfliktově uspořádatelný, je-li konfliktově ekvivalentní nějakému sériovému rozvrhu (tedy jsou v něm stejné, tj. žádné konflikty). Test na konfliktovou uspořádatelnost se dá provést jako test acykličnosti grafu, ve kterém konfliktní situace představují hrany a transakce vrcholy. Konfliktová uspořádatelnost je slabší podmínka než uspořádatelnost – nezohledňuje ROLLBACK (zotavitelnost – zachování konzistence, i když kterákoliv transakce selže) a dynamickou povahu databáze (vkládání a mazání objektů). Zotavitelnosti se dá dosáhnout tak, že každá transakce T je potvrzena až poté, co jsou

potvrzeny všechny ostatní transakce, které změnily data čtená v T. Pokud v zotavitelném rozvrhu dochází ke čtení změn pouze potvrzených transakcí, nemůže dojít ani k jejich kaskádovému rušení.

Při zpracování (i uspořádatelného) rozvrhu může dojít k situaci uv'aznut'i-deadlocku. To nastane tehdy, pokud jedna transakce T_1 čeká na zámek na objekt, který má přidělený T_2 a naopak. Situaci lze zobecnit i na více transakcí. Uváznutí lze buď přímo zamezit charakterem rozvrhu, nebo detekovat (hledáním cyklu v grafu čekajících transakcí, tzv. "waits-for" grafu) a jednu z transakcí "zabít" a spustit znova.

K zajištění uspořádatelnosti a zotavitelnosti a zabezpečení proti kaskádovým rollbackům a deadlocku se používají různá schémata (požadavky na rozvrhy). Jedním z nich jsou uzamykací protokoly.

Uzamykací protokoly

Vytváření rozvrhů a testování jejich uspořádatelnosti není pro praxi zřejmě ten nejvhodnější způsob. Pokud ale budeme transakce konstruovat podle určitých pravidel, tak za určitých předpokladů bude každý jejich rozvrh uspořádatelný. Soustavě takových pravidel se říká **protokol**.

Nejznámější protokoly jsou založeny na dynamickém zamykání a odemykání objektů v databázi. Zamykání (operace LOCK) je akce, kterou vyvolá transakce na objektu, aby ho chránila před přístupem ostatních transakcí.

Definice (Dobře formovaná transakce)

Transakci nazveme dobře formovanou pokud podporuje přirozené požadavky na transakce:

- 1. transakce zamyká objekt, chce-li k němu přistupovat,
- 2. transakce nezamyká objekt, který již je touto transakcí uzamčený,
- 3. transakce neodmyká objekt, který není touto transakcí zamčený,
- 4. po ukončení transakce jsou všechny objekty uzamčené touto transakcí odemčeny.

Dvoufázový protokol (2PL) – Dvoufázová transakce v první fázi zamyká vše co je potřeba a od prvního odemknutí (druhá fáze) již jen odemyká co měla zamčeno (již žádná operace LOCK). Tedy transakce musí mít všechny objekty uzamčeny předtím, než nějaký objekt odemkne. Dá se dokázat, že pokud jsou všechny transakce v dané množině transakcí dobře formované a dvoufázové, pak každý jejich legální rozvrh je uspořádatelný.

Dvoufázový protokol zajišťuje uspořádatelnost, ale ne zotavitelnost ani bezpečnost proti kaskádovému rušení transakcí nebo uváznutí.

Striktní dvoufázový protokol (S2PL) – Problémy 2PL jsou nezotavitelnost a kaskádové rušení transakcí. Tyto nedostatky lze odstranit pomocí striktních dvoufázových protokolů, které uvolňují zámky až po skončení transakce (COMMIT). Zřejmá nevýhoda je omezení paralelismu. 2PL navíc stále nevylučuje možnost deadlocku.

Konzervativní dvoufázový protokol (C2PL) – Rozdíl oproti 2PL je ten, že transakce žádá o všechny své zámky, ještě než se začne vykonávat. To sice vede občas k zbytečnému zamykání (nevíme co přesně budeme potřebovat, tak radši zamkneme víc), ale stačí to již k prevenci uváznutí (deadlocku).

"Vylepšení" zamykacích protokolů

Sdílené a výlučné zámky – Nevýhodou 2PL je, že objekt může mít uzamčený pouze jedna transakce. Abychom uzamykání provedli precizněji, je dobré vzít na vědomí rozdíl mezi operacemi READ a WRITE. Výlučný zámek (W.LOCK) může být aplikován na objekty jak pro operaci READ tak pro WRITE, sdílený zámek (R.LOCK) uzamyká objekt, který chceme pouze číst. Jeden objekt potom může být uzamčen sdíleným zámkem více transakcí a zvyšuje se tak možnost paralelního zpracování. Budeme-li s těmito zámky zacházet stejně jako u 2PL, opět máme zaručenou uspořádatelnost rozvrhu, ovšem nikoliv absenci uváznutí.

Strukturované uzamykání (multiple granularity) – Objekty jsou v tomto případě chápány hierarchicky dle relace *obsahuje*. Například databáze obsahuje soubory, které obsahují stránky a ty zase obsahují jednotlivé záznamy. Na tuto hierarchii se můžeme dívat jako na strom, ve kterém každý vrchol obsahuje své potomky. Když transakce zamyká objekt (vrchol) zamyká také všechny jeho potomky. Protokol se tak snaží minimalizovat počet zámků, tím snížit režii a zvýšit možnosti paralelního zpracování.

Alternativní protokoly

Časová razítka – Další z protokolů zaručující uspořádatelnost je využití časových razítek. Na začátku dostane transakce T časové razítko - TS(T) (časová razítka jsou unikátní a v čase rostou), abychom věděli pořadí, ve kterém by měli být transakce vykonány. Každý objekt v databázi má čtecí razítko - RTS(O) (read timestamp), které je aktualizováno, když je objekt čten, a zapisovací razítko - WTS(O) (write timestamp), které je aktualizováno, když nějaká transakce objekt mění.

Pokud chce transakce T číst objekt O mohou nastat dva případy:

• TS(T) < WTS(O), tzn. někdo změnil objekt O potom co byla spuštěna transakce T. V tomto případě musí být transakce zrušena a spouštěna znovu (a tedy s jiným časovým razítkem).

• TS(T) > WTS(O), tzn. je bezpečné objekt číst. V tomto případě T přečte O a RTS(O) je nastaveno na $\max\{TS(T), RTS(O)\}$.

Pokud chce transakce T zapisovat do objektu O rozlišujeme případy tři:

- TS(T) < RTS(O), tzn. někdo četl O poté co byla spuštěna T a předpokládáme, že si pořídil lokální kopii. Nemůžeme tedy O změnit, protože by lokální kopie přestala být platná a tedy je nutné T zrušit a spustit znova.
- TS(T) < WTS(O), tzn. někdo změnil O po startu T. V tomto případě přeskočíme write operaci a pokračujeme dále normálně. T nemusí být restartována.
- V ostatních případech T změní O a WTS(O) je nastaveno na TS(T).

Optimistické protokoly – V situaci kdy se většina transakcí neovlivňuje, je režie výše uvedených protokolů zbytečně velká a můžeme použít takzvaný optimistický protokol. V protokolu můžeme rozlišit tři fáze.

- 1. Fáze čtení: Čtou se objekty z databáze do lokální paměti a jsou na nich prováděny potřebné změny.
- 2. **Fáze kontroly:** Po dokončení všech změn v lokální paměti je vyvolán pokus o zapsání výsledků do databáze. Algoritmus zkontroluje, zda nehrozí potenciální kolize s již potvrzenými transakcemi, nebo s některými právě probíhajícími. Pokud konflikt existuje, je třeba spustit algoritmus pro řešení kolizí, který se je snaží vyřešit. Pokud se mu to nepodaří, je využita poslední možnost a tou je zrušení a restartování transakce.
- 3. Fáze zápisu: Pokud nehrozí žádné konflikty, jsou data z lokální paměti zapsány do databáze a transakce potvrzena.

4.7 Technologie XML, XML Schema

viz slidy:)

4.8 Organizace dat na vnější paměti, B-stromy a jejich varianty

Vnější paměť

Definice (Vnější paměť)

Vnější paměť je úložiště dat (paměťové médium), u kterého je rychlost načítání dat zpravidla nízká a přístup k nim ne úplně přímý (záleží na uspořádání dat na médiu), ne-li pouze sekvenční (oproti vnitřní paměti s rychlým náhodným přístupem a menší kapacitou). Příkladem vnější paměti je pevný disk nebo magnetická páska.

Magnetické pásky poskytují vysokou kapacitu, ale nízkou rychlost a pouze sekvenční přístup. Pro jejich kapacitu je důležitá hustota záznamu, potřebují meziblokové mezery pro vyrovnání nepřesnosti přetáčení pásky.

Pevné disky umožňují přímý přístup, ale jeho rychlost není vždy stejná. Ovlivňuje ji fyzická vzdálenost dat – pevný disk má několik válců, na nichž jsou uloženy jednotlivé datové stopy. K válcům přísluší čtecí hlavy (je jich stejně jako válců, ale pohybují se všechny současně, takže může v 1 okamžiku číst jen jedna). Disky jsou většinou rozděleny na sektory – nejmenší jednotku dat, kterou je možné načíst nebo uložit (zpravidla jednotky KB). Pro rychlost přístupu k datům jsou důležité tyto veličiny (výrobcem disků jsou zpravidla udávány průměrné hodnoty):

- \bullet seek~(s) přesun na jinou stopu, dnes zpravidla kolem 4-8 ms
- (average) rotational delay (r) otočení válců 1 půlotáčka, pro nejčastější 7200rpm disk je to cca 4 ms
- block transfer time (btt) doba přenesení 1 bloku po sběrnici, na ATA/100 disku se 4 KB bloky teoreticky 0.04 ms

Pokud jsou data umístěna na disku za sebou sekvenčně, rychlost jejich načtení je mnohem vyšší než při náhodném rozmístění, protože není třeba provádět přesuny mezi stopami a otáčení válců navíc.

Příklad

Jak vypadá načtení 1 MB dat z pevného disku? Předpokládejme, že na 1 stopu se vejde 512 KB a 1 blok má 4 KB. Jsou-li data umístěna na disku sekvenčně, potřebuji pro načtení 1 MB dat najít první blok a potom číst dvě celé stopy (2 otáčky), tj. celkem $s + r + (2 \cdot 2r)$ (a přenos po sběrnici lze zanedbat, protože probíhá zároveň se čtením). Pokud jsou data na disku náhodně rozprostřena, potřebuji celkem 256-krát najít blok a načíst ho: $256 \cdot (s + r + btt)$, takže operace trvá až 100-krát déle.

Soubor

Definice (Záznam, klíč)

 $(Logick\acute{y})$ záznam je jednotka dat (např. v databázi), má atributy (z nichž každý má jméno a doménu – povolenou množinu hodnot). Logickému záznamu v reprezentaci na disku odpovídá $fyzick\acute{y}$ záznam (nějaké délky R – pevné nebo proměnné), který navíc může obsahovat ještě další data – oddělovače, ukazatele, hlavičky.

Klíč je množina atributů, která jednoznačně identifikuje záznam; proti tomu vyhledávací klíč je množina atributů, pro kterou lze nalézt množinu odpovídajících záznamů. Vyhledávací klíče jsou tří druhů: hodnotový ("obyčejné" hodnoty některých atributů), hašovaný a relativní (přímo pozice v souboru).

Definice (Soubor)

(Homogenní) soubor je multimnožina záznamů. Fyzicky na vnější paměti je organizován do bloků (stránek) (velikosti B, typicky několika KB) – hl. jednotkou přenosu dat mezi vnitřní a vnější pamětí. Poměr velikosti záznamu k velikosti bloku (B/R) se nazývá $blokovací faktor (\lfloor b \rfloor)$. Záznamy mohou být rozprostřeny i přes několik stránek, nebo může být pouze jeden záznam na 1 stránku; ideální (ale ne vždy dosažitelné) je, pokud beze zbytku zaplňují stránky. Na souboru jsou definovány operace se záznamy: insert, delete, update a fetch.

Definice (Dotaz)

Dotaz je každá funkce, která každému svému argumentu přiřadí odpovídající množinu záznamů ze souboru ("totální vyčíslitelná funkce definovaná na souboru"). Dotazy mohou být těchto typů:

- Načtení všech záznamů (SELECT * FROM tabulka)
- Na úplnou shodu (SELECT * FROM tabulka WHERE sloupec1 = 'hodnota' AND sloupec2 = 'hodnota' pro tabulku se 2 sloupci dány jsou všechny atributy)
- Na částečnou shodu

(SELECT * FROM tabulka WHERE sloupec1 = 'hodnota' pro tabulku se 2 sloupci - zadaná je jen část atributů)

• Na intervalovou shodu (částečnou nebo úplnou) (SELECT * FROM tabulka WHERE sloupec1 > 'hodnota')

U souborů se sleduje rychlost provedení těchto operací.

Statické metody organizace souboru

Definice (Schéma organizace souboru)

Schéma organizace souboru je popis logické paměťové struktury, do níž lze zobrazit logický soubor, spolu s algoritmy operací nad touto strukturou. Ta je obvykle tvořena z logických stránek (bloků pevné délky) a může popisovat více provázaných log. souborů, z nichž primární soubor je ten, který obsahuje uživatelská data. Operace definované nad schématem org. souboru jsou kromě operací nad soubory ještě build, reorganization, open a close.

Proti němu stojí fyzické schéma souboru – struktura nad fyzickými soubory, nejblíže hardwaru je implementační schéma souboru.

Zajištění *Vyváženosti struktury* znamená zajištění omezení cesty při vyhledávání nějakým výrazem (zaručení asymptotické složitosti), navíc zaručení rovnoměrnosti zaplnění struktury – *faktor naplnění stránek*. Schémata, která splňují obě podmínky, se nazývají *dynamická*, ostatní jsou označována jako *statická*.

Poznámka (Časové odhady)

Pro schémata organizace souborů se počítají časové odhady provedení jednotlivých operací – jednodušších, jako je přístup k záznamu (T_F) , rewrite – přepis během 1 otáčky disku (T_{RW}) , příp. sekvenční čtení; dále i složitějších jako vyhledání záznamu, přidání, smazání a úprava záznamu, reorganizace struktury nebo načtení celého souboru.

Hromada (neuspořádaný sekvenční soubor)

Hromada(heap) je naprosto nejjednodušší schéma organizace souboru, kdy jsou záznamy v souboru jen náhodně seřazeny za sebou. Časová složitost vyhledávání je O(n), pokud n je počet záznamů. Jde o nehomogenní soubor, kde záznamy obvykle nemají pevnou délku.

Uspořádaný sekvenční soubor

V uspořádaném sekvenčním souboru jsou záznamy řazeny podle klíče. Aktualizované záznamy se umístí do zvláštního souboru a až při další operaci "reorganization" jsou přidány do primárního. Složitost nalezení záznamu je také O(n), ale pokud se hledá podle klíče, podle kterého jsou záznamy seřazeny, a navíc je soubor na médiu s přímým přístupem, sníží se na $O(\log n)$.

Index-sekvenční soubor

Toto schéma uvažuje primární soubor jako sekvenční, uspořádaný podle primárního klíče. Nad ním je pak vytvořen (třeba i víceúrovňový) index. Ten sestává ze seznamu čísel stránek a minimálních hodnot klíče jim odpovídajících záznamů. Pokud má index víc úrovní, provádí se pro vyšší úrovně to samé na blocích indexů úrovně o 1 nižší. Nejvyšší úroveň indexu se obvykle vejde do 1 bloku, tzv. master.

Počet potřebných úrovní pro n záznamů se dá spočítat jako $\lceil \log_p \frac{n}{\lfloor b \rfloor} \rceil$, kde $p = \lfloor \frac{B}{V+P} \rfloor$ při velikosti klíče V a pointeru na stránku P. Problémem je přidávání nových záznamů, kdy se tyto řetězí za sebe v tzv. *oblasti přetečení* (každý z nich má pointer na další záznam v oblasti přetečení). Pro oddálení nutnosti vkládání do oblasti přetečení lze iniciálně bloky plnit na méně než 100%.

Indexovaný soubor

Indexovaný soubor znamená primární soubor plus indexy pro různé vyhledávací klíče. Neindexují se už stránky, ale přímo záznamy, a proto primární soubor nemusí být nutně setříděný. Index může být podobný jako u index-sekvenčního souboru, pro záznamy se stejným klíčem je ale vhodné, aby byly na všech úrovních indexu kromě poslední sloučené. Při aktualizaci se nepoužívá oblast přetečení, mění se pouze index.

Existuje i několik dalších variant indexů. Pro zmenšení náročnosti dotazů na kombinovanou částečnou shodu se používá kombinovaný index pro více atributů, u něhož je ale nutné předem zjistit na které kombinace atributů budou často pokládány dotazy, a pro takové kombinace tento index teprve vytvořit. Clusterovaný index zaručuje, že záznamy s podobnou hodnotou indexovaného atributu jsou blízko sebe v primárním souboru – např. pokud je primární soubor podle tohoto atributu setříděny. Tento index lze použít jen pro 1 atribut.

Bitov'e mapy se dají použít jako index pro atributy s malou doménou (množinou možných hodnot) – pro každou hodnotu této domény se vyrobí vektor bitů stejné délky, jako je počet záznamu v primárním souboru, kde jednička na i-té pozici indikuje, že i-tý záznam má právě tuto hodnotu atributu. To umožňuje jednoduché provádění booleovských dotazů na tento atribut. Vektory bitů navíc lze komprimovat, takže nezabírají tolik místa.

Soubor s přímým přístupem

V tomto schématu jsou záznamy v primárním souboru ("adresovém prostoru" velikosti M) rozptýleny pomocí hashovací funkce. Často se používá funkce $h=k \mod M'$, kde M' je nejbližší prvočíslo menší než velikost adresového prostoru. Hashovací funkcí se určuje buď jenom číslo stránky, nebo i relativní pozice v ní. Při hashování vznikají kolize, které se dají řešit otevřeným adresováním (řetězením kolizních záznamů za sebe), rehashováním (další funkcí) nebo použitím oblasti přetečení. Snaha je většinou umístit kolizní záznamy do stejné stránky.

Pokud je hashovací funkce prostá, jedná se o perfektní hashování. Toho ale v praxi vlastně nelze dosáhnout, takže se tento výraz používá i pro označení stavu, kdy je pro nalezení záznamu potřeba nejvýš O(1) přístupů k médiu. Očekávaná délka řetězce kolizí při počtu N záznamů v prostoru velikosti M je $1/(1-\frac{N}{M})$.

Třídění na vnější paměti

Algoritmus (*Třídění sléváním* (*Mergesort*))

Tento algoritmus se používá pro třídění dat, která se nevejdou do vnitřní paměti. Dá se použít i při sekvenčním přístupu k datovým souborům. Nejjednodušší verze bez bufferů vypadá takto:

- inicializace: na začátku každého kroku data rozdělí do 2 souborů
- načte 2 záznamy, každý z jednoho souboru a porovná je
- ve správném pořadí je zapíše do výstupního souboru, ze vstupního souboru si načte další dva
- v prvním kroku získám uspořádané posloupnosti délky 2; v dalších krocích vždy porovnám načtené prvky, zapíšu menší z nich a ze souboru odkud tento pocházel si načtu další, takže získám vždy uspořádané posloupnosti dvojnásobné délky než v předchozím kroku
- po $\lceil \log n \rceil$ krocích je soubor s n záznamy setříděný.

Vylepšení se dosáhne např. přímo střídavým zapisováním výstupu do 2 souborů, kdy se zbavím nutnosti na začátku každého kroku data dělit, nebo použitím více souborů najednou. Je taky možné využít rostoucích posloupností prvků, které se v souboru nacházejí již před započetím třídění.

Algoritmus (Třídění haldou)

Pro třídění ve vnitřní paměti se používá algoritmus třídění haldou (heapsort), který se dá zakomponovat do vylepšení třídění sléváním (viz níže). Jeho základem je datová struktura halda (konkrétně maximální halda, max-heap), reprezentovaná jako pole záznamů, na kterém je binární stromová struktura: záznam k má vždy vyšší klíč než jeho dva synové, nacházející se na pozicích 2k + 1 a 2k + 2 při číslování od 0 (pokud tato pozice není větší než velikost haldy, v opačném případě záznam nemá syny). Na pozici 0 se tak nachází záznam s nejvyšším klíčem. Postup třídění je následovný:

- největší prvek (z pozice 0) se prohodí s tím prvkem, jehož číslo pozice odpovídá aktuální velikosti haldy
- velikost haldy se zmenší o 1
- dokud neplatí podmínka, že klíč prvku získaného z konce haldy je větší než oba klíče jeho synů, prohazuje se tento se synem s větším klíčem (a tak posouvá v haldě dál)
- toto se opakuje, dokud je velikost haldy větší než 1, odzadu tak v poli vzniká setříděná posloupnost

Časová složitost algoritmu je $O(n \cdot \log n)$ pro pole záznamů velikosti n.

Algoritmus (n-cestné třídění)

Pokud mám k dispozici ve vnitřní paměti n+1 stránek, mohu postupovat následovně:

- $\bullet\,$ v 1. kroku načíst do paměti nstránek
- ty setřídit pomocí heapsortu (nebo i quicksortu apod.) a získat tak delší setříděné úseky (běhy)
- \bullet slévat vždy n nejkratších běhů (pomocí mergesortu) a vytvářet tak jeden běh
- toto opakovat, dokud existuje více než 1 běh.

Čas. složitost pro M stránek v souboru je $O(2M\lceil \log_n M/n \rceil)$.

Algoritmus (Dvojitá halda)

Delší běhy při slévání se ďají vytvářet pomocí dvojité haldy – v paměti mám dvě haldy z celkem n prvků, opakovaně z první haldy odebírám a zapisuji minimální prvek do výstupního běhu a načítám další prvek, pokud ten je větší než minimum haldy, vložím ho do prvé haldy, pokud je menší, vložím ho do druhé haldy, která vzniká od konce mého pole. Až se první halda vyčerpá, použiji druhou a začnu nový běh. Toto v nejhorším případě dává stejnou velikost běhů jako obyčejná halda, průměrně je 2x lepší.

B-stromy

Definice (B-strom)

B-strom řádu m je výškově vyvážený strom, který má násl. vlastnosti:

- 1. Kořen má minimálně 2 syny, pokud není sám listem.
- 2. Každý jiný uzel kromě listů má nejméně $\lceil \frac{m}{2} \rceil$ a nejvíce m synů a vždy o 1 méně dat. záznamů (listy mají jen datové záznamy).
- 3. Klíče všech záznamů v i-tém podstromu uzlu A jsou větší než klíč i-tého záznamu uzlu A a menší nebo rovny klíči i+1-tého záznamu.
- 4. všechny *větve* (cesty od kořene k listu) jsou stejně dlouhé.

Variantou jsou redundantní B-stromy, kdy všechna data jsou umístěna v listech, vnitřní uzly obsahují pouze vyhledávací klíče. Jiná možnost je použití pouze klíče a odkazu na celý záznam, místo vkládání kompletních záznamů do stromu.

Algoritmus (Operace na B-stromě)

Vyhledávání v B-stromech podle klíče se provádí jednoduchým průchodem do hloubky.

Vkládání probíhá tak, že se najde místo, kam záznam vložit, pokud není uzel plný, prostě se záznam vloží, jinak se uzel rozštěpí, půlka prvků se dá vlevo, půlka vpravo a prostřední se vloží ("mezi ně") do otce. Pokud v otci není místo, pokračuje se stejným způsobem až do kořene, kde se případně vytvoří nový uzel a udělá se z něj kořen.

Odebírání prvků je opačný postup, v případě podtečení uzlu (zůstane v něm méně než $\lceil \frac{m}{2} \rceil$ synů) musím přebírat data od sousedních uzlů nebo slévat. V redundantních B-stromech není nutné při mazání odstraňovat vyhledávací klíč z vnitřních uzlů – prvek s touto hodnotou se ve stromě už nebude nacházet, ale vyhledávat podle jeho klíče je dál možné.

Lepší naplněnosti uzlů za cenu snížení rychlosti se dá dosáhnout pomocí *vyvažování stránek* – při přetečení stránky nejdřív kontroluji, jestli nejsou volné sousední; pokud ano, přerozdělím data a upravím klíče. Podobně je možné postupovat při mazání (i pokud není třeba slévat).

Dalším vylepšením je odložení štěpení – ke každému listu nebo skupině listů přísluší stránka přetečení, kam se vkládají záznamy, které se už do daného místa nevejdou. Nové vkládání a štěpení je provedeno až tehdy, jestliže se stránka přetečení i všechny příslušné uzly naplní. Takto upravený strom s více než 1 úrovní má vždy všechny listy zaplněné (za předpokladu nepoužití mazání). Přísluší-li stránky přetečení skupinám listů, musím je při mazání a přidávání listů taktéž štěpit a slévat.

Definice (B + stromy)

B+ stromy jsou mírným vylepšením B-stromů pro zrychlení intervalových dotazů: všechny uzly ve stejné úrovni (a nebo jenom listy) jsou spojeny do spojového seznamu (možná je jednosměrná i obousměrná varianta).

Definice $(B^* stromy)$

 B^* stromy (řádu m) jsou úpravou B-stromů na základě vyvažování stránek. Druhá podmínka B-stromů se upraví tak, že každý uzel kromě kořene a listů má minimálně $\lceil (2m-1)/3 \rceil$ a max. m synů a odpovídající počet dat. záznamů. Listy mají opět jen stejné rozmezí pro počet dat. záznamů. Při vkládání prvků se stěpení odkládá opět do té doby, dokud nejsou plní i sourozenci daného listu; potom se štěpí buď 2 listy do 3, nebo 3 do 4 (buď s pomocí jednoho nebo dvou sousedních sourozenců). Odebírání podobně zahrnuje slévání 3 uzlů do 2 (nebo 4 do 3). Při obém lze ve složitější variantě zapojit ještě více uzlů.

Definice (Prefixové stromy (Trie))

Tento druh stromů slouží k uložení dat, klíčovaných řetězci. Jde o redundantní stromy, data jsou uložena až v listech; vyhledávací klíče jsou vždy co nejkratší možné prefixy řetězců, nutné k odlišení uzlů. Celé hodnoty klíčů (a další data) se nacházejí až v listech. Při vkládání a štěpení stránek se nějakou heuristikou hledá nejkratší prefix, který by vzniklé stránky oddělil. Vylepšená varianta neukládá u synů předponu klíče, kterou má rodič – je to paměťově efektivnější, ale zvyšuje výpočetní nároky.

Definice (Stromy s proměnnou délkou záznamu)

Jde o modifikaci B-stromu, která umožňuje do něj uložit záznamy proměnné délky. Listy se neštěpí podle počtu záznamů, ale zhruba na poloviny podle velikosti dat. Druhá podmínka B-stromů se upraví následovně: celková délka záznamů v jednom uzlu je minimálně $\lceil B/2 \rceil$ a maximálně B (kde B je nějaká zvolená hodnota, větš. velikost stránky na disku). Existuje i varianta s podmínkou "2/3", jako mají B*-stromy.

Problémem této struktury je tendence delších záznamů ke stoupání ke kořeni, čímž se snižuje arita záznamů. To se řeší hledáním dělícího záznamu s min. délkou tak, aby vzniklé uzly splňovaly podmínky stromu (a je to docela náročné). Navíc štěpení je složitější – 1 stránka se může štěpit na 3 (vložím-li hodně dlouhý záznam), může dojít ke zmenšení stromu při vložení apod., běžně se používá obecný algoritmus nahrazování, jehož speciální případy jsou insert a delete.

Definice (Vícerozměrné B-stromy)

Používají se, je-li potřeba efektivně hledat záznamy podle více atributů. Jde o propojenou množinu stromů. K jednotlivým atributům příslušejí prvky pole odkazů na seznamy stromů, ve kterých se podle daných atributů dá hledat. Pro první atribut je potřeba jen 1 strom, v něm je pro každý klíč odkaz na celý strom 2. atributu (pro další je to podobné). Stromy stejného atributu jsou ve spojovém seznamu. Mohu hledat všechny záznamy, pro které znám hodnoty všech atributů, nebo jenom jejich podmnožinu – vyžaduje to projít více stromů, ale není třeba množinových operací.

5 Architektury počítačů a sítí

Požadavky

- Architektury počítače.
- $\bullet\,$ Procesory, multiprocesory.
- Vstupní a výstupní zařízení, ukládání a přenos dat.
- Architektury OS.
- Procesy, vlákna, plánování.
- Synchronizační primitiva, vzájemné vyloučení.
- Zablokování a zotavení z něj.
- Organizace paměti, alokační algoritmy.
- Principy virtuální paměti, stránkování.

- Systémy souborů, adresářové struktury.
- Bezpečnost, autentifikace, autorizace, přístupová práva.
- ISO/OSI vrstevnatá architektura sítí.
- TCP/IP.
- Spojované a nespojované služby, spolehlivost, zabezpečení protokolů.

5.1 Architektury počítače

Definice (Architektura počítača)

Architektura počítača popisuje "všetko, čo by mal vedieť ten, ktorý programuje v assembleri / tvorí operačný systém". Teda:

- z akých častí štruktúra počítača, usporadanie
- význam častí funkcia časti, ich vnútorná štruktúra
- ako spolu časti komunikujú riadenie komukácie
- ako sa jednotlivé časti ovládajú, aká je ich funkčnosť navonok

Definice (Víceúrovňová organizace počítače)

- Mikroprogramová úroveň (priamo technické vybavenie počítača)
- Strojový jazyk počítače (virtuálny stroj nad obvodovým riešením; vybavenie popis architektúry a organizácie)
- Úroveň operačního systému (doplnenie predchádzajúcej úrovne o súbor makroinštrukcií a novú organizáciu pamäti)
- Úroveň assembleru (najnižšia úroveň ľudsky orientovaného jazyka)
- Úroveň vyšších programovacích jazyků (obecné alebo problémovo orientované; prvá nestrojovo orientovaná úroveň)
- Úroveň aplikačních programů

Je teda potrebné definovať

- Inštrukčný súbor (definícia prechodovej funkcie medzi stavmi počítača, formát inštrukcie, spôsob zápisu, možnosti adresovania operandov)
- Registrový model (rozlišovanie registrov procesoru: podľa voľby, pomocou určenia registru explicitný/implicitný register; podľa funkcie registru riadiaci register/register operandu)
- Definice specializovaných jednotek (jednotka na výpočet vo floatoch; fetch/decode/execute jednotky)
- Paralelismy (rozklad na úlohy, ktoré sa dajú spracovať súčasne granularita (programy, podprogramy, inštrukcie...))
- Stupeň predikce (schopnosť pripraviť sa na očakávanú udalosť (načítanie inštrukcie, nastavenie prenosu dát) explicitná predikcia, štatistika, heuristiky, adaptívna predikcia)
- Datové struktury a reprezentáciu dát (spôsob uloženia dát v počítači, mapovacie funkcie medzi reálnym svetom a vnútorným uložením, minimálna a maximálna veľkosť adresovateľné jednotky)
- Adresové konvencie (ako sa pristupuje k dátovým štruktúram segment+offset alebo lineárna adresácia; veľkosť pamäti a jej šírika, "povolené" miesta)
- Řízení (spolupráca procesoru a ostatných jednotiek, interakcia s okolím, prerušenia vnútorne/vonkajšie)
- Vstupy a výstupy (metódy prenosu dát medzi procesorom a ostatnými jednotkami/počítačom a okolím; zahrňuje definície dátových štruktúr, identifikácia zdroja/cieľa, dátových ciest, protokoly, reakcie na chyby).
- Síře datových cest
- Stupeň sdílení (na úrovni obvodov zdieľanie obvodov procesoru a IO; na úrovni jednotiek zdieľanie ALU viacerými procesormi)

Základní definice

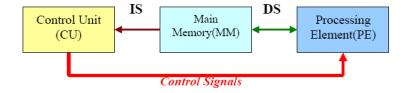
- ALU (také Processing Element) Aritmeticko-logická jednotka základní komponenta procesoru (2.základní je řadič).
- Řadič (Control Unit) je elektronická řídicí jednotka, realizovaná sekvenčním obvodem, která řídí činnost všech částí počítače. Toto řízení je prováděno pomocí řídicích signálů, které jsou zasílány jednotlivým modulům (dílčím částem počítače). Reakce na řídicí signály stavy jednotlivých modulů jsou naopak zasílány zpět řadiči pomocí stavových hlášení. Dílčí částí počítače je např. hlavní paměť, která rovněž obsahuje řadič, který je podřízen hlavnímu řadiči počítače, jenž je součástí CPU.
- Sběrnice (Bus) je sada dat.streamů propojující více zařízení. Instruction Stream (řízení komunikace požadavky/potvrzení, indikace typu dat na datových vodičích) Data Stream (přenos dat mezi zdrojovým a cílovým zařízením, adresy, data, složitější příkazy

Flynn's taxonomy

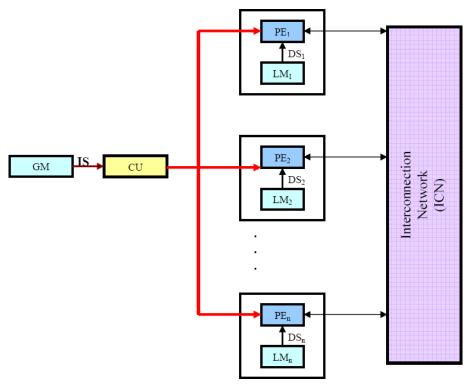
The taxonomy of computer systems proposed by M. J. Flynn in 1966 has remained the focal point in the field. This is based on the notion of instruction and data streams that can be simultaneously manipulated by the machine. A stream is just a sequence of items (instruction or data).

Single Instruction, Single Data stream (SISD) - A sequential computer (Von Neumann) which exploits no parallelism in either the instruction or data streams. Single control unit (CU) fetches single Instruction Stream (IS) from memory. The CU then generates appropriate control signals to direct single processing element (PE or ALU) to operate on single Data Stream (DS) i.e. one operation at a time

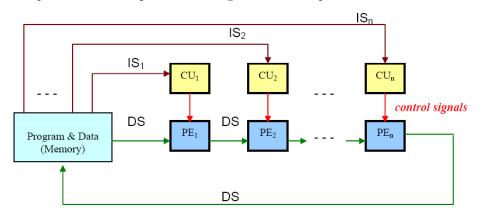
Examples of SISD architecture are the traditional uniprocessor machines like a PC (currently manufactured PCs have multiple processors) or old mainframes.



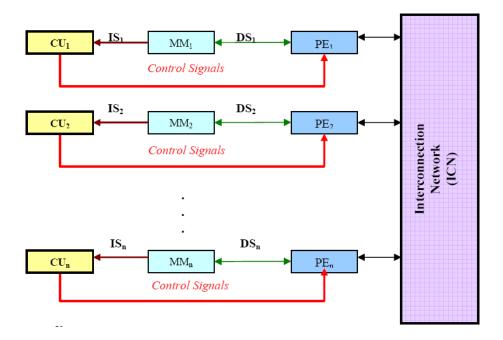
Single Instruction, Multiple Data streams (SIMD) - A computer which exploits multiple data streams against a single instruction stream to perform operations which may be naturally parallelized. For example, an array processor or GPU.



Multiple Instruction, Single Data stream (MISD) - Multiple instructions operate on a single data stream. Uncommon architecture which is generally used for fault tolerance. Heterogeneous systems operate on the same data stream and must agree on the result. Examples include the Space Shuttle flight control computer.



Multiple Instruction, Multiple Data streams (MIMD) - Multiple autonomous processors simultaneously executing different instructions on different data. Distributed systems are generally recognized to be MIMD architectures; either exploiting a single shared memory space or a distributed memory space.



Základní architektury počítačů

Von Neumannova

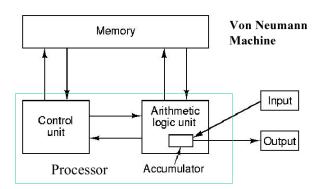
- Počítač se skládá z řídící jednotky, ALU, paměti a I/O jednotek
- Štruktúra počítača sa nemení typom úlohy (tj. počítač je programovaný obsahem paměti).
- Program se nejprve zavede do paměti, z ní se postupně popořadě vybírají instrukce (a následující krok závisí na předchozím), pořadí lze změnit instrukcemi skoku.
- Do jedné paměti, dělené na buňky stejné velikosti, se ukládají i zpracovávaná data. Data jsou reprezentovaná binárně.
- V každém okamžiku je vykonávána jen jedna činnost. Je to architektura SISD (viz Flynnova taxonomie).

Je pevně daná instrukční sada. Strojová instrukce obsahuje operační znak, který určuje druh operace, počet parametrů atd., a operandovú část – umístnění jednotlivých operandů. Vykonat jednu instrukci znamená:

- (fetch) načítať inštrukciu z pamäti do procesoru
- (decode) zistiť o akú inštrukciu ide
- (load) pripraviť zdrojové operandy
- (execute) vykonať operáciu
- (store) uloziť cieľové operandy

Při vykonávání programu jsou potřebné různé registry – nejdůležitější jsou: PC (Program Counter, obsahuje adresu následující instrukce), IR (Instruction Register, adresa právě vykonávané instrukce), SP (Stack Pointer, ukazatel na vrchol zásobníku), MAR (memory access register – adresa do operační paměti), MBR (memory buffer register, dáta čítána/zapisována do paměti).

Struktura jednoprocesorového počítače podle Von Neumanna:



Control-flow – význačným rysem von Neumannovy architektury je způsob provádění programu. Strojové instrukce, ze kterých se každý přímo spustitelný program skládá, se provádějí sekvenčně, jedna za druhou. Tedy každá instrukce se provede tehdy, až na ni dojde řada, a nad takovými daty, jaká jsou právě k dispozici.

Data-flow (architektura řízená daty) – Alternativa k Control-flow. Okamžik provedení určité akce se řídí připraveností všech dat, která jsou k provedení určité akce zapotřebí. Výhodou je možnost provádět více činností souběžně - tedy větší potenciál paralelismu, který von Neumannově koncepci naopak chybí.

Harvardská

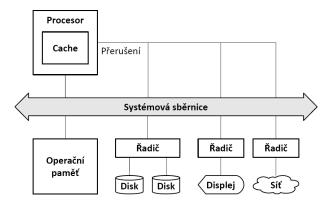
Vytvořena až po Von Neumannově, liší se hlavně tím, že program se ukládá do jiné paměti než data (tzn. jsou 2 "druhy paměti" – instrukcí a dat). Příkladem jsou DSP procesory a mikrokontrolery.

Např. AVR od Atmelu, a PIC – mají paměť na program a data a RISC instrukční sadu; výhoda oddělených pamětí je, že můžou mít různou bitovou hloubku – 8 bitové data, ale 12-, 14- či 16- bitové instrukce - např. ARM musí občas použít více než jednou instrukci na zpracování obsahu plné velikosti).

Oproti Von Neumannově nehrozí nebezpečí přepsání programu sebou samým, ale kvůli většímu počtu paměťových sběrnic je náročnější na výrobu. Paměť navíc nelze dělit podle potřeby (rozdělení je už dané).

Příklad (Načrtněte typickou architekturu pocitace, ze které bude zrejmé umísténí a propojení základnich stavebních prvku (procesor, pameti, radice a zarízeni, sbenice). Ilustrujte na úrovni zakladnich kroků ínstrukcního cyklu jak procesor vykonává program. Popište typy instrukci (a napište jejich příklady), ze kterých se program z pohledu procesoru skládá.)

Typická (sběrnicová) architektura systému:



Zpracování instrukcí

- čtení instrukce z paměti na adrese v registru PC (program counter, obsahuje adresu následující instrukce)
- dekódování instrukce a čtení operandů z registrů
- vykonání operace odpovídající instrukčnímu kódu (operace s obsahem registrů, výpočet adresy a čtení/zápis do paměti, porovnání operandů pro podmíněný skok)
- uložení výsledku do registru (výsledek operace s registry, data přečtená z paměti)
- **posun** PC na následující instrukci (následující instrukce následuje bezprostředně za právě čtenou instrukcí, pokud není řečeno jinak tzn. podmíněný/nepodmíněný skok, výjimka)

Typy instrukci (architektura MIPS):

- operace registr/registr, registr/immediate¹⁶ (ALU operace, přesun dat mezi registry)
- přesuny dat registr/paměť (load/store architektura)
- podmíněné skoky (při rovnosti/nerovnosti obsahu dvou registrů)
- nepodmíněné skoky (včetně nepřímých skoků a skoků do podprogramu)
- speciální instrukce (práce se speciálními registry)

Start-up PC (zmáčknu "power on" a následuje...)

- 1. procesor začne vykonávat kód (program) BIOSu (Basic Input/Output System)
- 2. BIOS zjistí, jaký HW je nainstalován, provede inicializaci grafické karty a z (uživatelem definovaného) disku načte a spustí boot sektor
- 3. boot sektor obsahuje kód, který s pomocí služeb BIOSu přečte z disku a spustí zavaděč OS
- 4. zavaděč OS přečte z disku kód OS a spustí ho
- 5. OS nastartuje systémové služby a uživatelské rozhraní

Report (Bulej)

Tenhle člověk se v tom vrtal hodně, ale já mám tu výhodu, že jsem na střední chodil na elektroprůmyslovku, takže instrukcí a typů instrukcí jsem mu tam popsal spoustu a i postup, jak procesor vykonává program, jsem věděl do detailů (a do detailů to chtěl). Přesvědčil jsem ho asi hlavně tím, že jsem odpovídal takovým tím "samozřejmým"způsobem ("a když procesor vykoná instrukci, co dělá dál?"-"pokračuje další instrukcí""no ale co přesně dělá"-"no tenhle postup znovu, načte další instrukci..." "co to přesně znamená?"-"no prostě zvětší instruction pointer o velikost právě zpracované instrukce a tím získá adresu následující instrukce, a opakuje tenhle postup").

¹⁶operand (číslo) uložené přímo ve strojovém kódu

Report (Peterka)

Peterka si narozdiel od Skopala aj precital to co som si napisal na papier. Popisal som tam Von Neumanna a Harvardsku architekturu (napisal som tam vsetko z vypiskov). K tomu nemal vyhrady. Potom vsak prisla horsia cast ked sa ma zacal vypytovat otazky typu:

myslite si ze je dobre/zle ked moze byt prepisana ta pamat kde sa nachadza program, alebo ake su vyhody programovatelneho radica... dalej sa ma pytal na SISD,SIMD,MISD,MIMD, mal som mu nakreslit MISD ... co som moc nevedel... potom sa ma spytal na rozdiel Instruction flow control/Data flow control... dialog s Peterkom mi prisiel v niektorich castiach skor ako jeho monolog s mojim prikyvovanim hlavy...

Akorat jsem nebyl schopny si vzpomenout na architektury rizenou daty. A chtel vedet kolik radicu a ALU je potreba pri instrukcich SIMD,MIMD. Znamku nevim.

DATA FLOW + CONTROL FLOW (asi :)) podotázka u mikroprocesorů a architektury

Report (Peterka)

Von Neumannova architektura - dost temno Harvardská Architektura - záblesky stroje řízené daty - brrr hrůza tady už otázky opravdu nevím... dodám jen nepodceňte hardware - peterka dává vždy jednu hardwarovou a jednu síťovou otázku doplňující: jaké jsou volací konvence v Pascalu a C? viz zpracované otázky co se stane když zavoláme virtuální fci před voláním konstruktoru? konečně jsem se chytil .)

Report (Tůma)

Za ferove povazujem ze vzal v uvahu ze som IOI a nedal mi konkretnu podotazku, skor tak prehladovo vsetko od architektur, cez procesory az po IO. Na druhej strane sa dost vrtal v zberniciach o ktorych som toho vedel pramalo (myslim, ze v tych materialoch na statnice tam toho o nich moc nebolo). Ked som zacal hovorit o preruseni, tak ma prerusil s tym, ze ak nechcem dopadnut ako kolega predo mnou (patrne ho vyhodil) tak nech som ticho

5.2 Procesory, multiprocesory

Definice (Procesor)

Procesor (CPU – central processing unit) je ústřední výkonnou jednotkou počítače, která čte z paměti instrukce a na jejich základě vykonává program.

Základnými súčasťami procesora sú:

- řadič nebo řídicí jednotka, která řídí tok programu, tj. načítání instrukcí, jejich dekódování, načítání operandů instrukcí z operační paměti a ukládání výsledků zpracování instrukcí
- sada registrů k uchování operandů a mezivýsledků.
- jedna nebo více aritmeticko-logických jednotek (ALU), které provádí s daty aritmetické a logické operace.
- některé procesory obsahují jednu nebo několik jednotek plovoucí čárky (FPU), které provádí operace v plovoucí řádové čárce.

Poznámka

Súčasné procesory navyše často obsahujú ďalšie rozsiahle funkčné bloky (cache, rôzne periférie) – ktoré z "ortodoxného hladiska" nie sú priamo súčasťou *jadra procesoru*. Niektoré procesory môžu obsahovať viac jadier (+logiku slúžiacu k ich vzájomnému prepojeniu). Ďalším trendom je SoC (System on Chip), kde sa na čipe procesora nachádzajú aj ďalšie subsystémy napr. na spracovanie zvuku, grafiky alebo pripojenie externých periférií (takéto riešenia sa využívajú väčšinou v PDA, domácej elektronike, mobiloch atď.).

Dělení podle instruční sady

Podľa inštrukčnej sady je možné procesory rozdeliť na:

- CISC (Complex Instruction Set Computer): poskytuje rozsiahlu inštrukčnú sadu spolu s rôznymi variantami inštrukcií. Jedna inštrukcia napr. môže vykonať veľa low-level operácií (načítanie z pamäti, vykonať aritmetickú operáciu a výsledok uložiť). Takéto inštrukcie zjednodušovali zápis programov (inštrukcie boli bližšie vyšším programovacím jazykom) a zmenšovali veľkosť programu a počet prístupov do pamäti čo bolo v 60tych rokoch dôležité. Avšak nie vždy je vykonanie jednej zložitej operácie rýchlejšie ako vykonanie viac menej zložitých miesto toho (napr. kvôli zložitému dekódovaniu a použitiu mikrokódu na volanie jednoduchých "podinštrukcií"). Príkladmi CISC architektúr procesorov sú System/360, Motorola 68000 a Intel x86. V súčasnosti napr. x86 rozkladá zložité inštrukcie na "micro-operations" ktoré môžu byť pipeline-ou spracované paralelne a vyšší výkon je tak dosahovaný na väčšom rozsahu inštrukcií. Vďaka tomu sú súčasné x86 procesory minimálne rovnako výkonné ako ozajstné RISC architektúry.
- RISC (Reduced Instruction Set Computer): design CPU ktorý uprednosňuje jednoduchšiu inštrukčnú sadu a menšiu zložitosť adresovacích modelov vďaka čomu je možné dosiahnuť lacnejšiu implementáciu, väčšiu úroveň paralelizmu a účinnejšie kompilátory. Dôvodom vzniku bolo aj nevyužívanie celej CISC inštrukčnej sady a upredňostňovania len obmedzenej podmnožiny (designéri procesorov potom optimalizovali len tieto podmnožiny a tak sa zvyšné inštrukcie používali ešte menej...). Kvôli väčšiemu počtu inštrukcií však musia RISC procesory častejšie pristupovať k pamäti... Príkladmi RISC procesorov sú napr. SPARC a ARM. V architekturách typu Post-RISC jde o spojení RISCových vlastností s technikami zvýšení výkonu, jako je out-of-order vykonávání a paralelismus.
- VLIW: Very Long Instruction Word or VLIW refers to a CPU architecture designed to take advantage of instruction level parallelism (ILP). A processor that executes every instruction one after the other (i.e. a non-pipelined scalar architecture) may use processor resources inefficiently, potentially leading to poor performance. The performance can be improved by executing different sub-steps of sequential instructions simultaneously (this is pipelining), or even executing multiple instructions entirely simultaneously as in superscalar architectures. The VLIW approach, on the other hand, executes operation in parallel based on a fixed schedule determined when programs are compiled. Since determining the order of execution of operations (including which operations can execute simultaneously) is handled by the compiler, the processor does not need the scheduling hardware that the three techniques described above require. As a result, VLIW CPUs offer significant computational power with less hardware complexity (but greater compiler complexity) than is associated with most superscalar CPUs.
- EPIC: (Někdy označován za poddruh VLIW) Explicitly Parallel Instruction Computing (EPIC) is a computing paradigm that began to be researched in the 1990s. This paradigm is also called Independence architectures. It was used by Intel and HP in the development of Intel's IA-64 architecture, and has been implemented in Intel's Itanium and Itanium 2 line of server processors. The goal of EPIC was to increase the ability of microprocessors to execute software instructions in parallel, by using the compiler, rather than complex on-die circuitry, to identify and leverage opportunities for parallel execution. This would allow performance to be scaled more rapidly in future processor designs, without resorting to ever-higher clock frequencies, which have since become problematic due to associated power and cooling issues.

TODO: asi opravit, možná zpřesnit VLIW a EPIC a určitě přeložit

Řekneme, že procesor má *ortogonální instrukční sadu*, pokud žádná instrukce nepředpokládá implicitně použití některých registrů. To umožňuje jednodušší práci algoritmům přidělování registrů v překladačích. Příkladem neortogonální instrukční sady je i x86.

Další dělení

Ďalej je možné procesory rozdeliť podľa dĺžky operandov v bitoch (8, 16, 32, 64...), ktorý je procesor schopný spracovať v jednom kroku. V embedded zariadeniach sa najčastejšie používajú 4- a 8-bitové procesory. V PDA, mobiloch a videohrách 8 resp. 16 bitové. 32 a viac bitov využíajú napr. osobné počítače a laserové tlačiarne.

Dôležitou vlastnosťou je aj taktovacia frekvencia jadra, MIPS (millions of instructions per second) a jeho rýchlosť. V súčasnosti je ťažké dávať do súvislosti výkon procesorov s ich frekvenciou (resp. MIPS) – kým Pentium zvládne na výpočet vo floatoch, jednoduchý 8-bitový PIC na to potrebuje oveľa viac taktov. Ďalším "problémom" je superskalarita procesorov, ktorá im umožňuje vykonať viacero nezávislých inštrukcií počas jedného taktu.

Techniky pro zvýšení výkonu

Zvyšovať výkon (procesorov) je možné viacerými spôsobmi. Najjednoduchším (a najpomalším) typom je Subskalárny CPU (načíta a spracúva len jednu inštrukciu naraz – preto musí celý procesor čakať kým vykonávanie inštrukcie skončí; je tak zdržovaný dlhšie trvajúcimi inštrukciami).

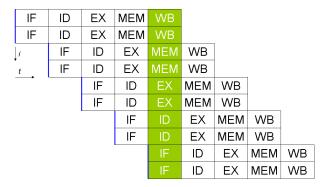


Pokusy o dosiahnutie skalárneho a lepšieho výkonu vyústili do designov ktoré sa správajú menej lineárne a viac paralelne. Čo sa týka paralelizmu v procesoroch, používajú sa dva druhy pojmov na ich klasifikáciu – *Instruction level parallelism* (zvyšovanie rýchlosti vykonávania inštrukcií v procesore a teda zväčšovanie využitia prostriedkov na čipe) a *Thread level parallelism* (zväčšovanie počtu vlákien, ktoré dokáže CPU vykonávať naraz).

• pipeline: Zlepšenie je možné dosiahnúť pomocou "instruction pipelining"-u, ktoré je použíté vo väčšine moderných procesorov. Umožňuje vykonanie viac ako jednej inštrukcie v jednom kroku vďaka rozloženiu spracovávania inštrukcie na viac menších krokov:

IF	ID	EX	MEM	WB				
↓ <i>i</i>	IF	ID	EX	MEM	WB			
<i>t</i> →		IF	ID	EX	MEM	WB		
			IF	ID	EX	MEM	WB	
				IF	ID	EX	MEM	WB

• superskalarita: Dialša možnosť je použitie superscalar designu, ktorý obsahuje dlhú inštrukčnú pipeline a viacero identických execution jednotiek.



• Out of order execution

- 1. Načtení instrukce, případně její rozdrobení na mikroinstrukce
- 2. Zařazení do vyčkávací stanice (instruction pool)
- 3. Instrukce čeká na všechny svoje operandy
- 4. Instrukce se vykoná ve své výkonné jednotce (je vybírána z instruction poolu nezávisle na ostatních)
- 5. Výsledky se uchovají ve frontě (reorder buffer)
- 6. Až se všechny starší instrukce zapíší do registrů, zapíše se výsledek této instrukce (opětovné řazení)
- Predikce skoků hluboké pipeliny mají problém, pokud podmíněný skok není proveden; dynamická predicke skoků (historie CPU vzory nějaké hloubky) vs. statická (bez nápovědy skok vpřed se neprovede, skok vzad se provede; s nápovědou překladač odhaduje pravděpodobnost skoku)
- **Spekulativní vykonávaní** vykonávání kódu, který nemusí být zapotřebí; významná disproporce mezi rychlostí CPU a paměti; typické využití je značné předsunutí čtecích operací; CPU provádí i odsouvání zápisových operací
- Data parallelism: SIMD inštrukcie (napr. multimediálne inštrukcie), vektorové procesory...

Multiprocesory

TODO: jde o copy & paste z Wiki ... předělat česky/slovensky

Definice (Multiprocesor)

O *multiprocesoru* mluvíme, pokud je použito dvou nebo více procesorů (CPU) v rámci jednoho počítačového systému. Termín je také používán mluvíme-li o schopnosti systému využívat více procesorů a/nebo schopnosti rozdělovat úlohy mezi jednotlivými procesory.

Vztah k datům a instrukcím

In multiprocessing, the processors can be used to execute a single sequence of instructions in multiple contexts (single-instruction, multiple-data or SIMD, often used in vector processing), multiple sequences of instructions in a single context (multiple-instruction, single-data or MISD, used for redundancy in fail-safe systems and sometimes applied to describe pipelined processors or hyperthreading), or multiple sequences of instructions in multiple contexts (multiple-instruction, multiple-data or MIMD).

Symetrie

In a multiprocessing system, all CPUs may be equal, or some may be reserved for special purposes. A combination of hardware and operating-system software design considerations determine the symmetry (or lack thereof) in a given system. For example, hardware or software considerations may require that only one CPU respond to all hardware interrupts, whereas all other work in the system may be distributed equally among CPUs; or execution of kernel-mode code may be restricted to only one processor (either a specific processor, or only one processor at a time), whereas user-mode code may be executed in any combination of processors. Multiprocessing systems are often easier to design if such restrictions are imposed, but they tend to be less efficient than systems in which all CPUs are utilized equally.

Systems that treat all CPUs equally are called symmetric multiprocessing (SMP) systems. In systems where all CPUs are not equal, system resources may be divided in a number of ways, including asymmetric multiprocessing (ASMP), non-uniform memory access (NUMA) multiprocessing, and clustered multiprocessing (qq.v.).

Těsnost spojení multiprocesorů

- Tightly-coupled multiprocessor systems contain multiple CPUs that are connected at the bus level. These CPUs may have access to a central shared memory (SMP or UMA), or may participate in a memory hierarchy with both local and shared memory (NUMA). The IBM p690 Regatta is an example of a high end SMP system. Intel Xeon processors dominated the multiprocessor market for business PCs and were the only x86 option till the release of AMD's Opteron range of processors in 2004. Both ranges of processors had their own onboard cache but provided access to shared memory; the Xeon processors via a common pipe and the Opteron processors via independent pathways to the system RAM.
- Chip multiprocessors, also known as multi-core computing, involves more than one processor placed on a single chip and can be thought of the most extreme form of tightly-coupled multiprocessing. Mainframe systems with multiple processors are often tightly-coupled.
- Loosely-coupled multiprocessor systems (often referred to as clusters) are based on multiple standalone single or dual processor commodity computers interconnected via a high speed communication system (Gigabit Ethernet is common). A Linux Beowulf cluster is an example of a loosely-coupled system.

Tightly-coupled systems perform better and are physically smaller than loosely-coupled systems, but have historically required greater initial investments and may depreciate rapidly; nodes in a loosely-coupled system are usually inexpensive commodity computers and can be recycled as independent machines upon retirement from the cluster.

SMP (Symmetric Multiprocessing): viac procesorov so zdieľanou operačnou pamäťou (nutné mechanizmy na zabránenie nesprávnych náhľadov na pamäť a migráciu procesov medzi procesormi). SMP systems allow any processor to work on any task no matter where the data for that task are located in memory; with proper operating system support, SMP systems can easily move tasks between processors to balance the workload efficiently.

5.3 Vstupní a výstupní zařízení, ukládání a přenos dat

Zařízení mají různé charakteristiky:

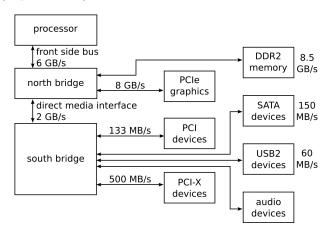
- druh blokové (disk, síťová karta), znakové (klávesnice, myš)
- přístup sekvenční (datová páska), náhodný (hdd, cd)
- komunikace synchronní (pracuje s daty na žádost disk), asynchronní ("nevyžádaná" data síťová karta)
- sdílení sdílené (preemptivní, lze odebrat síťová karta (po multiplexu OS)), vyhrazené (nepreemptivní tiskárna, sdílení se realizuje přes spooling frontou). Reálně se rozdíly stírají.
- rychlost (od několika Bps po GBps)
- směr dat R/W, R/O (CD-ROM), W/O (tiskárna)

Propojovací systémy

Dělí se na **dvoubodové spoje** (vztah 1:1), jde např. o přímé spojení porty, křížový přepínač, kde není nutná žádná adresace. Druhou možností jsou **vícebodové spoje**, kde více účastníků sdílí přenosové médium jako např. sběrnice nebo při broadcastingu.

Procesor může přistupovat k I/O zařízením dvěma způsoby:

- port-mapped I/O speciální adresový port CPU, který má i speciální instrukce pro práci (IN, OUT) s I/O zařízením, která také mají vlastní adresový prostor (buď přímo vlastní sběrnici, nebo extra I/O pinem), díky tomu se také říká "isolated I/O",
- memory-mapped I/O paměťové mapování, který mapuje I/O zařízení přímo do fyzické paměti, kterou tak sdílí s ostatními daty, tato část paměti může být vyhrazená trvale nebo i jen dočasně. Zařízení poslouchá na adresové sběrnici, aby vědělo, kdy má pracovat (odpovídat, ...).



Sběrnice

Sběrnice je sada vodičů propojující více zařízení. Vodiče jsou oddělené pro řízení (požadavky, potvrzení, typ dat) a data (přenos dat, adresování). Výhodou je univerzálnost a nízká cena, nevýhodami pak omezení délkou a dané v důsledku používání rozmanitých zařízení, také potenciální "bottleneck".

Transakce na sběrnici začíná požadavkem (vyslání příkazu a adresy cíle), na který musí cíl odpovědět potvrzením, načež následuje přenos dat mezi účastníky **master/initiator** (kteří posílají požadavek) a **slave/target**, kteří posílají/přijímají data.

řízení – **synchronní** (podle hodin, jednodušší, rychlejší, ale omezená délka sběrnice a stejný čas všem) vs. **asynchronní** (obecnější, složitější, zato bez omezení délky, ale s nižší rychlostí, např. USB, FireWire)

přidělování – **centralizované** (master žádá a čeká na přidělení, které přiděluje arbitr podle priority a fairness, master po provedení operace dá arbitrovi vědět, že je sběrnice opět volná) vs. **distribuované**, které může být kolizní nebo založené na "samovýběru".

Informace o stavu zařízení může CPU získávat:

- 1. polling aktivní čekání na změnu zařízení (program periodicky kontroluje stav), pro pomalá zařízení vzniká značná režie
- 2. **interrupt-driven I/O** asynchronní přerušení od zařízení, které samo signalizuje změnu stavu, na což reaguje obslužná rutina. CPU ovšem není na přerušení připraven, tak musí uložit stav programu → stojí to čas. CPU musí podporovat tuto signalizaci přerušení, identifikovat zdroj přerušení, vybrat správnou obslužnou rutinu. Systém musí zajistit doručení přerušení k CPU a dále řadič jejich podle priority určí jejich pořadí (může jich být více než má CPU vstupů).

Přenos dat mezi zařízením a CPU/pamětí:

- 1. **PIO (Programmed I/O)** data přenášena za účasti CPU (plně zaměstnán), přenos realizován cyklem v programu, rychlý přenos, ale neefektivní využití CPU, pak přišlo DMA
- 2. **DMA (Direct Memory Access)** zařízení si samo řídí přístup na sběrnici a přenáší data z/do paměti bez účasti CPU; po skončení přenosu přerušení (oznámení o dokončení) např, přenos dat mezi HDD a RAM

Bus mastering

Slouží pro přenos dat mezi zařízením a pamětí nebo mezi dvěma zařízeními. Jde o to, že sběrnici může řídit (začít transakci, být masterem) libovolný účastník (CPU vnímán jako jeden z nich), stále je nutné přenos *nastavit* z programu.

DMA

CPU nastaví přenos a nechá DMA pracovat, až je operace dokončena, pošle se přerušení, tedy mezitím může CPU pracovat jinde. DMA řadič je obvod pro řízení přenosů na sběrnici mezi pamětí a zařízeními nebo i pouze v paměti. U multiprocesorů se užívá i k přenosu dat mezi jádry. Dále běžně u pevných disků, grafických, zvukových a síťových karet. DMA řadič obsahuje registry, do kterých může CPU zapisovat nastavení přenosu (adresa v paměti, počet bytů, směr r/w, jaké zařízení) – tomu se říká burst mode, ve kterém vystačí jeden adresový cyklus na celý blok dat. Dále se využívá při přenosu dat do/z více nesouvislých bufferů (scatter/gather, také vektorové I/O).

Práce řadiče DMA

- generuje adresy paměti a periferie, generuje řídící signály pro čtení/zápis
- generuje signály pro procesor, aby zajistil, že procesor nepřistupuje (nezapisuje) na sběrnici
- řadič sám se chová jako periferie
- program nastavuje parametry přenosu, tj. odkud se bude přenášet, kam, a kolik (2 čítače, kanál DMA)
- zařízení připojena na kanál DMA, při přenosu je cílové zařízení aktivováno řadičem, nikoliv vystavením adresy

Posloupnost událostí

Čísla před událostí odpovídají číslům na obrázku níže.

- program nastaví řadič a periferii a povolí přenos
- (1) aktivací signálu DREQx periferie požádá řadič DMA o přenos slova z/do paměti
 - řadič DMA zkontroluje nastavení kanálu vyhodnotí prioritu žádosti
- (2) aktivací signálu HOLD řadič DMA požádá CPU o přidělení sběrnice
- (3) pokud CPU nepotřebuje sběrnici, odpojí se od sběrnice a signalizuje HLDA
 - CPU pořád testuje HOLD na začátku strojového cyklu
- (4) po přijetí HLDA řadič připraví sběrnici pro přenos
 - vystaví adresu v paměti a řídící signály pro čtení/zápis z/do paměti/periferie
- (5) řadič DMA aktivuje signál DACKx, kterým vyzve periferii k vystavení/přečtení dat na/ze sběrnice
- (7) v závislosti na režimu buď přenos končí, nebo pokračuje dalším slovem dokud je DREQx aktivní
 - při posledním slově řadič aktivuje signál EOP
- (8) při ukončení přenosu řadič uvolní signál HOLD
- (9) procesor uvolní HLDA a připojí se ke sběrnici

Problémy u DMA spočívají v odstínění CPU od paměti, což může vyvolat **paměťovou koherenci**, slušně řečeno pomocí DMA obejdeme cache CPU, kde mohou být aktuálnější hodnoty než v paměti, a tudíž máme problém Houstone. Řeší se to tím, že procesor sleduje, na jaké adresy se přistupuje a pokud tam padne nějaká, kterou má v cache, tak to začne řešit.

Cíle I/O software:

- Nezávislost zařízení programy nemusí dopředu vědět, s jakým přesně zařízením budou pracovat je jedno jestli pracuji se souborem na pevném disku, disketě nebo na CD-ROM
- Jednotné pojmenování (na UNIXu /dev)
- Připojení (mount) časté u vyměnitelných zařízení (disketa); možné i u pevných zařízení (disk); nutné pro správnou funkci cache OS
- Obsluha chyb v mnoha případech oprava bez vědomí uživatele (velmi často způsobeno právě uživatelem)

Report (Bulej + Yaghob)

zapisal som vyse strany, ale to co ma yaghob na slidoch a to co je vo vypracovanom ucebnom texte ich ani trochu nezaujimalo. zaujimal ich popis DMA a preruseni, pricom sa pytali ako to presne funguje - chceli popisat instrukcie ako to moze prebiehat, ako sa to presne implementuje apod., co som bohuzial vobec nevedel

Report (Bulej)

Prenos dat z disku do operacni pameti. Překvapivě dobrý výsledek, nicméně den předtím jsem si četl o DMA, takže bych to měl vědět žejo :-) Chtěl by prej ještě vědět, že to, co sedí na sběrnici a řídí ten přenos, se ovládá z procesoru tak, že v tom jsou nějaký registry, do kterejch se hodí instrukce, a taky že se načtou data z disku do diskový cache, pak se vyvolá přerušení, a pak se teprva ty data nějak dostanou do RAMky, třebas tim DMA nebo jinejma způsobama (a jakejma, pochopitelně).

5.4 Architektury OS

Klasická struktura – monolitická

Nejstarší, už IBM 360, Unix, Win., všechny služby uvnitř, prováděny ve chráněném módu, jádro poměrně velké, "údajně" nejrychlejší. Program zavolá službu OS, přes tabulku se zjistí adresa přísl. fce, ta se zavolá a vrátí výsledek. Nevýhoda: horší údržba – je-li v programu chyba, může poškodit zbývající části systému, rozšiřování za běhu je komplikované.

Virtuální stroje

Původní nápad : Virtual Machine pro IBM360 – oddělit multitasking od OS jako ext. stroj. Nad HW byla další vrstva – "Virtual Machine" – měla plánovat, vyrábí pro procesy iluzi holého HW; dneska např. VMWare dělá to samé. Pro IBM360 se dalo použít v kombinaci s CMS (jednoúlohový) i původního OS360 (rychlejší než OS360 na holém HW).

Dnes: definuji abstraktní stroj, pro něj překládám programy (.NET, Java) \rightarrow přenositelnost, kompatibilita (IBM AS400 – desítky let), problém – pomalé.

Mikrojádro

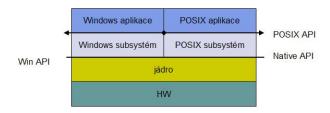
snaha aby část běžící v kernel módu byla co nejmenší (třeba jen cca 10 KB), nejnovější, experimentální, často pro Distribuované OS (dnes už nepoužívané), hodně procesů & komunikace (klient/server), mikrojádro řeší jenom komunikaci.

Filesystém apod. jsou procesy – aplikace jim posílají přes jádro požadavky. Jediný komerční OS – Chorus (ústředny). výhoda: když něco spadne, nepoškodí to zbytek, moduly jdou měnit za běhu, komunikace jde snadno rozšířit na komunikaci po síti.

Architektura WinNT

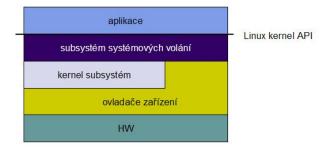
Jádro je poměrně malé (cca 1MB), schopné (pro vyšší vrstvy jsou některé schopnosti skryté), na jeho vzniku se podíleli schopní Unixáři. Byla zde snaha o malou velikost, přenositelnost. Jádro je neutrální vzhledem k vyšším vrstvám, nad ním lze vybudovat různé systémy (Windows subsystém, POSIX, OS/2).

Rozhraní OS a uživ. programů zajišťuje WinAPI, nad ním se nacházejí různé DLL, mezi kernelem a HW je "hardware abstraction layer", tj. kernel lze jednoduše upravit pro jiné architektury (Alpha, IA-64). Grafické drivery jediné mají přímý přístup k HW (kvůli výkonu), části API (USER, GDI) jsou implementované v jádře, přechod mezi user a kernel režimem zajišťuje ntdll.dll (a je tedy využíván všemi programy). Veškeré služby a aplikace běží v user módu nad jádrem.



Architektura Linuxu

- Na úrovni SW přenositelnost; abstrakce HW.
- nad HW kernel, nad ním systémová volání, hodně podobné Windows.



5.5 Procesy, vlákna, plánování

Procesy a vlákna

Systémové volání je interface mezi OS (kernelspace) a užívatelskými programy (userspace).

Definice (Proces)

Proces je inštancia vykonávaného programu. Kým program je len súbor inštrukcií, proces je vlastný "výkon" týchto inštrukcií. Proces má vlastný adresný priestor (pamäť), prostriedky, child procesy, globání proměnné, otevřené soubory, práva a napr. aj ID (Process ID).

Počas života sa môže proces nachádzať v rôznych stavoch:

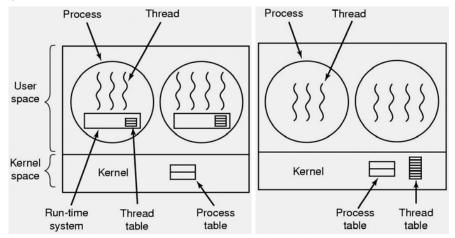
- bežiaci jeden proces na procesor,
- blokovaný pri použití blokujúceho volania I/O disku atď.,
- pripravený skončilo blokovanie; spotreboval všetok pridelený čas resp. vrátil riadenie systému, čaká na nové pridelenie procesora.
- zombie po ukončení procesu, keď už nepracuje ale ešte nebol vymazaný.

Definice (Vlákno (Thread))

Vlákno je možnosť pre program ako sa "rozdeliť" na dva alebo viac zároveň (resp. pseudo-zároveň) vykonávaných úloh. Oproti procesu mu nie je pridelená vlastná pamäť – je to len miesto vykonávania inštrukcií v programe. Oproti procesu sú jeho "atribútmi" len hodnota programového čítača, stav registrov CPU a zásobník.

Implementace:

- User Level Threads(1.diagram) thread management dělá aplikace (nemusí být podporovány OS), každý proces ma thread table, když systém zablokuje proces zablokují se i všechny jeho thready
- Kernel Threads(2.diagram) thread management dělá OS (musí podporovat), thread table je globální, systém blokuje pouze jednotlivé thready



Multithreading - schopnost systému efektivně používat více threadů, modely:

- many-to-one mnoho user-level threadů je namapováno na jeden kernel thread, používá se na systémech nepodporujících kernel thready (např. Linux pthreads)
- one-to-one každý user-level thread je namapován na jeden kernel thread (např. win2000, Linux NGPT)

Plánovanie

Prideľovanie procesorového času jednotlivým procesom má na starosti *plánovač*. Plánovanie pritom môže byť preemptívne (plně v režii OS) alebo nepreemptívne (vyžaduje spolupráci s programem, kooperatívne – alla Win16).

Ciele plánovania (niektoré z nich sú očividne protichodné):

- Spravodlivosť (každy procesor dostane adekvátnu časť času CPU)
- Efektívnosť (plne vyťažený procesor)
- Minimálna doba odpovede
- Průchodnost (maximálny počet spracovaných procesov)
- Minimálna réžia systému

Kritériá plánovania:

- Viazanosť procesu na dané CPU a I/O (presun procesu na iný procesor zaberie veľa prostriedkov)
- Proces je dávkovy/interaktívny?
- Priorita procesu (statická (nemenná okrem "renice") + dynamická, ktorá sa mení v čase kvôli spravodlivosti)
- Ako často proces generuje výpadky stránok (nejaký popis???)
- Kolik skutočného času CPU proces obdržel

Algoritmy:

- First Come First Served (FCFS): nepreemptívny, procesy plánovány v pořadí, v jakém přicházejí, procesy běží dokud neskončí
- Round Robin: preemptívne rozšírenie FCFS, každý proces má stejné povolené časové kvantum na běh, po jeho uplynutí je proces přesunut na konec fronty
- Plánovanie s viacerými frontami: niekoľko front, procesu z i-tej fronty je pridelený procesor až keď vo frontách $1, \ldots, i-1$ nie je pripravený ziadny proces. Ak proces skončil I/O operáciou, je blokovaný a presunutý do fronty i-1, ak skončil preempciou, je pripravený a presunutý do fronty i+1.
- Symmetric multiprocessing (SMP): druh víceprocesorových systémů, u kterých jsou všechny procesory v počítači rovnocenné, fronta CPU čakajúcich na pripravené procesy (aktívne (spotrebováva energiu) vs. pasívne čakanie (špeciálne inštrukcie)), "vzťah"/afinita procesov k CPU
- TODO: Plánovanie windows vs. linux???

Report (Zavoral)

zhruba to co je vo vypiskach, diskusia dalej pokracovala o rozdieloch medzi vlaknami a procesmi - napr ako su implementovane vlakna v OS ktory ich nepodporuje (snazil som sa to nejak ukazat na JVM, ale podrobnosti som velmi nevedel, takze to bolo dost napovedy pana Zavorala a par slov odo mna :?).

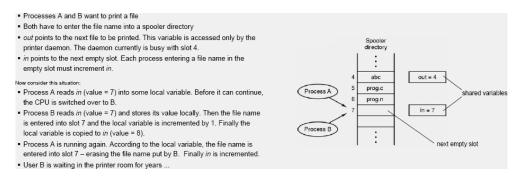
někdo jiny: som letel na Vlaknach (nevedel som ze su reprezentovane hodnotou registrov, prog. citaca a zasobnikom)

5.6 Synchronizační primitiva, vzájemné vyloučení

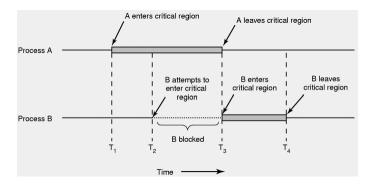
Pojmy

Časové závislé chyby (Race Conditions) Situace kde 2 nebo více procesů přistupuje ke stejnému sdílenému prostředku, a finální výsledek záleží na kdo proběhne kdy se jmenuje *race conditions*

Příklad na tiskové frontě:



Kritická sekce (Critical Regions) část programu, která dokud není dokončena není možné začít jinou (např. používá sdílené prostředky)



Vzájemné vyloučení (Mutual Exclusion) kritickou operaci provádí nejvýše jeden proces. Podmínky vzájemného vyloučení:

- 1. Zádné dva procesy nemohou být najednou ve stejné kritické sekci
- 2. Nemohou být učiněny žádné předpoklady o rychlosti procesu (žádné odhady rychlosti nebo priorit procesu, musí fungovat se všemi procesy)
- 3. Žádný proces mimo kritickou sekci nesmí blokovat jiný proces
- 4. Žádný proces nesmí čekat nekonečně dlouho v kritické sekci (jinak dead-lock)

Metody dosáhnutí vzájemného vyloučení: aktivní čekání (busy waiting) a pasivní čekání/blokování.

Aktivní čekání (Busy Waiting)

Vlastnosti: **spotřebovává čas procesoru**, vhodnější pro předpokládané krátké doby čekání, nespotřebovává prostředky OS, rychlejší.

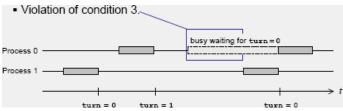
Navrhovaná řešení:

- Zakázání přerušení nevhodné proces má plnou kontrolu nad počítačem
- **Zámky v proměnné**] nefungují mezi přečtěníma nastavením locku může být program přerušen pak by si "nevšim"lock == 1 a vesel pokračoval, akorát jsme přidali novou race condition.

```
int lock;
void proc(void) {
  for (;;) {
    nekritická_sekce();
    while (lock != 0);
    lock = 1;
    kritická_sekce();
    lock = 0;
}
```

• Důsledné střídání (Strict Alternation) funguje ale porušuje podmínku 3 - proměnná turn hlídá kdo je na řadě

```
int turn = 0;
void p1(void)
                              void p2(void)
{
                               {
  for (;;) {
                                 for (;;) {
    while (turn != 0);
                                   while (turn != 1);
    kritická_sekce();
                                   kritická_sekce();
                                   turn = 0;
    turn = 1;
    nekritická_sekce();
                                   nekritická_sekce();
}
                              }
```



Petersonovo řešení - zobecnění pro N procesů:

```
/* počet procesů */
#define N 2
int turn:
int interested[N];
                              /* kdo má zájem */
void enter_region(int proc) { /* proc: kdo vstupuje */
                                /* číslo opačného procesu */
int other = 1-proc;
    interested[proc] = TRUE;
                                /* mám zájem o vstup */
    turn = proc;
                                /* nastav příznak */
    while (turn == proc && interested[other] == TRUE);
}
void leave_region(int proc) { /* proc: kdo vystupuje */
    interested[proc] = FALSE; /* už odcházím */
}
```

- Instrukce Test-and-Set Lock (TSL) atomická operace na úrovni strojového kódu, nemůže být přerušena je nutné aby ji podporoval HW (všechny současné procesory nějakou mají):
 - implementace spin-locku (druh zámku, na nějž je třeba aktivně čekat čekající proces při čekání na spinlock spotřebovává systémové prostředky) pořád ale méně prostředků než předchozí řešení

```
enter_region:
```

```
; načti zámek do registru R a
   tsl
         R,lock
                           ; nastav zámek na 1
         R,#0
                           ; byl zámek nulový?
   cmp
                           ; byl-li nenulový, znova
         enter_region
   jnz
                           ; návrat k volajícímu - vstup do
   ret
                           ; kritické sekce
leave_region:
                           ; ulož do zámku 0
         lock,#0
   mov
   ret
                           ; návrat k volajícímu
```

Pasivní čekání

Vlastnosti: proces je ve stavu blokován, vhodné pro delší doby čekání, spotřebovává prostředky OS, pomalejší.

Postup používající Sleep/Wakeup (implementovány OS, atomické operace - sleep uspí volající proces, wakeup probudí udaný proces) nefunguje (viz Problém producent/konzument).

• **Semafory** – počítá počet probuzených, reprezentace volných a přidělených prostředků Atomické operace (nesmí být přerušeny):

```
\label{eq:constraint} \begin{split} &\mathbf{down}(\mathbf{semaphore*}\ \mathbf{s})\ -\ \mathrm{zabere}\ \mathrm{semafor}\ (\mathbf{s--;})\ \mathrm{pokud}\ \mathrm{je}\ \mathrm{voln\acute{y}}\ (\mathbf{s}{>}0),\ \mathrm{jinak}\ \check{\mathrm{cek\acute{a}}}\ \mathrm{na}\ \mathrm{uvoln\check{e}}\mathrm{n\'{i}}\\ &\mathbf{up}(\mathbf{semaphore*}\ \mathbf{s})\ -\ \mathrm{uvoln\acute{i}}\ \mathrm{semafor}\ (\mathbf{s++;}),\ \mathrm{vzbud\acute{i}}\ \check{\mathrm{cekaj\acute{i}}}\mathrm{c\acute{i}}\ \mathrm{proces}\ \mathrm{(pokud}\ \mathrm{existuje}) \end{split}
```

- -nutná podpora OS (většinou v kernelu)
- Mutex Špeciálny (binárny) typ semaforu, kde sú povolené len hodnoty 0 a 1 (v Up sa miesto s := s + 1 volá s := 1) sa nazýva mutex a používa sa na riadenie prístupu k jednej premennej. Většinou pomocí TSL.

• Monitory

Implementovány překladačem, lze si představit jako třídu C++ (všechny proměnné privátní, funkce mohou být i veřejné), vzájemné vyloučení v jedné instanci (zajištěno synchronizací na vstupu a výstupu do/z veřejných funkcí, synchronizace implementována blokovacím primitivem OS). ???TODO

• Zprávy

Operace SEND a RECEIVE, zablokování odesílatele/příjemce, adresace proces/mailbox, rendez-vous...

• RWL - read-write lock, bariéry...

Ekvivalence primitiv - pomocí jednoho blokovacího primitiva lze implementovat jiné blokovací primitivum. Rozdíly mezi platformami: Windows - jednotné funkce pro pasivní čekání, čekání na více primitiv, timeouty. Unix - OS implementuje semafor, knihovna pthread.

Klasické synchronizační problémy

• Problém producent/konzument

Producent vyrába predmety, konzument ich spotrebúva. Medzi nimi je buffer pevnej veľkosti (N). Konzument nemá čo spotrebúvať ak je buffer prázdny; producent prestane vyrábať, ak je buffer plný.

```
int N = 100;
int count = 0;
void producer(void) {
    int item;
    while(TRUE) {
        produce_item(&item);
        if(count==N) sleep ();
        enter_item(item);
        count++;
        if(count == 1) wake(consumer);
    }
}
void consumer(void) {
    int item;
    while(TRUE) {
        if(count==0) /*pozice A*/ sleep ();
        remove_item(&item);
        count--;
        if(count==N-1)
            wake(producer);
        consume_item(&item);
    }
}
```

- 1. Buffer je prázdny, a konzument práve prečítal count, aby zistil, či je rovný nule
- 2. Preplánovanie na producenta ("pozice A")
- 3. Producent vytvoří item a zvýší count
- 4. Producent zistí, či je count rovný jednej. Zistí že áno, čo znamená že konzument bol predtým zablokovaný (pretože muselo byť 0), a zavolá wakeup
- 5. Teraz môže dôjsť k zablokovaniu: konzument pokračuje na "pozici A"a uspí se, pretože si myslí, že nemá čo zobrať; producent bude chvíľu produkovať a dôjde "preplneniu" ⇒ uspí sa; spí producent aj konzument :o)

Řešení pomocí semaforu:

```
#define N 10
typedef int semaphore;
                           //a semaphore is an integer
semaphore empty = N;
                           //counting empty slots
semaphore full = 0;
                           //counting full slots
semaphore mutex = 1;
                           //mutual exclusion on buffer access
void producer() {
  while (TRUE) {
    int item = produce_item();
    down(&empty);
                           //possibly sleep, decrement empty counter
    down(&mutex);
                           //possibly sleep, claim mutex (set it to 0) thereafter
    insert_item(item);
    up(&mutex);
                           //release mutex, wake up other process
    up(&full);
                           //increment full counter, possibly wake up other ...
```

• Problém obědvajících filosofů

Pět filosofů sedí okolo kulatého stolu. Každý filosof má před sebou talíř špaget a jednu vidličku. Špagety jsou bohužel slizké a je třeba je jíst dvěma vidličkami. Život filosofa sestává z období jídla a období přemýšlení. Když dostane hlad, pokusí se vzít dvě vidličky, když se mu to podaří, nají se a vidličky odloží.

• Problém ospalého holiče

Holič má ve své oficíně křeslo na holení zákazníka a pevný počet sedaček pro čekající zákazníky. Pokud v oficíně nikdo není, holič se posadí a spí. Pokud přijde první zákazník a holič spí, probudí se a posadí si zákazníka do křesla. Pokud přijde zákazník a holič už střihá a je volné místo v čekárně, posadí se, jinak odejde.

Report (Bulej)

- 1. priklad Producent-konzument pomoci semaforu
- 2. stacilo napsat aktivni vs. pasivni, kriticka sekce, spinlock, semafor (obecne monitor) a pak nasledovalo par otazek, zda je mozne naprogramovat synch. primitivum bez podpory HW

Report (Bulej)

Myslím, že jsem je pochopil, až když mi to pan Skopal vysvětlil. To, co je v materiálech opravdu nestačí. TSL je dobrý v tom, že má pravě operaci Test and Set Lock jako atomickou. Pak jsem se pokoušel udělat semafor pro problém producent a konzument a dělal jsem ho uplně špatně

Report (Hnětýnka)

na jedničku musíte umět praktické užití (např. z více mutexů postavit semafor)

Report (Bednárek)

Na tuhle jsem byl připravený ze zadaných otázek asi nejhůř, kupodivu jsem toho k ní ale nakonec na papír vyplodil poměrně dost a dostal k tématu jen málo doplňujících otázek (nějaké drobné praktické a jak implementovat mutex bez podpory OS, tj. pomocí test-and-set instrukce), pak se plynule a nepozorovaně přešlo na zablokování a zotavení z něj. Něco jsem věděl, vzpomněl jsem si na 3 ze 4 Coffmanových podmínkek a jejich ošetření, čtvrtou jsem pak vymyslel s Bednárkovou vydatnou pomocí. Žádné otázky na "klasické synchronizační problémy" nebo Petersonovo řešení, tj. věci, o kterých jsem se sám radši nezmínil.

na konci sa opytal, ze aky problem okrem vyhladovania moze nastat... deadlock

Sleep/wakeup, semafory, monitory, správy, polling - u každého ako funguje a či to robí aplikácia/OS/HW. Potom sme sa pobavili o možnosti implementovať jedno druhým.

5.7 Zablokování a zotavení z něj

Prostředek je cokoliv, k čemu je potřeba hlídat přístup (HW zařízení – tiskárny, cpu; informace – záznamy v DB). Je možné je rozdělit na *odnímatelné* (lze odejmout procesu bez následků – CPU, paměť) a *neodnímatelné* (nelze odejmnout bez nebezpečí selhání výpočtu – CD-ROM, tiskárna... tento druh způsobuje problémy).

Práce s prostředky probíhá v několika krocích: *žádost o prostředek* (blokující, právě tady dochází k zablokování), *používání* (např. tisk), *odevzdání* (dobrovolné/při skončení procesu).

Množina procesů je *zablokována*, jestliže každý proces z této množiny čeká na událost, kterou může způsobit pouze jiný proces z této množiny.

Coffmanovy podmínky

Splnenie týchto podmienok je nutné pre zablokovanie:

- 1. Výlučný přístup každý prostředek je buď vlastněn právě jedním procesem nebo je volný.
- 2. Drž a čekej procesy aktuálně vlastnící nějaké prostředky mohou žádat o další.
- 3. **Neodnímatelnost** přidělené prostředky nemohou být procesům odebrány.
- 4. Čekání do kruhu existuje kruhový řetěz procesů, kde každý z nich čeká na prostředek vlastněný dalším článkem řetězu.

Řešení zablokování

- Pštrosí algoritmus Zablokování se ani nedetekuje, ani se mu nezabraňuje, ani se neodstraňuje, Uživatel sám rozhodne o řešení (kill). Nespotřebovává prostředky OS nemá režii ani neomezuje podmínky provozu. (Nejčastější řešení Unix, Windows)
- Detekce a zotavení Hledá kružnici v orientovaném grafu (hrany vedou od procesu, který čeká, k procesu, který prostředek vlastní), pokud tam je kružnice, nastalo zablokování a je třeba ho řešit:
 - Odebrání prostředku dohled operátora, pouze na přechodnou dobu
 - Zabíjení procesů z cyklu (resp. mimo cyklus vlastnící identický prostředek)
 - Rollback (OS ukládá stav procesů, při zablokování se některé procesy vrátí do předchozího stavu ⇒ ztracena práce... obdoba u DB)
- **Vyhýbání se** Bezpečný stav (procesy/prostředky nejsou zablokovány, existuje cesta, jak uspokojit všechny požadavky na prostředky spouštěním procesů v jistém pořadí); Viď. bankéřův algoritmus. Nutné je předem znát všechny prostředky, které budou programy potřebovat; OS pak dává prostředky tomu, který je nejblíž svému maximu potřeby a navíc pro který je prostředků dost na dokončení. Dnes se moc nepoužívá.
- Předcházení (prevence) napadení jedné z Coffmanovy podmínek
 - 1. *Výlučný přístup spooling* (prostriedky spravuje jeden systemový proces, ktory dohliada na to, aby jeho stav bol konzistentny (tiskarna) pozor na místo na disku)
 - 2. $Drž~a~\check{c}ekej$ žádat o všechny prostředky před startem procesu. Nejprve všechno uvolnit a pak znovu žádat o všechny najednou
 - 3. Neodnímatelnost odnímatelné prostředky mohou být odejmuty bez následků (procesor-přeplánování, paměť-swapping), neodnímatelné nelze bez nebezpečí selhání výpočtu
 - 4. $\check{C}ek\acute{a}n\acute{i}$ do kruhu všechny prostředky jednoznačně očíslovány (stačí prostředky v nějakém kontextu), procesy mohou žádat o prostředky jen ve vzestupném pořadí
- Dvojfázové zamykání nejprve postupně všechno zamykám (první fáze). Potom se může pracovat se zamčenými prostředky –
 a na závěr se už jen odemyká (druhá fáze) viď transakční spracování u databází ((striktní/konzervativní) dvoufázové
 zpracování)

Bankéřův algoritmus: Bankéř má klienty a těm slíbil jistou výšku úvěru. Bankéř ví, že ne všichni klienti potřebují plnou výši úvěru najednou. Klienti občas navštíví banku a žádají postupně o prostředky do maximální výšky úvěru. Až klient skončí s obchodem, vrátí bance vypůjčené peníze. Bankéř peníze půjčí pouze tehdy, zůstane-li banka v bezpečném stavu. Problémy: složitost $O(N^2)$, požadované info je typicky nedostupné, efektivnéjší bývá řešit až vzniklé problémy

5.8 Organizace paměti, alokační algoritmy

Hierarchie paměti (směrem odshora dolů roste velikost, cena na bajt a rychlost klesá – a naopak...):

- registry CPU 10ky-100vky bajtů (IA-32: obecné registy pár 10tek), IA-64 až kB (extrém), stejně rychlé jako CPU.
- cache z pohledu aplikací není přímo adresovatelná; dnes řádově MB, rozdělení podle účelu, několik vrstev. L1 cache (cca 10ky kB) dělené instrukce/data; L2 (cca MB) sdílené instr&data, běží na rychlosti CPU (dřív bývala pomalejší), servery L3 (cca 10MB). Vyrovnává rozdíl rychlosti CPU a RAM. Využívá lokality programů cyklení na místě; sekvenčního přístupu k datům. Pokud nenajdu co chci v cache "cache-miss", načítá se potřebné z RAM (po blocích), jinak (v 95-7% případů) nastane "cache-hit", tj. požadovaná data v cache opravdu jsou a do RAM nemusím.
- hlavní paměť (RAM) přímo adresovatelná procesorem, 100MB GB; pomalejší než CPU; CAS doba přístupu na urč.
 místo nejvíc zdržuje (v 1 sloupci už čte rychle, dat. tok dostatečný), další latence doba než data dotečou do CPU hraje roli vzdálenost (AMD- integrovaný řadič v CPU)
- pomocná paměť není přímo adresovatelná, typicky HDD; náh. přístup, ale pomalejší. 100GB, různé druhy IDE, SATA, SCSI; nejvíc zdržuje přístupová doba (čas seeku) cca 2-10ms; obvykle sektor 512 B; roli hraje i rychlost otáčení (4200 15000 RPM) taky řádově ms.
- zálohovací paměť nejpomalejší, z teorie největší, dnes ale neplatí; typicky pásky; pro větší kapacitu autoloadery ; sekvenční přístup; dnes kvůli rychlosti často zálohování RAIDem.

Správce paměti: část OS, která spravuje paměťovou hierarchii se nazývá správce paměti (memory manager):

- udržuje informace o volné/plné části paměti
- stará se o přidělování paměti
- a "výměnu paměti s diskem"

Přiřazení adresy

- při překladu (je již známo umístění procesu, generuje se absolutní kód, PS: statické linkování)
- při zavádění (OS rozhodne o umístění generuje se kód s relokacemi, PS: dynamické linkování)
- za běhu (proces se může stěhovat i za běhu, relokační registr)

Overlay – Proces potřebuje více paměti než je skutečně k dispozici. Programátor tedy rozdělí program na nezávislé části (které s v paměti podle potřeby vyměňnují) a část nezbytnou pro všechny části... Používáno hlavně v DOSu, nyní se stejného cíle dosahuje pomocí virtuální paměti

Výměna (swapping) – dělá se, protože proces musí být v hlavní paměti, aby jeho instrukce mohly být vykonávány procesorem... Jde o výměnu obsahu paměti mezi hlavní a záložní.

Překlad adresy – nutný, protože proces pracuje v logickém (virtuálním) adresovém prostoru, ale HW pracuje s fyzickým adresovým prostorem...

Spojité přidělování paměti – přidělení jednoho bloku / více pamětových oddílů (*pevně* – paměť pevně rozdělena na části pro různé velikosti bloků/*volně* – v libovolné části volné paměti může být alokován libovolně veliký blok)

Informace o obsazení paměti – bitová mapa / spojový seznam volných bloků (spojování uvolněného bloku se sousedy) Alokační algoritmy:

- First-fit první volný dostatečné velikosti rychlý, občas ale rozdělí velkou díru
- Next-fit další volný dostatečné velikosti, začíná se na podlední prohledávané pozici jako First-fit, ale rychlejší
- Best-fit nejmenší volný dostatečné velikosti pomalý (prohledává celý seznam), zanechává malinké díry (ale nechává velké díry vcelku)
- Worst-fit největší volný pomalý (prohledává celý seznam), rozdělí velké díry
- $Buddy \ syst\'em -$ paměť rozdělena na bloky o velikosti 2^n , bloky stejné velikosti v seznamu, při přidělení zaokrouhlit na nejbližší 2^n , pokud není volný, rozštípnou se větší bloky na příslušné menší velikosti, při uvolnění paměti se slučují sousední bloky (buddy)

Fragmentace paměti:

- externí volný prostor rozdělen na malé kousky, pravidlo 50% po nějaké době běhu programu bude cca 50% paměti fragmentováno a u toho to zůstává plýtvání místem mezi alokovanými oblastmi
- interni nevyužití celého přiděleného prostoru (50% velikosti posledního bloku prostoru nevyužito) plýtvání místem uvnitř alokované oblasti
- sesypání pouze při přiřazení adresy za běhu, nebo segmentaci nelze při statickém přidělení adresy

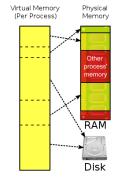
5.9 Principy virtuální paměti, stránkování, algoritmy pro výměnu stránek, výpadek stránky, stránkovací tabulky, segmentace

Virtuální paměť

Virtuální paměť způsob správy operační paměti počítače, který umožňuje předložit běžícímu procesu adresní prostor paměti, který je uspořádán jinak nebo je dokonce větší, než je fyzicky připojená operační paměť RAM. Z tohoto důvodu procesor rozlišuje mezi virtuálními adresami (pracují s nimi strojové instrukce, resp. běžící proces) a fyzickými adresami paměti (odkazují na konkrétní adresové buňky paměti RAM). Převod mezi virtuální a fyzickou adresou je zajišťován samotným procesorem v MMU (je nutná hardwarová podpora) nebo samostatným obvodem.

Šlo by to bez HW podpory? Jistě že ano VM to tak dělají, nicméně rychlost není nijak osňující, proto se do novych strojů už přidává jejich HW podpora (?? ověřit).

- Umožňuje sdílení paměti (operačním systémem)
- Vzájemná ochrana programů (v současnosti je důležitější ochrana dat než využití principu lokalit), tzn. to aby jeden program nepřepisoval druhému programu jeho data a tak.
- Každý běžící program pracuje se svým virtuálním adresním prostorem



Obrázek 5: Virtuální paměť

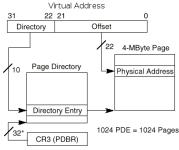
Existují dvě základní metody implementace virtuální paměti – stránkování a segmentace.

Stránkování

Při stránkování je paměť rozdělena na větší úseky stejné velikosti, které se nazývají stránky. Správa virtuální paměti rozhoduje samostatně o tom, která paměťová stránka bude zavedena do vnitřní paměti a která bude odložena do odkládacího prostoru (swapu).

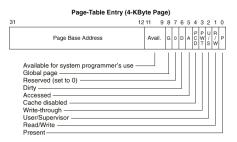
Podporované všemi velkými CPU a OS, jednorozměrný VAP (virtuální adresní prostor).

- VAP rozdělen na stránky (velikost je mocnina 2), FAP na rámce (úseky stejné délky)
- převod stránkovací tabulkou každý proces má svojí, příznak existence mapování (v.stránka není v FAP \rightarrow událost "výpadek stránky" \rightarrow synchronní přerušení) umístěna v fyzické paměti

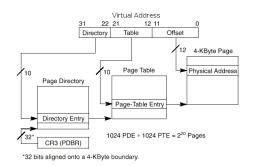


*32 bits aligned onto a 4-KByte boundary.

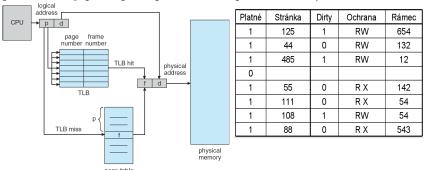
- umožnuje oddělené VAP i sdílenou paměť mapování virtuální stránky 2 procesů na jednu fyzickou
- OS mění tabulky stránek změnou PTBR (Page Table Base Register) PTBR obsahuje bázovou adresu tabulky stránek procesu
- \bullet Příklad: položka stránkovací tabulky Intel IA32 (= x86) \rightarrow její struktura je závislá na architektuře CPU



• víceúrovňové stránkování (např. kvůli velikosti - jedna tabulka je už moc velká =>pomalá)

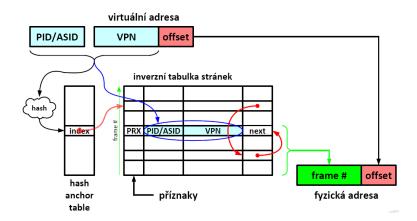


• TLB (Translation Lookaside Buffer) - asociativní paměť sloužící na rychlé mapování virtuální stránky na fyzickou, vyhledává se v ní paralelně, typicky ma 128-256 položek, využívá princip prostorové lokality programů (většina programů provádí velký počet přístupů k malému počtu stránek) umístěva většinou v L1 nebo L2 cache na procesoru



...0-úrovňové stránkování - procesor hledá pouze TLB, zbytek řeší OS (oblíbené u 64-bitových CPU - UltraSPARC III)

• inverzní stránkování (např. když FAP je menší než VAP, 64-bitové CPU - IA-64 = UtraSPARC, PowerPC) - inverzní stránkovací tabulka (IPT) nad rámci (nikoliv stránkami) společná pro všechny procesy, pro vyhledávání se používá hashovací tabulka



Akce vykonávané při výpadku stránky:

- výjimka procesoru
- uložit stav CPU (kontext)
- zjistit VA
- kontrola platnosti adresy a práv
- nalezení vhodného rámce
- zrušit mapování na nalezený rámec
- pokud je vyhazovaný rámec vyhazován, spustit ukládání na disk
- načíst z disku požadovanou stránku do rámce
- zavést mapování
- obnovit kontext

Při implementaci stránkování je nutno brat v úvahu:

- znovuspuštění instrukce je potřeba aby procesor po výpadku zkusil přístup do paměti znova. dnes umí všechny CPU, např. 68xxx problémy (přerušení v půlce instrukce)
- sdílení stránek jednomu rámci odp. víc stránek pokud s ním něco dělám, týká se to všech stránek! musím vše ost. odmapovat. musím si pamatovat mapování pro každý rámec obrácené tabulky.
- velikost stránek
 - velké stránky \rightarrow fragmentace

- malé stránky \rightarrow mnoho registrů, zvyšuje cenu výpočtů a zpomaluje chod
- optimum 1-4kB¹⁷
- odstranění položky z TLB při rušení mapování nestačí změnit tabulky, musí se vyhodit i z TLB (kde to může, ale nemusí být). problém u multiprocesorů má každá CPU vlastní TLB, tabulky jsou sdílené → CPU při rušení mapování musí poslat interrupt s rozkazem ke smazání všem (i sobě), počkat na potvrzení akce od všech.

Příklad

Uvažujte procesor, který podporuje stránkovani, má dvouúrovnove stránkovaci tabulky, velikost virtuální i fyzické adresy 32 bitu, velikost stránky 4 kB. Nakreslete formát strankovací tabulky (položky potřebné pro překlad adresy i typické další příznakové bity, nezadané detaily rozumne zvolte) a v nem ilustrujte, jak se prelozi virtuálni adresa 12345678h (nezadané konstanty tvoricí konkrétní obsah tabulky opet rozumne zvolte). Pozn.: h nakonci znamená že je číslo v hex (assembler)

Algoritmy pro výměnu stránek (výběr oběti)

- Optimální stránka (v okamžiku výpadku stránky vybírám stránku, na níž se přistoupí za největší počet instrukcí) nelze implementovat
- <u>NRU</u> (Not Recently Used) každá stránka má příznaky Accessed a Dirty (typicky implementovatelné v HW, možno simulovat SW); jednou za čas se smažou všechna A; při výpadku rozdělím stránky podle A,D a vyberu stránku z nejnižší (0,1..4) neprázdné třídy:

	A	D
0	0	0
1	0	1
2	1	0
3	1	1

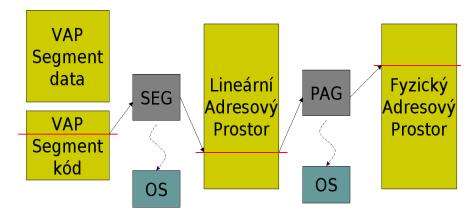
- <u>FIFO</u> vyhodit nejdéle namapovanou stránku vykazuje anomálie Belady (zvětšení počtu výpadků stránky, když zvýšíme počet stránek v paměti), druhá šance (úprava FIFO; pokud A=1, zařadím na konec FIFO... nevykazuje anomálie)
- Hodiny modifikace druhé šance: kruhový zoznam stránek + iterátor na ukazující na nejstarší stránku v zoznamu. Při výpadku (a neexistenci volého rámce) se zjistí, jestli má *iterator nastavený příznak Accessed. Jestli ne, tato stránka bude nahrazena v opačném případě se Accessed příznak zruší a iterator++. Toto se opakuje, dokud nedojde k výměně...
- LRU (Least Recently Used) často používané stránky v posledním krátkém časovém úšeku budou znovu použity, čítač použití stránek, možné implementovat v HW
- NFU (Not Frequently Used) SW simulace LRU, SW čítač ke každé stránce; jednou za čas projdu všechna A a přičtu je k odpovídajícím čítačům; vybírám stránku s nejnižším čítačem; nezapomíná je možná modifikace se stárnutím čítače

Segmentace

dnes pouze Intel IA-32, dvojrozměrný VAP

- rozdělení programu na segmenty (napr. podle částí s různými vlastnostmi kód, data, zásobníky...), různé délky segmentů, ktoré můžou měnit svoji délku za běhu
- VAP dvourozměrný (segment, offset), FAP jednorozměrný (vyzerá jako při spojitém pridělování paměti)
- segmentová převodní tabulka (VA se skládá ze dvou častí S:D, v tabulce se najde adresa segmentu S...k této adrese se poté přičte D, co je umístnění adresy v FA), příznak existence mapování
- při výpadku je nutné měnit celý segment (ty mohou být velké), je možné segmenty sesypat ale nelze mít segment větší než FAP

Segmentaci je možné kombinovat se stránkováním (odstraňuje nevýhody segmentace, neprovádí se výpadky segmentů):



Report (Bednárek)

Třeba mě překvapila Bednákova otázka u jednoúrovňovýho stránkování, když se zeptal, co z toho dělá OS a co procesor (jako co je děláno hardwareově a co softwareově).

Report (Bulej)

Strankovaci tabulku ma kazdy proces vlastni -¿ ochrana pameti, nemuze pristoupit na cizi stranky (mozna ze to v materialech ke statnicim je, ale ja to z nich nepochopil...)

Report (Skopal)

Nejdriv jsem popsal k cemu to je a potom princip. Chtel popsat postup toho co se deje, kdyz se hleda nejaky pointer. Co dela HW, co OS. Pak se zeptal jestli by slo udelat strankovani bez HW podpory (coz rozumne nejde, muselo by se to resit i v prekladacich a bylo by to nefektivni). Pak se zeptal na algoritmy vyhazovani stranek. Popsal jsem FIFO a NRU a to mu stacilo. Na segmentaci nastesti nedoslo. Celkove velmi prijemne zkouseni. V zasade se spokojil s principy a nestoural moc do detailu.

Report (Kofron)

klasika, prečo, kde, ako ... prečo to funguje, čo sa robí pri výpadku stránky, prečo dve inštancie jedného programu nelezú do kapusty aj keď pracujú s rovnakými virtuálnymi adresami (každý má vlastnú str. tabuľku), tvar adresy, prevody... každý proces má vlastní tabuľku, její adresa v registru

Report (IOI 21. 6. 2011)

Daný procesor používá 32-bitovou architekturu a dvouúrovňové stránkování. Instrukce MOV[0x12345678], EAX zapisuje obsah registru EAX na adresu 0x12345678. Popište, jaká operace (přístupy do registrů a podobně) vykonává při provádění této instrukce procesor a jak při tom spolupracuje operační systém. Rozeberte všechny možné (z hlediska naplnění stránkovacích tabulek) případy, nepopisujte strategie výměny stránek.

Report (Yaghob)

mel ruzné dotazy, jako proc je stránka veliká zrovna 4kB, jak je to se stránkováním na 64-bitových procesorech

5.10 Systémy souborů, adresářové struktury

Definice (soubor)

Soubor je pojmenovaná množina souvisejících informací, která leží v pomocné paměti (na disku).

Soubor je abstrakce, která umožňuje uložit informaci na disk a později ji přečíst. Abstrakce odstiňuje uživatele od podrobností práce s disky.

Soubory

- pojmenování souboru (umožňuje uživateli přístup k jeho datům; přesná pravidla pojmenování určuje OS malá vs. velká písmenka, speciální znaky, délka jména, přípony a jejich význam)
- atributy souborů (opět určuje OS) jméno, typ, umístění, velikost, ochrana, časy, vlastník, ...
- struktura souborů sekvence bajtů / sekvence záznamů / strom
- typy souborů běžné soubory, adresáře (systémové soubory vytvářející strukturu souborového systému), speciální soubory (znakové/blokové, soft linky)
- přístup
 - sekvenční pohyb pouze vpřed, OS může přednačítat
 - náhodný možno měnit aktuální pozici
 - paměťově mapované soubory pojmenovaná virtuální paměť, práce se souborem instrukcemi pro práci s pamětí,
 ušetří se kopírování pamětí; mají i problémy (přesná velikost souboru, zvětšování souboru, velikost souborů)
- volné místo na disku bitmapa / spojový seznam volných bloků

Uložení souborů

Soubory se ukládají na disk po blocích

- souvislá alokace souvislý sled bloků
- spojovaná alokace blok odkazuje na další
- indexová alokace inode (UNIX)

Adresáře

- zvláštní typ souboru
- operace nad adresáři hledání souboru / vypsání adresáře / přejmenování, vytvoření, smazání souboru
- kořen, aktuální adresář, absolutní/relativní cesta
- hierarchická struktura
 - strom jednoznačné pojmenování (cesta)
 - DAG víceznačné pojmenování, ale nejsou cykly
 - obecný graf cykly vytváří problém při prohledávání
- implementace adresářů záznamy pevné velikosti, spojový seznam, B-stromy

Co musí filesystém umět?

musí splňovat 3 věci: správu souborů (kde jsou, jak velké), správu adresářů (převod jméno ↔ id) (někdy to dělá jiný prostředek, dnes větš. umí FS sám), správu volného místa. někdy mohou být i další (odolnost proti výpadkům)

Velikost bloků – blok = nejmenší jednotka pro práci s diskem; disk pracuje s min. 1 sektorem (typicky 512 B) - někdy by pak bylo moc bloků \rightarrow OS sdruží několik sektorů lineáně vedle sebe = 1 blok. velikost: velké = rychlejší práce, ale vnitřní fragmentace (průměrný soubor má cca pár KB), malé = malá vnitřní fragmentace, větší režie na info o volném místě/ umístění souboru (zabírá víc bloků!), navíc fragmentace souborů \rightarrow zpomalení. dnes má blok cca 2-4KB.

Linky

- Hard link Na jedna data souboru se odkazuje z různých položek v adresářích (na urovni FS)
- Soft link Speciální soubor, který obsahuje jméno souboru (na urovni OS)

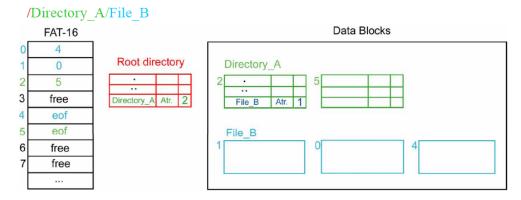
MBR

A master boot record (MBR) is a type of boot sector. It consists of a sequence of 512 bytes located at the first sector of a data storage device such as a hard disk. May be used for one or more of the following:

- Holding a partition table which describes the partitions of a storage device. In this context the boot sector may also be known as a partition sector.
- Bootstrapping an operating system. The BIOS built into a PC-compatible computer loads the MBR from the storage device and passes execution to machine code instructions at the beginning of the MBR.
- Uniquely identifying individual disk media, with a 32-bit disk signature, even though it may never be used by the operating system.

FAT

- System souboru FAT rozdeluje disk na dve vyznacne casti samotnou tabulku FAT (ta je zpravidla ve dvou kopiich) a datovou oblast. Datova oblast je rozdelena na clustery (napriklad po 4096 bajtech) a FAT tabulka ma tolik polozek, kolik ma datova oblast clusteru (1:1).
- FAT tabulka obsahuje čislo dalsiho clusteru v řadě + speciální záznamy (označení end of clusterchain, bad cluster, reserved cluster a free cluster)
- Alokace souboru spojovaná, kždý blok ukazuje na další přes FAT tabulku



- Kdyz je nejaky cluster volny, v prislusne polozce FAT je 0. Tedy kdyz chci najit volne misto, tak staci najit libovolnou polozku FAT, ktera je 0, odpovidajici cluster pak je volny.
- Adresare i soubory jsou ulozeny stejne. Rozdily mezi adresari a soubory (krom daneho atributu) neexistuji. Z hlediska ulozeni na disku je adresar proste soubor, jehoz obsahem jsou adresarove polozky. Vyjimka viz root adresar.
- Root adresář V root adresari, i ve vsech ostatnich adresarich, jsou proste jen za sebou ulozeny polozky. Kazda polozka obsahuje jmeno souboru nebo adresare, ke kteremu se vztahuje, atributy rozlisujíci napriklad prave adresare od souboru, delku, prvni cluster, atd.
 - Root directory ma pevnou velikost ve FAT 12/16
 - Polozky root adresare, ktere nejsou pouzite, jsou oznacene jako prazdne (ale porad patri do root adresare, aby velikost zustala konstantni). Pridani pak pouzije nekterou prazdnou polozku. Pokud jsou jiz vsechny polozky plne, dalsi nelze pridat.
- Vyhledávání souboru Postupne ... v root adresari se najde prvni podadresar cesty, v nem se najde druhy a tak dale. (tzn. lineární struktura)
- Adresarova struktura je ulozena prave v jednotlivych adresarich. Napriklad, pokud je na disku soubor FOO

BAR

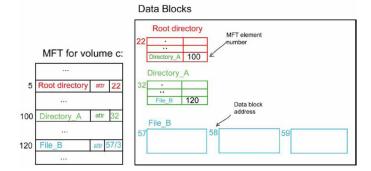
SOUBOR.TXT, tak v korenovem adresari bude polozka FOO s atributem indikujicim, ze se jedna o adresar a s cislem prvniho clusteru adresare FOO, rekneme ze 123. V clusteru 123 pak budou polozky adresare FOO, mezi nimi bude podobne polozka BAR pro adresar BAR a cislem prvniho clusteru adresare BAR, rekneme 456. A v clusteru 456 budou polozky adresare BAR, mezi kterymi bude i polozka SOUBOR.TXT ...

- dnes se ni setkame ještě na flashkách a paměťových kartách
- nevyhody FAT:
 - velikost souboru max 4 GB
 - svazky FAT32 reálně okolo 8TB (32kB clustery), nemá ale ochranu proti fragmentaci
 - práva None of the various FAT-flavours has facilities for user-based access restrictions.
- https://d3s.mff.cuni.cz/pipermail/osy/2005-June/000167.html
- http://en.wikipedia.org/wiki/File_Allocation_Table

NTFS

- Zase rozděluje oddíl na dvě části tabulka MFT (jako soubor, ma ale přiřazenou prázdnou oblast aby se při růstu nefragmentovala) a datovou oblast.
- Metafiles prvních cca 16 souboru jsou tzv. Metafiles, každý se stará o něco ⇒ flexibilita např. pri poskozenem povrchu příklady souboru: \$MFT,\$MFTmirr(MFT a zalozni kopie uprostred disku),\$LogFile (zurnalovaci soubor),\$. (root directory),\$Bitmap (bitove pole volneho mista) atd...
- **Žurnál** Operace s diskem se provadeji jako Transakce, takže např. pokud pri zapisu souboru FS zjisti ze cluster je fyz. vadný, celou trasakci rollbackuje a pusti ji jinde znovu.
- Další vlastnosti ktere ma navic: sifrovani, komprese, hardlinky (soubor je fyz. na disku jednou a ma vic zaznamu v MFT)
- MFT tabulka obdoba FAT, vsechna metadata o souborech (jmeno,datum,prava) jsou ulozena v MFT omoznuje pridavat ficury, muze obsahovat primo i male soubory nebo odkaz na clustery (všechny)
- Vnitřní struktura adresáře se realizuje B+Stromem (lexikograficky setrideny) zase pokud je malej zustane v MFT pokud je vetsi je v clusteru a v MFT je jenom kořenová část B+Stromu.

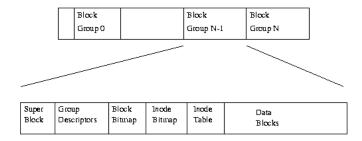
C:\Directory_A\File_B



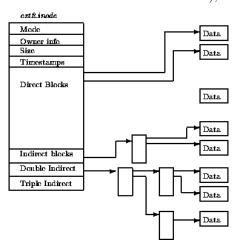
- http://pages.cs.wisc.edu/~bart/537/lecturenotes/s26.html
- http://www.digit-life.com/articles/ntfs/
- http://www.pcguide.com/ref/hdd/file/ntfs/archSector-c.html
- http://cs.wikipedia.org/wiki/NTFS
- http://ixbtlabs.com/articles/ntfs/

ext2

• Prostor je u ext2 rozdělen do bloků, ty jsou rozděleny do skupin (Block Groups) typicky jeden soubor se drží v jedné skupině (redukce fragmentace). Každá skupina obsahuje kopii superbloku (obsahuje kritické informace pro boot systemu) bitmapu bloků, inodes, Inode tabulku a nakonec datové bloky.



• inode – každý soubor nebo složka je reprezentována jako inode (v inode tabulce), obsahuje práva, velikost a hlavně pointery na datové bloky (12pointerů na přímý odkaz a další na stromovou strukturu), složky obsahují list inodes které obsahují



- Proc se porad pouziva kvůli rychlosti
- Žurnálování zavedeno u ext3
- http://homepage.smc.edu/morgan_david/cs40/analyze-ext2.htm
- http://www.science.unitn.it/~fiorella/guidelinux/tlk/node95.html
- http://www.linux-security.cn/ebooks/ulk3-html/0596005652/understandlk-CHP-18.html

Plánování pohybu hlav disků

- FCFS (First-Come, First-Served) žádné plánování, fronta požadavků, jeden za druhým
- SSTF (Shortest Seek Time First) krajní žádosti mohou "hladovět"
- LOOK (výtah), C-LOOK (circular LOOK) pohyb jen jedním směrem, na konci otočka

RAID (Redundant Array of Inexpensive Disks)

- JBOD (Just a Bunch of Disks)
- RAID 0 striping, žádná redundance
- RAID 1 mirroring, redundance
- RAID 0+1 mirroring a striping
- RAID 2 7-bitový paritní Hammingův kód
- RAID 3 1 paritní disk, po bitech na disky
- RAID 4 1 paritní disk a striping
- RAID 5 distribuovaná parita a striping
- RAID 6 distribuovaná parita dvojitá P+Q, striping

Report (Galamboš)

inode

Report (Galamboš)

Konkretni soubory system NTFS - tady jsem popletl jak vlastne pracuje FATka, o NTFS jsem mel tak jako povesechne informace, proste nic moc jsem nevedel, ale zase jsme si popovidali, byly mi vysvetleny me omyly a nakonec oka. Jinak je pravda, ze toho chce docela hodne a dopodrobna, ale kdyz clovek rekne, ze proste k tomuhle vic nesehnal a ze podrobnosti proste nevi, pobavi se o tom s Vami a vetsinou se to da dokupy.

Report (Skopal)

Zkoušel sám p. Skopal a jelikož jsem se FS učil jako jednu z prvních otázek, v návalu dalších informací jsem toho mezitím dost zapomněl. Popsal jsem jeden a půl strany obecnými vlastnostmi FS, co to je soubor, adresář atd. Popsal jsem FAT, NTFS a ext2, a to dost stručně. Obecné vlastnosti ho nezajímaly, hned přešel k FAT a jejím nevýhodám, otázky byly rychlé a dost podrobné, bylo vidět, že to se mnou nebude mít jednoduché. Pak měl otázky na NTFS, co má za spec. soubory, kdeže je v systému implementován B-strom atd. K ext2 jsme se nedostali až na jedinou zmínku, a to je alokace souborů (ve FAT lineární struktura, v ext2 strom). Když položil otázku na B-stromy v NTFS a po mojí těžce nejisté odpovědi prohlásil, že mu to stačí a odešel, bylo mi jasné, že tohle nedopadne dobře.

Report (Yaghob)

Konkretni Filesystemy - no jeste pred dvema dny by to byla moje smrt, nastesti sem se na to vcera zameril a nasel si opravdu presne jak funguje FAT, NTFS a ext2. Nakonec z toho byly tri papiry, az jsem na sebe byl pysny U FAT bylo treba napsat, jak se to alokuje, jak vypada ta tabulka, jakou roli ma kor. adresar, jak jsou tam ulozeny adresare, soubory apod. U NTFS jsem popsal vlastnosti ktere to ma navic, jako zurnal, sifrovani a pak rozepsal MFT docela podrobne, zase jak se resi soubory, adresare. Veci jako jak jsou tam ulozeny jednotlivy volume, MBR atd po me nastesti nechtel U ext2 je asi dulezite pochopit jak ten inode funguje, jak je to tam ve skupinach bloku, co je to superblok. Prislo mi, ze hlavni duraz je kladeny na to, at se vi, jak jsou tam ulozeny adresare a soubory. Pak prislo par otazek typu, jake jsou omezeni FATky, (velikost souboru, partitiony, ale hlavne se po me chtelo slyset: prava), kde se s tim dnes setkame (flashky, pametove karty) - na ty jsem dosel po vyjmenovani win98, mobilu, zkusil jsem i routery a ind. pocitace a nakonec me uspesne dovedl ke spravne odpovedi U ext2 prislo, proc se to porad jeste pouziva,kdyz je to tak stary FS - jedine co me napadlo byla rychlost - spravne

5.11 Bezpečnost, autentizace, autorizace, přístupová práva

(z přednášek ZOS(Yaghob) a OI1(Beneš))

Definice

- Ochrana s prostředky OS mohou pracovat pouze autorizované procesy
- Autorizace zjištění oprávněnosti požadavku
- Bezpečnost zabraňuje neautorizovaný přístup do systému
- Přistupové právo povolení/zakázání vykonávat nějakou operaci
- Doména ochrany uchovánání autorizací, množina párů (objekt:práva)
 - ACL (Access Control List) ke každému objektu seznam práv pro uživatele/skupiny
 - C-list (Capability List) ke každému uživateli/skupině seznam práv pro objekty
 - ACM (Access Control Matrix) řádky matice odpovídají uživatelům, sloupce objektům. V políčku daném řádkem a sloupcem je záznam o úrovni oprávnění odpovídajícího uživatele k příslušnému objektu. Přístupová matice je zpravidla velmi velká záležitost, zhusta řídká.

Bezpečnost

Bezpečnostní modely obecně

První fází tvorby bezpečného IS je volba vhodného bezpečnostního modelu. Základní požadavky bezpečnosti: utajení, integrita, dostupnost, anonymita. Předpokládejme, že umíme rozhodnout, zda danému subjektu poskytnout přístup k požadovanému objektu. Modely poskytují pouze mechanismus pro rozhodování!

- **Jednoúrovňové modely** jsou vhodné pro případy, kdy stačí jednoduché ano/ne rozhodování, zda danému subjektu poskytnout přístup k požadovanému objektu a není nutné pracovat s klasifikací dat.
- Víceúrovňové modely Může existovat několik stupňů senzitivity a "oprávněnosti". Tyto stupně senzitivity se dají použít k algoritmickému rozhodování o přístupu daného subjektu k cílovému objektu, ale také k řízení zacházení s objekty. Víceúrovňový systém "rozumí" senzitivitě dat a chápe, že s nimi musí zacházet v souladu s požadavky kladenými na daný stupeň senzitivity. Rozhodnutí o přístupu pak nezahrnuje pouze prověření žadatele, ale též klasifikaci prostředí, ze kterého je přístup požadován.

Bezpečnost fyzické přenosové vrstvy

Bezpečnost je do určité míry závislá na použitém přenosovém médiu. útok proti komunikačním linkám může být pasivní (pouze odposlech), nebo aktivní (vkládání dalších informací do komunikace).

Víceůrovňová bezpečnost v DB¹⁸

- partitioning Databáze je rozdělena dle stupně citlivosti informací na několik subdatabází, což vede ke zvýšení redundance s následnou ztíženou aktualizací a neřeší problém nutnosti současného přístupu k objektům s různým stupněm utajení.
- šifrování Senzitivní data jsou chráněna šifrováním před náhodným vyzrazením. Zná-li útočník doménu daného atributu, může snadno provést chosen plaintext attack (utocnik muze ukladat plaintexty podle sveho vyberu a prohlizet si ciphertexty). Těžko totiž někoho zbavíme znalosti šifrovacího klíče. řešením je používat jiný klíč pro každý záznam, což je však poměrně náročné. V každém případě nutnost neustálého dešifrování snižuje výkon systému.
- Integrity lock Každá položka v databázi se skládá ze tří částí: < vlastnidata : klasifikace : checksum >. Vlastní data jsou uložena v otevřené formě. Klasifikace musí být nepadělatelná, nepřenositelná a skrytá, tak aby ůtočník nemohl vytvořit, okopírovat ani zjistit klasifikaci daného objektu. Checksum zajišťuje svázání klasifikace s daty a integritu vlastních dat. Model byl navržen jako doplněk (access controller) komerčního SŘBD, který měl zajistit bezpečnost celého systému. šedá oblast na obrázku vyznačuje bezpečnostní perimetr systému. Access controller nevidí na výstup databáze a není schopen zajistit, na výstupu označovala data stupněm senzitivity.
- Spolehlivý front-end (guard) Systém je opět zamýšlen jako doplněk komerčních SŘBD, které nemají implementovánu bezpečnost. Uživatel se autentizuje spolehlivému front-endu, který od něho přebírá dotazy, provádí kontrolu autorizace uživatele pro požadovaná data, předává dotazy k vyřízení SŘBD a na závěr provádí testy integrity a klasifikace výsledků před předáním uživateli. SŘBD přistupuje k datům prostřednictvím spolehlivého access controlleru.
- Commutative Filter Jde o proces, který přebírá ůlohu rozhraní mezi uživatelem a SŘBD. Filtr přijímá uživatelovy dotazy, provádí jejich přeformulování a upravené dotazy posílá SŘBD k vyřízení. Z výsledků, které SŘBD vrátí, odstraní data, ke kterým uživatel nemá přístupová práva a takto upravené výsledky předává uživateli. Filtr je možno použít k ochraně na ůrovni záznamů, atributů a jednotlivých položek. V rámci přeformulování dotazu může např. vkládat další podmínky do dotazu, které zajistí, že výsledek dotazu závisí jen na informacích, ke kterým má uživatel přístup.
- View Pohled je část databáze, obsahující pouze data, ke kterým má daný uživatel přístup. Pohled může obsahovat i záznamy nebo atributy, které se v původní databázi nevyskytují a vznikly nějakou funkcí z informací původní databáze. Pohled je generován dynamicky, promítají se tedy do něho změny původní DB. Uživatel klade dotazy pouze proti svému pohledu nemůže dojít ke kompromitaci informací, ke kterým nemá přístup. Záznam / atribut původní databáze je součástí

 $^{^{18}{\}rm zdroj}:$ vypracované otázky na zkoušku z OI1

pohledu, pokud alespoň jedna položka z tohoto záznamu / atributu je pro uživatele viditelná, ostatní položky v tomto jsou označeny za nedefinované. Uživatel při formulování dotazu může používat pouze omezenou sadu povolených funkcí. Tato metoda je již návrhem směřujícím k vytvoření bezpečného SŘBD.

Autentizace

Identifikace něčím, co uživatel ví, má nebo je.

- Hesla
 - slovníkový útok (80–90% hesel je jednoduchých), hrubá síla
 - vynucování délky a složitosti hesla
- Model otázka/odpověď (challenge-response) např. autentizace počítačů. Počítač, který se chce autentizovat obdrží náhodný dotaz, který zpracuje (např. zašifruje tajným klíčem) a odešle výsledek. Výsledek je ověřen a pokud je správný, autentizace je uskutečněna.
- Fyzický objekt smartcards, USB klíče (certifikáty)
- Biometrika otisky prstů, rohovka, hlas

Autentizace v prostředí databáze

Každý, komu je povolen přístup k databázi, musí být pozitivně identifikován. databáze potřebuje přesně vědět, komu odpovídá. Protože však zpravidla běží jako uživatelský proces, nemá spolehlivé spojení s jádrem OS a tedy musí provádět vlastní autentizaci.

Autentizace v síti

Protože síťové prostředí zpravidla není považováno za bezpečné, je třeba využívat autentizační mechanismy odolné vůči odposlechu, resp. aktivním utokům. často bývá žádoucí řešit jednotné přihlášení (single sign on). S procesem integrace autentizačních mechanismů souvisí nutnost zavedení centrální správy uživatelů nebo alespoň synchronizace záznamů o uživatelích.

Autorizace

Existují různé úrovně ochrany objektu:

- 1. Žádná ochrana Je nutna alespon samovolná casová separace procesů.
- 2. Izolace Procesy o sobe vůbec neví a systém zajisťuje ukrytí objektů před ostatními procesy.
- 3. **Sdílení vseho nebo niceho** Vlastník objektu deklaruje, zda je objekt public nebo private (tedy jen pro neho).
- 4. **Sdílení s omezenými prístupy** OS testuje oprávněnost každého prístupu k objektu. U subjektu i objektu existuje záznam, zda má subjekt právo prístupu k objektu.
- 5. Sdílení podle způsobilosti rozšíření předchozího Oprávnení dynamicky závisí na aktuálním kontextu.
- 6. Limitované pouzití objektů Krome oprávnení prístupu specifikujeme, jaké operace smí subjekt s objektem provádet.

TODO: přístupová práva ??? Ochrana informace I.

5.12 Architektury OS

Klasická struktura – monolitická

Nejstarší, už IBM 360, Unix, Win., všechny služby uvnitř, prováděny ve chráněném módu, jádro poměrně velké, "údajně" nejrychlejší. Program zavolá službu OS, přes tabulku se zjistí adresa přísl. fce, ta se zavolá a vrátí výsledek. Nevýhoda: horší údržba – je-li v programu chyba, může poškodit zbývající části systému, rozšiřování za běhu je komplikované.

Virtuální stroje

Původní nápad : Virtual Machine pro IBM360 – oddělit multitasking od OS jako ext. stroj. Nad HW byla další vrstva – "Virtual Machine" – měla plánovat, vyrábí pro procesy iluzi holého HW; dneska např. VMWare dělá to samé. Pro IBM360 se dalo použít v kombinaci s CMS (jednoúlohový) i původního OS360 (rychlejší než OS360 na holém HW).

Dnes: definuji abstraktní stroj, pro něj překládám programy (.NET, Java) \rightarrow přenositelnost, kompatibilita (IBM AS400 – desítky let), problém – pomalé.

Mikrojádro

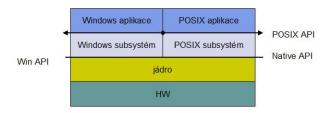
snaha aby část běžící v kernel módu byla co nejmenší (třeba jen cca 10 KB), nejnovější, experimentální, často pro Distribuované OS (dnes už nepoužívané), hodně procesů & komunikace (klient/server), mikrojádro řeší jenom komunikaci.

Filesystém apod. jsou procesy – aplikace jim posílají přes jádro požadavky. Jediný komerční OS – Chorus (ústředny). výhoda: když něco spadne, nepoškodí to zbytek, moduly jdou měnit za běhu, komunikace jde snadno rozšířit na komunikaci po síti.

Architektura WinNT

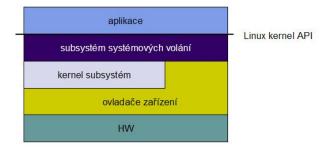
Jádro je poměrně malé (cca 1MB), schopné (pro vyšší vrstvy jsou některé schopnosti skryté), na jeho vzniku se podíleli schopní Unixáři. Byla zde snaha o malou velikost, přenositelnost. Jádro je neutrální vzhledem k vyšším vrstvám, nad ním lze vybudovat různé systémy (Windows subsystém, POSIX, OS/2).

Rozhraní OS a uživ. programů zajišťuje WinAPI, nad ním se nacházejí různé DLL, mezi kernelem a HW je "hardware abstraction layer", tj. kernel lze jednoduše upravit pro jiné architektury (Alpha, IA-64). Grafické drivery jediné mají přímý přístup k HW (kvůli výkonu), části API (USER, GDI) jsou implementované v jádře, přechod mezi user a kernel režimem zajišťuje ntdll.dll (a je tedy využíván všemi programy). Veškeré služby a aplikace běží v user módu nad jádrem.



Architektura Linuxu

- Na úrovni SW přenositelnost; abstrakce HW.
- nad HW kernel, nad ním systémová volání, hodně podobné Windows.



5.13 Rodina protokolů TCP/IP (ARP, IPv4, IPv6, ICMP, UDP, TCP) – adresace, routing, fragmentace, spolehlivost, flow control, congestion control, NAT

ISO/OSI	TCP/IP
aplikační vrstva	aplikační vrstva
prezentační vrstva	
relační vrstva	
transportní vrstva	transportní vrstva
síťová vrstva	síťová vrstva (též IP vrstva)
linková vrstva	vrstva síťového rozhraní
fyzická vrstva	

Obvyklé označenie je TCP/IP protocol suite (súčasťou je viac ako 100 protokolov). Architektúra vznikla postupne (v akademickom prostredí, neskôr sa rozšírila aj do komerčnej sféry) – najprv vznikli protokoly, potom vrstvy – a od vzniku sa toho zmenilo len málo (zmeny sú aditívne). Je to najpoužívanejšia sieťová technológia (IP over everything, everything over IP). Prístup autorov bol, na rozdiel od ISO/OSI, od jednoduchšieho k zložitejšiemu – najprv sa vytvárajú jednoduché riešenia, ktoré sa postupne obohacujú. Až sa riešenie prakticky overí (2 nezávislé implementácie), vznikne štandard. TCP/IP predpokladá že siete sú typu nespojované, nespoľahlivé a best effort. Všetká inteligencia je sústredená do koncových uzlov, sieť je "hlúpa" ale rýchla.

TCP/IP bol pôvodne určený pre ARPAnet – nemohol mať teda žiadnu centrálnu časť a musel byť robustný voči chybám (nespoľahlivé/nespojované prenosy). Dôraz sa kládol aj na "internetworking". Nebolo však požadované zabezpečenie, mobilita ani kvalita služieb.

TCP/IP nedefinuje rôzne siete (čo sa hardvérových vlastností týka) a technológie vo vrstve sieťového rozhrania – iba sa snaží nad nimi prevádzkovať protokol IP (okrem SLIP a PPP pre dvojbodové spoje). V sieťovej vrstve je IP protokol, v transportnej jednotné transportné protokoly (TCP a UDP), v aplikačnej potom jednotné základy aplikácií (email, prenos súborov, remote login...).

Adresace, IPv4, IPv6

Data se v IP síti posílají po blocích nazývaných datagramy. Jednotlivé datagramy putují sítí zcela nezávisle, na začátku komunikace není potřeba navazovat spojení či jinak "připravovat cestu" datům, přestože spolu třeba příslušné stroje nikdy předtím nekomunikovaly.

IP protokol v doručování datagramů poskytuje nespolehlivou službu, označuje se také jako best effort – "nejlepší úsilí"; tj. všechny stroje na trase se datagram snaží podle svých možností poslat blíže k cíli, ale nezaručují prakticky nic. Datagram vůbec nemusí dorazit, může být naopak doručen několikrát a neručí se ani za pořadí doručených paketů. Pokud aplikace potřebuje spolehlivost, je potřeba ji implementovat v jiné vrstvě síťové architektury, typicky protokoly bezprostředně nad IP (viz TCP).

Pokud by síť často ztrácela pakety, měnila jejich pořadí nebo je poškozovala, výkon sítě pozorovaný uživatelem by byl malý. Na druhou stranu příležitostná chyba nemívá pozorovatelný efekt, navíc se obvykle používá vyšší vrstva, která ji automaticky opraví.

V IPv4 je adresou 32bitové číslo, zapisované po jednotlivých bajtech, oddělených tečkami. Takových čísel existuje celkem 2³². Určitá část adres je ovšem rezervována pro vnitřní potřeby protokolu a nemohou být přiděleny. Dále pak praktické důvody vedou k tomu, že adresy je nutno přidělovat hierarchicky, takže celý adresní prostor není možné využít beze zbytku. To vede k tomu, že v současnosti je již znatelný nedostatek IP adres, který řeší různými způsoby: dynamickým přidělováním (tzn. např. každý uživatel dial-up připojení dostane dočasnou IP adresu ve chvíli, kdy se připojí, ale jakmile se odpojí, je jeho IP adresa přidělena někomu jinému; při příštím připojení pak může tentýž uživatel dostat úplně jinou adresu), překladem adres (NAT) a podobně. Ke správě tohoto přidělování slouží specializované síťové protokoly, jako např. DHCP.

Pôvodný koncept adries počítal so štruktúrou adresy IPv4 v tvare sieť:počítač, kde bolo delenie častí pevne dané. Neskôr sa to ale ukázalo ako príliš hrubé delenie a lokálna časť adresy (v rámci jednej podsiete) može mäť dnes promenlivú dĺžku. Obecne platí, že medzi adresami v rovnakej podsieti (majú rovnakú sieťovú časť) je možné dopravovať dáta priamo – dotyční účastníci sú prepojení jedným ethernetom alebo inou lokálnou sieťou. V opačnom prípade sa dáta dopravujú smerovačmi/routermi. Hranicu v adrese medzi adresou siete a počítača určuje dnes maska podsiete. Jedná sa o 32 bitovú hodnotu, ktorá obsahuje jednotky tam, kde je v adrese určená sieť.

Adresovanie sietí bolo v prvopočiatkoch internetu vyriešené staticky – prvých 8 bitov adresy určovalo sieť, zvyšok jednotlivé počítače (existovať tak mohlo max. 256 sietí). S nástupom lokálnych sietí bolo tento systém potrebné zmeniť – zaviedli sa triedy IP adries. Existovalo 5 tried (A(začiatok 0, hodnoty prvého bajtu 0-127, maska 255.0.0.0), B(10, 128-191, 255.255.0.0), C(110, 192-223, 255.255.255.0), D(1110, 224-239, určené na multicast) a E(1111, 240-255, určené ako rezerva)). Postupom času sa ale aj toto rozdelenie ukázalo ako nepružné a bol zavedený CIDR (Classless Inter-Domain Routing) systém v ktorom je možné hranicu medzi adresou siete a lokálnou časťou adresy umiestniť ľubovoľne (označuje sa potom ako kombinácia prefixu a dĺžky vo forme 192.168.0.0/24, kde 24 znamená že adresu tvorí prvých 24 bitov – jiný zápis je pomocí už zmiňované masky podsítě, tj. 192.168.0.0 s maskou 255.255.255.0).

Medzi adresami existujú niektoré tzv. vyhradené adresy, ktoré majú špeciálny význam.

- Adresa s (binárnymi) nulami v časti určujúcej počítač (192.168.0.0 (/24)) znamená "táto sieť", resp. "táto stanica".
- Adresa s jednotkami v časti určujúcej počítač (192.168.0.255 (/24)) znamená broadcast všesmerové vysielanie.
- Adresy 10.0.0.0 10.255.255.255, 172.16.0.0 172.31.255.255 a 192.168.0.0 192.168.255.255 sa používajú na adresovanie interných sietí smerovače tieto adresy nesmie smerovať ďalej do internetu.

 ${\bf IPv6}$ je trvalejším riešením nedostatku adries – zatiaľ sa ale rozširuje veľmi pozvolna. Adresa v IPv6 má dĺžku 128 bitov (oproti 32), čo znamená cca. 6×10^{23} IP adries na $1m^2$ zemského povrchu – umožňuje teda, aby každé zariadenie na zemi malo vlastnú jednoznačnú adresu. Adresa IPv6 sa zapisuje ako osem skupín po štyroch hexadecimálnych číslach (napr. 2001:0718:1c01:0016:0214:22ff:fec9:0ca5) – pričom úvodné nuly v číslach je možné vynechať. Ak po sebe nasleduje niekoľko nulových skupín, je možné použiť len znaky :: – napr. ::1 miesto 0000:0000:.....:0001. Toto je možné použiť len raz v zápise adresy. RFC 4291 zavádza 3 typy adries:

- inidividuálne / unicast identifikujú práve jedno rozhranie
- skupinové / multicast určuje skupinu zariadení, ktorým sa má správa dopraviť
- výberové / anycast určuje tiež skupinu zariadení, dáta sa však doručia len jednému z členov (najbližšiemu)

IPv6 neobsahuje všesměrové (broadcast) adresy. Byly nahrazeny obecnějším modelem skupinových adres a pro potřeby doručení dat všem zařízením připojeným k určité síti slouží speciální skupinové adresy (např. ff02::1 označuje všechny uzly na dané lince).

IPv6 zavádí také koncepci dosahu (scope) adres. Adresa je jednoznačná vždy jen v rámci svého dosahu. Nejčastější dosah je pochopitelně globální, kdy adresa je jednoznačná v celém Internetu. Kromě toho se často používá dosah linkový, definující jednoznačnou adresu v rámci jedné linky (lokální sítě, např. Ethernetu). Propracovanou strukturu dosahů mají skupinové adresy (viz níže).

Adresní prostor je rozdělen následovně:

prefix	význam
::/128	neurčená
::1/128	smyčka (loopback)
ff00::/8	skupinové
fe80::/10	individuální lokální linkové
ostatní	individuální globální

Výběrové adresy nemají rezervovánu svou vlastní část adresního prostoru. Jsou promíchány s individuálními a je otázkou lokální konfigurace, aby uzel poznal, zda se jedná o individuální či výběrovou adresu.

Strukturu globálních individuálních IPv6 adres definuje RFC 3587. Je velmi jednoduchá a de facto odpovídá (až na rozměry jednotlivých částí) výše uvedené struktuře IPv4 adresy.

n bitů	64-n bitů	64 bitů
globální směrovací prefix	adresa podsítě	adresa rozhraní

Globální směrovací prefix je de facto totéž co adresa sítě, následuje adresa podsítě a počítače (přesněji síťového rozhraní). V praxi je adresa podsítě až na výjimky 16bitová a globální prefix 48bitový. Ten je pak přidělován obvyklou hierarchií, jejíž stávající pravidla jsou:

- první dva bajty obsahují hodnotu 2001 (psáno v šestnáctkové soustavě)
- další dva bajty přiděluje regionální registrátor (RIR)
- další dva bajty přiděluje lokální registrátor (LIR)

Reálná struktura globální individuální adresy tedy vypadá následovně:

16 bitů	16 bitů	16 bitů	16 bitů	64 bitů
2001	přiděluje RIR	přiděluje LIR	adresa podsítě	adresa rozhraní

Adresa rozhraní by pak měla obsahovat modifikovaný EUI-64 identifikátor. Ten získáte z MAC adresy jednoduchým postupem: invertuje se druhý bit MAC adresy a doprostřed se vloží dva bajty obsahující hodnotu fffe. Z ethernetové adresy 00:14:22:c9:0c:a5 tak vznikne identifikátor 0214:22ff:fec9:0ca5.

Adresy začínajúce hodnotou ff sú tzv. "skupinové adresy" – štyri nasledujúce bity v nej obsahujú príznaky, ďalšie štyri potom dosah (napr. interface-local, link-local, admin-local, site-local, organization-local, global...)

IPv6 d'alej podporuje QoS a bezpečnosť (IPsec).

Routing

Pojmem **směrování** (routing, routování) je označováno hledání cest v počítačových sítích. Jeho úkolem je dopravit datový paket určenému adresátovi, pokud možno co nejefektivnější cestou. Síťová infrastruktura mezi odesílatelem a adresátem paketu může být velmi složitá. Směrování se proto zpravidla nezabývá celou cestou paketu, ale řeší vždy jen jeden krok – komu data předat jako dalšímu (tzv. "distribuované směrování"). Ten pak rozhoduje, co s paketem udělat dál.

V prípade, že je cieľová stanica packetu v rovnakej sieti ako je odosielateľ, o doručenie sa postará linková vrstva. V opačnom prípade musí odosielateľ určiť najvhodnejší odchodzí smer a poslať datagram smerovaču vo zvolenom smere.

Základní datovou strukturou pro směrování je směrovací tabulka (routing table). Představuje vlastně onu sadu ukazatelů, podle kterých se rozhoduje, co udělat s kterým paketem. Směrovací tabulka je složena ze záznamů obsahujících:

• cílovou adresu, které se dotyčný záznam týká. Může se jednat o adresu individuálního počítače, častěji však je cíl definován prefixem, tedy začátkem adresy. Prefix mívá podobu 147.230.0.0/16. Hodnota před lomítkem je adresa cíle, hodnota za lomítkem pak určuje počet významných bitů adresy. Uvedenému prefixu tedy vyhovuje každá adresa, která má v počátečních 16 bitech (čili prvních dvou bajtech) hodnotu 147.230.

• akci určující, co provést s datagramy, jejichž adresa vyhovuje prefixu. Akce mohou být dvou typů: doručit přímo adresátovi (pokud je dotyčný stroj s adresátem přímo spojen) nebo předat některému ze sousedů (jestliže je adresát vzdálen).

Směrovací rozhodnutí pak probíhá samostatně pro každý procházející datagram. Vezme se jeho cílová adresa a porovná se směrovací tabulkou následovně:

- Z tabulky se vyberou všechny vyhovující záznamy (jejichž prefix vyhovuje cílové adrese datagramu).
- Z vybraných záznamů se použije ten s nejdelším prefixem. Toto pravidlo vyjadřuje přirozený princip, že konkrétnější záznamy (jejichž prefix je delší, tedy přesnější; specielním případem je host-specific route) mají přednost před obecnějšími (co může být např. i default route; ps: agregace).

Zajímavou otázkou je, jak vznikne a jak je udržována směrovací tabulka. Tento proces mají obecně na starosti směrovací algoritmy. Když jsou pak pro určitý algoritmus definována přesná pravidla komunikace a formáty zpráv nesoucích směrovací informace, vznikne směrovací protokol (routing protocol). Směrovací algoritmy můžeme rozdělit do dvou základních skupin: na statické a dynamické. Často se také mluví o statickém a dynamickém směrování, které je důsledkem činnosti příslušných protokolů.

Při statickém (též neadaptivním) směrování se směrovací tabulka nijak nemění. Je dána konfigurací počítače a případné změny je třeba v ní provést ručně. Tato varianta vypadá jako nepříliš atraktivní, ve skutečnosti ale drtivá většina zařízení v Internetu směruje staticky.

Dynamické (adaptivní) směrování průběžně reaguje na změny v síťové topologii a přizpůsobuje jim směrovací tabulky. Na vytváranie tabuliek existuje niekoľko algoritmov – routovacích protokolov (vector-distance/link-state) – RIP, BGP, OSPF.

Distribuované směrování

V distribuovaném směrování může výpočet cesty (směru předání paketu) provádět buď každý uzel nezávisle, nebo mohou uzly kooperovat (distribuovaný výpočet). Rozlišuje se také četnost aktualizace informací. Dva základní algoritmy distribuovaného směrování jsou:

- vector distance každý uzel si udržuje tabulku vzdáleností, přímí sousedé si vyměňují informace o cestách ke všem uzlům, tj. jde o distribuovaný výpočet, přenáší se dost informací. Trpí problémem "count-to-infinity" tj. když 1 uzel přestane existovat, postupně si jeho sousedé mezi sebou přehazují vzdálenost, postupně o 1 zvětšovanou (do nekonečna). Řeší se pomocí technik "split horizon" (neinzeruj vzdálenost zpět) a "poisoned reverse" (inzeruj zpět nekonečno), někde ale přesto selhává.
- link state každý uzel hledá změny svých sousedů a pokud k nějaké dojde, pošle floodem informaci do celé sítě. Výpočet vzdáleností dělá každý uzel sám.

Tyto algoritmy se používají u některých známých směrovacích protokolů:

- RIP (Routing Information Protocol) protokol z BSD Unixu, typu vector distance. Počítá s max. 16 přeskoky, změny se updatují 2x za minutu. Informace ve směrovací tabulce může zahrnovat max. 25 sítí, používá split horizon & poisoned reverse. Hodí se ale jen pro malé sítě.
- OSPF (Open Shortest Path First) jde o protokol typu link state, uzly si počítají vzdálenosti do všech sítí Dijkstrovým algoritmem. Pro zjišťování změn se posílají pakety "HELLO" a "ECHO". Má lepší škálovatelnost, hodí se pro větší sítě.

Hierarchické směrování, autonomní systémy

Hierarchické směrování znamená rozdělení sítě do oblastí (areas) a směrování mezi nimi jen přes vstupní body. Je vhodné pro velké, složitě propojené nebo různým způsobem spravované sítě. Nad oblastmi se vytvoří propojení – backbone area (páteřní systém), přes které se směrování mezi oblastmi provádí. Celému tomuto (areas + backbone area) se říká autonomní systém. Detailní směrovací informace neopouštějí jednotlivé oblasti.

Pro směrování v rámci jedné oblasti i mezi oblastmi v rámci jednoho autonomního systému slouží jeden z tzv. interior gateway protocols, může být použit např. OSPF nebo RIP, případně další jako IGRP (interior gateway routing protocol, typu vector distance) nebo EIGRP (enhaced IGRP, hybrid mezi vector distance a link state). Mezi jednotlivými autonomními systémy (přes AS boundary routers) se směruje pomocí exterior gateway protocolu, jedním z nich je např. Border Gateway Protocol (BGP).

Díky existenci autonomních systémů jde např. při peeringu stanovit, který provoz půjde přes peering a který výše po upstreamu do páteřních sítí.

Fragmentace

Maximum transmission unit (MTU) je maximální velikost paketu, který je možné přenést z jednoho síťového zařízení na druhé. Obvyklá hodnota MTU v případě Ethernetu je cca 1500 bajtů, nicméně mezi některými místy počítačové sítě (spojených například modemem nebo sériovou linkou) může být maximální délka přeneseného paketu nižší. Hodnotu MTU lze zjistit prostřednictvím protokolu ICMP. Při posílání paketů přes několik síťových zařízení je samozřejmě důležité nalézt nejmenší MTU na dané cestě. Hodnota MTU je omezena zdola na 576 bajtů.

U přenosového protokolu TCP je při směrování paketu do přenosového kanálu s nižším MTU než je délka paketu, provedena fragmentace paketu. U protokolu UDP není fragmentace paketu podporována a paket je v takovém případě zahozen.

Pokud dorazí na směrovač paket o velikosti větší, než kterou je přenosová trasa schopna přenést (např. při přechodu z Token Ringu používajícího 4 kByte pakety na Ethernet používajícího maximálně 1,5 kByte pakety), musí směrovač zajistit tzv. fragmentaci, neboli rozebrání paketu na menší části a cílový uzel musí zajistit opětovné složení, neboli defragmentaci.

Fragmenty procházejí přes síť jako samostatné datagramy. Aby byl koncový uzel schopen fragmenty složit do originálního datagramu, musí být fragmenty příslušně označeny. Toto označování se provádí v příslušných polích IP hlavičky.

Pokud nesmí být datagram fragmentován, je označen v příslušném místě IP hlavičky příznakem "Don't Fragment". Jestliže takto označený paket dorazí na směrovač, který by jej měl poslat prostředím s nižším MTU a tudíž je nutnost provést fragmentaci, provede směrovač jeho zrušení a informuje odesílatele chybovou zprávou ICMP.

Aby byl cílový uzel schopen složit originální datagram, musí mít dostatečný buffer do něhož jsou jednotlivé fragmenty ukládány na příslušnou pozici danou offsetem. Složení je dokončeno v okamžiku, kdy je vyplněn celý datagram začínající fragmentem s nulovým offsetem (identification a fragmentation offset v hlavičke) a končící segmentem s příznakem "More Data Flag" (resp. More Fragments) nastaveným na False.

V IPv4 je možné fragmentované pakety ďalej deliť; naproti tomu v IPv6 musí fragmentáciu zabezpečiť odosielateľ – nevyhovujúce pakety sa zahadzujú.

Spolehlivost, Flow control, Congestion control

Keďže TCP/IP funguje nad obecne nespojovanými a nespoľahlivými médiami, **spoľahlivosť** ktorú TCP poskytuje nie je "skutočná", ale len "softvérovo emulovaná" – medziľahlé uzly o spojení nič nevedia, fungujú nespojovane (pre komunikáciu sa používa sieťová vrstva, transportná "existuje" iba medzi koncovými uzlami). Je teda nutné ošetriť napr. nespoľahlivosť infraštruktúry (strácanie dát, duplicity – pričom stratiť sa môže aj žiadosť o vytvorenie pripojenia, potvrdenie...) a reboot uzlov (uzol stratí históriu, je potrebné ošetriť existujúce spojenia...).

Používa sa celá rada techník, kde základom je kontinuálne potvrdzovanie: príjemca posiela kladné potvrdenia; odosielateľ po každom odoslaní spúšťa časovač a ak mu do vypršania nepríde potvrdenie, posiela dáta znovu. Potvrdzovanie nie je samostatné ale vkladá sa do paketov cestujúcich opačným smerom – piggybacking.

TCP priebežne kontroluje "dobu obrátky" a vyhodnocuje vážený priemer a rozptyl dôb obrátky. Čakaciu dobu (na potvrdenie) potom vypočítava ako funkciu tohto váženého priemeru a rozptylu. Výsledný efekt je potom ten, že čakacia doba je tesne nad strednou dobou obrátky. V prípade konštantnej doby obrátky sa čakacia doba približuje strednej dobe obrátky; ak kolíše, čakacia doba sa zväčšuje.

Dáta v TCP sa príjímajú/posielajú po jednotlivých byteoch – interne sa však bufferujú a posielajú až po naplnení buffera (pričom aplikácia si môže vyžiadať okamžité odoslanie – operácia PUSH). TCP si potrebuje označovať jednotlivé byty v rámci prúdu (keďže nepracuje s blokmi) – napr. kvôli potvrdzovaniu; používa sa na to 32-bitová pozícia v bytovom prúde (začína sa od náhodne zvoleného čísla).

TCP sa snaží **riadiť tok dát** – aby odosielateľ nezahlcoval príjemcu a kvôli tomu nedochádzalo k stráte dát. Podstata riešenia je tzv. *metóda okienka*. Okienko udáva veľkosť voľných bufferov na strane prijímajúceho a odosielateľ môže posielať dáta až do "zaplnenia" okienka. Príjemca spolu s každým potvrdením posiela aj svoju ponuku – údaj o veľkosti okienka (window advertisment)., ktorý hovorí koľko ešte dát je schopný prijať (naviac k práve potvrdeným). Znovu – používa sa metóda kontinuálneho potvrďovania.

Väčšina strát prenášaných dát ide skôr na vrub zahlteniu ako chybám HW a transportné protokoly môžu nevhodným chovaním zhoršovať dôsledky. TCP každú stratu dát chápe ako dôsledok zahltenia – nasadzuje **opatrenia proti zahlteniu** (congestion control). Po stráte paketu ho pošle znovu ale neposiela ďalšie a čaká na potvrdenie (tj. prechod z kontinuálneho potvrdzovania na jednotlivé ⇒ vysiela menej dát ako mu umožňuje okienko). Ak príde potvrdenie včas, zdvojnásobí množstvo odosielaných dát – a tak pokračuje kým nenarazí na aktuálnu veľkosti okienka (postupne sa tak vracia na kontinuálne potvrdzovanie).

Dôležitou vlastnosťou je aj korektné chovanie pri naväzovaní a rušení spojenia (v prostredí, kde môže dôjsť k spomaleniu, strate, duplicite...) – používa sa tzv. 3-fázový handshake. Vytvorenie spojenia prebieha nasledovne:

- 1. Klient pošle serveru SYN paket (v pakete je nastavený príznak SYN) spolu s náhodným sequence number (X).
- 2. Server tento paket prijme, zaznamená si sequence number (X) a pošle späť paket SYN-ACK. Tento paket obsahuje pole Acknowledgement, ktoré označuje ďalšie číslo (sequence number), ktoré tento host očakáva (X+1). Tento host rovno vytvorí spätnú session s vlastným sekvenčným číslom (Y).
- 3. Klient odpovie so sekvenčným číslom (X+1) a jednoduchým Acknowledgement číslom (Y+1) čo je sekvenčné číslo servera+1.

Pak už spojení považováno za navázané. Rušenie spojenia funguje podobne, posílají se pakety FIN (finish), FIN+ACK a ACK. Pokud více než nějaký určitý počet pokusů o odeslání (po spočítaných time-outech) jednoho z 3-way handshake paketů selže (druhá strana neodešle to, co mělo následovat), spojení se považuje za přerušené (i u navazování, i u rušení).

NAT

TODO: přeložit ty copy & paste z Wiki

Network address translation (zkráceně NAT, česky překlad síťových adres) je funkce síťového routeru pro změnu IP adres packetů procházejících zařízením, kdy se zdrojová nebo cílová IP adresa převádí mezi různými rozsahy. Nejběžnější formou je tzv. maškaráda (maskování), kdy router IP adresy z nějakého rozsahu mění na svoji IP adresu a naopak – tím umožňuje, aby počítače ve vnitřní síti (LAN) vystupovaly v Internetu pod jedinou IP adresou. Router si drží po celou dobu spojení v paměti tabulku překladu adres.

Překlad síťových adres je funkce, která umožňuje překládání adres. Což znamená, že adresy z lokální sítě přeloží na jedinečnou adresu, která slouží pro vstup do jiné sítě (např. Internetu), adresu překládanou si uloží do tabulky pod náhodným portem, při odpovědi si v tabulce vyhledá port a pošle pakety na IP adresu přiřazenou k danému portu. NAT je vlastně jednoduchým proxy serverem (na sieťovej vrstve).

Komunikace

Klient odešle požadavek na komunikace, směrovač se podívá do tabulky a zjistí, zdali se jedná o adresu lokální, nebo adresu venkovní. V případě venkovní adresy si do tabulky uloží číslo náhodného portu, pod kterým bude vysílat a k němu si přiřadí IP adresu. Během přeposílání "ven" a změny adresy v paketu musí NAT také přepočítat CRC checksum TCP i IP (aby pakety nebyly zahazovány kvůli špatnému CRC, protože změněná adresa je jejich součástí).

Výhodami NAT sú umožnenie pripojenie viacerých počítačov do internetu cez jednu zdieľanú verejnú IP adresu, a zvýšenie bezpečnosti počítačov za NATom (aj keď je to security through obscurity a nie je dobré postaviť bezpečnosť iba na NATe). Nevýhodami potom sú nefungujúce protokoly (napr. aktívne FTP) – čo je zrejmé z fungovania NATu.

NAT Traversal

NAT traversal refers to an algorithm for the common problem in TCP/IP networking of establishing connections between hosts in private TCP/IP networks that use NAT devices.

This problem is typically faced by developers of client-to-client networking applications, especially in peer-to-peer and VoIP activities. NAT-T is commonly used by IPsec VPN clients in order to have ESP packets go through NAT.

Many techniques exist, but no technique works in every situation since NAT behavior is not standardized. Many techniques require a public server on a well-known globally-reachable IP address. Some methods use the server only when establishing the connection (such as STUN), while others are based on relaying all the data through it (such as TURN), which adds bandwidth costs and increases latency, detrimental to conversational VoIP applications.

Druhy uspořádání NATu

- Static NAT: A type of NAT in which a private IP address is mapped to a public IP address, where the public address is always the same IP address (i.e., it has a static address). This allows an internal host, such as a Web server, to have an unregistered (private) IP address and still be reachable over the Internet.
- Dynamic NAT— A type of NAT in which a private IP address is mapped to a public IP address drawing from a pool of registered (public) IP addresses. Typically, the NAT router in a network will keep a table of registered IP addresses, and when a private IP address requests access to the Internet, the router chooses an IP address from the table that is not at the time being used by another private IP address. Dynamic NAT helps to secure a network as it masks the internal configuration of a private network and makes it difficult for someone outside the network to monitor individual usage patterns. Another advantage of dynamic NAT is that it allows a private network to use private IP addresses that are invalid on the Internet but useful as internal addresses.
- PAT PAT (NAT overloading) je další variantou NATu. U této varianty NATu se více inside local adres mapuje na jednu inside global adresu na různých portech. Tedy máme jednu veřejnou adresu a vnitřní síť oadresovanou inside local adresami. Překladová tabulka je rozšířena o dvě položky: inside local port port, ze kterého byl paket odeslán a inside global port číslo portu, na který je paket odeslaný ze zdrojového portu počítače mapován. Výhodou je, že se tak připojuje více počítačů přes jednu IP adresu.

\mathbf{ARP}

Address Resolution Protocol (ARP) se v počítačových sítích s IP protokolem používá k získání ethernetové (MAC) adresy sousedního stroje z jeho IP adresy. Používá se v situaci, kdy je třeba odeslat IP datagram na adresu ležící ve stejné podsíti jako odesílatel. Data se tedy mají poslat přímo adresátovi, u něhož však odesílatel zná pouze IP adresu. Pro odeslání prostřednictvím např. Ethernetu ale potřebuje znát cílovou ethernetovou adresu.

Proto vysílající odešle ARP dotaz (ARP request) obsahující hledanou IP adresu a údaje o sobě (vlastní IP adresu a MAC adresu). Tento dotaz se posílá linkovým broadcastem – na MAC adresu identifikující všechny účastníky dané lokální sítě (v případě Ethernetu na ff:ff:ff:ff:ff). ARP dotaz nepřekročí hranice dané podsítě, ale všechna k ní připojená zařízení dotaz obdrží a jako optimalizační krok si zapíší údaje o jeho odesílateli (IP adresu a odpovídající MAC adresu) do své ARP cache. Vlastník hledané IP adresy pak odešle tazateli ARP odpověď (ARP reply) obsahující vlastní IP adresu a MAC adresu. Tu si tazatel zapíše do ARP cache a může odeslat datagram.

Informace o MAC adresách odpovídajících jednotlivým IP adresám se ukládají do ARP cache, kde jsou uloženy do vypršení své platnosti. Není tedy třeba hledat MAC adresu před odesláním každého datagramu – jednou získaná informace se využívá opakovaně. V řadě operačních systémů (Linux, Windows XP) lze obsah ARP cache zobrazit a ovlivňovat příkazem arp.

Alternativou pro počítač bez ARP protokolu je používat tabulku přiřazení MAC adres IP adresám definovanou jiným způsobem, například pevně konfigurovanou. Tento přístup se používá především v prostředí se zvýšenými nároky na bezpečnost, protože v ARP se dá podvádět – místo skutečného vlastníka hledané IP adresy může odpovědět někdo jiný a stáhnout tak k sobě jeho data.

ARP je definováno v RFC 826. Používá se pouze pro IPv4. Novější verze IP protokolu (IPv6) používá podobný mechanismus nazvaný Neighbor Discovery Protocol (NDP, "objevování sousedů").

Ačkoliv se ARP v praxi používá téměř výhradně pro překlad IP adres na MAC adresy, nebyl původně vytvořen pouze pro IP sítě. ARP se může použít pro překlad MAC adres mnoha různých protokolů na síťové vrstvě. ARP byl také uzpůsoben tak,

aby vyhodnocoval jiné typy adres fyzické vrstvy: například ATMARP se používá k vyhodnocení ATM NSAP adres v protokolu Classical IP over ATM.

ICMP

ICMP protokol (anglicky Internet Control Message Protocol) je jeden z jádrových protokolů ze sady protokolů internetu. Používají ho operační systémy počítačů v síti pro odesílání chybových zpráv – například pro oznámení, že požadovaná služba není dostupná nebo že potřebný počítač nebo router není dosažitelný.

ICMP se svým účelem liší od TCP a UDP protokolů tím, že se obvykle nepoužívá sítovými aplikacemi přímo. Jedinou výjimkou je nástroj ping, který posílá ICMP zprávy "Echo Request" (a očekává příjem zprávy "Echo Response") aby určil, zda je cílový počítač dosažitelný a jak dlouho paketům trvá, než se dostanou k cíli a zpět.

ICMP protokol je součást sady protokolů internetu definovaná v RFC 792. ICMP zprávy se typicky generují při chybách v IP datagramech (specifikováno v RFC 1122) nebo pro diagnostické nebo routovací účely. Verze ICMP pro IPv4 je známá jako ICMPv4. IPv6 používá obdobný protokol: ICMPv6.

ICMP zprávy se konstruují nad IP vrstvou; obvykle z IP datagramu, který ICMP reakci vyvolal. IP vrstva patřičnou ICMP zprávu zapouzdří novou IP hlavičkou (aby se ICMP zpráva dostala zpět k původnímu odesílateli) a obvyklým způsobem vzniklý datagram odešle. Například každý stroj (jako třeba mezilehlé routery), který forwarduje IP datagram, musí v IP hlavičce dekrementovat políčko TTL ("time to live", "zbývající doba života") o jedničku. Jestliže TTL klesne na 0 (a datagram není určen stroji provádějícímu dekrementaci), router přijatý paket zahodí a původnímu odesílateli datagramu pošle ICMP zprávu "Time to live exceeded in transit" ("během přenosu vypršela doba života").

Každá ICMP zpráva je zapouzdřená přímo v jediném IP datagramu, a tak (jako u UDP) ICMP nezaručuje doručení. Ačkoli ICMP zprávy jsou obsažené ve standardních IP datagramech, ICMP zprávy se zpracovávají odlišně od normálního zpracování prokolů nad IP. V mnoha případech je nutné prozkoumat obsah ICMP zprávy a doručit patřičnou chybovou zprávu aplikaci, která vyslala původní IP paket, který způsobil odeslání ICMP zprávy k původci.

Mnoho běžně používaných síťových diagnostických utilit je založeno na ICMP zprávách. Příkaz traceroute je implementován odesíláním UDP datagramů se speciálně nastavenou životností v TTL políčku IP hlavičky a očekáváním ICMP odezvy "Time to live exceeded in transit" nebo "Destination unreachable". Příbuzná utilita ping je implementována použitím ICMP zpráv "Echo" a "Echo reply".

Nejpoužívanější ICMP datagramy:

- *Echo*: požadavek na odpověď, každý prvek v síti pracující na IP vrstvě by na tuto výzvu měl reagovat. Často to z různých důvodů není dodržováno.
- Echo Reply: odpověď na požadavek
- Destination Unreachable: informace o nedostupnosti cíle, obsahuje další upřesňující informaci
 - Net Unreachable: nedostupná cílová síť, reakce směrovače na požadavek komunikovat se sítí, do které nezná cestu
 - Host Unreachable: nedostupný cílový stroj
 - Protocol Unreachable: informace o nemožnosti použít vybraný protokol
 - Port Unreachable: informace o nemožnosti připojit se na vybraný port
- Redirect: přesměrování, používá se především pokud ze sítě vede k cíli lepší cesta než přes defaultní bránu. Stanice většinou nepoužívají směrovací protokoly a proto jsou informovány touto cestou. Funguje tak, že stanice pošle datagram své, většinou defaultní, bráně, ta jej přepošle správným směrem a zároveň informuje stanici o lepší cestě.
 - Redirect Datagram for the Network: informuje o přesměrování datagramů do celé sítě
 - Redirect Datagram for the Host: informuje o přesměrování datagramů pro jediný stroj
- Time Exceeded: vypršel časový limit
 - Time to Live exceeded in Transit: během přenosu došlo ke snížení TTL na 0 aniž byl datagram doručen
 - Fragment Reassembly Time Exceeded: nepodařilo se sestavit jednotlivé fragmenty v časovém limitu(např pokud dojde ke ztrátě části datagramů)

Ostatní datagramy jsou používány spíše vzácně, někdy je používání ICMP znemožněno zcela špatným nastavením firewallu.

UDP, TCP

UDP – nespoľahlivý nespojovaný prenos datagramov... pridáva len porty

TCP – porty+spoľahlivý spojovaný prenos streamov...

...d'alšie info vid' kapitolu o BSD Sockets :-)

5.14 Spojované a nespojované služby, spolehlivost, zabezpečení protokolu

Spojované a nespojované služby

Spojovaná obě strany musí navázat spojení, které je pak potřeba ukončit. Jde o stavovou komunikaci a přechody musí být koordinované. Pro spojení je nalezena jedna cesta po které komunikace probíhá a mohou ji být vyhrazeny zdroje. Potřeba ošetřit nestandartní situace (výpadek spojení). Zachovává pořadí – díky jedné cestě. Každé spojené má své ID.

Nespojovaná Komunikující strany o sobě neví. Komunikuje se pomocí zasílání zpráv – datagramů a cesta je hledána pro každý datagram znovu, tj není žádná pevně vytyčena. Každý datagram musí nést plnou adresu příjemce. Je bezstavová. Neřeší se nestandartní situace a pokračuje se v přenosu. Nezachovává pořadí, přenos jednotlivých bloků je vzájemně nezávislý, každý jde jinou cestou.

Spolehlivost

Přenosy nejsou ideální, může dojít k poškození, kdo se pak má starat o nápravu?

Spolehlivá přenosová služba O napravení se stará ten kdo data přenáší, musí rozpoznat chybu a vyžádat si nový přenos (opravu)

Nespolehlivá přenosová služba Kdo přenáší se o data nestará a chybná prostě zahodí a přenáší dál. Zajistění spolehlivosti vyžaduje režiji a ruší pravidelnost doručování dat, také není nikdy absolutní. Někomu vadí víc horší pravidelnost než chyba v datech (obraz a zvuk).

Jaké jsou možnosti zajištění spolehlivosti (v závislosti na dostupnosti zpětné vazby)?

Moze byt realizovane na ktorejkolvek vrstve okrem fyzickej. Princip a sposob realizacie je v zasade rovnaky na vsetkych vrstvach.

Podmienkou je rozpoznat, ze doslo k nejakej chybe pri prenose.

Pri nespolahlivom prenose, sa neda robit nic.

Pri spolahlivom sa postarat o napravu. Moznosti:

- pouzitie samoopravnych kodov, napri Hammingove kody, problemom je velka redundacia, ktora zvysuje objem prenasanych dat, pouziva sa vynimocne
- pomocou potvrdzovania: prijemca si necha znovu zaslat poskodene data, podmienkou je existenica spatnej vazby (aspon polovicny duplex, aby prijemca mohol kontaktovat odosielatela).

Jak se používá parita a kontrolní součet pro detekci chyb při přenosech?

Parita

- Paritny bit: bit pridany naviac k datovym bitom. Suda parita (paritny bit je nastaveny tak, aby celkovy pocet 1 bol sudy), licha parita (1 lichy), jednickova parita (paritny bit pevne nastaveny na 1, neni zabezpecovaci efekt), nulova parita (nastaveny na 0).
- **Priecna parita:** po jednotlivych bytoch/slovach, informacie o tom, ktory byte je poskodeny je nadbytocna, aj tak sa posiela rovno cely blok (ramec, pakec).
 - Podelna parita: parita zo vsetkych rovnolahlych bitov vsetkych bytov/slov

Kontrolny sucet: jednotlive byty/slova/dvojslova tvoriace prenasany blok sa interpretuju ako cisla a scitaju sa, vysledny sucet sa pouzije ako zabezpecovaci udaj (obvykle sa pouzije iba cast suctu, napr nizsi byte alebo nizsie slovo.

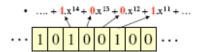
Alternativa: miesto suctu sa pocita XOR jednotlivych bitov.

Je ucinnejsi ako parita, ale stale je miera zabezpecenia nizka.

Jak se používá CRC pro detekci chyb při přenosech?

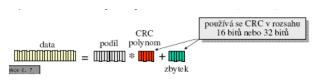
CRC = Cyclic Redundancy Check

Postupnost bitu, tvoriaca blok dat, je interpretovana ako polynom, polynom nad telesom charakteristiky 2, kde bity su jeho koeficienty.



Tento polynom je vydeleny inym polynomom, vysledkom je podiel a zvysok, v roli zabezpecenia sa pouzije zvysok po deleni charakteristickym polynomom.

Schopnosti detekcie su vynikajuce: vsetky shluky chyb s lichym poctom bitov, vsetky shluky chyb do velkosti n bitu, kde n je stupen charakteristickeho polynomu, vsetky shluky chyb velkosit i, n+1 s pravdepodobnostou 99,999



Spolahlivost CRC kodov sa opiera o vysledky z algebry, samotny vypocet je velmi jednoduchy a moze byt lahko implementovany v HW, pomocou XOR hradiel a posuvnych registrov.

Jaký je princip potvrzování? Jak funguje jednotlivé a kontinuální potvrzování?

Ide o obecnejsi mechanizmus, ktory sluzi viac ucelom sucasne: 1. zaistenie spolehlivosti

(umoznuje, aby si prijemca vyziadal opakovane zaseialanie poskodeneho ramca), 2. riadenie toku (aby prijemca mohol regulovat tempo, akym odosielatel posiela data.

Sposoby:

- kladne a zaporne potvrdzovanie: potvrdzuju sa spravy, resp chybne prijate bloky
- jednotlive a kontinualne potvrdzovania: podla toho, ci odosielatel vzdy caka na potvrdenie alebo odosiela do fronty.
- Samostatne a nesamostatne potvrdzovanie: ci potvrdenie cestuje ako samostatny ramec/paket, alebo je vnorene do datoveho paketu.
- Metoda okienka

Jednotlive potvrdzovanie: Stop&Wait ARQ

- ide o samostatne jednotlive potvrdzovanie, potvrdenie je prenasane ako samostatny (riadiaci) blok, potvrdzovany je kazdy jeden paket (kladne, zaporne, timeout)
- pribeh: odosielatel odosle datovy ramec a caka na jeho potvrdenie (kladne, zaporne), dalsi ramec neodosiela, prijemca odosle potvrdenie, podla druhu potvrdenia odosielatel bud odosle dalsi ramec alebo opakuje prenos, timeout interpretuje ako zapornu odpoved
- jednoducha a priamociara interpretacia, charatker prenosu cisto poloduplexny, napr. protokoly IPX/SPX
- ma zmysel v LAN (kratka odozva), nie WAN (zpozdeni velke)

Kontinualne potvrdzovanie: continuous ARQ

- idea: odosielatel bude vysielat datove ramce dopredu, a prislusne potvrdenia prijimat priebezne, s urcitym zpozdenim
- ak dostane zapornu odpoved: 1. selektivne opakovanie: odosle iba ramec, ktory sa poskodil (prijimatel musi ukladat do bufferu, narocne hospodarenie s pamatou), 2. navrat spat: riesi

Jaký je rozdíl mezi samostatným a nesamostatným potvrzováním? Jak funguje piggybacking?

Samostatne: potvrdenie je prenasane ako samostatny ramec specialneho typu, spojene s relativne vysokou reziou, samostatne potvrdenie je male, obale je velky

Nesamostatne: potvrdenie je zasielane ako sucast datovych ramcov, prenasanych v opacnom smere, ktore su potvrdzovane, tzv. piggybacking

Zabezpečení protokolu

Jaká je podstata sítí VPN (Virtual Private Network)?

Samostatná podsíť jiné sítě (věřejné datové sítě). Z pohledu uživatele jde o samostatnou síť. Uživatel chce mít vlastní síť ale nevyplatí se mu jí vybudovat. Samostatný adresový prostor, přístup k uzlům mimo VPN je jen přes bránu.

Ekonomický efekt: lacinejší

Praktičnost: jednoduchá údržba a efekt vlastní sítě.

Bezpečnost: poskytují určitou ochranu

Spojení poboček firmy přes internet do VPN, takovéto pobočkové sítě pak splývají do jednoho logického celku. Připojení vzdáleného uživatele do firemní sítě.

Jaké bezpečností funkce jsou schopny zabezpečit sítě VPN?

Funkce a služby: identifikace a autentizace uživatele. Takovýto uživatel se pak může volně pohybovat po VPN. Zajištění dúvěrnisti – šifrování a zajištění integrity – nelze komunikaci neoprávněně pozměnit.

Jak je v TCP/IP řešena bezpečnost (a zabezpečení)?

Zabezpečení si musí každá aplikace zajistit sama (na aplikační úrovni). Přenos. Infrastruktura je tak jednoduší rychlejší a lacinější.

V ISO/OSI to řeší relační vrstva.

Report (Galambos)

Chtel vedet, jak vypada navazovani spojeni, v jake vrstve se resi zabezpeceni a takovy ruzny nesmysly, nakonec to byla pry horsi dvojka.

Report (Peterka)

Zajímal ho především způsob jakým lze spolehlivosti dosáhnout, konkrétní metody - tedy samoopravné kódy, CRC a kontrolní součty - a jejich použití v konkrétních případech. Dále se také ptal na rozdíl mezi jednotlivým a kontinuálním potvrzováním - v jakých situacích lze resp. nelze použít - a piggybacking.

V pohode, udelala se z toho takova lehka prochazka po lehce pribuznych tematech a dostali jsme se i k tomu, kdo muze za fragmentaci

6 Programovací jazyky

Požadavky

- Principy implementace procedurálních programovacích jazyků, oddělený překlad, sestavení.
- Objektově orientované programování.
- Neprocedurální programování, logické programování.
- Generické programování.

6.1 Principy implementace procedurálních a objektové orientovaných programovacích jazyků, oddělený překlad, sestavení

Principy implementace proceduralnich programovacich jazyku je v zasade jednoducha vec. Je treba vedet, jak funguji zakladni veci uvnitr. Ze program ma ctyri kusy pameti (code, data, stack a heap) a co ktera dela. Jak probiha volani procedur, kam se pri nem co schova. Jak funguje rekurze, kam se ukladaji lokalni promenne a kam globalni, ... atd.

Strukturované programování

Počítačový program je nějakým způsobem zaznamenaný postup počítačových operací, který speciálním způsobem popisuje praktickou realizaci zadané úlohy (tedy algoritmus výpočtu). Program z procedurálního úhlu pohledu je vlastně přesná specifikace všech kroků, které musí počítač vykonat, aby došel k cíli, a jejich pořadí. Pro určování pořadí kroků se používají základní operace řízení toku – skoky, podmínky, cykly apod.

Jedním z důležitých konceptů procedurálního programování je strukturované programování – jeho idea je založena na rodělení programu na procedury (rutiny, podrutiny, metody, funkce), které samy obsahují výčet výpočetních kroků k vykonání, mohou být ale spouštěny opakovaně a z libovolného místa v programu. Jejich výhodou je mnohem názornější pohled na strukturu programu a snazší udržování kódu, než v případě použití jen nejjednoduššího řízení toku (tedy hlavně skoků, které by se ve strukturovaném programování správně používat neměly).

Datové a řídící struktury vyšších programovacích jazyků a jejich implementace

Řízení toku

V informatice se tokem řízení rozumí pořadí ve kterém se provádějí jednotlivé příkazy programu. V imperativních (=procedurálních) programovacích jazycích se příkazy pro řízení toku rozumí příkazy, které dokážou změnit pořadí provádění příkazů na jiné než přirozené (to v jakém jsou zapsány). Některé funkcionální jazyky také obsahují takové příkazy (které již nepatří do funkcionálního programování), ale potom už se jim většinou neříká příkazy pro řízení toku.

Druhy příkazů pro řízení toku se mezi jazyky liší, ale přibližně mohou být rozděleny do následujících kategorií.

- Pokračování na jiném místě programu (skok).
- Vykonání skupiny příkazů pouze pokud je splněna určitá podmínka (if-then-else)
- Nevykonání skupiny příkazů nebo jejich opakování do té doby než je splněna určitá podmínka (smyčka/cyklus). Cykly
 mohou být s podmínkou na začátku, na konci, uprostřed, nekonečné, s daným počtem opakování.
- Vykonání skupiny příkazů, které se nacházejí na jiném místě kódů, a následné (volitelné) vrácení řízení toku zpět (subroutines, coroutines, and continuations).
- Zastavení/ukončení programu.

Přerušení a signály jsou nízkoúrovňový mechanizmus, který může změnit tok řízení podobně jako se to dělá u podprogramů, ale většinou je vyvolán vnější událostí a není tedy použit ve smyslu řízení toku programu, jak bylo popsáno.

Výjimky

Výjimky jsou speciálním příkazem řízení toku, vyskytujícím se v některých vyšších programovacích jazycích. Základní myšlenkou je, že program může na nějakém místě vyhodit výjimku (příkaz throw), což způsobí, že provádění programu se zastaví a buď pokračuje tam, kde je výjimka "ošetřena" (tzv. catch blok), nebo pokud takové místo není nalezeno, program skončí s chybou. Během hledání místa ošetření je datová hodnota výjimky uložena stranou a pak může být použita.

Při hledání místa ošetření výjimky (try-bloku, následovaného catch-blokem se správným datovým typem výjimky) se postupuje zpět po zásobníku volání funkcí, tato technika se nazývá "stack unwinding" (odvíjení zásobníku). V některých jazycích (Java) lze definovat i akci, která se provede v každém případě, i pokud nastane výjimka, ještě před odvíjením zásobníku – finally blok.

Volací konvence

Při volání procedur a funkcí je nejdůležitější zásobník. Ukládá se na něj

- kam se vrátit po volání
- argumenty funkce (v překladem definovaném pořadí nutné mít ve všech modulech stejné; většinou se liší v závislosti na programovacím jazyku)

- návratová hodnota funkce
- ukazatel na sémanticky nadřazenou funkci (Pascal)

Dohromady všem těmto datům se někdy říká *aktivační záznam* procedury. Po skončení funkce je nutné zásobník opět uklidit (vymazat zbytečná uložená data, většinou jen zůstává návratová hodnota) a která část programu to dělá (volaná nebo volající procedura), závisí opět na překladači a konvenci jazyka.

Volací konvence dvou nejtypičtějších jazyků:

- Pascal uklízí volaná funkce, argumenty se ukládají na zásobník zleva doprava (nejlevejší nejdřív, tj. nejhlouběji)
- uklízí funkce volající, argumenty se ukládají zprava doleva (tj. nejlevější je na vrcholu zásobníku. Je to kvůli funkcím s proměnným počtem parametrů. Volaná funkce musí podle prvního argumentu poznat, jaký je skutečný počet argumentů. Kdyby byl první argument někde hluboko v zásobníku, tak ví prd.)

Volání funkcí a procedur z pohledu procesoru

- 1. uložení vstupních parametrů pro funkci
- 2. předání řízené do kódu funkce "skok"
- 3. získání prostředků pro vykonání funkce
- 4. provedení požadované funkce
- 5. uložení výsledků pro volajícího
- 6. návrat do místa volání

Máme registry pro data (vstupní parametry a návratovou hodnotu) a registr pro návratovou hodnotu, kam se uloží adresa instrukce následující po instrukci volání (neboli hodnota Program Counteru PC + 4).

V případě rekurzivního volání nebo většího počtu parametrů musíme registry dostat na zásobník v paměti (ten roste směrem k nižším adresám, tj. čím větší zásobník, tím nižší hodnota stack pointeru SP).

Organizace paměti

Paměť procesu (spuštěného programu) lze rozdělit do několika částí:

- kód programu (kódový segment) vytvořen při překladu, součást spustitelného souboru, neměnný a má pevnou délku; obvykle bývá chráněn proti zápisu
- statická data (datový segment)
 data programu, jejichž velikost je známa již při překladu a jejichž pozice se během programu nemění (je připraven kompilátorem a jeho formát je taktéž zadrátovaný ve spustitelném souboru, u inicializovaných statických dat je tam celý uložený); v jazyce C jde o globální proměnné a lokální data deklarovaná jako static, konstanty
- halda (heap segment)
 vytvářen startovacím modulem (C Runtime library), ukládají se sem dynamicky vznikající objekty (malloc, new) neinicializovaná data, i seznam volného místa
- volná paměť
 postupně jí zaplňuje z jedné strany zásobník a z druhé halda
- zásobník (stack segment)
 informace o volání procedur ("aktivační záznamy") návratové adresy, parametry a návratové hodnoty (nejsou-li předávány
 v registrech), některé jazyky (Pascal, C) používají i pro úschovu lokálních dat. Typicky roste zásobník proti haldě (od
 "konce" paměti k nižším adresám).

Poznámka (Vnořené funkce)

V Pascalu mohou být funkce definované uvnitř jiné funkce. Ta vnitřní potřebuje přistupovat k proměnným té vnější. Proměnné jsou sice na zásobníku, ale pouhý odkaz na volající funkci nestačí, protože se vnořená funkce může volat rekurzivně. Proto je na zásobníku ukazatel na funkci sémanticky nadřazenou.

Alokace místa pro různé typy proměnných

- Dynamicky alokované proměnné (přes pointer) se alokují na haldě. Opakovanou alokací a dealokací paměťových bloků různé velikosti vznikají v haldě "díry" (střídavé úseky volného a naalokovaného místa). Existuje několik strategií pro vyhledání volného bloku požadované velikosti (first-fit, next-fit, buddy systém) a udržení informací o volném místě, které jsou většinou implementovány v knihovních funkcích jazyka (C, Pascal).
- Lokální proměnné se ukládají na zásobník, po skončení funkce, které přísluší, jsou zase odstraněny.
- Globální a statické se ukládají do segmentu pro statická data. Tady se díry tvořit nebudou, protože tyhle proměnné vznikají na začátku a zanikají na konci programu (takže se formát segmentu nemění).

Oddělený překlad, sestavení

Struktura programu

Program se skládá z modulů:

- Překládány samostatně kompilátorem
- Spojovány linkerem

Modul z pohledu programátora

• Soubor s příponou .cpp (.c)

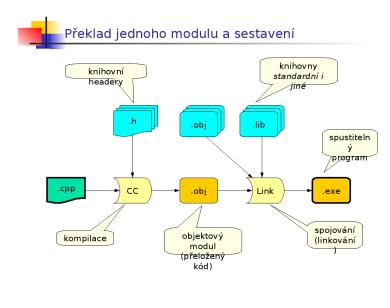
Hlavičkové soubory

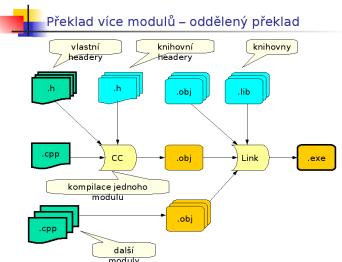
- Soubory s příponou .h
- Deklarují (a někdy i definují) identifikátory používané ve více modulech
- Vkládány do modulů direktivou include
 - Direktivu zpracovává preprocesor čistě textově
 - Preprocesor je integrován v kompilátoru jako první fáze překladu

Modul z pohledu kompilátoru

- Samostatná jednotka překladu
- Výsledek práce preprocesoru

Oddělený překlad





Smysl odděleného překladu modulů je urychlení celkového překladu – nepřekládat to, co se od minula nezměnilo. Oddělený překlad dnes díky automatizaci makefily (viz níže) a integrovanými prostředími není téměř pro programátora vidět.

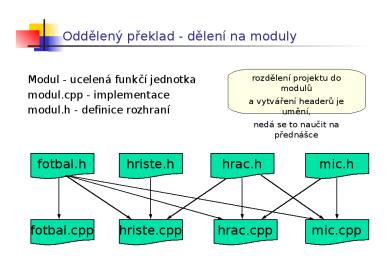
...na tomto slide je vhodné si ujasnit, jak funguje statické a dynamické linkování (jak a kde a kdy se opravují adresy objektů atd...):

• Statické linkování

Po odděleném překladu jednotlivé object moduly ještě neobsahují přímo adresy všech funkcí a externích identifikátorů, jen odkazy na ně. Linker se postará o jejich spojení dohromady. Je nutné, aby jména byla unikátní, takže u přetížených a virtuálních funkcí, jako je v C++, musí bý jména zpotvořena tak, aby ukazovala i třídu, namespace, parametry a jejich typy. To má na starosti compiler a říká se tomu name mangling.

• Dynamické linkování

Nastává po volání operačního systému – zavedení dynamické knihovny do paměti. Jsou dvě možnosti jeho provedení, první je právě při zavádění knihovny, kdy se odkazy na všechny funkce (a mezi nimi navzájem) naplní správnými hodnotami (podle bázové adresy, na kterou se knihovna do paměti nahraje). Druhá možnost je použití dvou pointerů při volání funkcí z knihovny – to se vytvoří tabulka skutečných adres, na kterou se z knihovny ukazuje. První možnost trvá déle při zavádění knihovny, druhá je zase pomalejší při provádění, ale umožňuje kód knihovny beze změn sdílet více procesy.



Linker je program, který prijímá jeden alebo více objektů generovaných kompilátorem a složí je v jeden spustitelný program. Objektový kód, nebo objektový soubor je reprezentace kódu, který kompilátor nebo assembler vytvoří zpracováním zdrojového kódu. Objektové soubory obsahují kompaktní kód, často nazývaný "binárky":-) Linker se typicky používá na vytvoření spustitelnýho souboru nebo knihovny spojením (slinkováním) objektových souborů. Základní častí objektového souboru je strojový kód (kód přimo vykonávaný CPU počítače).

Makefile

Smyslem programu *make* je řízení překladu a linkování. Popis závislostí jednotlivých modulů a hlavičkových souborů je definován v 1 textovém souboru – *Makefile* (tj. které soubory je nutné mít aktuální/vytvořené pro překlad kterého souboru). Make vždy po změně souboru přeloží jen to, co na něm závisí. Formát souboru make:

```
targets: files;
    commands; #comment; line-begin\
    line contd.;
```

Targets – cíle činností / cílové soubory, možno definovat vic, při spuštění make bez parametrů se bere první; univ. nástroj (nejen pro překlad C/C++). Lze definovat i vlastní makra (příkazem <název makra> = <string>) a pak je používat (\${makro}).

6.2 Objektově orientované programování

(podle zkoušení Burešem a Tůmou)

Účel objektového programování

In the 1960s, language design was often based on textbook examples of programs, which were generally small (due to the size of a textbook); however, when programs become very large, the focus changes. In small programs, the most common statement is generally the assignment statement; however, in large programs (over 10,000 lines), the most common statement is typically the procedure-call to a subprogram. Ensuring parameters are correctly passed to the correct subprogram becomes a major issue.

Many small programs can be handled by coding a hierarchy of structures; however, in large programs, the organization is more a network of structures, and insistence on hierarchical structuring for data and procedures can produce cumbersome code with large amounts of "tramp data" to handle various options across the entire program.

Although structuring a program into a hierarchy might help to clarify some times of software, even for some special types of large programs, a small change, such as requesting a user-chosen new option (text font-color) could cause a massive ripple-effect with changing multiple subprograms to propagate the new data into the program's hierarchy. The object-oriented approach is allegedly more flexible, by separating a program into a network of subsystems, with each controlling their own data, algorithms, or devices across the entire program, but only accessible by first specifying named access to the subsystem object-class, not just by accidentally coding a similar global variable name. Rather than relying on a structured-programming hierarchy chart, object-oriented programming needs a call-reference index to trace which subsystems or classes are accessed from other locations.

Definice (Objektově orientované programování)

Objektově orientované programování (zkracováno na OOP, z anglického Object-oriented programming) je metodika vývoje softwaru. Dá se na něj nahlédnout jako na kolekci spolupracujících objektů – v protikladu k tradičnímu pohledu, kdy se za program považuje sled instrukcí pro počítač. V OOP je každý objekt schopný přijímat zprávy, zpracovávat data a posílat zprávy jiným objektům. Na každý objekt se tak dá nahlížet jako na nezávislý "malý stroj" s vlastní rolí a zodpovědností. Zjednodušeně řečeno jde o dotažení konceptu data + algoritmy = program. Data tvoří s kódem, který je spravuje, jeden celek. Je založeno na následujících myšlenkách, koncepci:

Objekty

Jednotlivé prvky modelované reality (jak data, tak související funkčnost) jsou v programu seskupeny do entit, nazývaných objekty. Objekty si pamatují svůj stav a navenek poskytují operace (přístupné jako metody pro volání).

Implementace objektů Z hlediska jazyka není velký rozdíl mezi složenými datovými typy a třídami. Deklarace třídy obsahuje, stejně jako u složeného dat. typu, datové položky. Navíc ale obsahuje i deklarace funkcí (metod), které s nimi pracují. Některé funkce mohou mít speciální vlastnosti – statické, virtuální, konstruktory, destruktory. Navíc většina jazyků přidává možnost označení kterýchkoliv položek jako veřejné nebo privátní. Třídy mohou někdy (C++, Java) obsahovat i vnořené datové typy (výčty, ...) a dokonce vnořené třídy.

Za běhu je jedna instance třídy – objekt reprezentována v paměti pomocí:

- datových položek (stejně jako složený datový typ),
- skrytých pomocných položek umožňujících funkci virtuálních metod, výjimek, RTTI a dědičnosti (identifikace typu / jeho velikosti apod.)

Abstrakce

Programátor, potažmo program, který vytváří, může abstrahovat od některých detailů práce jednotlivých objektů. Každý objekt pracuje jako černá skříňka, která dokáže provádět určené činnosti a komunikovat s okolím, aniž by vyžadovala znalost způsobu, kterým vnitřně pracuje.

Zapouzdření

Zaručuje, že objekt nemůže přímo přistupovat k "vnitřnostem" jiných objektů, což by mohlo vést k nekonzistenci. Každý objekt navenek zpřístupňuje rozhraní, pomocí kterého (a nijak jinak) se s objektem pracuje.

Jake ma vyhody OOP proti pouze proceduralnimu programovani - Zacal jsem zapouzdrenim, kde me vcelku potrapil pure C jazykem jehoz moduly, .h soubory, pouziti staticu, ifdefu a dalsich konstruktu muze slouzit jako slusne zapouzdreni - ukolem bylo rict na konkretnim jazyce co prinasi OOP navic (napr. vetsi granularita oddeleni (Java a viditelnost v Packagi, protected, final...))

We use these keywords to specify access levels for member variables, or for member functions (methods).

- public variables, are variables that are visible to all classes.
- private variables, are variables that are visible only to the class to which they belong.
- protected variables, are variables that are visible only to the class to which they belong, and any subclasses.

Skládání

Objekt může využívat služeb jiných objektů tak, že je požádá o provedení operace.

Třída

Třída definuje abstraktní vlastnosti nějakého objektu, včetně obsažených dat (atributy, pole (fields) a vlastnosti (properties)) a věcí, které může dělat (chování, metody a schopnosti (features)). Například třída *Dog* by obsahovala věci spoločné pro všechny psy - např. atributy rasa, barva srsti a schopnosti štěkat.

Třídy poskytují v objektově-orientovaném programu modularitu a strukturu. Třída by typicky měla být rozpoznatelná i ne-programátorovi, který se ale v dané doméně problémů orientuje – tzn. že charakteristiky třídy by měly "dávat v kontextu smysl". Podobně i kód třídy by měl být relativně samostané, ("self-contained")". Vlastnosti a metódy tříd se dohromady nazývají i *members*.

Kontruktory

Konstruktor je v objektově orientovaném programování speciální metoda třídy, která se volá, když je instance přislušného objektu této třídy nově vytvářena.

Konstruktor se podobá ostatním metodám třídy, ale liší se od nich tím, že nemá nikdy explicitní návratový typ, nedědí se a obvykle má jiná pravidla pro modifikátory přístupu. Konstruktory inicializují datové členy. Správně napsaný konstruktor nechá objekt v "platném" stavu.

Ve většině jazyků může být kontruktor přetížen, takže má jedna třída několik konstruktorů s odlišnými parametry. Některé jazyky (např. C++) rozlišují speciální typy konstruktorů:

- implicitní konstruktor konstruktor bez parametrů
- kopírovací konstruktor konstruktor, který má jeden parametr typu dané třídy (nebo reference na ní)

Dědičnost

Objekty jsou organizovány stromovým způsobem, kdy objekty nějakého druhu mohou dědit z jiného druhu objektů, čímž přebírají jejich schopnosti, ke kterým pouze přidávají svoje vlastní rozšíření. Tato myšlenka se obvykle implementuje pomocí rozdělení objektů do tříd, přičemž každý objekt je instancí nějaké třídy. Každá třída pak může dědit od jiné třídy (v některých programovacích jazycích i z několika jiných tříd). Umožňuje zacházet s množinou tříd, jako by byly všechny reprezentovány tím samým objektem. Například známá hierarchie: grafický objekt, bod, kružnice. Navíc je to prostředek pro úsporu práce při kódování.

Máme dva druhy dědičnosti podle násobnosti:

- Jednoduchá dědičnost každá podtřída dědí pouze z jedné supertřídy
- Vícenásobná dědičnost můžeme dědit z více tříd

A další dva druhy dědičnosti podle použití:

- Implementation Inheritance: in which class inherits one class and implement/override its methods and properties for example Control object in which System.Windows.Forms.Textbox,System.Windows.Forms.Button both inherits their self from control class. But provides different functionality
- Interface inheritance: in which a class inherits from Interface. For example IDisposable. It just inherits definition not implementation. Any type which does interface inheritance it means that it will provide defined functionality called as "Contract".

Implementace dědičnosti v C++: Je-li třída B (přímým či nepřímým) potomkem třídy A, pak paměťová reprezentace objektu typu B obsahuje část, která má stejný tvar jako paměťová reprezentace samostatného objektu typu A. Z každého ukazatele na typ B je možno odvodit ukazatel na část typu A – tato konverze je implicitní, tj. není třeba ji explicitně uvádět ve zdrojovém kódu. Tato konverze může (obvykle pouze při násobné dědičnosti) vyžadovat jednoduchý výpočet (přičtení posunutí).

Z ukazatele na typ A je možno odvodit ukazatel na typ B, jen pokud konkrétní objekt, do kterého ukazuje ukazatel na typ A, je typu B (nebo jeho potomka). Zodpovědnost za ověření skutečného typu objektu má programátor a tuto konverzi je třeba explicitně vynutit přetypováním. Může to znamenat odečtení posunutí v paměti.

Dědičnost typu Diamant

Vícenásobná dědičnost bohužel přináší řadu problémů. Z toho důvodu celá řada objektově orientovaných jazyků nepodporuje vícenásobnou dědičnost. Jeden z příkladů je *dědičnost typu diamant*, kde třídy B a C jsou potomci nějaké třídy A. Potom má třída D, potomek třídy B a C, atributy z prapředka A dvakrát. To lze řešit pomocí virtuální dědičnosti.

Implementace problému Diamant v C++: Postupuje po obou cestách odděleně, takže objekt D pak obsahuje 2 separátní A objekty a kód pravděpodobně skončí na COMPILE ERROR. Pokud je dědičnost z A do B a A do C označena jako "virtual" (například "class B: virtual public A"), C++ pak vytvoří pouze 1 A objekt a jeho části budou správně fungovat. Pokud ale smícháme na obou virtuální a nevirtuální dědičnost dojde také ke COMPILE ERROR - při přístupu k částem A z D.

Virtuální metody

V objektově orientovaném programování se pod pojmem virtuální funkce nebo virtuální metoda myslí funkce/metoda (v kódu označená klíčovým slovem – typicky virtual), jejíž chování je určeno definicí v posledním objektu (ve směru dědičnosti od rodičů k potomkům), který definici funkce s danou signaturou obsahuje. Tento koncept je důležitou součástí polymorfismu v objektově orientovaném programování.

Koncept virtuálních funkcí řeší následující problém:

Když v OOP dědí nějaká třída od jiné, tak instance poděděné třídy může být přetypována na libovolného ze svých předků. Pokud však poděděná třída předefinovala poděděnou metody, nebude při jejím přetypování na předka jasné, kterou z definicí metody použít.

Rozhodnutí otázky, kterou funkci zavolat, přináší právě rozdělení metod na virtuální a nevirtuální. Když je funkce označena jako virtuální, je použita definice funkce z poděděné třídy (pokud existuje). V opačném případě je použita definice ze třídy na kterou je instance třídy právě přetypována.

Pozdní vazba (late binding; virtual call): Je-li metoda nějaké třídy virtuální či čistě virtuální, pak všechny metody se stejným jménem, počtem a typy parametrů deklarované v potomcích třídy jsou považovány za různé implementace téže funkce. Která implementace se vybere, tedy které tělo bude zavoláno, se rozhoduje až za běhu programu podle skutečného typu celého objektu. Použije se tělo z posledního potomka, který definuje tuto funkci a je součástí celého objektu. Pozdní vazba má smysl pouze u vyvolání na objektu určeném odkazem.

Pozdní vazba je implementačně umožněná skrytým pointerem na *tabulku virtuálních funkcí (VMT)* uvnitř každého objektu. Existuje pro každou třídu jedna. Při dědičnosti zůstává v celém objektu odkaz jeden (v C++ jich může být při výsenásobné dědičnosti i více), ale (i pro "nejvnitřnější" bázovou třídu) odkazuje na tabulku odvozené třídy. V tabulce musí být proto pointery na funkce, deklarované už u bázové třídy, umístěny na začátku (aby bylo možné volat funkce bázové třídy mezi sebou bez změny kódu).

Polymorfismus

Odkazovaný objekt se chová podle toho, jaký je jeho skutečný typ. Pokud několik objektů poskytuje stejné rozhraní, pracuje se s nimi stejným způsobem, ale jejich konkrétní chování se liší. V praxi se tato vlastnost projevuje např. tak, že na místo, kde je očekávána instance nějaké třídy, můžeme dosadit i instanci libovolné její podtřídy (třídy, která přímo či nepřímo z této třídy dědí), která se může chovat jinak, než by se chovala instance rodičovské třídy, ovšem v rámci "mantinelů", daných popisem rozhraní.

Příklad polymorfismu, dědičnosti (případně zapouzdření) v C#:

```
namespace Program
   public interface IAnimal
        string Name { get; }
        string Talk();
   public abstract class AnimalBase
       public string Name { get; private set; }
       protected AnimalBase(string name) {
           Name = name;
   }
   public class Cat : AnimalBase, IAnimal
        public Cat(string name) : base(name) {
       public string Talk() {
           return "Meowww!";
   }
   public class Dog : AnimalBase, IAnimal
        public Dog(string name) : base(name) {
        public string Talk() {
           return "Arf! Arf!";
   public class TestAnimals
        // prints the following:
        // Missy: Meowww!
        //
           Mr. Mistoffelees: Meowww!
        //
           Lassie: Arf! Arf!
       //
       public static void Main(string[] args)
           var animals = new List<IAnimal>() {
               new Cat("Missy"),
               new Cat("Mr. Mistoffelees"),
               new Dog("Lassie")
           };
           foreach (var animal in animals) {
                Console.WriteLine(animal.Name + ": " + animal.Talk());
       }
   }
```

}

6.3 Neprocedurální programování, logické programování

Neprocedurální programování

Deklarativní programování je postaveno na paradigmatu, podle něhož je program založen na tom, co se počítá a ne jak se to počítá. Je zde deklarován vstup a výstup a celý program je chápán jako funkce vyhodnocující vstupy podávající jediný výstup. Například i webovské stránky jsou deklarativní protože popisují, jak by stránka měla vypadat – titulek, font, text a obrázky – ale nepopisují, jak konkrétně zobrazit stránky na obrazovce.

Logické programování a funkcionální programování jsou poddruhy deklarativního programování. Logické programování využívá programování založené na vyhodnocování vzorů - tvrzení a cílů. Klasickým zástupcem jazyka pro podporu tohoto stylu je Prolog.

Tento přístup patří pod deklarativní programování stejně jako funkcionální programování, neboť deklaruje, co je vstupem a co výstupem, a nezabývá se jak výpočet probíhá. Naopak program jako posloupnost příkazů je paradigma imperativní.

Funkcionální programování patří mezi deklarativní programovací principy.

Alonzo Church vytvořil formální výpočtový model nazvaný λ -kalkul. Tento model slouží jako základ pro funkcionální jazyky. Funkcionální jazyky dělíme na:

- typované Haskell
- netypované Lisp, Scheme

Výpočtem funkcionálního programu je posloupnost vzájemně ekvivalentních výrazů, které se postupně zjednodušují. Výsledkem výpočtu je výraz v normální formě, tedy dále nezjednodušitelný. Program je chápán jako jedna funkce obsahující vstupní parametry mající jediný výstup. Tato funkce pak může být dále rozložitelná na podfunkce.

Prolog

Prolog je logický programovací jazyk. Název Prolog pochází z francouzského programmation en logique ("logické programování"). Byl vytvořen Alainem Colmerauerem v roce 1972 jako pokus vytvořit programovací jazyk, který by umožňoval vyjadřování v logice místo psaní počítačových instrukcí. Prolog patří mezi tzv. deklarativní programovací jazyky, ve kterých programátor popisuje pouze cíl výpočtu, přičemž přesný postup, jakým se k výsledku program dostane, je ponechán na libovůli systému.

Prolog je využíván především v oboru umělé inteligence a v počítačové lingvistice (obzvláště zpracování přirozeného jazyka, pro nějž byl původně navržen). Syntaxe jazyka je velice jednoduchá a snadno použitelná pravě proto, že byl původně určen pro počítačově nepříliš gramotné lingvisty.

Prolog je založen na predikátové logice prvního řádu (konkrétně se omezuje na Hornovy klauzule). Běh programu je pak představován aplikací dokazovacích technik na zadané klauzule. Základními využívanými přístupy jsou unifikace, rekurze a backtracking.

Interpret Prologu se snaží nalézt nejobecnější substituci, která splní daný cíl - tzn. nesubstituuje zbytečně, pokud nemusí (použití interních proměnných – $_123$ atd.). Za dvě proměnné může být substituována jedna interní proměnná (např. při hledání svislé úsečky – konstantní X souřadnice) – tomu se říká unifikace proměnných. Pro proměnnou, jejíž hodnota může být libovolná, se v prologu užívá znak " $_-$ ".

Datové typy v prologu se nazývají termy. Základním datovým typem jsou atomy (začínají malým písmenem, nebo se skládají ze speciálních znaků (+ - * / ..., nebo jsou to znakové řetězce ('text')). Dále "jsou" v prologu čísla (v komerčních implementacích i reálná), proměnné (velké písmeno) a struktury (definované rekursivně - pomocí funktoru dané arity a příslušným počtem termů, které jsou jeho argumenty - okamzik(datum(1,1,1999),cas(10,10))). Posledním typem proměnných jsou seznamy, které jsou probírány později.

Základní principy:

Programování v Prologu se výrazně liší od programování v běžných procedurálních jazycích jako např. C. Program v prologu je databáze faktů a pravidel (dohromady se faktům a pravidlům paradoxně říká procedury), nad kterými je možno klást dotazy formou tvrzení, u kterých Prolog zhodnocuje jejich pravdivost (dokazatelnost z údajů obsažených v databázi).

Například lze do databáze uložit fakt, že Monika je dívka:

```
dívka (monika).
```

Poté lze dokazatelnost tohoto faktu prověřit otázkou, na kterou Prolog odpoví yes (ano):

```
?- dívka(monika).
    yes.
```

Také se lze zeptat na všechny objekty, o kterých je známo, že jsou dívky (středníkem požadujeme další výsledky):

```
?- dívka(X).
    X = monika;
    no.
```

Pravidla (závislosti) se zapisují pomocí implikací, např.

```
syn(A,B) := rodič(B,A), muž(A).
```

Tedy: pokud B je rodičem A a zároveň je A muž, pak A je synem B. První části pravidla (tj. důsledku) se říká hlava a všemu co následuje za symbolem: – (tedy podmínkám, nutným pro splnění hlavy) se říká tělo. Podmínky ke splnění mohou být odděleny buď čárkou (pak jde o konjunkci, musejí být splněny všechny), nebo středníkem (disjunkce), přičemž čárky mají větší prioritu.

Příklad:

Typickou ukázkou základů programování v Prologu jsou rodinné vztahy.

```
sourozenec(X,Y) :- rodič(Z,X), rodič(Z,Y).
rodič(X,Y) :- otec(X,Y).
rodič(X,Y) :- matka(X,Y).
muž(X) :- otec(X,_).
žena(X) :- matka(X,_).
matka(marie,monika).
otec(jiří,monika).
otec(jiří,marek).
otec(michal,tomáš).
```

Prázdný seznam je označen atomem [], neprázdný se tvoří pomocí funktoru '.' (tečka) - .(Hlava,Tělo). V praxi se to (naštěstí;-)) takhle složitě rekurzivně zapisovat nemusí, stačí napsat [a,b,c...], resp [Začátek | Tělo], kde začátek je výčet prvků (ne seznam) stojících na začátku definovaného seznamu, a tělo je (rekurzivně) seznam (např. [a,b,c|[]]).

Aritmetické výrazy se samy o sobě nevyhodnocují, dokud jim to někdo nepřikáže. Takže např. predikát 5*1 = 5 by selhal. Vyhodnocení se vynucuje pomocí operátoru *is* (pomocí = by došlo jen k unifikaci) - není to ale ekvivalent "=" z jiných jazyků. Tento operátor se musí použít na nějakou volnou proměnnou a aritmetický výraz, s jehož hodnotou bude tato proměnná dále svázaná (jako např. X is 5*1,X=5 uspěje).

Důležitý je i operátor řezu (značíme vykřičníkem). Tento predikát okamžitě uspěje, ale při tom zakáže backtrackování přes sebe zpět. (prvek1(X,[X|L]):-!. prvek1(X,[_|L]):-prvek1(X,L). - je-li prvek nalezen, je zakázán návrat = najde jen první výskyt prvku). Dále je důležitá negace (not(P):- P, !, fail. not(P). - uspěje, pokud se nepodaří cíl P splnit). Řez tedy umožňuje ovlivňovat efektivitu prologovských programů, definovat vzájemně se vylučující použití jednotlivých klauzulí procedury, definovat negaci atd.

Haskell

Haskell je standardizovaný funkcionální programovací jazyk používající zkrácené vyhodnocování, pojmenovaný na počest logika Haskella Curryho. Byl vytvořen v 80. letech 20. století. Posledním polooficiálním standardem je Haskell 98, který definuje minimální a přenositelnou verzi jazyka využitelnou k výuce nebo jako základ dalších rozšíření. Jazyk se rychle vyvíjí, především díky svým implementacím Hugs a GHC (viz níže).

Haskell je jazyk dodržující referenční transparentnost. To, zjednodušeně řečeno, znamená, že tentýž (pod)výraz má na jakémkoliv místě v programu stejnou hodnotu. Mezi další výhody tohoto jazyka patří přísné typování proměnných, které programátorovi může usnadnit odhalování chyb v programu. Haskell plně podporuje práci se soubory i standardními vstupy a výstupy, která je ale poměrně složitá kvůli zachování referenční transparentnosti. Jako takový se Haskell hodí hlavně pro algoritmicky náročné úlohy minimalizující interakci s uživatelem.

Příklady:

Definice funkce faktoriálu:

```
fac 0 = 1
fac n = n * fac (n - 1)
```

Jiná definice faktoriálu (používá funkci product ze standardní knihovny Haskellu):

```
fac n = product [1..n]
```

Naivní implementace funkce vracející n-tý prvek Fibonacciho posloupnosti:

```
fib 0 = 0
fib 1 = 1
fib n = fib (n - 2) + fib (n - 1)
```

Elegantní zápis řadícího algoritmu quicksort:

```
qsort [] = []
qsort (pivot:tail) =
  qsort left ++ [pivot] ++ qsort right
  where
    left = [y | y <- tail, y < pivot]
    right = [y | y <- tail, y >= pivot]
```

TODO: popsat stráže (případy, otherwise), seznamy, řetězení, pattern matching u parametrů funkcí, lok. definice (where, let) – patří to sem?

Lisp

Lisp je funkcionální programovací jazyk s dlouhou historií. Jeho název je zkratka pro List processing (zpracování seznamů). Dnes se stále používá v oboru umělé inteligence. Nic ale nebrání ho použít i pro jiné účely. Používá ho například textový editor Emacs, GIMP či konstrukční program AutoCAD.

Další jazyky od něj odvozené jsou například Tcl, Smalltalk nebo Scheme.

Syntaxe: Nejzákladnějším zápisem v Lispu je seznam. Zapisujeme ho jako:

```
(1 2 "ahoj" 13.2)
```

Tento seznam obsahuje čtyři prvky:

- celé číslo 1
- celé číslo 2
- text "ahoj"
- reálné číslo 13,2

Jde tedy o uspořádanou čtveřici. Všimněte si, že závorky nefungují tak jako v matematice, ale pouze označují začátek a konec seznamu. Seznamy jsou v Lispu implementovány jako binární strom degenerovaný na jednosměrně vázaný seznam. Co se seznamem Lisp udělá, záleží na okolnostech.

Příkazy: Příkazy píšeme také jako seznam, první prvek seznamu je však název příkazu. Například sčítání provádíme příkazem +, což interpreteru zadáme takto:

```
(+ 1 2 3)
```

Interpretr odpoví 6.

Ukázka kódu: Program hello world lze zapsat několika způsoby. Nejjednoduší vypadá takto:

```
(format t "Hello, World!")
```

Funkce se v Lispu definují pomocí klíčového slova defun:

Na prvních dvou řádcích je definice funkce hello, na třetím řádku je tato funkce svým jménem zavolána. Funkcím lze předávat i argumenty. V následujícím příkladu je ukázka funkce fact, která vypočítá faktoriál zadaného čísla:

Pro výpočet faktoriálu čísla 6 předáme tuto hodnotu jako argument funkci fact:

(fact 6)

Návratovou hodnotou funkce bude hodnota 720.

Logické programování

TODO (není součástí otázek pro obor Programování)

6.4 Generické programování – šablony a generika

Základní myšlenkou, která se skrývá za pojmem generické programování, je rozdělení kódu programu na algoritmus a datové typy takovým způsobem, aby bylo možné zápis kódu algoritmu chápat jako obecný, bez ohledu na to, nad jakými datovými typy pracuje. Konkrétní kód algoritmu se z něj stává dosazením datového typu.

U kompilovaných jazyků dochází k rozvinutí kódu v době překladu. Typickým příkladem jazyka, který podporuje tuto formu generického programování, je jazyk C++. Mechanismem, který zde generické programování umožňuje, jsou takzvané šablony (templates).

Poznámka (Metaprogramování a Generické programování)

Generické programování se liší od normálního tím, že rozšiřuje jazyk o možnosti metaprogramování. Úzce souvisí s metaprogramováním, ale negeneruje žádný další zdrojový kód (alespoň ne takový jaký by viděl programátor). Liší se od maker, protože ty provádějí jen preprocesorové "search-and-replace" a nejsou součástí gramatiky jazyka (viz níže podrobnější srovnání). Jediná vyjímka jsou makra a v Common Lisp, kde parsují stromy a ne text (?? zkontrolovat Lisp).

Definice (Šablony)

Šablony jsou používány kompilátorem pro vygenerování dočasného zdrojového kódu, který se pak spojí se zbytkem a je pak zkompilován. Výstup šablon můžou tvořit compile-time konstanty, datové struktury i celé funkce. Použití šablon může být chápáno jako spouštění kódu během kompilace. Tato technika je používána v mnoha jazycích, například C++, Curl, D a XL. Obyčejné fce v C++ mají přednost před generickými.

Příklad (*Třída parametrizovaná typem (kontejner*))

Příklad ukazuje výhodu generického programování, místo abychom psali specifickou implementaci pro každý typ (i když bude kód téměř identický), vytvoříme si šablonu třídy:

```
template<typename T>
class List
{
    T x;
    List<T> *next;
};

List<Animal> list_of_animals;
List<Car> list_of_cars;
...

conductor = root;
while ( conductor != NULL ) {
    cout<< conductor->x;
    conductor = conductor->next;
}
```

T reprezentuje typ který bude instanciován. Vygenerovaný List se pak chová jako List podle určeného typu. Tyto "kontejnerytypu-T", běžně nazývané generiky (anglicky "generics"), je programovací technika umožňující definici třídy která přijímá a obsahuje různé datové typy (nepleťme si teď s dynamickým polymorfismem, který je algoritmicky používá záměnné podtřídy). I když toto je nejčastější použití generického programování (a některé jazyky implementují pouze tento aspekt), generické programování obsahuje i další techniky.

Příklad (Šablony vs. makra)

V mnoha směrech šablony fungují stejně jako šablony pre-procesoru, nahrazují šablonovanou proměnnou daným typem. Na druhou stranu je tu mnoho rozdílů mezi makrem jako toto:

```
#define min(i, j) (((i) < (j)) ? (i) : (j))
a a šablonou:
template<class T> T min (T i, T j) { return ((i < j) ? i : j) }
```

Makro má například tyto problémy:

- Kompilátor nemůže zkontrolovat jestli jsou parametry makra (tj. i,j) kompatibilní typy. Makro se použije bez typové kontroly.
- Hodnoty i a j jsou vyhodnoceny dvakrát. Například pokud jeden parametr používá post-inkrementaci je provedena dvakrát (?? tohle chce ověřit).
- Protože jsou makra jsou interpretována preprocesorem, chybové zprávy kompilátoru budou ukazovat na "rozbalený" výsledek makra v kódu a ne na makro (i když chyba bude v něm).

Příklad (Faktoriál pomocí šablon)

Tento příklad jasně ukazuje výhodu nad makry, v nich takto jednoduše rekurzivní konstrukce napsat nejde (alespoň v C++ ne).

```
template <int N>
struct Factorial
{
    enum { value = N * Factorial<N - 1>::value };
};

template <>
struct Factorial<0>
{
    enum { value = 1 };
};

// použití:
int x = Factorial<4>::value; // == 24
int y = Factorial<0>::value; // == 1
```

Příklad (traits)

Programovací technika využívající šablony, ze kterých nejsou vytvářeny objekty. Určeny k doplnění informací o nějakém typu.

Obsahují pouze definice typů a statické funkce.

```
template< typename T > struct is_void{
   static const bool value = false;
};

template<> struct is_void< void >{
   static const bool value = true;
};

// použití:
is_void<int>::value; // false
is_void<void>::value; // true
```

Příklad (policy classes)

Určeny k definování určitého chování. Jsou to třídy, ze kterých obvykle nejsou vytvářeny objekty a jsou předávány jako parametr šablonám. Defaultní hodnotou parametru často bývá šablona traits. Hlavně spojené s C++ (v ostatních jazycích se zatím nerozšířilo).

```
template < typename output_policy, typename language_policy >
class HelloWorld : public output_policy, public language_policy
{
   using output_policy::Print;
   using language_policy::Message;
   public: void Run() //behaviour method
   {
        //two policy methods
        Print( Message() );
   }
};
class OutputPolicy_WriteToCout
{
protected:
    template< typename message_type >
   void Print( message_type message )
    {
        std::cout << message << std::endl;</pre>
    }
};
class LanguagePolicy_English
   protected: std::string Message() { return "Hello, World!"; }
};
class LanguagePolicy_German
{
   protected: std::string Message() { return "Hallo Welt!"; }
};
int main()
{
    /* example 1 */
   HelloWorld<OutputPolicy_WriteToCout, LanguagePolicy_English> hello_world;
   hello_world.Run(); // Prints "Hello, World!"
   /* example 2
    * does the same but uses another policy, the language has changed
   HelloWorld<OutputPolicy_WriteToCout, LanguagePolicy_German> hello_world2;
   hello_world2.Run(); // Prints "Hallo Welt!"
}
```

```
Definice (Dynamický (run-time) polymorfismus)
  Dědění + VMT = flexibilita. Zde uvedeno jako jako srovnání k šablonám.
class Base
public:
    virtual void method() { std::cout << "Base"; }</pre>
    virtual ~Base() {}
};
class Derived : public Base
public:
    virtual void method() { std::cout << "Derived"; }</pre>
int main()
    Base *pBase = new Derived;
    pBase->method(); //outputs "Derived"
    delete pBase;
    return 0;
}
     Lze rozšířit o šablony.
Definice (Statický (compile-time) polymorfismus)
  Je přetěžování fukcí a operátorů, řeší se při kompilaci = rychlost. Případně jeho varianta s šablonami:
template <class Derived>
struct base
{
    void interface()
    {
          // ...
          static_cast<Derived*>(this)->implementation();
          // ...
    }
};
struct derived : base<derived>
{
     void implementation();
};
  Lze tak dosáhnout podobných věcí jako s VMT.
Použití v programovacích jazycích
  Jazyk D také nabízí plně generické šablony založené na svém předchůdci C++ ale má jednodušší syntaxi. Java má syntaxi
  generického programování založenou na C++ od uvedení J2SE 5.0 a implementuje generiky (anglicky "generics") neboli
  "kontejnery-typu-T" (tedy pouze podmnožinu generického programování).
Report (IP 21.6.2011)
  Co je to generické programování, k čemu se používá a v čem spočívají jeho výhody?
     Napište stručnou implementaci generické třídy List nebo HashTable.
     Popište implementaci v C++ a Javě (asi by stačil i C#, ale v zadání byla explicitně napsaná java).
Report (IP 21.6.2011 (<2007))
  Popiste sablony
  Jak jsou implementovany (popiste jak jsou implementovany v C++ nebo Java) (to som teda fakt netusil)
Report (IOI 21.6.2011 (<2007))
  Co je to generické programování, k čemu se používá a v čem spočívají jeho výhody?
     Napište stručnou implementaci generické třídy List nebo HashTable.
Report (Yaghob)
```

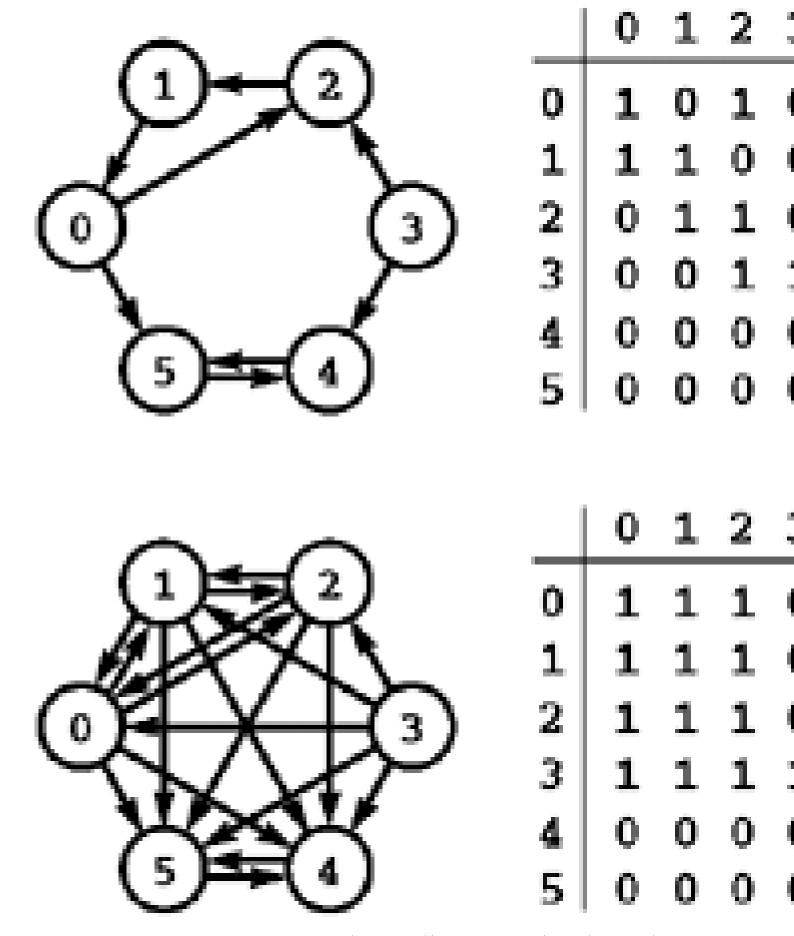
že to vím, takže taky za 1.

Co je to traits a policy classes, co je to statický polymorfismus apod. Nakonec jsem to nějak vymyslel a shodli jsme se na tom,

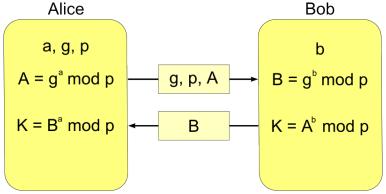
Zařazení do Chomskeho hierarchie	Gramatiky
Тури О	Gramatiky typu 0
není	(není společný název)
Typu 1	Kontextové gramatiky
Typu 2	Bezkontextové gramatiky
není	Deterministické bezkontextové gramatiky
Тури З	Regulární gramatiky
a jakýkoli automat v každé kategor "není" znamená že nepatří do Cho	natik je podmnožinou jazyků nebo gr rii má ekvivaletní automat v kategori omskeho hierarchie. p/wiki/Template:Formal Janguages

<u>Uzávěrové vlastnosti v ko</u>

	RJ
Sjednocení	√
Průnik	√
Průnik s RJ	√
Doplněk	√
Substituce/ homomorfismus	√
Inverzní homomorfismus	√

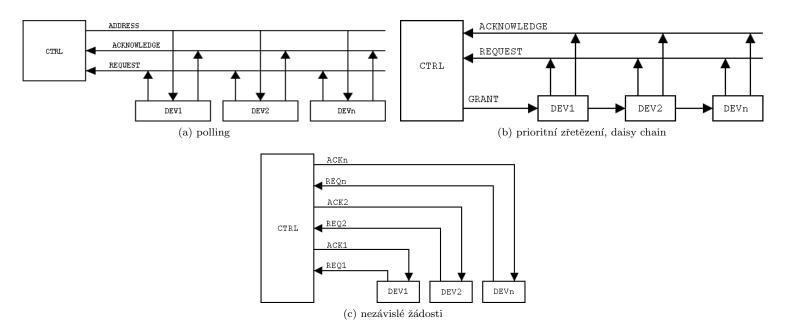


Obrázek 1: Tranzitivní uzávěr grafu (zdroj: http://zorro.fme.vutbr.cz/graphs/foil36.html)

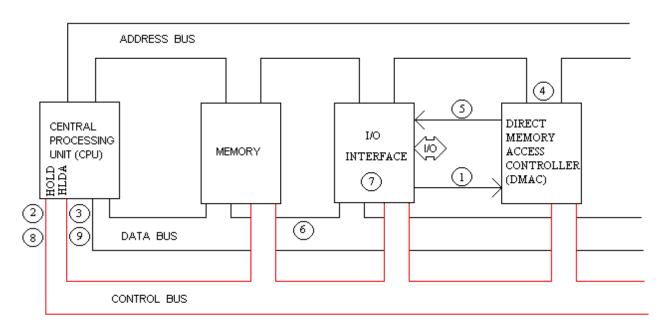


 $K = A^b \mod p = (g^a \mod p)^b \mod p = g^{ab} \mod p = (g^b \mod p)^a \mod p = B^a \mod p$

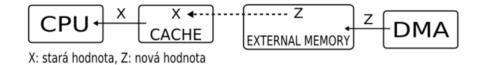
Obrázek 2: D-H protokol



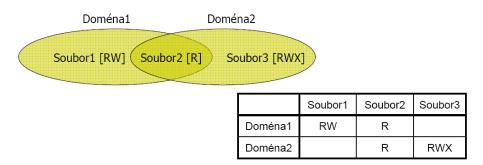
Obrázek 3: centralizované přidělování



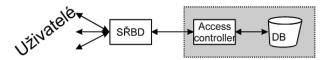
DATA TRANSFER WITH A DMA CONTROLLER



Obrázek 4: paměťová koherence



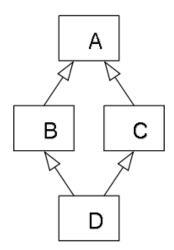
Obrázek 6: Domény ochrany



Obrázek 7: Access Controller



Obrázek 8: Spolehlivý front-end



Obrázek 9: Diamond problem